# Gabarito: Frases de Nível Desconhecido

Respostas Oficiais, Avaliação do Modelo Humano e Guia de Feature Engineering

Projeto ALFA-Gen

10/10/2026

## Contents

**Apresentação do Gabarito** **2**

**Tabela Oficial de Respostas** **2**

Resumo com Trecho Inicial de Cada Frase . . . . . 2

**Folha de Avaliação do Modelo Humano** **3**

**Guia para Feature Engineering do Detector de Nível** **3**

Table 1: Gabarito Oficial das Frases Desconhecidas (Teste Cego)

| ID da Frase | Nível Verdadeiro | Nível Simplificado | ID Original | Nº Palavras | Nº Caracteres |
|---|---|---|---|---|---|
| ID_01 | Ensino Superior | Superior | 187_1006.txt | 401 | 2602 |
| ID_02 | Ensino Superior | Superior | 591_1623.txt | 331 | 2346 |
| ID_03 | Ensino Fundamental II | Fundamental II | 68_2778.txt | 507 | 3120 |
| ID_04 | Ensino Fundamental II | Fundamental II | 313_5144.txt | 428 | 2689 |
| ID_05 | Ensino Médio | Médio | 222_1583.txt | 301 | 1745 |
| ID_06 | Ensino Fundamental I | Fundamental I | 82_638.txt | 328 | 1937 |
| ID_07 | Ensino Fundamental I | Fundamental I | 280_839.txt | 314 | 1811 |
| ID_08 | Ensino Médio | Médio | 286_1647.txt | 400 | 2573 |
| ID_09 | Ensino Médio | Médio | 334_1695.txt | 336 | 2061 |
| ID_10 | Ensino Fundamental I | Fundamental I | 178_736.txt | 329 | 1782 |

Table 2: Identificação das Frases Desconhecidas pelo Trecho Inicial

| ID da Frase | Nível Simplificado | Início do Texto |
|---|---|---|
| ID_01 | Superior | Eletrônica Digital/Códigos O homem através dos tempos sentiu... |
| ID_02 | Superior | Logística/Serviço ao cliente/Os serviços mais comuns Os ser... |
| ID_03 | Fundamental II | Política. Charle Montesquieu (1689-1755), um dos ícones do i... |
| ID_04 | Fundamental II | A lista divide os animais de acordo com o estado de conserv... |
| ID_05 | Médio | Como a união do retângulo determinado por formula_29 e form... |
| ID_06 | Fundamental I | Nas noites de verão, quando não há uma única nuvem no céu e... |
| ID_07 | Fundamental I | Em troca, o governo que administra nosso país deveria melho... |
| ID_08 | Médio | Historicamente, o Vedanta tem sido compreendido como um est... |
| ID_09 | Médio | Sexo/O lado social Ao longo da história, as diferentes cult... |
| ID_10 | Fundamental I | Acordar cedo não é mesmo uma tarefa fácil. Depois das féria... |

# Apresentação do Gabarito

Este documento apresenta o gabarito oficial das 10 frases de nível desconhecido presentes na seção final do documento `01_amostras_niveis_ensino.pdf`.

Utilize as tabelas a seguir para:

1. **Conferir suas predições**: Verificar quais frases você classificou corretamente.
2. **Mensurar sua acurácia baseline**: Calcular o percentual de acerto do seu "modelo humano" inicial.
3. **Mapear hipóteses de *Feature Engineering***: Identificar quais pistas linguísticas orientaram seus acertos e quais características levaram a eventuais confusões entre níveis adjacentes.

# Tabela Oficial de Respostas

A tabela abaixo relaciona o **ID Mascarado** de cada frase desconhecida com a **resposta correta (nível verdadeiro)**, além do identificador original no conjunto de dados e métricas básicas de extensão:

### Resumo com Trecho Inicial de Cada Frase

Para facilitar a conferência visual imediata de cada texto lido:

# Folha de Avaliação do Modelo Humano

Preencha a tabela abaixo com as suas anotações para calcular a performance do seu modelo intuitivo:

| ID | Seu Palpite | Nível Real | Acertou? (Sim / Não) |
|---|---|---|---|
| ID_01 | | Superior | |
| ID_02 | | Superior | |
| ID_03 | | Fundamental II | |
| ID_04 | | Fundamental II | |
| ID_05 | | Médio | |
| ID_06 | | Fundamental I | |
| ID_07 | | Fundamental I | |
| ID_08 | | Médio | |
| ID_09 | | Médio | |
| ID_10 | | Fundamental I | |

**Cálculo da Acurácia Inicial:**

$$\text{Acurácia Baseline} = \frac{\text{Total de Acertos}}{10} \times 100\% = \qquad \%$$

# Guia para Feature Engineering do Detector de Nível

A leitura atenta dessas amostras revela diferenças estilísticas e estruturais fundamentais entre os quatro níveis. Abaixo estão recomendações práticas de variáveis a serem extraídas na etapa de modelagem:

**1. Métricas de Superfície e Extensão**

- **Comprimento Médio da Sentença (ASL - *Average Sentence Length*)**: Textos do Fundamental I tendem a usar períodos curtos e coordenação, enquanto Superior e Médio utilizam períodos longos e estruturas subordinadas.
- **Comprimento Médio da Palavra (AWL - *Average Word Length*)**: Quantidade média de letras ou sílabas por vocábulo. Palavras polissílabas são muito mais frequentes no Ensino Médio e Superior.
- **Proporção de Palavras Complexas**: Porcentagem de palavras com 3 ou mais sílabas (ou mais de 7 letras).

**2. Riqueza e Diversidade Lexical**

- **Type-Token Ratio (TTR)**: Proporção de palavras únicas em relação ao total de palavras.
- **Frequência de Vocabulário Cotidiano vs. Vocabulário Raro**: Cruzamento das palavras do texto com listas de frequência de palavras da língua portuguesa (ex.: corpus NILC).
- **Densidade Lexical**: Proporção de palavras de conteúdo (*content words*: substantivos, verbos plenos, adjetivos) sobre palavras gramaticais (*function words*: preposições, conjunções, artigos).

**3. Características Morfossintáticas (POS-Tagging)**

- **Densidade de Conjunções Subordinativas**: Indicador direto de complexidade de raciocínio lógico e argumentativo.
- **Uso de Pronomes e Verbos de 1ª e 2ª Pessoa**: No Fundamental I, há muita interlocução direta com o leitor (*"você"*, *"a gente"*, *"vamos ver"*). No Superior, predomina a impessoalidade (3ª pessoa e voz passiva).
- **Proporção de Substantivos Abstratos e Termos Técnicos**: Alta frequência de sufixos de nominalização (*-ção*, *-dade*, *-ismo*, *-mento*) no Ensino Superior e Médio.

**4. Fórmulas Clássicas de Legibilidade**

- **Flesch Reading Ease (Adaptado para Português)**: $248.835 - (1.015 \times \text{ASL}) - (84.6 \times \text{ASW})$.
- **Índice Gulpease**: Métrica calibrada para línguas latinas baseada no tamanho das palavras e das sentenças.