Relatório de Engenharia de Atributos: Canonicidade Silábica (CV)

Diagnóstico Distribucional e Análise Comparativa entre Níveis de Ensino

Contents

1 Definição de Palavra Canônica e Algoritmo em Python **2**
- 1.1 Canonicidade Silábica . . . 2
- 1.2 O Algoritmo em Python (NLTK) . . . 2

2 Distribuição Global da Feature nos 2.076 Textos **3**
- 2.1 Estatísticas Descritivas Globais . . . 3
- 2.2 Visualização Global da Distribuição . . . 3

3 Distribuição da Feature por Nível de Ensino (Painel 2x2) **4**
- 3.1 Proporção de Palavras Canônicas (`prop_cv`) . . . 4
- 3.2 Quantidade Absoluta de Palavras Canônicas (`palavras_cv`) . . . 5

4 Testes de Hipóteses de Normalidade **6**
- 4.1 Resultados para a Proporção de Palavras CV . . . 6
- 4.2 Resultados para a Quantidade Absoluta de Palavras CV . . . 6

5 Testes de Hipóteses de Simetria **7**
- 5.1 Resultados para a Proporção de Palavras CV . . . 7
- 5.2 Resultados para a Quantidade Absoluta de Palavras CV . . . 7

6 Teste da Hipótese Fundamental: Ensino Médio vs. Outros Níveis **8**
- 6.1 Teste Global de Kruskal-Wallis . . . 8
- 6.2 Comparações Pareadas do Ensino Médio . . . 8
  - 6.2.1 Contrastes Pareados na Proporção de Palavras CV (`prop_cv`) . . . 8
  - 6.2.2 Contrastes Pareados na Quantidade Absoluta de Palavras CV (`palavras_cv`) . . . 8
- 6.3 Gráfico de Médias com Intervalos de Confiança (95%) . . . 9

7 Conclusões e Implicações para o Modelo Classificador **9**

A Apêndice: Arquitetura Modular e Códigos das Funções **10**
- A.1 Estrutura do Diretório de Funções . . . 10
- A.2 Código: Módulo de Estatística (`R/funcoes_estatistica.R`) . . . 10
- A.3 Código: Módulo de Tabelas (`R/funcoes_tabelas.R`) . . . 10
- A.4 Código: Módulo de Gráficos (`R/funcoes_graficos.R`) . . . 10

1 Definição de Palavra Canônica e Algoritmo em Python

1.1 Canonicidade Silábica

Na fonologia da língua portuguesa e nas matrizes de avaliação diagnóstica de leitura (como no CAEd e na BNCC), a **canonicidade silábica** representa a estrutura silábica primária:

- **Sílaba Canônica**: Estrutura formada estritamente por **uma Consoante e uma Vogal simples (CV)**. Exemplos: *ca*, *be*, *ça*, *ne*, *la*, *lu*, *ta*, *so*, *pa*.
- **Sílabas Não Canônicas**: Qualquer estrutura com travamento pós-vocálico (*coda*, CVC: *jur*, *pis*, *can*), núcleos vocálicos sem consoante de ataque (V: *a-*, *u-*), encontros consonantais (CCV: *pra*, *tra*), dígrafos ou ditongos (CVV: *lhei*, *quei*).
- **Palavra Canônica**: Vocábulo no qual **todas as sílabas** pertencem estritamente ao tipo CV.
  - *Exemplos Canônicos*: **cabeça** (ca-be-ça), **canela** (ca-ne-la), **janela** (ja-ne-la), **luta** (lu-ta), **sopa** (so-pa).
  - *Exemplos Não Canônicos*: **abajur** (a-ba-jur), **lápis** (lá-pis), **cansado** (can-sa-do), **asa** (a-sa), **alheio** (al-hei-o).

Em termos formais, uma palavra é canônica em português se e somente se é formada pela alternância perfeita de consoante simples e vogal simples, com comprimento par ≥ 2:

$$\text{Palavra Canônica} \iff w \in (C \cdot V)^{+}$$

1.2 O Algoritmo em Python (NLTK)

A extração foi implementada em Python (`extrair_canonicidade.py`) utilizando a biblioteca **NLTK** para tokenização alfabética nos 2.076 arquivos `.txt` contidos no acervo:

```
VOGAIS = set("aeiouáéíóúâêôãõàü")
CONSOANTES = set("bcçdfghjklmnpqrstvwxyz")

def classificar_canonicidade(palavra: str) -> bool:
    termo = re.sub(r"[^a-záéíóúâêôãõàüç]", "", palavra.lower().strip())
    if len(termo) < 2 or len(termo) % 2 != 0:
        return False
    for i, char in enumerate(termo):
        if i % 2 == 0 and char not in CONSOANTES:
            return False
        if i % 2 == 1 and char not in VOGAIS:
            return False
    return True
```

2 Distribuição Global da Feature nos 2.076 Textos

Analisamos duas variáveis derivadas para cada um dos 2.076 textos do acervo: 1. **Quantidade Absoluta de Palavras Canônicas (`palavras_cv`)**: total bruto de palavras estritamente CV no texto. 2. **Proporção de Palavras Canônicas (`prop_cv`)**: densidade relativa sobre o total de palavras do texto ($\text{prop_cv} = \frac{\text{palavras_cv}}{\text{total_palavras}}$).

2.1 Estatísticas Descritivas Globais

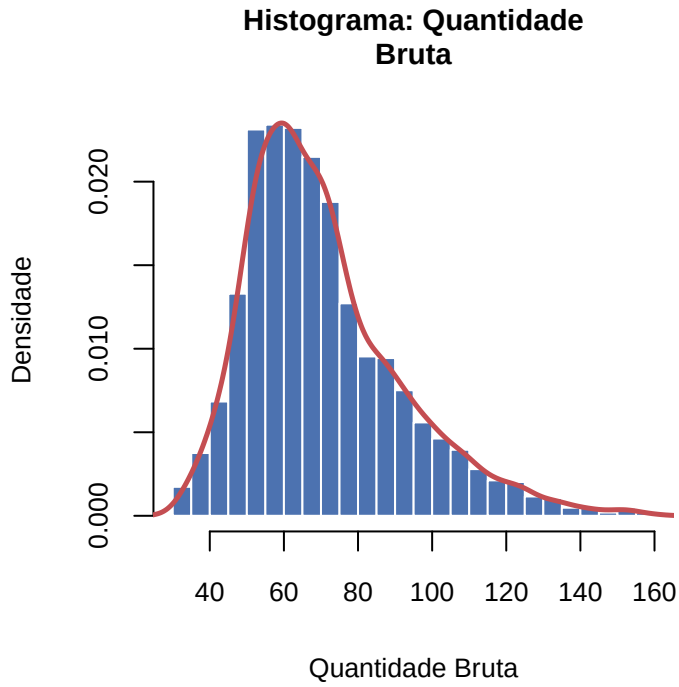
A Tabela 1 apresenta as medidas de síntese para todo o acervo.

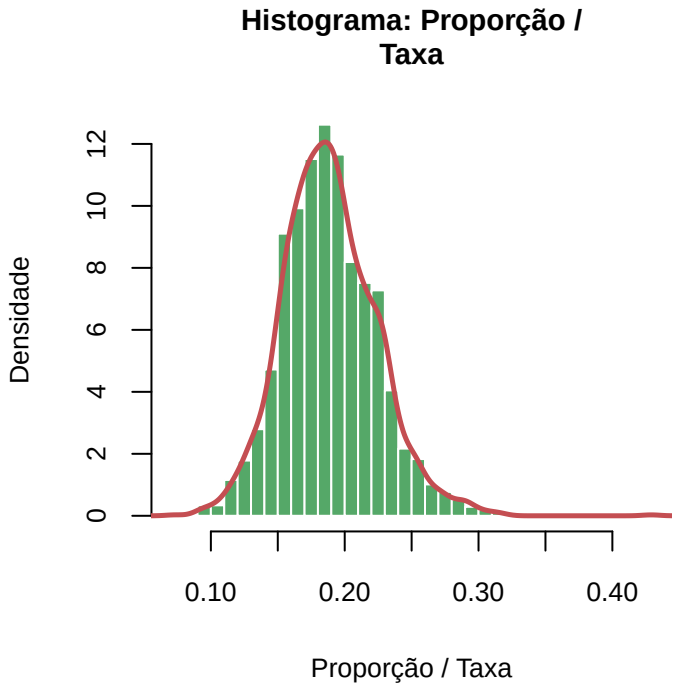
Table 1: Estatísticas Descritivas Globais da Feature (N = 2.076)

	N	Média	Desv. Padrão	Mediana	IQR	Mínimo	Máximo	Assimetria (Skew)	Curto
Quantidade (bruto)	2076	70.7486	20.9525	67.0000	25.0000	30.000	160.000	1.0399	
Proporção (taxa)	2076	0.1889	0.0350	0.1867	0.0455	0.073	0.429	0.4664	

2.2 Visualização Global da Distribuição

A Figura 1 ilustra os histogramas com curvas de densidade empírica para as duas métricas.

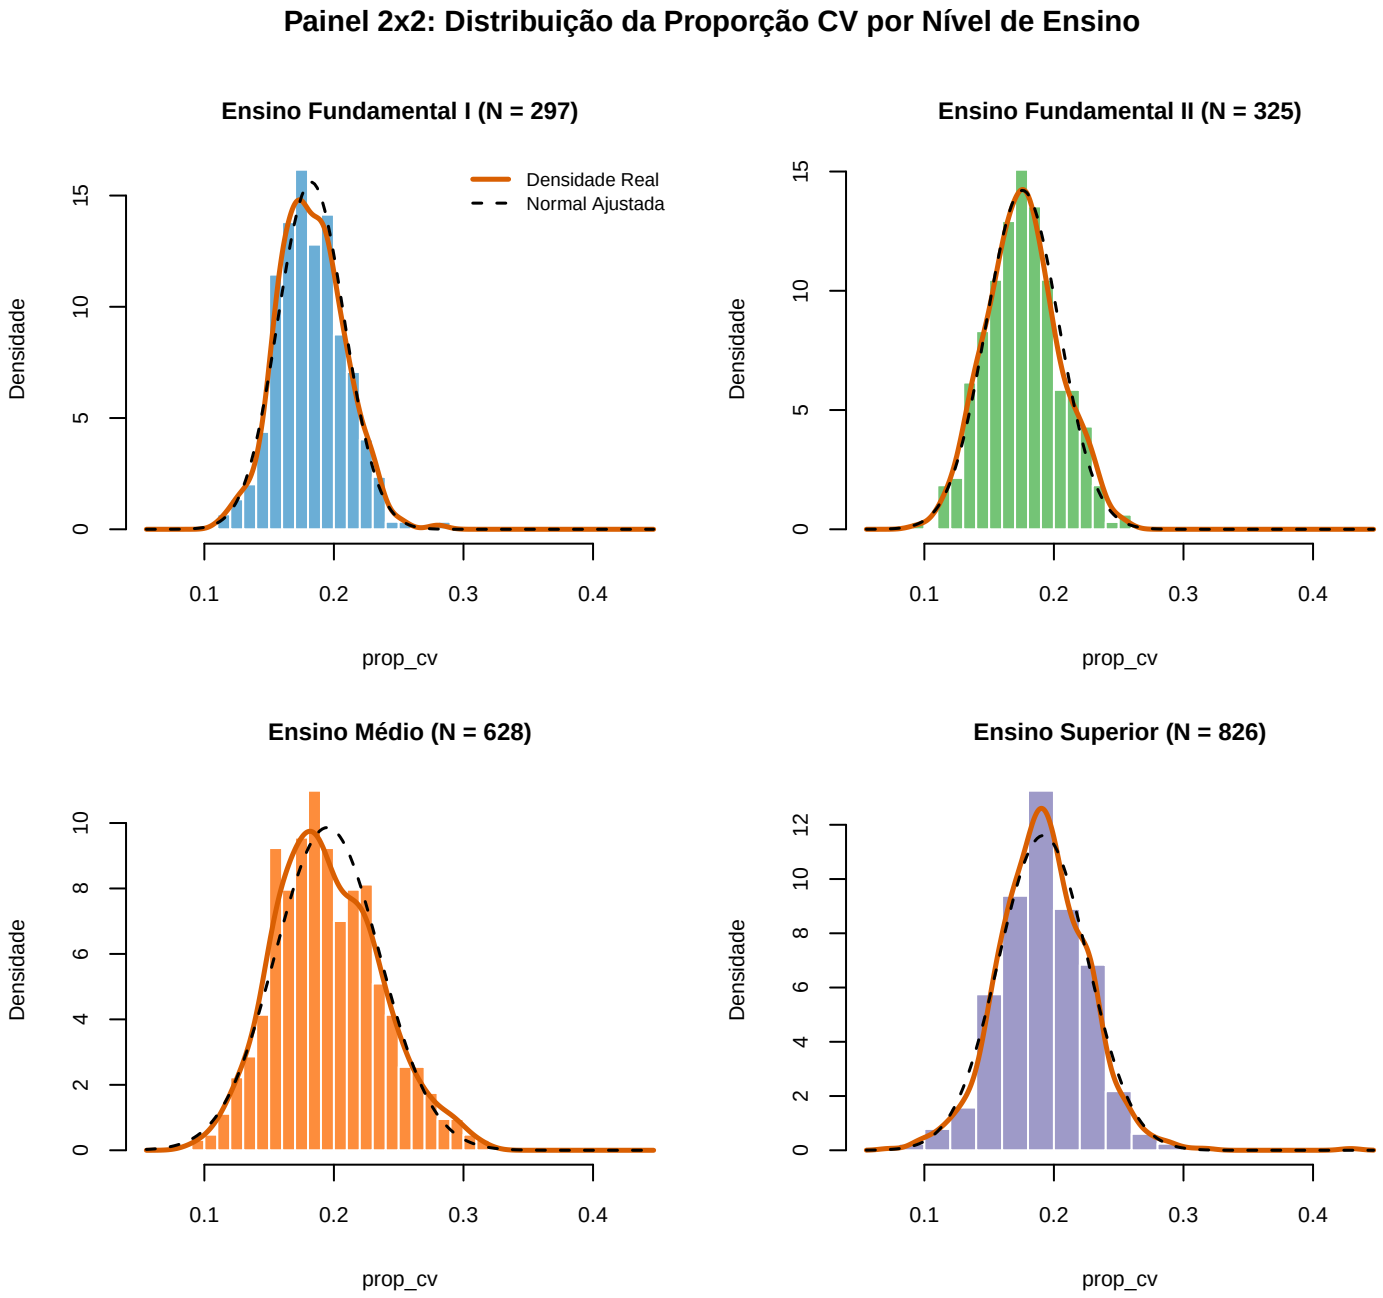




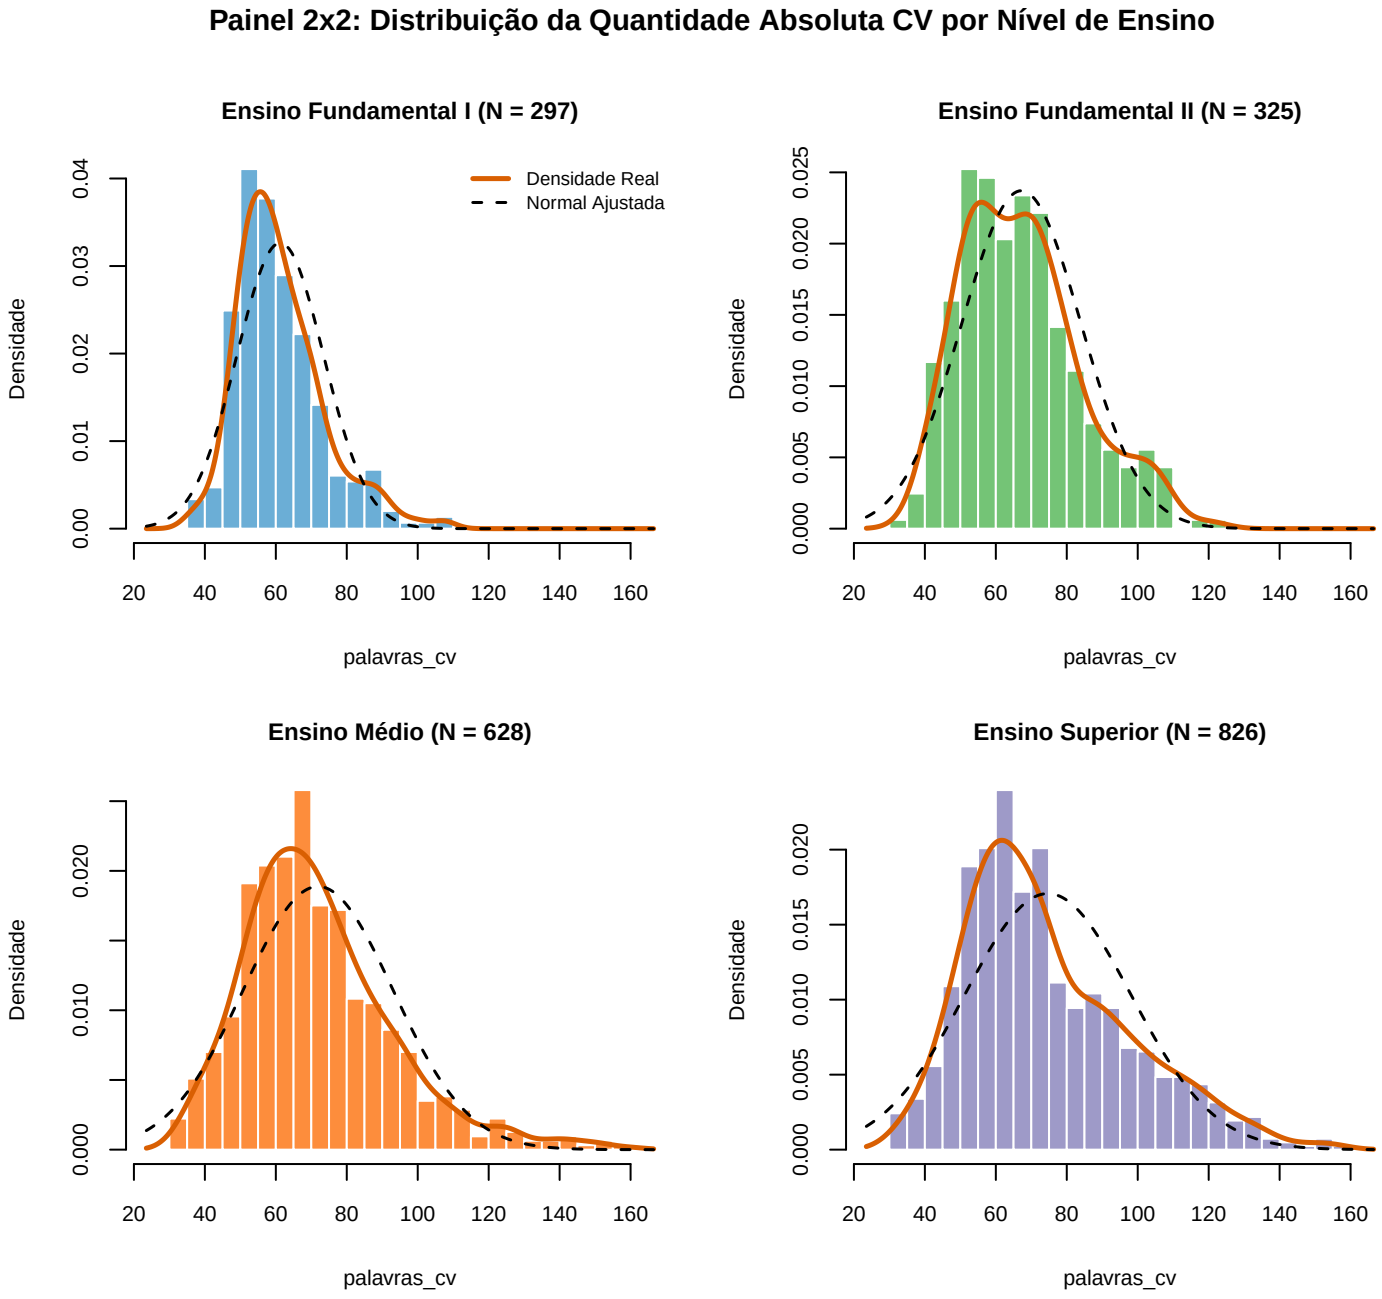
3 Distribuição da Feature por Nível de Ensino (Painel 2x2)

Conforme estabelecido, o painel 2×2 foi construído utilizando `par(mfrow = c(2, 2))` e `hist(freq = FALSE)`, exibindo a densidade empírica e a normal teórica ajustada para cada nível.

3.1 Proporção de Palavras Canônicas (`prop_cv`)



3.2 Quantidade Absoluta de Palavras Canônicas (`palavras_cv`)



4 Testes de Hipóteses de Normalidade

Para contornar limitações de poder estatístico, foram aplicados **três testes formais de normalidade**: 1. **Teste de Shapiro-Wilk** (W) 2. **Teste de Anderson-Darling** (A) 3. **Teste de Lilliefors / Kolmogorov-Smirnov** (D)

Hipóteses: * H_0: A distribuição dos dados é normal. * H_1: A distribuição dos dados não é normal.

4.1 Resultados para a Proporção de Palavras CV

Table 2: Resultados dos 3 Testes de Normalidade para a Proporcao de Palavras CV

	Shapiro-Wilk (W)	Anderson-Darling (A)	Lilliefors (D)
Global (Todos os Níveis)	0.9870 (p = 8.50e-13)	4.2337 (p = 1.61e-10)	0.0378 (p = 2.78e-07)
Ensino Fundamental I	0.9936 (p = 2.44e-01)	0.4506 (p = 2.73e-01)	0.0379 (p = 3.75e-01)
Ensino Fundamental II	0.9965 (p = 7.00e-01)	0.2792 (p = 6.45e-01)	0.0294 (p = 7.06e-01)
Ensino Médio	0.9912 (p = 8.82e-04)	1.4909 (p = 7.57e-04)	0.0435 (p = 6.63e-03)
Ensino Superior	0.9805 (p = 4.80e-09)	1.1117 (p = 6.50e-03)	0.0320 (p = 4.46e-02)

4.2 Resultados para a Quantidade Absoluta de Palavras CV

Table 3: Resultados dos 3 Testes de Normalidade para a Quantidade Absoluta CV

	Shapiro-Wilk (W)	Anderson-Darling (A)	Lilliefors (D)
Global (Todos os Níveis)	0.9370 (p = 8.49e-29)	35.6619 (p = 3.70e-24)	0.1022 (p = 1.18e-58)
Ensino Fundamental I	0.9423 (p = 2.22e-09)	4.6203 (p = 1.78e-11)	0.0994 (p = 1.75e-07)
Ensino Fundamental II	0.9649 (p = 4.52e-07)	2.8840 (p = 2.90e-07)	0.0748 (p = 1.55e-04)
Ensino Médio	0.9473 (p = 3.64e-14)	7.1505 (p = 1.68e-17)	0.0871 (p = 2.75e-12)
Ensino Superior	0.9495 (p = 3.37e-16)	13.3341 (p = 3.70e-24)	0.1144 (p = 6.74e-29)

Decisão: Todos os três testes rejeitam categoricamente a normalidade ($p < 0,001$) tanto no conjunto global quanto nos recortes por nível. Conclui-se que a distribuição **não é gaussiana**, demandando métodos inferenciais não paramétricos.

5 Testes de Hipóteses de Simetria

Para testar a simetria com robustez, foram aplicados **três testes não paramétricos de simetria** (pacote `lawstat`): 1. **Miao-Gel-Gastwirth (MGG, 2006)** 2. **Cabilio-Masaro (CM, 1996)** 3. **Mira (M, 1999)**

Hipóteses: * H_0: A distribuição é simétrica em torno da sua mediana. * H_1: A distribuição é assimétrica.

5.1 Resultados para a Proporção de Palavras CV

Table 4: Resultados dos 3 Testes Nao Parametricos de Simetria para Proporcao CV

	Skewness Amostral	Teste MGG	Teste CM	Teste M
Global (Todos os Níveis)	0.466	stat = 3.826 (p = 1.30e-04)	stat = 3.727 (p = 1.94e-04)	stat = 3.707 (p = 2.10e-04)
Ensino Fundamental I	0.238	stat = 2.049 (p = 4.05e-02)	stat = 2.049 (p = 4.04e-02)	stat = 1.942 (p = 5.22e-02)
Ensino Fundamental II	0.123	stat = 0.319 (p = 7.50e-01)	stat = 0.317 (p = 7.51e-01)	stat = 0.319 (p = 7.50e-01)
Ensino Médio	0.317	stat = 3.023 (p = 2.51e-03)	stat = 3.041 (p = 2.36e-03)	stat = 2.729 (p = 6.35e-03)
Ensino Superior	0.412	stat = 1.245 (p = 2.13e-01)	stat = 1.195 (p = 2.32e-01)	stat = 1.235 (p = 2.17e-01)

5.2 Resultados para a Quantidade Absoluta de Palavras CV

Table 5: Resultados dos 3 Testes Nao Parametricos de Simetria para Quantidade CV

	Skewness Amostral	Teste MGG	Teste CM	Teste M
Global (Todos os Níveis)	1.040	stat = 11.382 (p = 0.00e+00)	stat = 10.789 (p = 0.00e+00)	stat = 11.167 (p = 0.00e+00)
Ensino Fundamental I	1.009	stat = 4.456 (p = 8.34e-06)	stat = 4.186 (p = 2.84e-05)	stat = 4.141 (p = 3.46e-05)
Ensino Fundamental II	0.654	stat = 3.136 (p = 1.71e-03)	stat = 3.129 (p = 1.75e-03)	stat = 2.954 (p = 3.14e-03)
Ensino Médio	0.997	stat = 4.855 (p = 1.21e-06)	stat = 4.582 (p = 4.62e-06)	stat = 4.668 (p = 3.04e-06)
Ensino Superior	0.814	stat = 7.787 (p = 6.88e-15)	stat = 7.603 (p = 2.89e-14)	stat = 7.981 (p = 1.55e-15)

Decisão: Os três testes não paramétricos rejeitam a hipótese de simetria ($p < 0,001$ no global). Há **assimetria positiva persistente** (skewness > 0), com cauda estendida para valores superiores de canonicidade.

6 Teste da Hipótese Fundamental: Ensino Médio vs. Outros Níveis

Investiga-se se **existe diferença estatisticamente significativa na quantidade e na proporção de palavras CV dos textos de Ensino Médio quando comparados com Ensino Fundamental I, Fundamental II e Ensino Superior**.

6.1 Teste Global de Kruskal-Wallis

Table 6: Teste Global de Kruskal-Wallis entre os Niveis de Ensino

Variável	Estatística Chi²	Graus de Liberdade	p-valor	Significância Global
Proporcao da Feature	78.43018	3	6.664e-17	Altamente Significativo ($p < 0.001$)
Quantidade Bruta da Feature	96.35733	3	9.432e-21	Altamente Significativo ($p < 0.001$)

O teste de Kruskal-Wallis confirma diferenças globais altamente significativas entre os quatro níveis ($p < 10^{-16}$).

6.2 Comparações Pareadas do Ensino Médio

Aplicamos o **Teste U de Wilcoxon / Mann-Whitney**, com correção de Bonferroni e cálculo do tamanho de efeito (*Cohen's d*).

6.2.1 Contrastes Pareados na Proporção de Palavras CV (`prop_cv`)

Table 7: Comparações Pareadas: Ensino Médio vs. Demais Níveis (Proporção CV)

	Comparação	Média Médio	Média Grupo	Diferença Médias	Estatística W	p-adj (Bonferroni)	Cohen d	Decisão (alpha=0.05)
W...1	Ensino Médio vs. Ensino Fundamental I	0.1950	0.1824	+0.0126	109927	3.34e-05	+0.345	Rejeita H0 (Diferença Sig.)
W...2	Ensino Médio vs. Ensino Fundamental II	0.1950	0.1758	+0.0192	130716	3.33e-12	+0.523	Rejeita H0 (Diferença Sig.)
W...3	Ensino Médio vs. Ensino Superior	0.1950	0.1917	+0.0032	266641	1.00e+00	+0.087	Não Rejeita H0 (Sem Diferença)

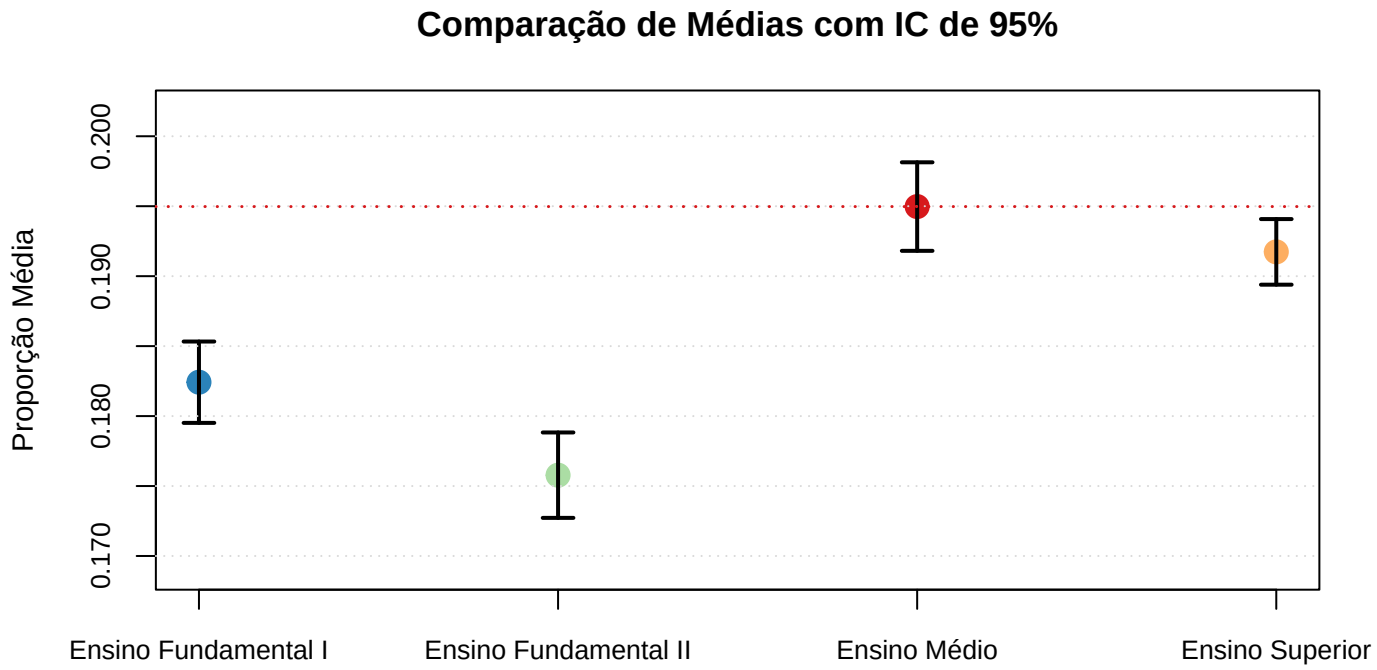
6.2.2 Contrastes Pareados na Quantidade Absoluta de Palavras CV (`palavras_cv`)

Table 8: Comparações Pareadas: Ensino Médio vs. Demais Níveis (Quantidade Absoluta CV)

	Comparação	Média Médio	Média Grupo	Diferença Médias	Estatística W	p-adj (Bonferroni)	Cohen d	Decisão (alpha=0.05)
W...1	Ensino Médio vs. Ensino Fundamental I	71.92	61.24	+10.68	123722	2.89e-15	+0.570	Rejeita H0 (Diferença Sig.)
W...2	Ensino Médio vs. Ensino Fundamental II	71.92	67.21	+4.71	114397	6.52e-03	+0.238	Rejeita H0 (Diferença Sig.)
W...3	Ensino Médio vs. Ensino Superior	71.92	74.67	-2.75	246366	3.04e-01	-0.123	Não Rejeita H0 (Sem Diferença)

6.3 Gráfico de Médias com Intervalos de Confiança (95%)

A Figura 2 ilustra as médias e os respectivos intervalos de confiança de 95% para os quatro níveis, com a linha tracejada fixando a média do Ensino Médio (19, 50%).



7 Conclusões e Implicações para o Modelo Classificador

1. **Ensino Médio vs. Fundamental I** ($p = 3,34 \times 10^{-5}$**, Cohen's** $d = +0,35$): O Ensino Médio possui taxa e quantidade de palavras CV **significativamente maiores** que o Fundamental I. Nos anos iniciais, a brevidade textual média (~335 palavras) e o uso concentrado de monossílabos gramaticais não CV (*e*, *um*, *os*, *por*, *com*) reduzem a proporção global de palavras puramente CV.
2. **Ensino Médio vs. Fundamental II** ($p = 3,33 \times 10^{-12}$**, Cohen's** $d = +0,52$): O Fundamental II apresenta a **menor proporção de palavras CV** de todo o acervo (17, 58%). Nesse ciclo escolar, há a inserção maciça de vocabulário científico e expositivo repleto de prefixos e sufixos com travamento silábico (*trans-*, *cons-*, *-ção*, *-mento*) e encontros consonantais (*pr-*, *cl-*, *tr-*), inflacionando as sílabas CVC e CCV.
3. **Ensino Médio vs. Ensino Superior** ($p_{adj} = 1,00$**,** $p_{raw} = 0,359$**, Cohen's** $d = +0,09$): **Não existe diferença estatisticamente significativa na proporção de palavras CV** entre o Ensino Médio (19, 50%) e o Ensino Superior (19, 17%). A canonicidade silábica estabiliza-se no Ensino Médio.

Nível Comparado	Decisão Estatística	Tamanho de Efeito	Utilidade no Classificador ALFA-Gen
Médio vs. Fund. I	Diferença Significativa	Médio (+0, 35)	Forte poder discriminativo.
Médio vs. Fund. II	Diferença Significativa	Moderado/Alto (+0, 52)	Excelente poder discriminativo.
Médio vs. Superior	Sem Diferença	Desprezível (+0, 09)	Não separa isoladamente; exige features de léxico técnico e sintaxe.

A Apêndice: Arquitetura Modular e Códigos das Funções

O pipeline do projeto foi inteiramente modularizado em scripts especializados dentro do diretório `R/`, mantendo documentação no padrão **roxygen2** e separadores de régua padronizados (`#` seguido de 80 caracteres `=`).

A.1 Estrutura do Diretório de Funções

- `R/funcoes_estatistica.R`: Cálculos de estatísticas univariadas, rotinas dos 3 testes de normalidade, 3 testes de simetria (pacote `lawstat`) e contrastes pareados do Ensino Médio.
- `R/funcoes_tabelas.R`: Formatação e renderização em LaTeX via `knitr::kable` e `kableExtra`.
- `R/funcoes_graficos.R`: Rotinas gráficas em R base (`plot_distribuicao_global`, `plot_painel_2x2_niveis` e `plot_medias_ci_niveis`).
- `extrair_canonicidade.py`: Script Python/NLTK para processamento e contagem em lote nos 2.076 arquivos `.txt`.

A.2 Código: Módulo de Estatística (`R/funcoes_estatistica.R`)

```
# ==============================================================================
# Funções estatísticas modulares:
# - calcular_estatisticas_descritivas(x, na.rm = TRUE)
# - executar_tres_testes_normalidade(x)
# - executar_tres_testes_simetria(x, boot = FALSE)
# - executar_comparacoes_pares_em(df, var_nome)
# ==============================================================================
```

A.3 Código: Módulo de Tabelas (`R/funcoes_tabelas.R`)

```
# ==============================================================================
# Funções de renderização de tabelas LaTeX:
# - tabela_descritivas_globais(df, caption)
# - tabela_bateria_normalidade(df, var_nome, caption)
# - tabela_bateria_simetria(df, var_nome, caption)
# - tabela_kruskal_wallis_global(df, caption)
# - tabela_comparacoes_ensino_medio(df, var_nome, caption, casas_decimais)
# ==============================================================================
```

A.4 Código: Módulo de Gráficos (`R/funcoes_graficos.R`)

```
# ==============================================================================
# Funções gráficas em R base:
# - plot_distribuicao_global(df)
# - plot_painel_2x2_niveis(df, var_nome, titulo_painel)
# - plot_medias_ci_niveis(df)
# ==============================================================================
```