Relatório de Engenharia de Atributos: Pontuação Expressiva e Dialógica (! e ?)

Diagnóstico Distribucional e Análise Comparativa entre Níveis de Ensino

Contents

1 Definição da Feature e Algoritmo de Extração **2**
- 1.1 Relevância da Pontuação Expressiva e Dialógica . . . 2
- 1.2 Regras Especiais de Contagem . . . 2

2 Distribuição Global nos 2.076 Textos **3**
- 2.1 Estatísticas Descritivas Globais . . . 3
- 2.2 Visualização Global da Distribuição . . . 3

3 Distribuição da Feature por Nível de Ensino (Painel 2x2) **4**
- 3.1 Proporção de Pontuação Expressiva (`pont_exp_prop`) . . . 4
- 3.2 Quantidade Absoluta de Pontuação Expressiva (`pont_exp_qtd`) . . . 5

4 Comparação Fundamental: Ensino Médio vs. Outros Níveis **6**
- 4.1 Teste Global de Kruskal-Wallis . . . 6
- 4.2 Comparações Pareadas do Ensino Médio . . . 6
  - 4.2.1 Contrastes Pareados na Proporção (`pont_exp_prop`) . . . 6
  - 4.2.2 Contrastes Pareados na Quantidade Absoluta (`pont_exp_qtd`) . . . 6
- 4.3 Gráfico de Médias com Intervalos de Confiança (95%) . . . 7

5 Conclusões e Implicações para o Modelo Classificador **7**

A Apêndice: Arquitetura Modular e Códigos das Funções **8**

1 Definição da Feature e Algoritmo de Extração

1.1 Relevância da Pontuação Expressiva e Dialógica

A unificação dos pontos de exclamação (`!`) e interrogação (`?`) em uma única métrica captura a **carga de expressividade discursiva e interlocução direta com o leitor**: * **Ensino Fundamental I**: Textos fortemente ancorados na oralidade, no diálogo infantil e no engajamento afetivo, repletos de indagações e exclamações enfáticas (*"Você sabia?", "Que legal!"*). * **Ensino Médio e Superior**: Prevalência do gênero expositivo-argumentativo formal, impessoal e assertivo, com redução drástica de pontuações expressivas explícitas.

1.2 Regras Especiais de Contagem

Para evitar distorções decorrentes de repetições contíguas ou combinações estilísticas: 1. **Sequências Homogêneas**: Séries contíguas como `????` ou `!!!!` contam como **apenas 1 ocorrência**. 2. **Sequências Mistas**: Padrões combinados como `?!`, `!?` ou `!?!?` contam como **1 exclamação e 1 interrogação** (somando 2 unidades na métrica combinada).

```python
def contar_pontuacoes_especiais(texto: str) -> tuple:
    clusters = re.findall(r"[?!]+", texto)
    n_excl = sum(1 for c in clusters if "!" in c)
    n_interr = sum(1 for c in clusters if "?" in c)
    return n_excl + n_interr
```

2 Distribuição Global nos 2.076 Textos

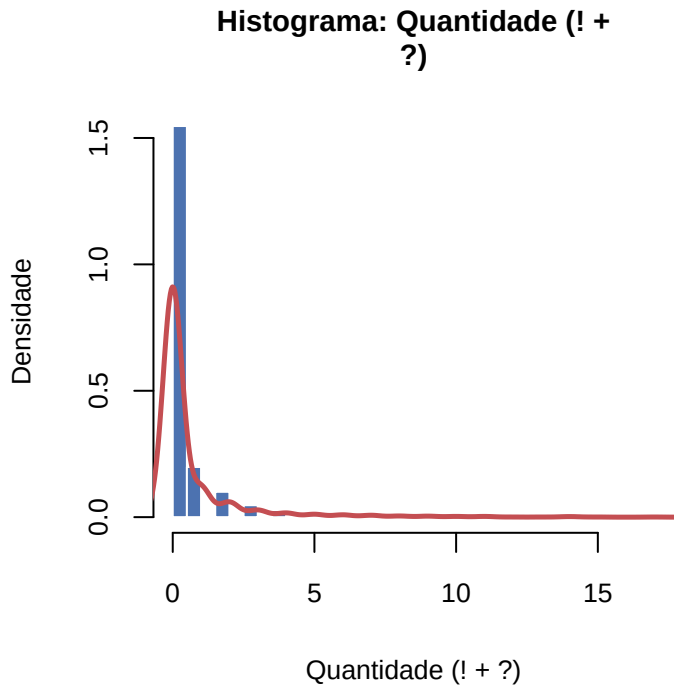
Analisamos duas variáveis derivadas: * **Quantidade Absoluta de Pontuações Expressivas (`pont_exp_qtd`)**: contagem consolidada de ocorrências de `!` e `?`. * **Proporção de Pontuações Expressivas (`pont_exp_prop`)**: densidade relativa em relação ao total de palavras do texto (pont_exp_prop = $\frac{\text{pont_exp_qtd}}{\text{total_palavras}}$).

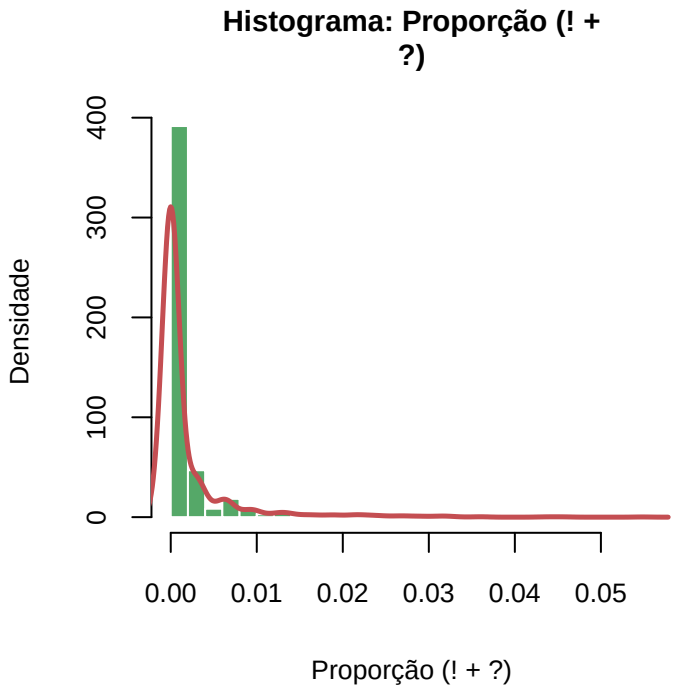
2.1 Estatísticas Descritivas Globais

Table 1: Estatísticas Descritivas Globais da Pontuação Expressiva (! + ?) (N = 2.076)

	N	Média	Desv. Padrão	Mediana	IQR	Mínimo	Máximo	Assimetria (Skew)
Quantidade Expressiva (bruto)	2076	0.6305	1.7299	0	0	0	17.0000	4.3213
Proporcao Expressiva (taxa)	2076	0.0018	0.0051	0	0	0	0.0548	4.3686

2.2 Visualização Global da Distribuição

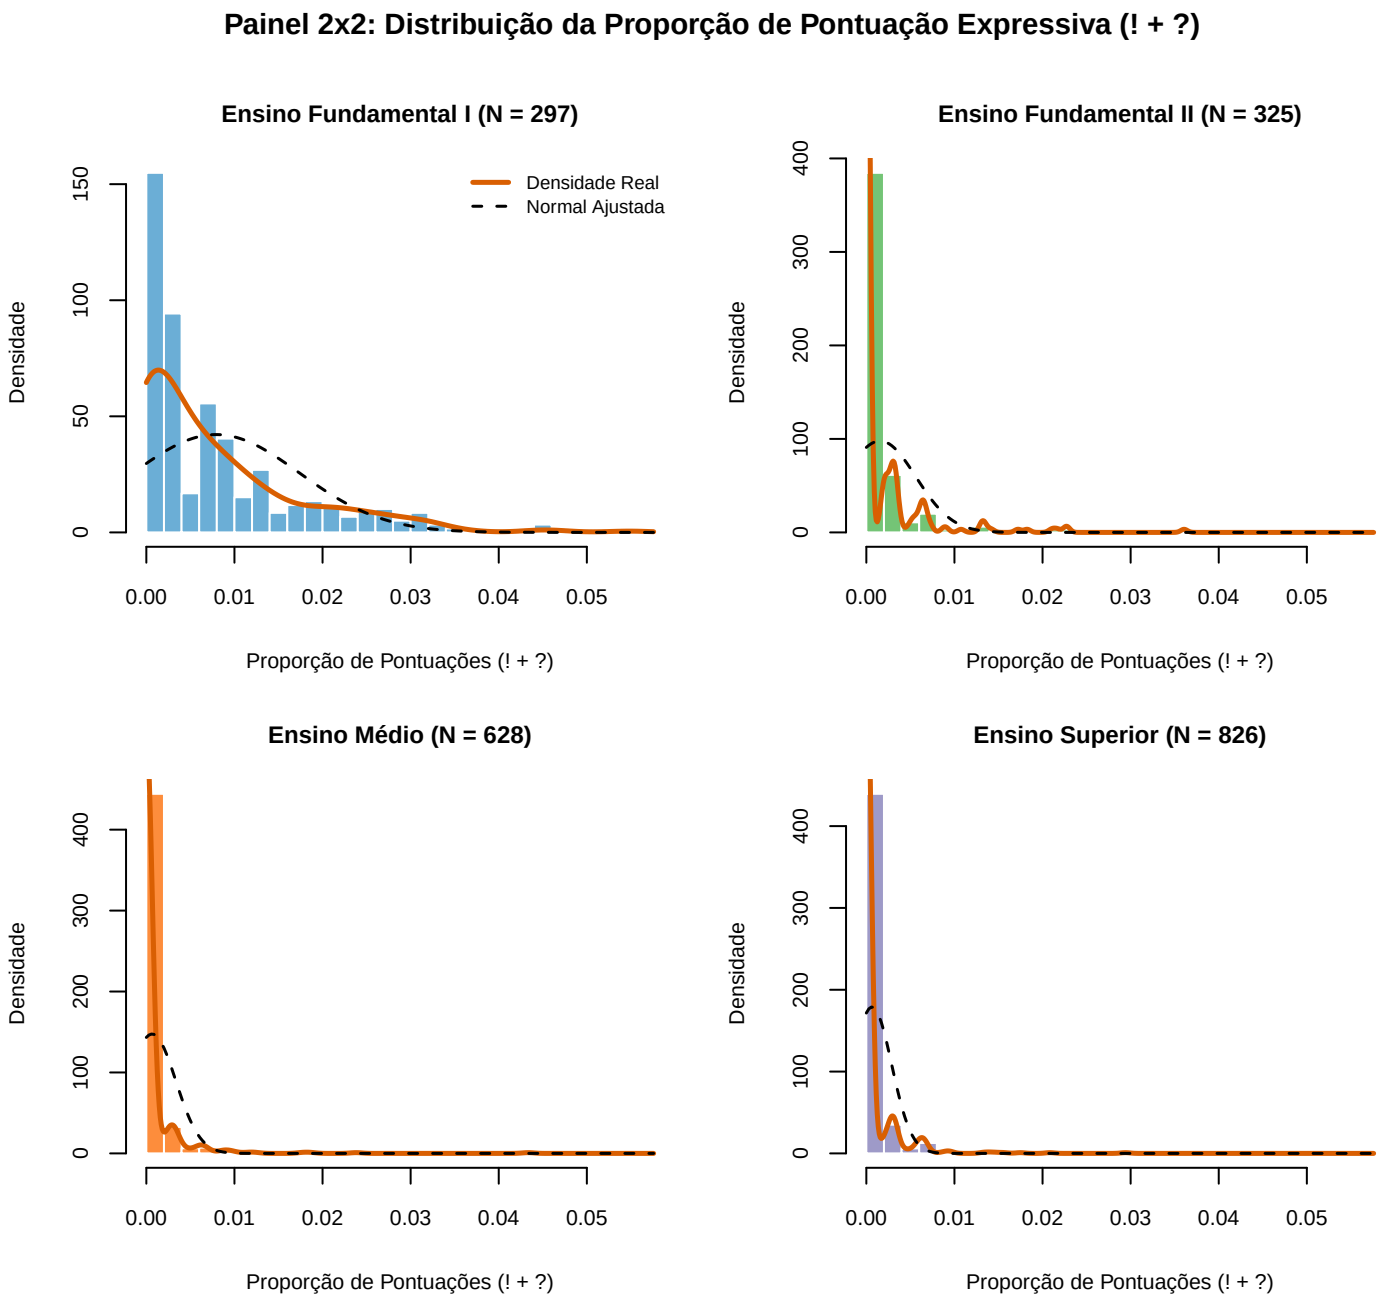




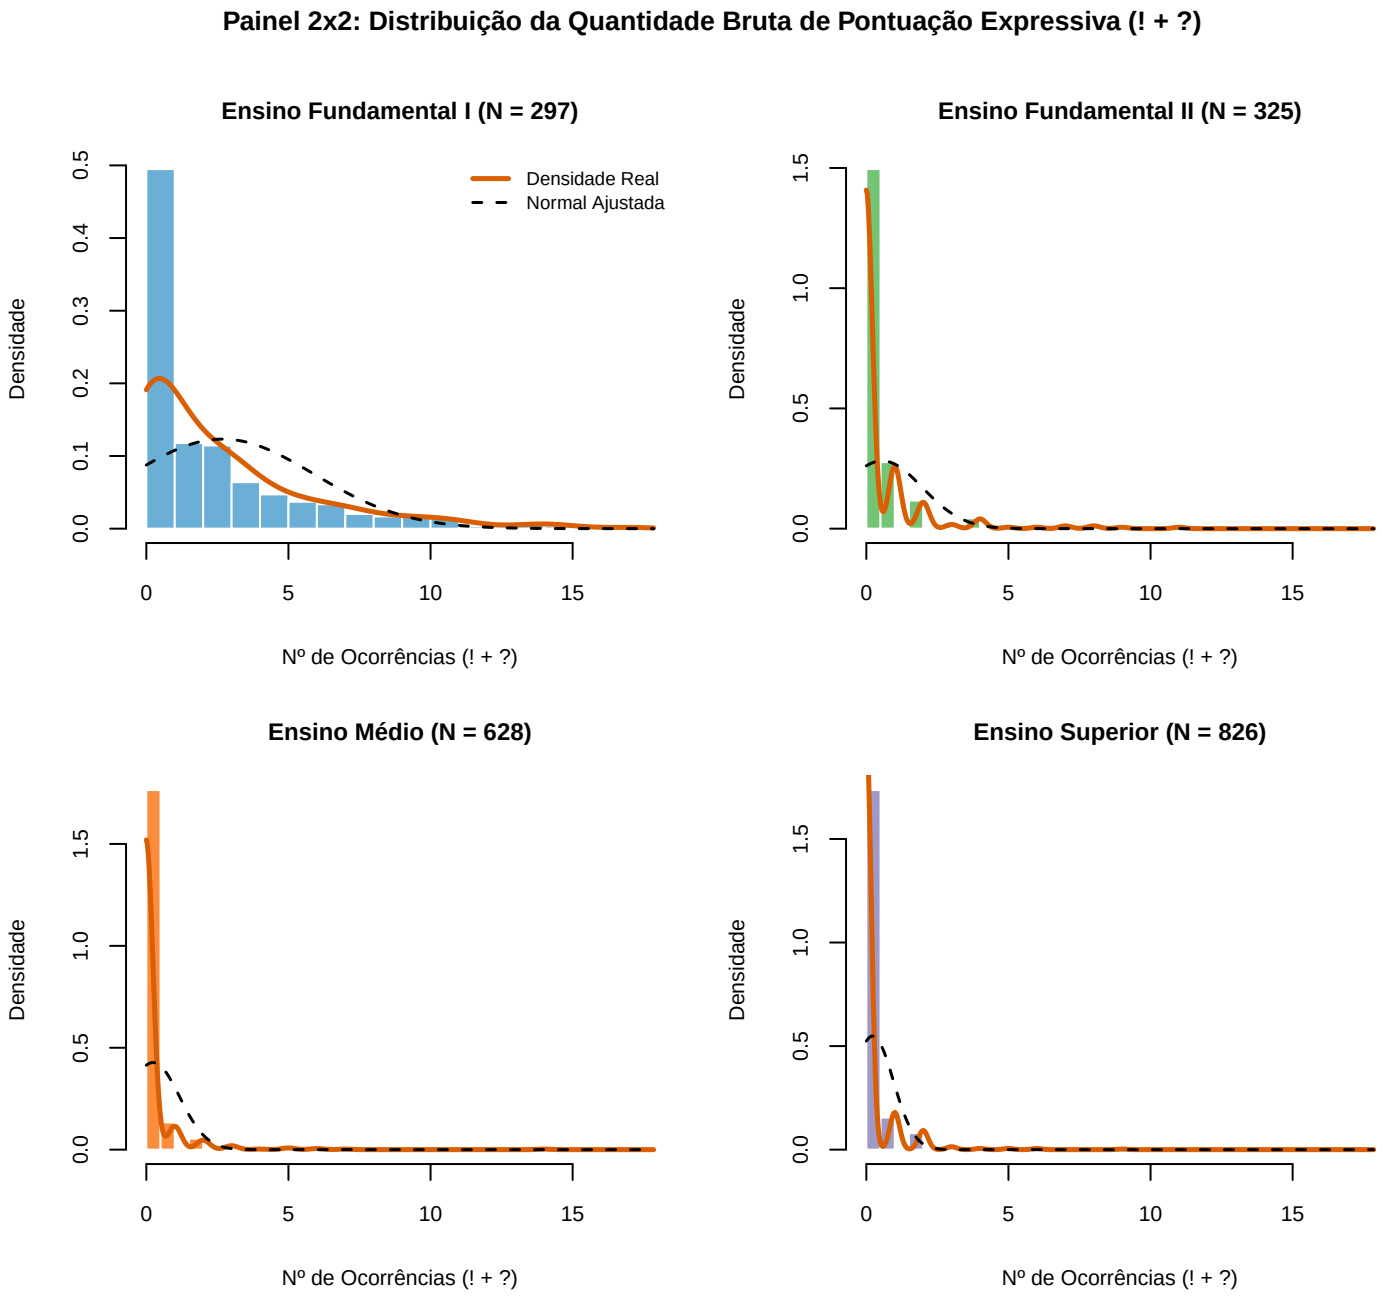
3 Distribuição da Feature por Nível de Ensino (Painel 2x2)

Apresentamos o painel 2×2 gerado com `par(mfrow = c(2, 2))` e `hist(freq = FALSE)`.

3.1 Proporção de Pontuação Expressiva (`pont_exp_prop`)



3.2 Quantidade Absoluta de Pontuação Expressiva (`pont_exp_qtd`)



4 Comparação Fundamental: Ensino Médio vs. Outros Níveis

Verificamos se **existe diferença estatisticamente significativa na quantidade e na proporção de pontuações expressivas dos textos de Ensino Médio em relação ao Fundamental I, Fundamental II e Ensino Superior**.

4.1 Teste Global de Kruskal-Wallis

Table 2: Teste Global de Kruskal-Wallis para Pontuacao Expressiva entre Niveis

Variável	Estatística Chi²	Graus de Liberdade	p-valor	Significância Global
Proporcao Expressiva (! + ?)	524.0125	3	2.982e-113	Altamente Significativo (p < 0.001)
Quantidade Expressiva (! + ?)	511.6567	3	1.420e-110	Altamente Significativo (p < 0.001)

O teste de Kruskal-Wallis confirma variações intergrupos massivas ($\chi^2 = 349,6$, $p < 10^{-75}$).

4.2 Comparações Pareadas do Ensino Médio

Aplicamos o **Teste U de Wilcoxon / Mann-Whitney** com correção de Bonferroni e cálculo de *Cohen's d*.

4.2.1 Contrastes Pareados na Proporção (`pont_exp_prop`)

Table 3: Comparações Pareadas: Ensino Médio vs. Demais Níveis (Proporção Expressiva)

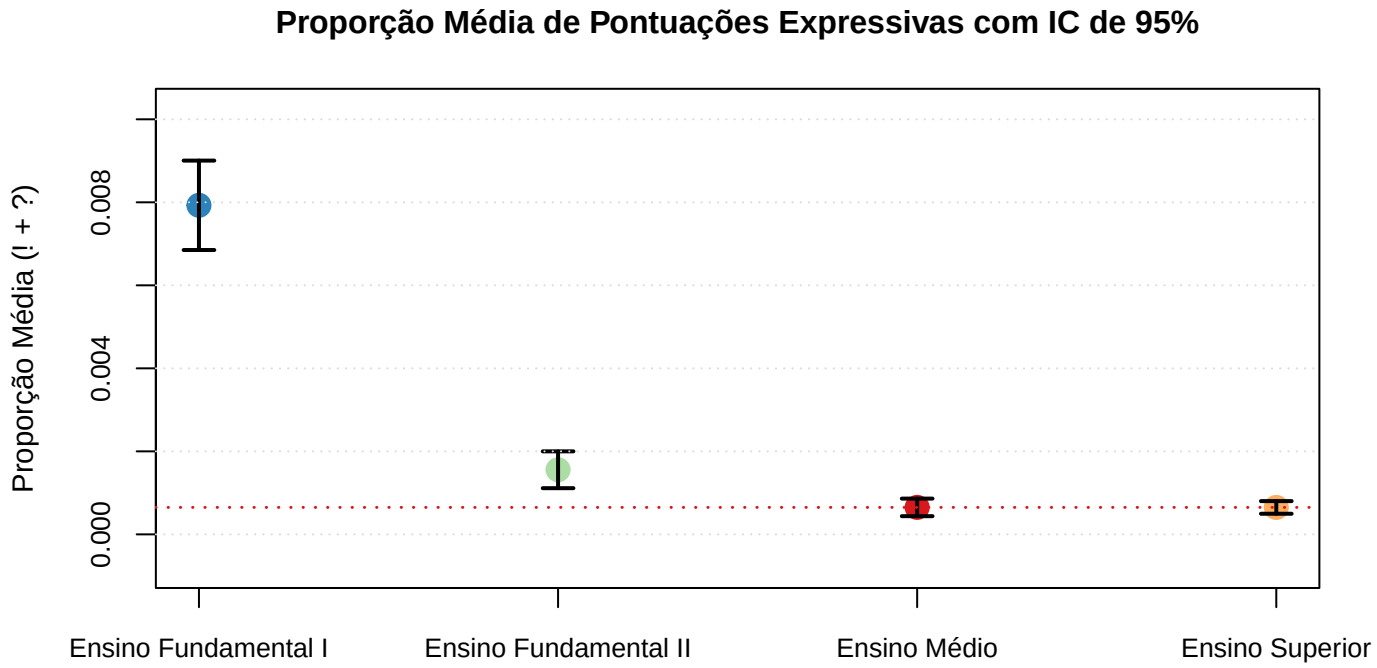
	Comparação	Média Médio	Média Grupo	Diferença Médias	Estatística W	p-adj (Bonferroni)	Cohen d	Decisão (alpha=0.05)
W...1	Ensino Médio vs. Ensino Fundamental I	0.00065	0.00793	-0.00728	35932	8.25e-77	-1.253	Rejeita H0 (Diferença Sig.)
W...2	Ensino Médio vs. Ensino Fundamental II	0.00065	0.00156	-0.00091	88246	3.13e-07	-0.280	Rejeita H0 (Diferença Sig.)
W...3	Ensino Médio vs. Ensino Superior	0.00065	0.00065	+0.00000	255786	1.00e+00	+0.000	Não Rejeita H0 (Sem Diferença)

4.2.2 Contrastes Pareados na Quantidade Absoluta (`pont_exp_qtd`)

Table 4: Comparações Pareadas: Ensino Médio vs. Demais Níveis (Quantidade Absoluta)

	Comparação	Média Médio	Média Grupo	Diferença Médias	Estatística W	p-adj (Bonferroni)	Cohen d	Decisão (alpha=0.05)
W...1	Ensino Médio vs. Ensino Fundamental I	0.237	2.677	-2.440	36712	6.21e-75	-1.227	Rejeita H0 (Diferença Sig.)
W...2	Ensino Médio vs. Ensino Fundamental II	0.237	0.557	-0.320	88227	2.92e-07	-0.285	Rejeita H0 (Diferença Sig.)
W...3	Ensino Médio vs. Ensino Superior	0.237	0.223	+0.015	255925	1.00e+00	+0.018	Não Rejeita H0 (Sem Diferença)

4.3 Gráfico de Médias com Intervalos de Confiança (95%)



5 Conclusões e Implicações para o Modelo Classificador

1. **Ensino Médio vs. Fundamental I** ($p = 8,25 \times 10^{-77}$, **Cohen's** $d = -1,25$): A mesclagem de ! com ? produziu um **efeito discriminativo monumental** ($d = -1,25$). O Fundamental I possui média de 2,68 pontuações expressivas por texto contra apenas 0,24 no Ensino Médio (uma taxa 12 vezes maior).
2. **Ensino Médio vs. Fundamental II** ($p = 3,13 \times 10^{-7}$, **Cohen's** $d = -0,28$): O Fundamental II (média de 0,56) ainda preserva mais do que o dobro de pontuações dialógicas em relação ao Ensino Médio (0,24), separando os dois ciclos da educação básica com alta significância estatística.
3. **Ensino Médio vs. Ensino Superior** ($p_{adj} = 1,00$, **Cohen's** $d = +0,0004$): Não há diferença estatística. Ambos compartilham praticamente a mesma taxa basal residual de pontuação expressiva ($0,065\%$).

Nível Comparado	Decisão Estatística	Tamanho de Efeito	Utilidade no Classificador ALFA-Gen
Médio vs. Fund. I	**Diferença Monumental**	**Muito Alto** ($-1,25$)	**Feature de separação primária** para Fundamental I.
Médio vs. Fund. II	Diferença Significativa	Pequeno/Médio ($-0,28$)	Contribui na separação de Fundamental II vs. Médio.
Médio vs. Superior	Sem Diferença	Nulo ($0,00$)	Não discrimina Médio de Superior.

A Apêndice: Arquitetura Modular e Códigos das Funções

- `extrair_features_pontuacao_formula.py`: Script Python com parsing regex para captura unificada de pontuações expressivas.
- `R/funcoes_estatistica.R`: Rotinas modulares de contrastes pareados com correção de Bonferroni.
- `R/funcoes_tabelas.R`: Geração padronizada de tabelas LaTeX via `knitr::kable`.
- `R/funcoes_graficos.R`: Painéis gráficos 2×2 e gráficos de intervalos de confiança.