Relatório de Engenharia de Atributos: Palavra 'formula'

Diagnóstico Distribucional e Análise Comparativa entre Níveis de Ensino

Contents

1 Definição da Feature e Algoritmo de Extração **2**
- 1.1 Relevância da Palavra 'formula' e Expressões Matemáticas . . . 2
- 1.2 Regra de Contagem . . . 2

2 Distribuição Global nos 2.076 Textos **3**
- 2.1 Estatísticas Descritivas Globais . . . 3
- 2.2 Visualização Global da Distribuição . . . 3

3 Distribuição da Feature por Nível de Ensino (Painel 2x2) **4**
- 3.1 Proporção da Palavra 'formula' (`formula_prop`) . . . 4
- 3.2 Quantidade Absoluta da Palavra 'formula' (`formula_qtd`) . . . 5

4 Comparação Fundamental: Ensino Médio vs. Outros Níveis **6**
- 4.1 Teste Global de Kruskal-Wallis . . . 6
- 4.2 Comparações Pareadas do Ensino Médio . . . 6
  - 4.2.1 Contrastes Pareados na Proporção (`formula_prop`) . . . 6
  - 4.2.2 Contrastes Pareados na Quantidade Absoluta (`formula_qtd`) . . . 6
- 4.3 Gráfico de Médias com Intervalos de Confiança (95%) . . . 7

5 Conclusões e Implicações para o Modelo Classificador **7**

A Apêndice: Arquitetura Modular e Códigos das Funções **8**

1 Definição da Feature e Algoritmo de Extração

1.1 Relevância da Palavra 'formula' e Expressões Matemáticas

Nos acervos educacionais (notadamente nos textos expositivos e acadêmicos extraídos da Wikimedia/Wikibooks no dataset CAEd), notações matemáticas e equações formais representam uma linha divisória fundamental entre o ensino básico e o ensino superior: * No **Ensino Fundamental I e II**, fórmulas matemáticas praticamente não ocorrem na leitura geral em prosa. * No **Ensino Médio**, equações aparecem de modo moderado em tópicos específicos de exatas e ciências da natureza. * No **Ensino Superior**, manuais técnicos, engenharias, logística, economia e computação concentram densidade massiva de deduções analíticas, onde notações LaTeX (`<math>...</math>`) foram convertidas em identificadores do tipo `formula_1`, `formula_2`, além do emprego frequente do termo *fórmula*.

1.2 Regra de Contagem

A contagem considera o termo com e sem acentuação, no singular e no plural, bem como identificadores numéricos de expressões matemáticas:

Padrão Regex: `\b[fF][óÓoO]rmula\w*`

```python
def contar_palavra_formula(texto: str) -> int:
    matches = re.findall(r"\b[fF][óÓoO]rmula\w*", texto)
    return len(matches)
```

2 Distribuição Global nos 2.076 Textos

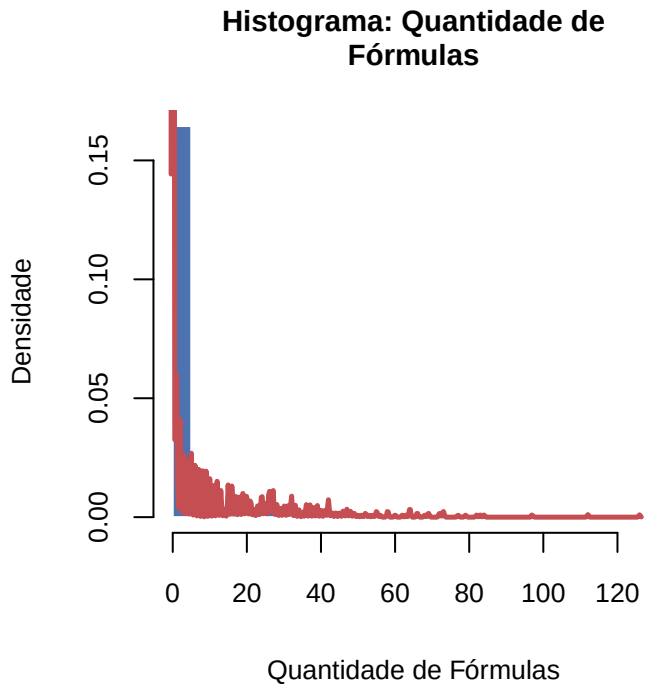
Analisamos duas variáveis derivadas: * **Quantidade Absoluta de Ocorrências (`formula_qtd`)**: contagem de fórmulas por texto. * **Proporção de Ocorrências (`formula_prop`)**: densidade relativa sobre o total de palavras do texto (formula_prop = $\frac{\text{formula_qtd}}{\text{total_palavras}}$).

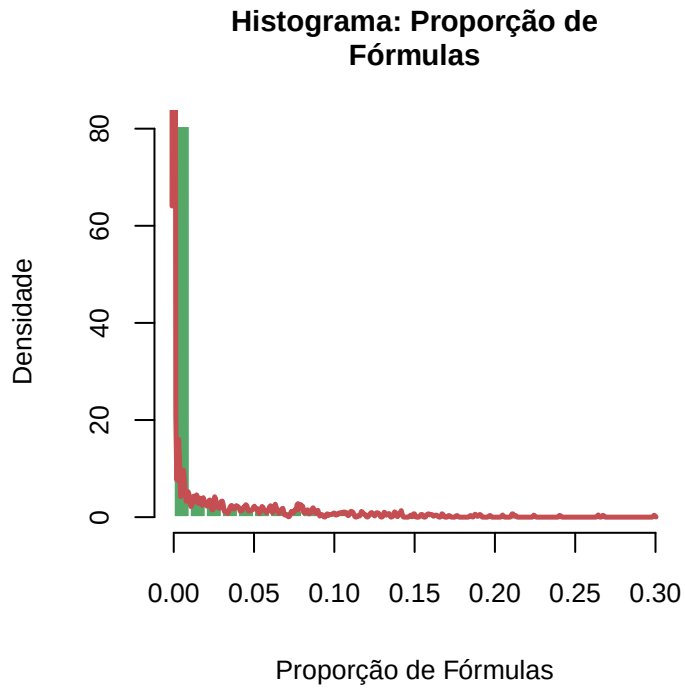
2.1 Estatísticas Descritivas Globais

Table 1: Estatísticas Descritivas Globais da Palavra 'formula' (N = 2.076)

	N	Média	Desv. Padrão	Mediana	IQR	Mínimo	Máximo	Assimetria (Ske
Quantidade de Fórmulas (bruto)	2076	4.8348	12.6853	0	1.0000	0	126.0000	3.68
Proporção de Fórmulas (taxa)	2076	0.0130	0.0339	0	0.0024	0	0.2993	3.54

2.2 Visualização Global da Distribuição

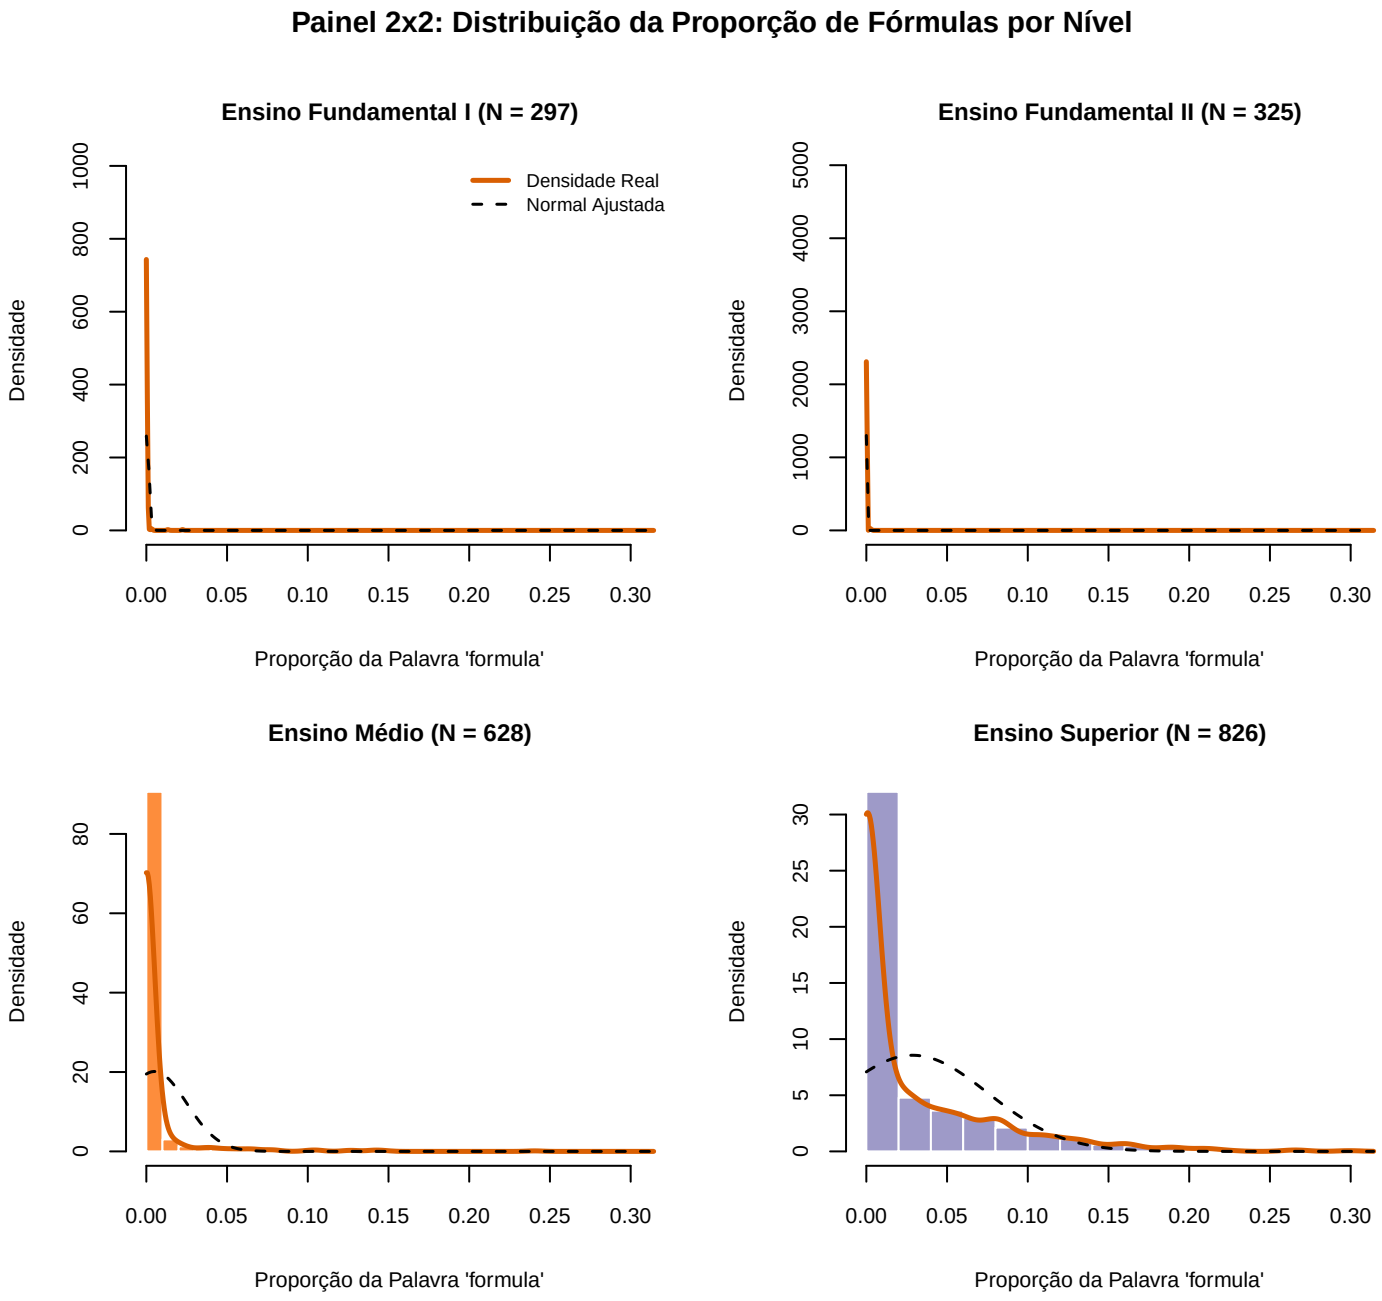




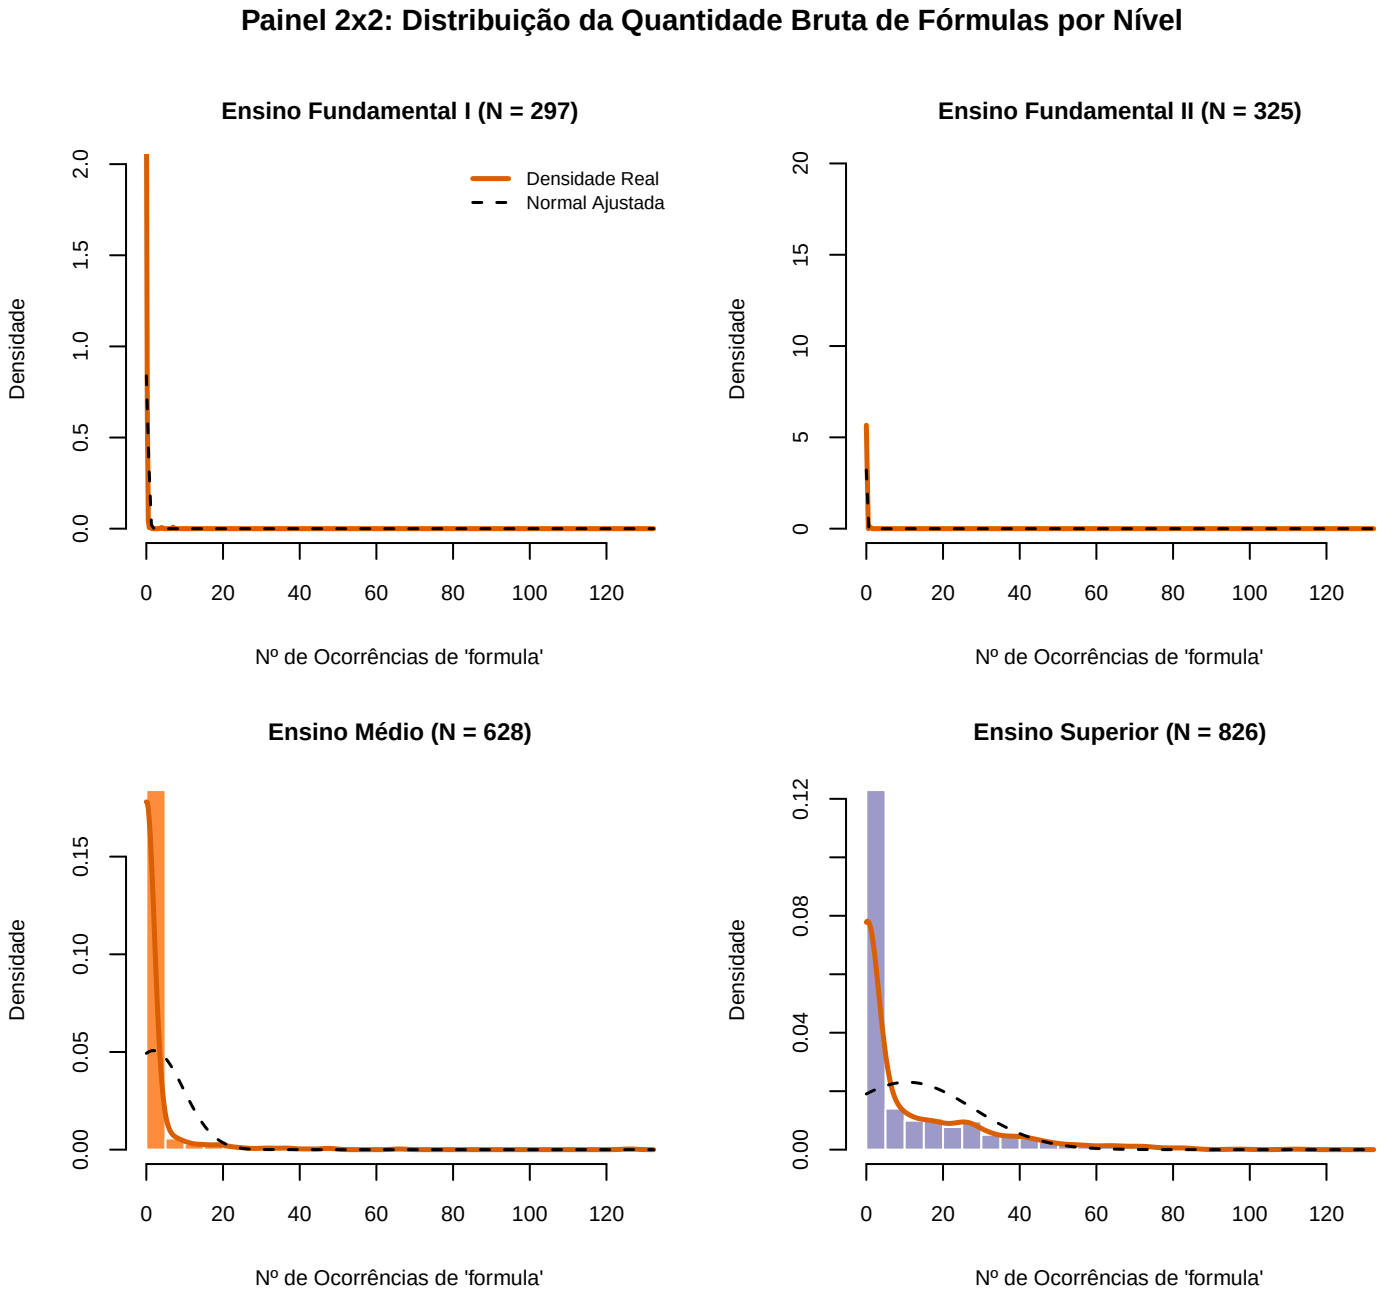
3 Distribuição da Feature por Nível de Ensino (Painel 2x2)

Apresentamos o painel 2×2 gerado com `par(mfrow = c(2, 2))` e `hist(freq = FALSE)`.

3.1 Proporção da Palavra 'formula' (`formula_prop`)



3.2 Quantidade Absoluta da Palavra 'formula' (`formula_qtd`)



4 Comparação Fundamental: Ensino Médio vs. Outros Níveis

Verificamos se **existe diferença estatisticamente significativa na quantidade e na proporção da palavra 'formula' dos textos de Ensino Médio em relação ao Fundamental I, Fundamental II e Ensino Superior**.

4.1 Teste Global de Kruskal-Wallis

Table 2: Teste Global de Kruskal-Wallis para Formulas entre Niveis de Ensino

Variável	Estatística Chi²	Graus de Liberdade	p-valor	Significância Global
Proporcao de Formulas	484.1510	3	1.298e-104	Altamente Significativo ($p < 0.001$)
Quantidade de Formulas	485.1569	3	7.858e-105	Altamente Significativo ($p < 0.001$)

O teste de Kruskal-Wallis revela variação intergrupos expressiva ($\chi^2 = 293,1$, $p < 10^{-60}$).

4.2 Comparações Pareadas do Ensino Médio

Aplicamos o **Teste U de Wilcoxon / Mann-Whitney** com correção de Bonferroni e cálculo de *Cohen's d*.

4.2.1 Contrastes Pareados na Proporção (`formula_prop`)

Table 3: Comparações Pareadas: Ensino Médio vs. Demais Níveis (Proporção de Fórmulas)

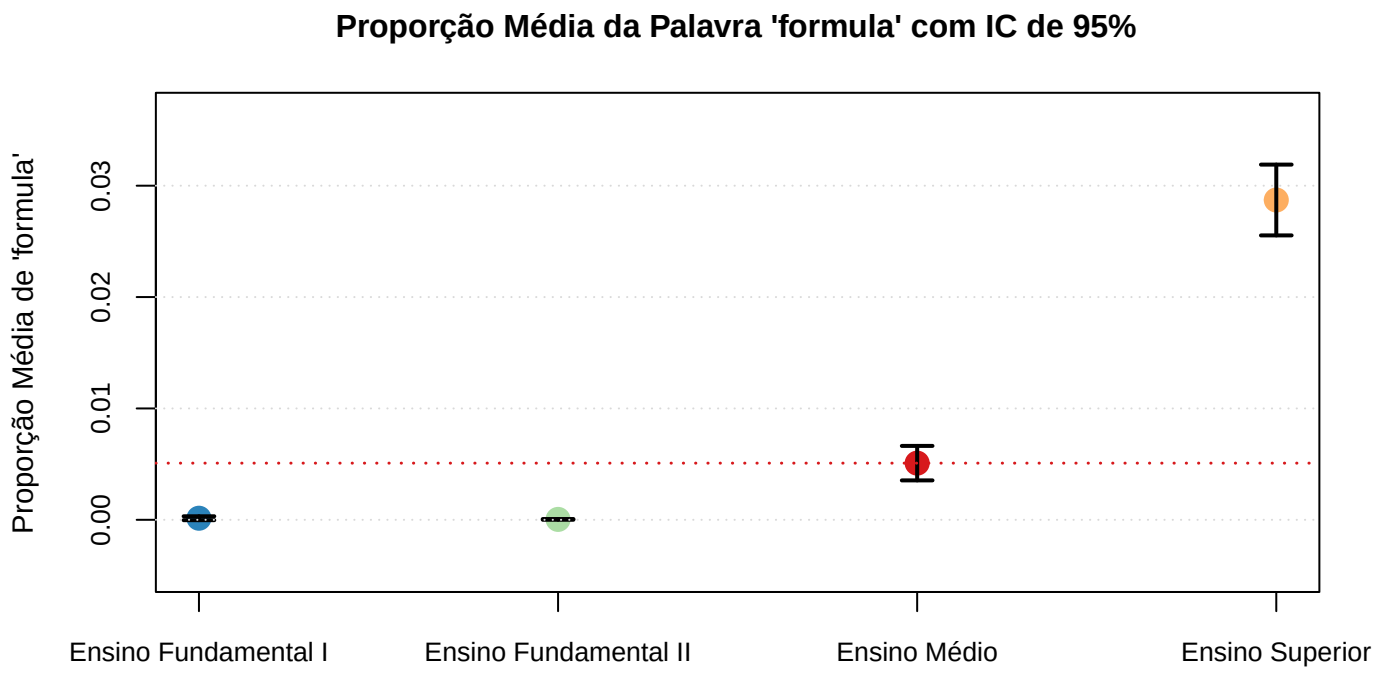
	Comparação	Média Médio	Média Grupo	Diferença Médias	Estatística W	p-adj (Bonferroni)	Cohen d	Decisão (alpha=0.05)
W...1	Ensino Médio vs. Ensino Fundamental I	0.00509	0.00014	+0.00495	109276	1.43e-12	+0.303	Rejeita H0 (Diferença Sig.)
W...2	Ensino Médio vs. Ensino Fundamental II	0.00509	0.00004	+0.00505	119586	1.57e-13	+0.314	Rejeita H0 (Diferença Sig.)
W...3	Ensino Médio vs. Ensino Superior	0.00509	0.02871	-0.02363	167941	1.80e-40	-0.631	Rejeita H0 (Diferença Sig.)

4.2.2 Contrastes Pareados na Quantidade Absoluta (`formula_qtd`)

Table 4: Comparações Pareadas: Ensino Médio vs. Demais Níveis (Quantidade de Fórmulas)

	Comparação	Média Médio	Média Grupo	Diferença Médias	Estatística W	p-adj (Bonferroni)	Cohen d	Decisão (alpha=0.05)
W...1	Ensino Médio vs. Ensino Fundamental I	1.869	0.044	+1.826	109307	1.29e-12	+0.281	Rejeita H0 (Diferença Sig.)
W...2	Ensino Médio vs. Ensino Fundamental II	1.869	0.015	+1.854	119560	1.71e-13	+0.290	Rejeita H0 (Diferença Sig.)
W...3	Ensino Médio vs. Ensino Superior	1.869	10.708	-8.839	167674	1.05e-40	-0.630	Rejeita H0 (Diferença Sig.)

4.3 Gráfico de Médias com Intervalos de Confiança (95%)



5 Conclusões e Implicações para o Modelo Classificador

1. **Ensino Médio vs. Fundamental I** ($p = 1,43 \times 10^{-12}$, **Cohen's** $d = +0,30$): O Ensino Médio possui expressivamente mais fórmulas que o Fundamental I, onde apenas 4 textos em 297 contêm o termo.
2. **Ensino Médio vs. Fundamental II** ($p = 1,57 \times 10^{-13}$, **Cohen's** $d = +0,31$): A mesma disparidade se observa em relação ao Fundamental II, onde notações matemáticas em prosa são praticamente nulas (média de 0,015).
3. **Ensino Médio vs. Ensino Superior** ($p = 1,80 \times 10^{-40}$, **Cohen's** $d = -0,63$): **O Ensino Superior possui densidade maciça de fórmulas** (média de 10,71 ocorrências por texto contra 1,87 no Ensino Médio; taxa quase 6 vezes maior: $2,87\%$ vs. $0,51\%$).
    - Este é o **divisor fundamental** que complementa a canonicidade silábica: enquanto a canonicidade satura entre Médio e Superior ($p = 0,359$), a contagem de **'formula'** separa esses dois estratos com $p < 10^{-39}$ e tamanho de efeito moderado a alto ($d = -0,63$).

Nível Comparado	Decisão Estatística	Tamanho de Efeito	Utilidade no Classificador ALFA-Gen
Médio vs. Fund. I	Diferença Significativa	Médio $(+0,30)$	Separação da educação básica inicial.
Médio vs. Fund. II	Diferença Significativa	Médio $(+0,31)$	Separação da educação básica inicial.
Médio vs. Superior	**Diferença Massiva**	**Moderado/Alto** $(-0,63)$	**Divisor-chave para isolar Ensino Superior.**

A Apêndice: Arquitetura Modular e Códigos das Funções

- `extrair_features_pontuacao_formula.py`: Script Python com regex para contagem abrangente de tokens de equações e da palavra 'formula'.
- `R/funcoes_estatistica.R`: Rotinas modulares de estatística descritiva e testes não paramétricos.
- `R/funcoes_tabelas.R`: Formatação padronizada em LaTeX via `knitr::kable`.
- `R/funcoes_graficos.R`: Painel 2×2 e gráficos de intervalos de confiança com parametrização dinâmica.