Relatório de Engenharia de Atributos: Comprimento Médio da Sentença (ASL)

Diagnóstico Distribucional e Análise Comparativa entre Níveis de Ensino

Contents

1 Definição da Feature e Algoritmo de Extração **2**
- 1.1 O Papel do ASL na Legibilidade e Complexidade Sintática . . . 2
- 1.2 Algoritmo em Python (NLTK) . . . 2

2 Distribuição Global nos 2.076 Textos **3**
- 2.1 Estatísticas Descritivas Globais . . . 3
- 2.2 Visualização Global da Distribuição . . . 3

3 Distribuição da Feature por Nível de Ensino (Painel 2x2) **4**
- 3.1 Comprimento Médio da Sentença (`asl`) . . . 4
- 3.2 Total de Sentenças por Texto (`total_sentencas`) . . . 5

4 Comparação Fundamental: Ensino Médio vs. Outros Níveis **6**
- 4.1 Teste Global de Kruskal-Wallis . . . 6
- 4.2 Comparações Pareadas do Ensino Médio . . . 6
  - 4.2.1 Contrastes Pareados no Comprimento Médio da Sentença (`asl`) . . . 6
  - 4.2.2 Contrastes Pareados no Total de Sentenças (`total_sentencas`) . . . 6
- 4.3 Gráfico de Médias com Intervalos de Confiança (95%) . . . 7

5 Conclusões e Implicações para o Modelo Classificador **7**

A Apêndice: Arquitetura Modular e Códigos das Funções **9**

1 Definição da Feature e Algoritmo de Extração

1.1 O Papel do ASL na Legibilidade e Complexidade Sintática

O **Comprimento Médio da Sentença (*Average Sentence Length* - ASL)** é a métrica fundacional de praticamente todos os índices clássicos de legibilidade textual (como Flesch Reading Ease, Flesch-Kincaid, Gunning Fog e Coleman-Liau):

$$ASL = \frac{\text{Total de Palavras no Texto}}{\text{Total de Sentenças no Texto}}$$

Na psicolinguística educacional: * **Períodos Simples e Curtos (Fundamental I)**: Leitores em processo inicial de alfabetização processam com mais facilidade estruturas coordenadas diretas com poucas orações encaixadas ($ASL \approx 14$ a 17 palavras). * **Períodos Compostos e Hipotaxe (Fundamental II e Médio)**: Ocorre ampliação da subordinação oracional (causais, temporais, conformativas, relativas), aumentando a extensão dos períodos ($ASL \approx 20$ a 24 palavras). * **Períodos Acadêmicos e Alta Densidade Informativa (Superior)**: Textos de graduação e manuais especializados articulam orações reduzidas de gerúndio e particípio, intercalações explicativas e vocabulário denso, resultando nos maiores períodos médios ($ASL > 25$ palavras).

1.2 Algoritmo em Python (NLTK)

A extração utiliza a biblioteca **NLTK** com o modelo `punkt_tab` para tokenização de sentenças em língua portuguesa e filtragem de tokens alfabéticos:

```
from nltk.tokenize import sent_tokenize, word_tokenize

def extrair_asl(texto: str) -> tuple:
    sentencas = sent_tokenize(texto, language='portuguese')
    total_sentencas = max(len(sentencas), 1)

    palavras = [t for t in word_tokenize(texto, language='portuguese')
                if re.search(r"^[a-záéíóúâêôãõàüç]+$", t.lower())]
    total_palavras = max(len(palavras), 1)

    asl = total_palavras / total_sentencas
    return total_sentencas, asl
```

2 Distribuição Global nos 2.076 Textos

Analisamos duas variáveis derivadas: * **Comprimento Médio da Sentença (`asl`)**: média de palavras por sentença no texto. * **Total de Sentenças (`total_sentencas`)**: contagem bruta de períodos delimitados no texto.

2.1 Estatísticas Descritivas Globais

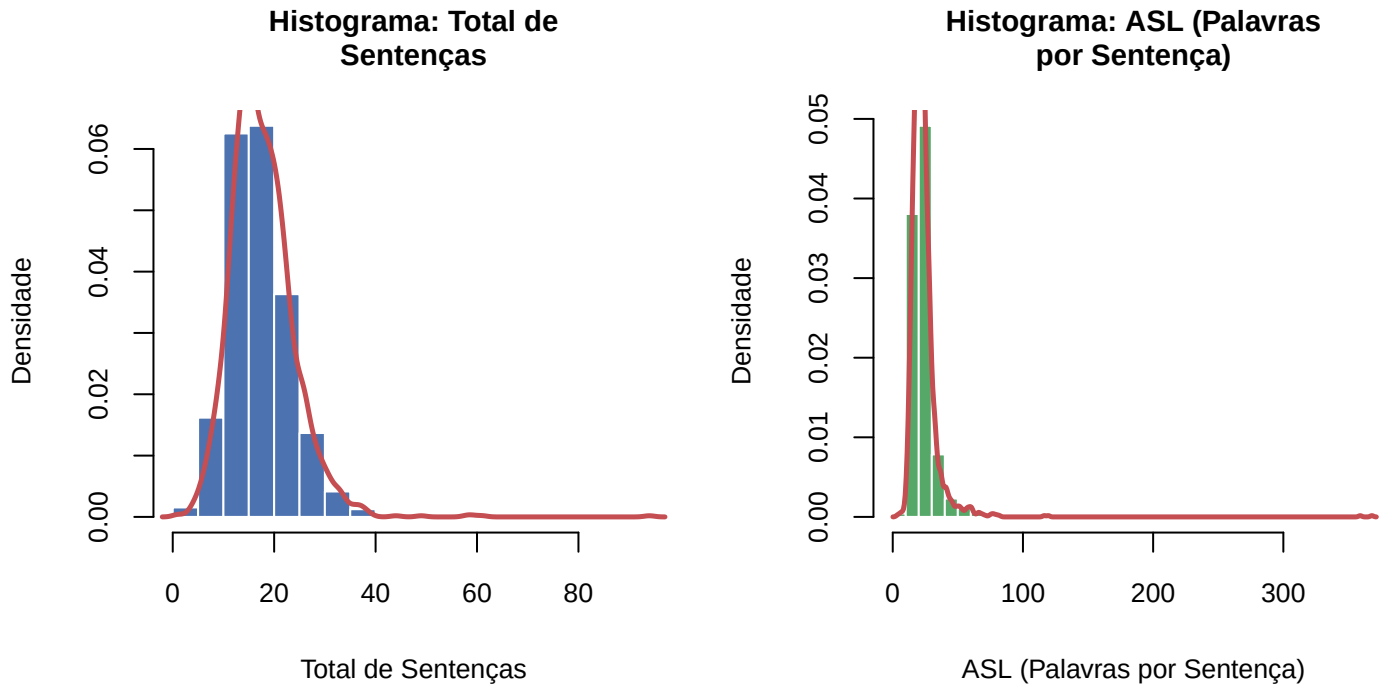
A Tabela 1 sintetiza as medidas de posição e dispersão para todo o acervo.

Table 1: Estatísticas Descritivas Globais do ASL e Sentenças (N = 2.076)

	N	Média	Desv. Padrão	Mediana	IQR	Mínimo	Máximo	Assimet
Total de Sentencas por Texto	2076	17.6541	6.3065	17.000	7.0000	1.0000	94	
Comprimento Medio da Sentenca (ASL)	2076	23.5981	13.8856	21.756	7.7366	3.5638	368	

2.2 Visualização Global da Distribuição

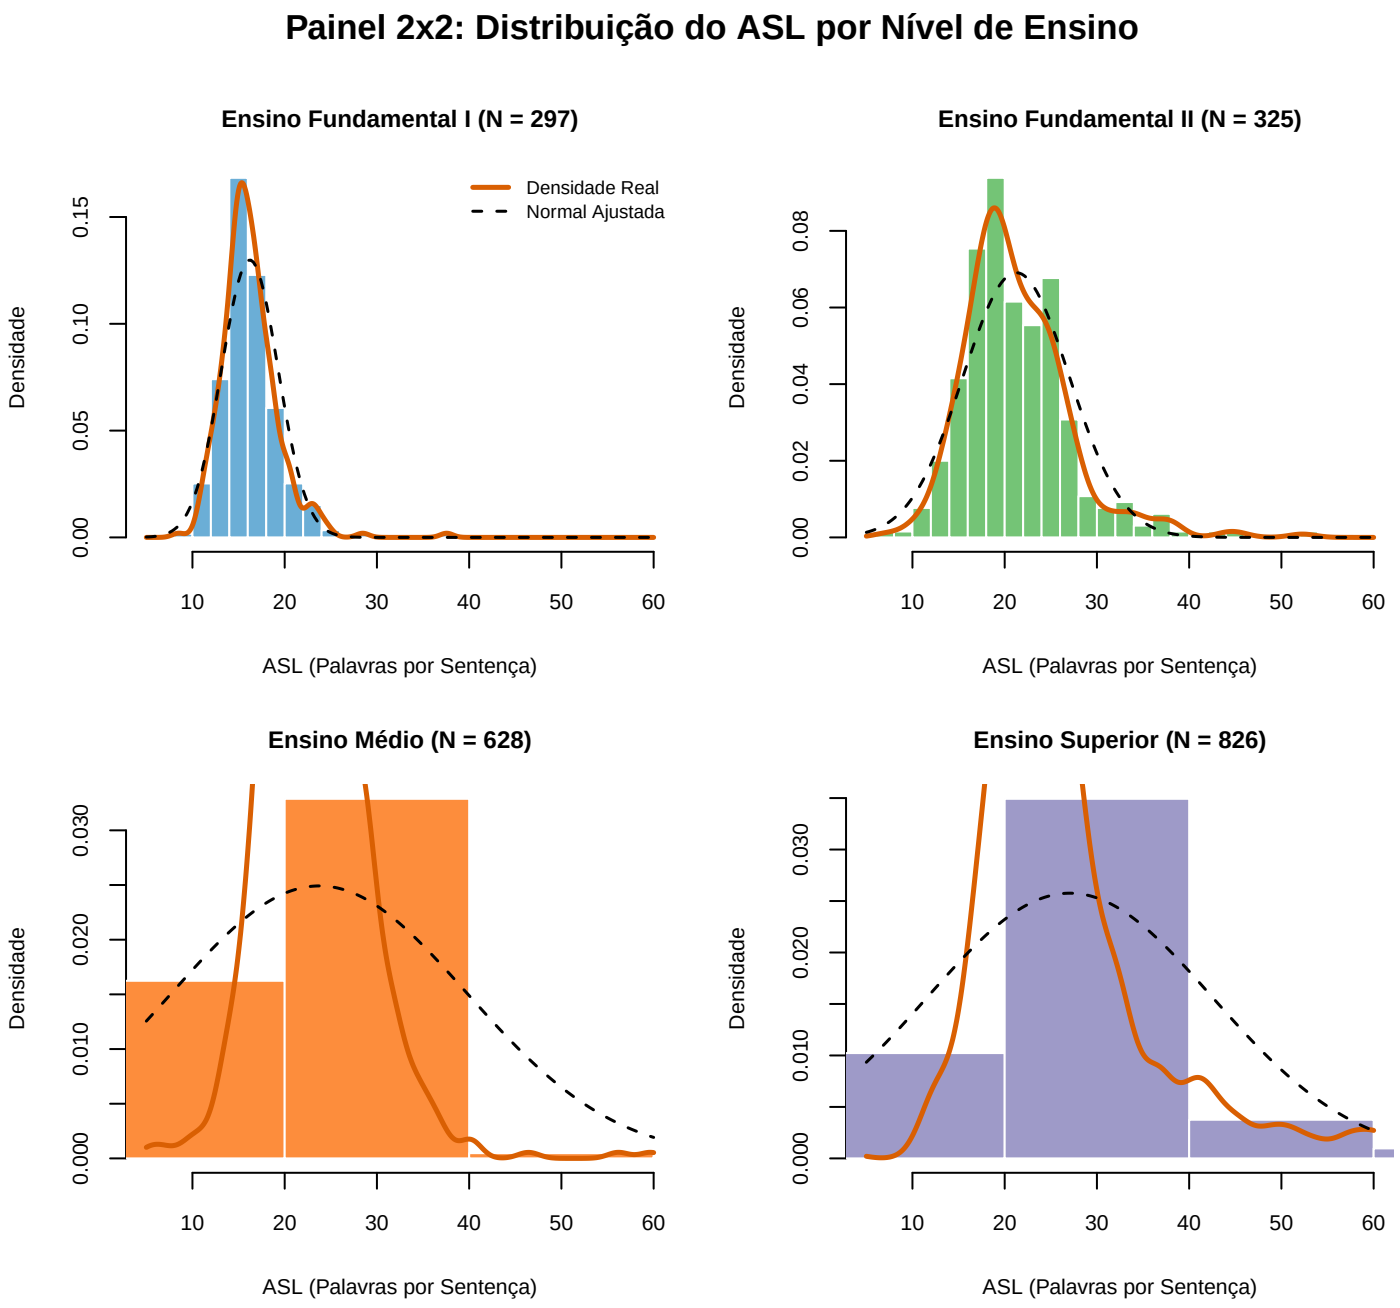
A Figura 1 apresenta os histogramas com curvas de densidade empírica para as duas métricas.



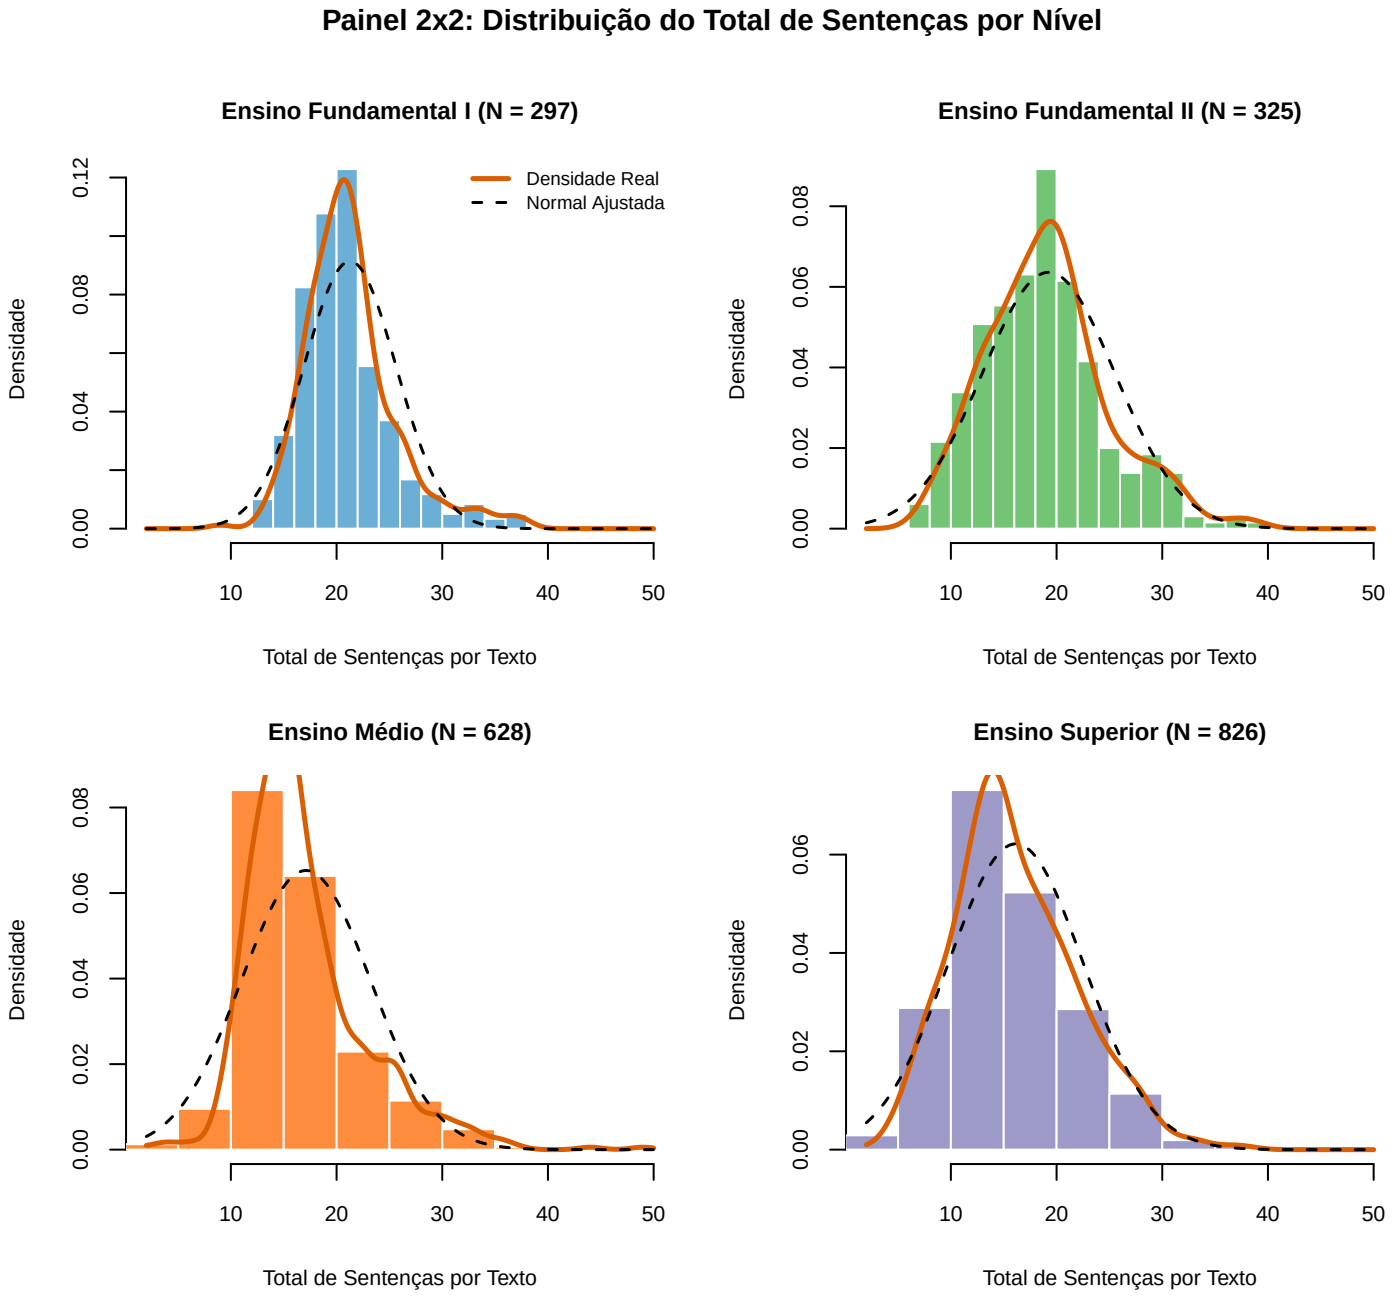
3 Distribuição da Feature por Nível de Ensino (Painel 2x2)

Apresentamos o painel 2×2 gerado com `par(mfrow = c(2, 2))` e `hist(freq = FALSE)` para os 4 níveis.

3.1 Comprimento Médio da Sentença (`asl`)



3.2 Total de Sentenças por Texto (`total_sentencas`)



4 Comparação Fundamental: Ensino Médio vs. Outros Níveis

Verificamos se **existe diferença estatisticamente significativa no ASL dos textos de Ensino Médio quando comparados com Ensino Fundamental I, Fundamental II e Ensino Superior**.

4.1 Teste Global de Kruskal-Wallis

Table 2: Teste Global de Kruskal-Wallis para ASL entre Niveis de Ensino

Variável	Estatística Chi²	Graus de Liberdade	p-valor	Significância Global
Comprimento Medio (ASL)	557.6733	3	1.509e-120	Altamente Significativo (p < 0.001)
Total de Sentencas	253.1085	3	1.392e-54	Altamente Significativo (p < 0.001)

O teste de Kruskal-Wallis confirma variações intergrupos colossais ($\chi^2 = 557,7$, $p < 10^{-120}$).

4.2 Comparações Pareadas do Ensino Médio

Aplicamos o **Teste U de Wilcoxon / Mann-Whitney** com correção de Bonferroni e cálculo do tamanho de efeito (*Cohen's d*).

4.2.1 Contrastes Pareados no Comprimento Médio da Sentença (`asl`)

Table 3: Comparações Pareadas: Ensino Médio vs. Demais Níveis (ASL em Palavras)

	Comparação	Média Médio	Média Grupo	Diferença Médias	Estatística W	p-adj (Bonferroni)	Cohen d	Decisão (alpha=0.05)
W...1	Ensino Médio vs. Ensino Fundamental I	23.75	16.22	+7.53	165084	1.85e-79	+0.566	Rejeita H0 (Diferença Sig.)
W...2	Ensino Médio vs. Ensino Fundamental II	23.75	21.25	+2.50	122309	1.48e-06	+0.186	Rejeita H0 (Diferença Sig.)
W...3	Ensino Médio vs. Ensino Superior	23.75	27.06	-3.32	200697	4.17e-13	-0.211	Rejeita H0 (Diferença Sig.)

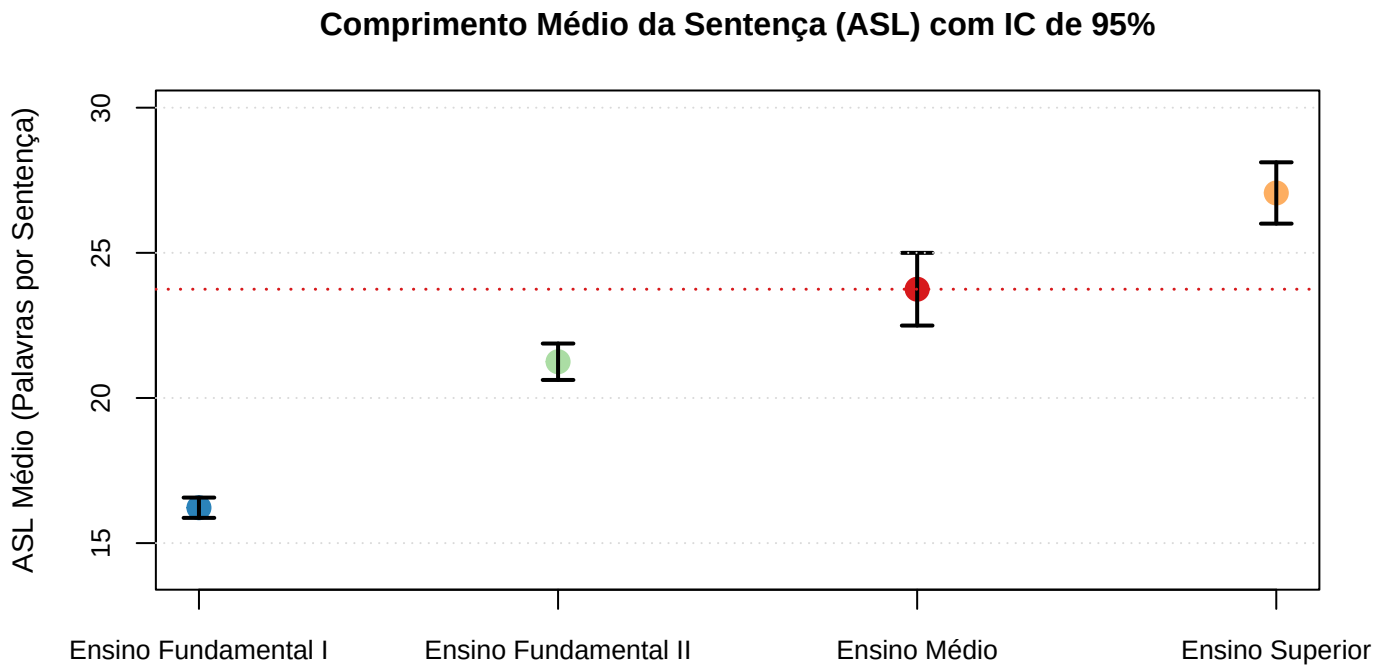
4.2.2 Contrastes Pareados no Total de Sentenças (`total_sentencas`)

Table 4: Comparações Pareadas: Ensino Médio vs. Demais Níveis (Total de Sentenças)

	Comparação	Média Médio	Média Grupo	Diferença Médias	Estatística W	p-adj (Bonferroni)	Cohen d	Decisão (alpha=0.05)
W...1	Ensino Médio vs. Ensino Fundamental I	17.11	21.27	-4.16	43103	1.45e-39	-0.742	Rejeita H0 (Diferença Sig.)
W...2	Ensino Médio vs. Ensino Fundamental II	17.11	19.25	-2.14	76289	4.42e-10	-0.347	Rejeita H0 (Diferença Sig.)
W...3	Ensino Médio vs. Ensino Superior	17.11	16.15	+0.96	281812	1.37e-02	+0.153	Rejeita H0 (Diferença Sig.)

4.3 Gráfico de Médias com Intervalos de Confiança (95%)

A Figura 2 ilustra as médias do ASL com intervalos de confiança de 95% para cada nível educacional. A linha tracejada em vermelho destaca a média do Ensino Médio (23, 75 palavras por sentença).



5 Conclusões e Implicações para o Modelo Classificador

O Comprimento Médio da Sentença (ASL) exibiu um **comportamento monotônico estritamente crescente** ao longo de toda a trajetória escolar:

$$\text{Fund. I } (16,22) \quad < \quad \text{Fund. II } (21,25) \quad < \quad \text{Médio } (23,75) \quad < \quad \text{Superior } (27,06)$$

1. **Ensino Médio vs. Fundamental I** ($p = 1,85 \times 10^{-79}$, **Cohen's** $d = +0,57$): Diferença estatística massiva com tamanho de efeito moderado/alto. Sentenças no Fundamental I possuem cerca de 7,5 palavras a menos que no Ensino Médio.
2. **Ensino Médio vs. Fundamental II** ($p = 1,48 \times 10^{-6}$, **Cohen's** $d = +0,19$): Diferença altamente significativa. O Ensino Médio apresenta períodos em média 2,5 palavras mais longos que o Fundamental II, refletindo maior maturidade sintática.
3. **Ensino Médio vs. Ensino Superior** ($p = 4,17 \times 10^{-13}$, **Cohen's** $d = -0,21$): Diferença altamente significativa. O Ensino Superior possui períodos significativamente mais longos que o Ensino Médio (27,06 vs. 23,75 palavras por sentença).

Nível Comparado	Decisão Estatística	Tamanho de Efeito	Utilidade no Classificador ALFA-Gen
Médio vs. Fund. I	**Diferença Massiva**	Moderado/Alto $(+0,57)$	Separação robusta da infância/alfabetização.
Médio vs. Fund. II	**Diferença Significativa**	Pequeno $(+0,19)$	Separação da transição para a adolescência.

Nível Comparado	Decisão Estatística	Tamanho de Efeito	Utilidade no Classificador ALFA-Gen
Médio vs. Superior	**Diferença Significativa**	Pequeno/Médio $(-0,21)$	**Separa Médio de Superior continuamente**.

A Apêndice: Arquitetura Modular e Códigos das Funções

- `extrair_features_asl.py`: Script Python/NLTK que segmenta sentenças (`sent_tokenize`) e palavras alfabéticas (`word_tokenize`) para computar o ASL em cada um dos 2.076 arquivos.
- `R/funcoes_estatistica.R`: Rotinas inferenciais não paramétricas e contrastes pareados de Wilcoxon.
- `R/funcoes_tabelas.R`: Formatação padronizada de tabelas LaTeX via `knitr::kable`.
- `R/funcoes_graficos.R`: Painéis gráficos 2×2 e gráficos de intervalos de confiança com parametrização dinâmica.