Relatório de Engenharia de Atributos: Densidade de Conjunções Subordinativas

Diagnóstico Distribucional e Análise Comparativa entre Níveis de Ensino

Contents

1 Definição da Feature e Algoritmo de Extração **2**
- 1.1 Relevância Sintática das Conjunções Subordinativas . . . 2
- 1.2 Algoritmo em Python (spaCy e Universal Dependencies) . . . 2

2 Distribuição Global nos 2.076 Textos **3**
- 2.1 Estatísticas Descritivas Globais . . . 3
- 2.2 Visualização Global da Distribuição . . . 3

3 Distribuição da Feature por Nível de Ensino (Painel 2x2) **4**
- 3.1 Densidade de Conjunções Subordinativas (`sconj_densidade`) . . . 4
- 3.2 Quantidade Absoluta de Conjunções Subordinativas (`sconj_qtd`) . . . 5

4 Comparação Fundamental: Ensino Médio vs. Outros Níveis **6**
- 4.1 Teste Global de Kruskal-Wallis . . . 6
- 4.2 Comparações Pareadas do Ensino Médio . . . 6
  - 4.2.1 Contrastes Pareados na Densidade (`sconj_densidade`) . . . 6
  - 4.2.2 Contrastes Pareados na Quantidade Absoluta (`sconj_qtd`) . . . 6
- 4.3 Gráfico de Médias com Intervalos de Confiança (95%) . . . 7

5 Conclusões e Implicações para o Modelo Classificador **7**

A Apêndice: Arquitetura Modular e Códigos das Funções **9**

1 Definição da Feature e Algoritmo de Extração

1.1 Relevância Sintática das Conjunções Subordinativas

Na gramática da língua portuguesa, as **conjunções subordinativas** conectam orações sintaticamente dependentes à oração principal. Elas constituem o mecanismo nuclear de articulação de hipóteses, causas, concessões, condições, finalidades e relações temporais complexas:

1. **Integrantes**: *que*, *se* (introduzem orações subordinadas substantivas);
2. **Causais**: *porque*, *visto que*, *já que*, *como*, *uma vez que*;
3. **Comparativas**: *como*, *que/do que*, *assim como*, *tanto quanto*;
4. **Concessivas**: *embora*, *ainda que*, *mesmo que*, *se bem que*, *apesar de que*;
5. **Condicionais**: *se*, *caso*, *desde que*, *contanto que*, *a não ser que*;
6. **Conformativas**: *conforme*, *segundo*, *consoante*, *como*;
7. **Consecutivas**: *que* (precedido de *tal*, *tanto*, *tão*), *de modo que*;
8. **Finais**: *para que*, *a fim de que*;
9. **Proporcionais**: *à medida que*, *à proporção que*, *ao passo que*;
10. **Temporais**: *quando*, *enquanto*, *logo que*, *assim que*, *antes que*.

A **Densidade de Conjunções Subordinativas** quantifica o grau de hipotaxe e subordinação lógica por palavra:

$$\text{sconj_densidade} = \frac{\text{Total de Conjunções Subordinativas}}{\text{Total de Palavras no Texto}}$$

1.2 Algoritmo em Python (spaCy e Universal Dependencies)

Para evitar ambiguidades sintáticas (por exemplo, diferenciar o *que* pronome relativo do *que* conjunção integrante, ou o *se* pronome apassivador do *se* conjunção condicional), a extração foi implementada utilizando o modelo pré-treinado **spaCy** (`pt_core_news_sm`). As conjunções subordinativas são etiquetadas estritamente sob a classe gramatical `SCONJ` (*Subordinating Conjunction*) da taxonomia internacional *Universal Dependencies*:

```
import spacy

nlp = spacy.load("pt_core_news_sm", disable=["ner", "lemmatizer"])

def extrair_subordinativas(doc) -> tuple:
    palavras = [t for t in doc if t.is_alpha and not t.is_space]
    total_palavras = max(len(palavras), 1)

    sconjs = [t.text.lower() for t in doc if t.pos_ == "SCONJ"]
    n_sconj = len(sconjs)

    densidade = n_sconj / total_palavras
    return n_sconj, densidade
```

2 Distribuição Global nos 2.076 Textos

Analisamos duas variáveis derivadas: * **Quantidade Absoluta de Conjunções Subordinativas (`sconj_qtd`)**: contagem bruta de conectivos `SCONJ` no texto. * **Densidade de Conjunções Subordinativas (`sconj_densidade`)**: fração de conectivos subordinativos em relação ao total de palavras (sconj_densidade = $\frac{\text{sconj_qtd}}{\text{total_palavras}}$).

2.1 Estatísticas Descritivas Globais

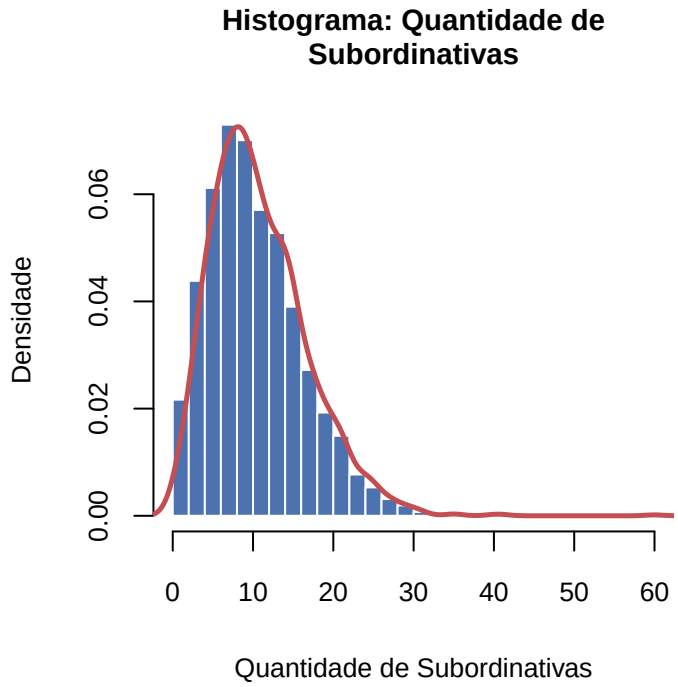
A Tabela 1 sintetiza as medidas de posição e dispersão para todo o acervo.

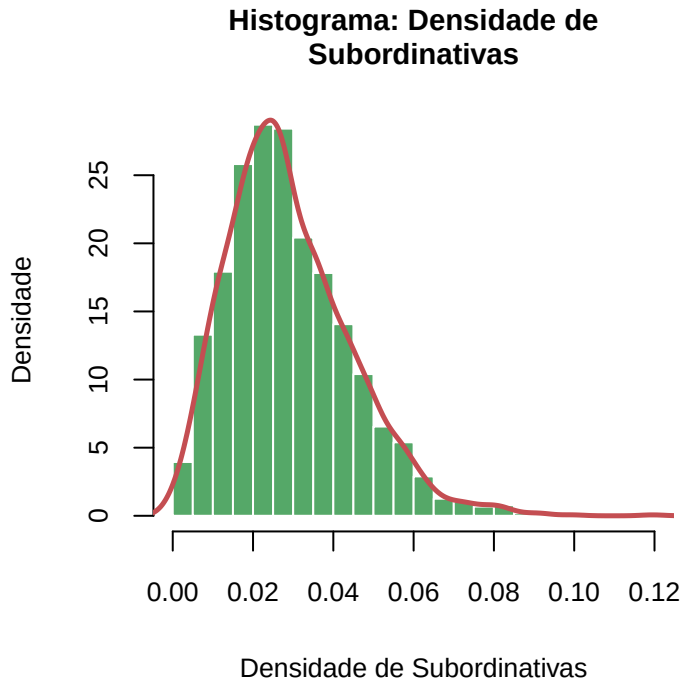
Table 1: Estatísticas Descritivas Globais das Conjunções Subordinativas (N = 2.076)

	N	Média	Desv. Padrão	Mediana	IQR	Mínimo	Máximo	Assimetri
Quantidade de Subordinativas (bruto)	2076	10.8184	5.9772	10.0000	8.0000	0	60.0000	
Densidade de Subordinativas (taxa)	2076	0.0290	0.0154	0.0267	0.0199	0	0.1195	

2.2 Visualização Global da Distribuição

A Figura 1 apresenta os histogramas com curvas de densidade empírica para as duas variáveis.

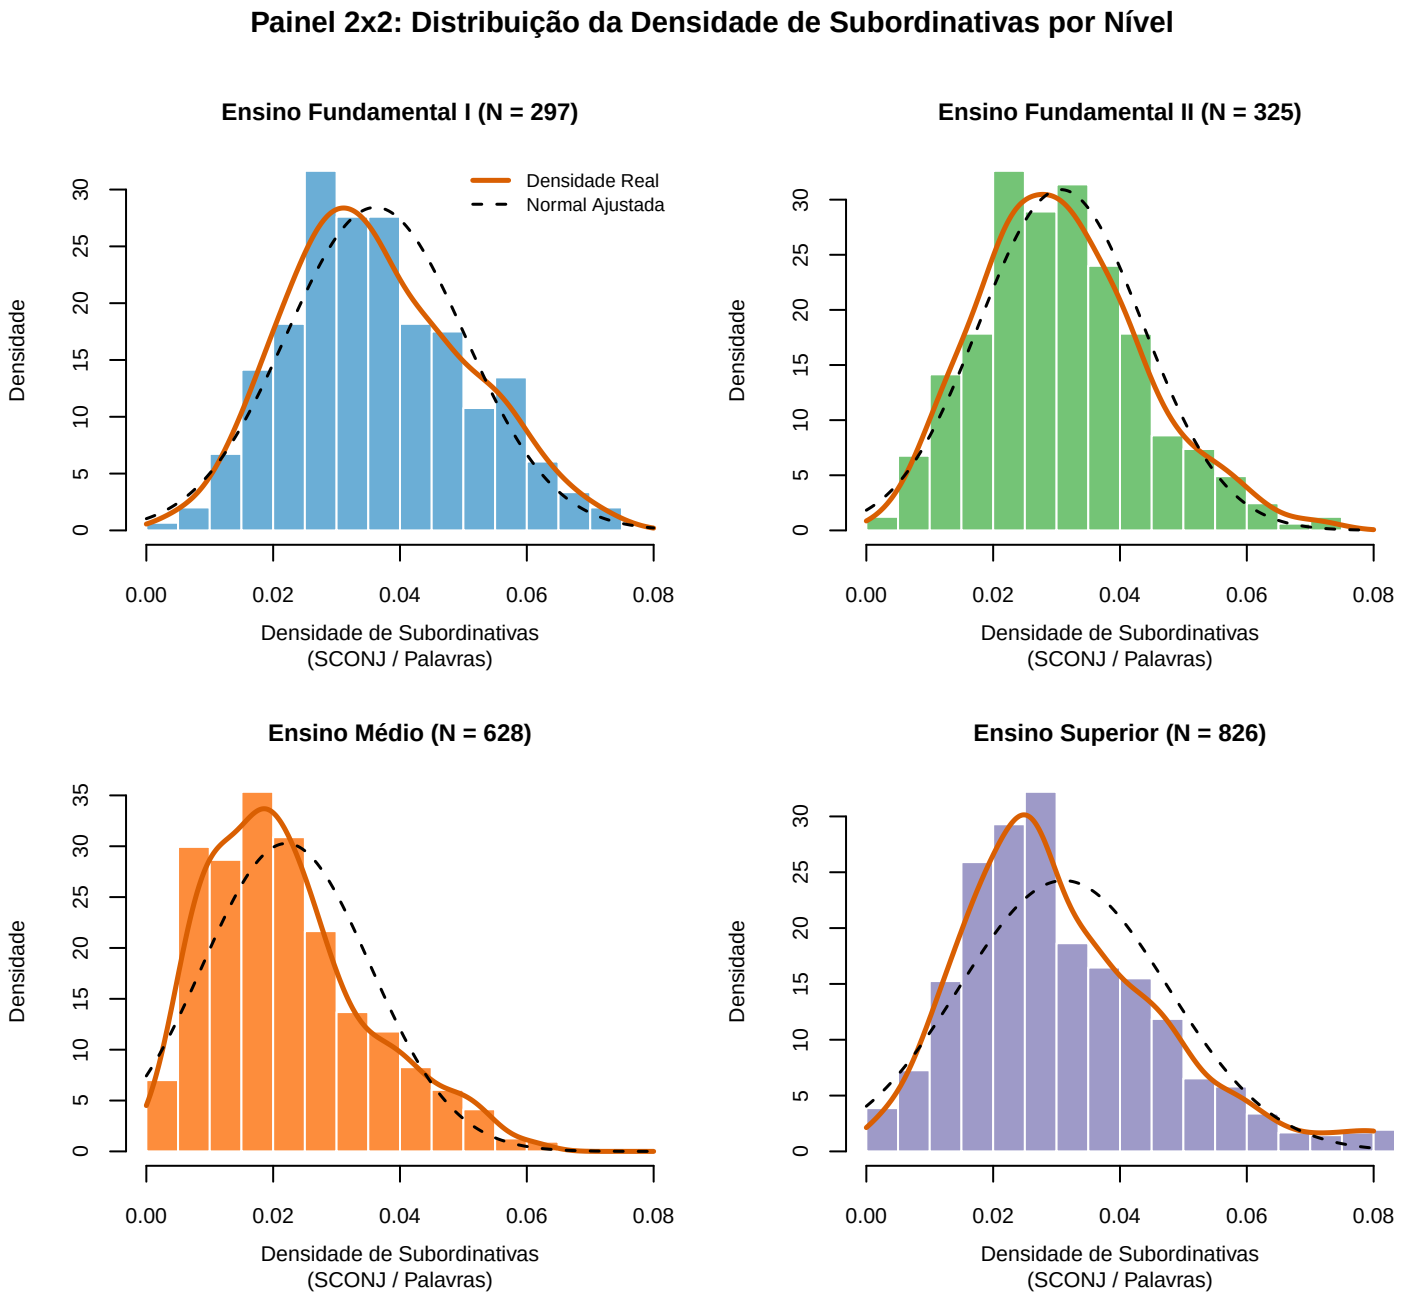




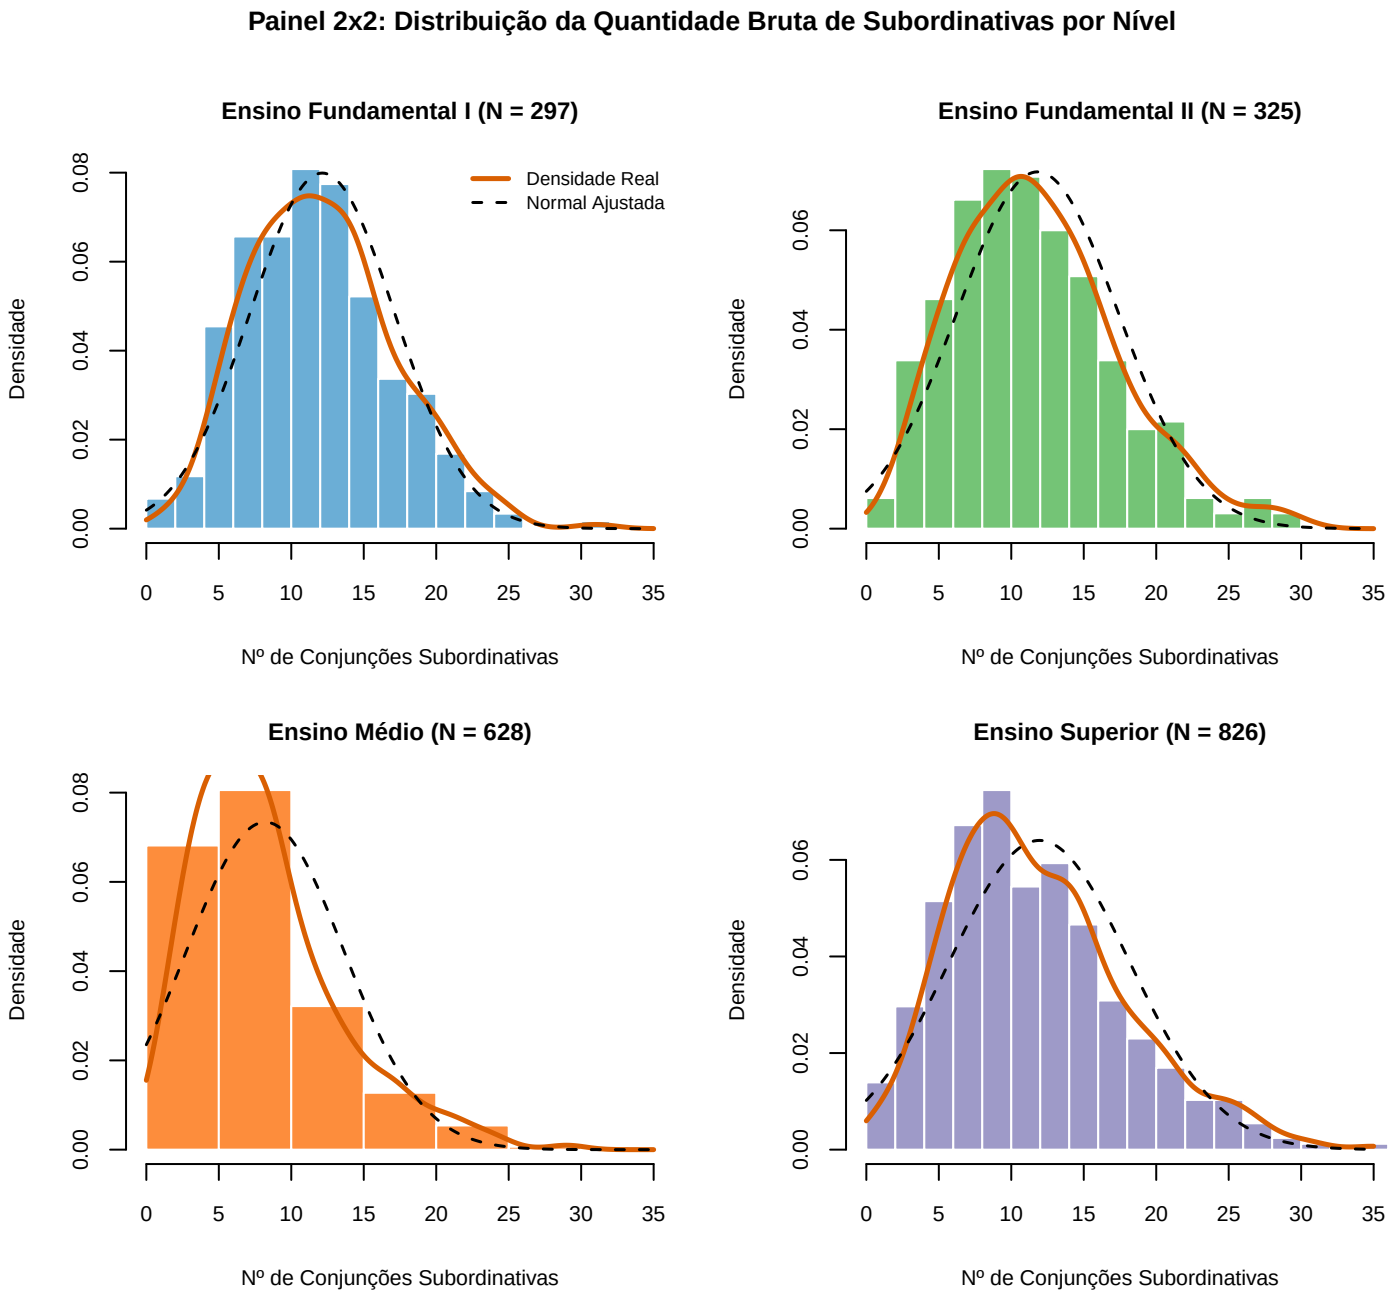
3 Distribuição da Feature por Nível de Ensino (Painel 2x2)

Apresentamos o painel 2×2 gerado com `par(mfrow = c(2, 2))` e `hist(freq = FALSE)` para os 4 níveis.

3.1 Densidade de Conjunções Subordinativas (`sconj_densidade`)



3.2 Quantidade Absoluta de Conjunções Subordinativas (`sconj_qtd`)



4 Comparação Fundamental: Ensino Médio vs. Outros Níveis

Verificamos se **existe diferença estatisticamente significativa na densidade e na quantidade de conjunções subordinativas dos textos de Ensino Médio quando comparados com Ensino Fundamental I, Fundamental II e Ensino Superior**.

4.1 Teste Global de Kruskal-Wallis

Table 2: Teste Global de Kruskal-Wallis para Conjuncoes Subordinativas entre Niveis

Variável	Estatística Chi²	Graus de Liberdade	p-valor	Significância Global
Densidade de Subordinativas	244.9234	3	8.199e-53	Altamente Significativo ($p < 0.001$)
Quantidade de Subordinativas	218.2135	3	4.885e-47	Altamente Significativo ($p < 0.001$)

O teste de Kruskal-Wallis confirma variações intergrupos altamente significativas ($\chi^2 = 244,9$, $p < 10^{-52}$).

4.2 Comparações Pareadas do Ensino Médio

Aplicamos o **Teste U de Wilcoxon / Mann-Whitney** com correção de Bonferroni e cálculo do tamanho de efeito (*Cohen's d*).

4.2.1 Contrastes Pareados na Densidade (`sconj_densidade`)

Table 3: Comparações Pareadas: Ensino Médio vs. Demais Níveis (Densidade de Subordinativas)

	Comparação	Média Médio	Média Grupo	Diferença Médias	Estatística W	p-adj (Bonferroni)	Cohen d	Decisão (alpha=0.05)
W...1	Ensino Médio vs. Ensino Fundamental I	0.02210	0.03613	-0.01404	41210	2.34e-42	-1.043	Rejeita H0 (Diferença Sig.)
W...2	Ensino Médio vs. Ensino Fundamental II	0.02210	0.03069	-0.00859	61899	6.34e-23	-0.657	Rejeita H0 (Diferença Sig.)
W...3	Ensino Médio vs. Ensino Superior	0.02210	0.03113	-0.00903	169821	4.38e-29	-0.597	Rejeita H0 (Diferença Sig.)

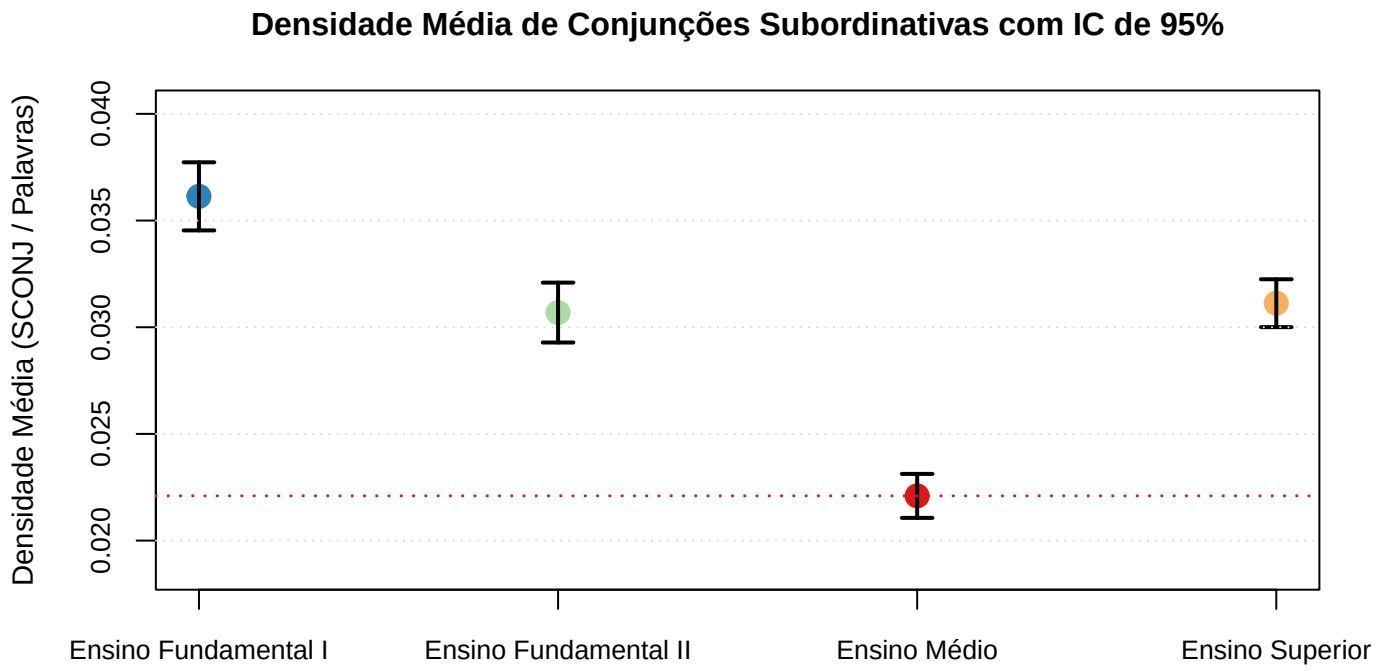
4.2.2 Contrastes Pareados na Quantidade Absoluta (`sconj_qtd`)

Table 4: Comparações Pareadas: Ensino Médio vs. Demais Níveis (Quantidade de Subordinativas)

	Comparação	Média Médio	Média Grupo	Diferença Médias	Estatística W	p-adj (Bonferroni)	Cohen d	Decisão (alpha=0.05)
W...1	Ensino Médio vs. Ensino Fundamental I	8.20	12.14	-3.94	50022	1.01e-29	-0.743	Rejeita H0 (Diferença Sig.)
W...2	Ensino Médio vs. Ensino Fundamental II	8.20	11.82	-3.61	60945	4.67e-24	-0.660	Rejeita H0 (Diferença Sig.)
W...3	Ensino Médio vs. Ensino Superior	8.20	11.94	-3.74	159807	8.81e-36	-0.634	Rejeita H0 (Diferença Sig.)

4.3 Gráfico de Médias com Intervalos de Confiança (95%)

A Figura 2 ilustra as médias da densidade de conjunções subordinativas com intervalos de confiança de 95% para cada nível educacional. A linha tracejada em vermelho destaca a média do Ensino Médio (2, 21%).



5 Conclusões e Implicações para o Modelo Classificador

A análise revelou um **perfil discursivo singular para o Ensino Médio**:

1. **Ensino Médio vs. Fundamental I** ($p = 2,34 \times 10^{-42}$, **Cohen's** $d = -1,04$): Diferença estatística massiva com tamanho de efeito muito alto ($d > 1$). No Fundamental I, os textos são predominantemente narrativos e conversacionais, repletos de orações temporais, causais e integrantes (*quando*, *porque*, *que* disse).
2. **Ensino Médio vs. Fundamental II** ($p = 6,34 \times 10^{-23}$, **Cohen's** $d = -0,66$): Diferença altamente significativa. O Fundamental II exibe densidade substantivamente superior (3, 07% vs. 2, 21%), articulando períodos explicativos em ciências e história.
3. **Ensino Médio vs. Ensino Superior** ($p = 4,38 \times 10^{-29}$, **Cohen's** $d = -0,60$): Diferença altamente significativa. O Ensino Superior apresenta densidade de subordinação acentuadamente maior (3, 11% vs. 2, 21%). Textos acadêmicos exigem argumentação hipotática densa (*posto que*, *uma vez que*, *à medida que*, *embora*).

   A Assinatura do Ensino Médio: No acervo CAEd, os excertos do Ensino Médio concentram resumos conceituais, sínteses enciclopédicas e guias práticos com períodos assertivos e coordenação, resultando na **menor densidade de subordinação de todo o acervo**. Essa feature atua como um **marcador distintivo negativo do Ensino Médio contra todos os outros 3 níveis**!

Nível Comparado	Decisão Estatística	Tamanho de Efeito	Utilidade no Classificador ALFA-Gen
Médio vs. Fund. I	**Diferença Massiva**	Muito Alto ($-1,04$)	Forte separação discursiva.

Nível Comparado	Decisão Estatística	Tamanho de Efeito	Utilidade no Classificador ALFA-Gen
Médio vs. Fund. II	**Diferença Significativa**	Moderado/Alto ($-0,66$)	Isola o Ensino Médio do Fundamental II.
Médio vs. Superior	**Diferença Significativa**	Moderado/Alto ($-0,60$)	Isola o Ensino Médio do Ensino Superior.

A Apêndice: Arquitetura Modular e Códigos das Funções

- `extrair_features_subordinativas.py`: Pipeline Python com modelo `pt_core_news_sm` do spaCy em lote (`nlp.pipe`), etiquetando orações e tokens sob a classe morfossintática `SCONJ`.
- `R/funcoes_estatistica.R`: Rotinas modulares de análise estatística descritiva e testes de Wilcoxon com correção de Bonferroni.
- `R/funcoes_tabelas.R`: Formatação padronizada de tabelas LaTeX via `knitr::kable`.
- `R/funcoes_graficos.R`: Painéis gráficos 2×2 e gráficos de intervalos de confiança com parametrização dinâmica.