Relatório de Engenharia de Atributos: Razão Nominal (Substantivos / Verbos)

Diagnóstico Distribucional e Análise Comparativa entre Níveis de Ensino

Contents

1 Definição da Feature e Algoritmo de Extração **2**
- 1.1 Fundamentação Linguística: Densidade Nominal vs. Dinâmica Verbal . . . 2
- 1.2 Algoritmo em Python (spaCy e Universal Dependencies) . . . 2

2 Distribuição Global nos 2.076 Textos **3**
- 2.1 Estatísticas Descritivas Globais . . . 3
- 2.2 Visualização Global da Distribuição . . . 3

3 Distribuição da Feature por Nível de Ensino (Painel 2x2) **4**
- 3.1 Razão Nominal (`razao_nominal`) . . . 4
- 3.2 Quantidade Absoluta de Substantivos (`substantivos_qtd`) . . . 5

4 Comparação Fundamental: Ensino Médio vs. Outros Níveis **6**
- 4.1 Teste Global de Kruskal-Wallis . . . 6
- 4.2 Comparações Pareadas do Ensino Médio . . . 6
  - 4.2.1 Contrastes Pareados na Razão Nominal (`razao_nominal`) . . . 6
  - 4.2.2 Contrastes Pareados na Quantidade Absoluta (`substantivos_qtd`) . . . 6
- 4.3 Gráfico de Médias com Intervalos de Confiança (95%) . . . 7

5 Conclusões e Implicações para o Modelo Classificador **7**

A Apêndice: Arquitetura Modular e Códigos das Funções **9**

1 Definição da Feature e Algoritmo de Extração

1.1 Fundamentação Linguística: Densidade Nominal vs. Dinâmica Verbal

Na linguística textual e na teoria de gêneros discursivos (Biber, 1988), a proporção entre **substantivos** e **verbos** constitui um dos marcadores mais robustos de maturação textual e densidade informacional:

- **Estilo Verbal / Narrativo:** Característico dos anos iniciais da escolarização (Ensino Fundamental I e II). Os textos são estruturados em torno de sequências de ações, eventos cronológicos e diálogos, gerando alta densidade de verbos e formas verbais auxiliares.
- **Estilo Nominal / Expositivo:** Característico do Ensino Médio e Ensino Superior. A escrita acadêmica e científica opera por **nominalização** — o processo de empacotar processos e fenômenos complexos em substantivos abstratos (ex.: em vez de *"a temperatura aumentou rapidamente"*, emprega-se *"o aumento térmico acelerado"*).

A **Razão Nominal** (RN) quantifica a densidade de substantivos em relação ao fluxo de ações verbais:

$$\text{razao_nominal} = \frac{\text{Total de Substantivos (NOUN)}}{\max(\text{Total de Verbos e Auxiliares (VERB, AUX)}, 1)}$$

Valores RN $\approx 1,0$ indicam equilíbrio narrativo, enquanto valores RN $> 1,8$ evidenciam forte condensação conceitual e estilo dissertativo-expositivo.

1.2 Algoritmo em Python (spaCy e Universal Dependencies)

A extração foi implementada utilizando o modelo pré-treinado **spaCy** (`pt_core_news_sm`), etiquetando tokens alfabéticos sob as classes gramaticais `NOUN` (substantivos) e `VERB`/`AUX` (verbos e auxiliares) da taxonomia *Universal Dependencies*:

```python
import spacy

nlp = spacy.load("pt_core_news_sm", disable=["ner"])

def extrair_razao_nominal(doc) -> tuple:
    substantivos = [t for t in doc if t.pos_ == "NOUN"]
    verbos = [t for t in doc if t.pos_ in ("VERB", "AUX")]

    n_subst = len(substantivos)
    n_verb = len(verbos)

    razao = n_subst / max(n_verb, 1)
    return n_subst, n_verb, razao
```

2 Distribuição Global nos 2.076 Textos

Analisamos duas variáveis derivadas: * **Quantidade de Substantivos (`substantivos_qtd`)**: contagem bruta de substantivos no texto. * **Razão Nominal (`razao_nominal`)**: índice de empacotamento nominal por verbo (substantivos/verbos).

2.1 Estatísticas Descritivas Globais

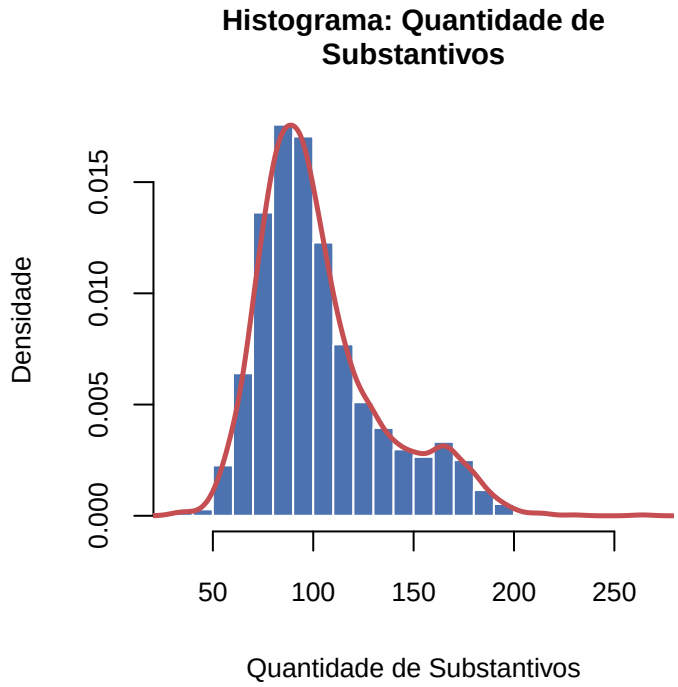
A Tabela 1 sintetiza as medidas de posição e dispersão para todo o acervo.

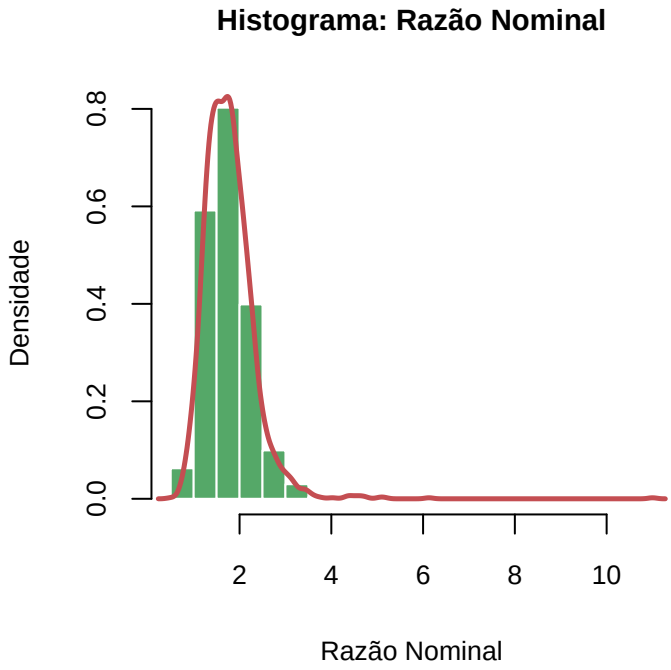
Table 1: Estatísticas Descritivas Globais da Razão Nominal (N = 2.076)

	N	Média	Desv. Padrão	Mediana	IQR	Mínimo	Máximo	Assim
Quantidade de Substantivos (NOUN)	2076	103.1493	31.0281	96.0000	35.0000	31.0000	264	
Razão Nominal (Substantivos / Verbos)	2076	1.7735	0.5604	1.7143	0.6357	0.5078	11	

2.2 Visualização Global da Distribuição

A Figura 1 apresenta os histogramas com curvas de densidade empírica para as duas variáveis.

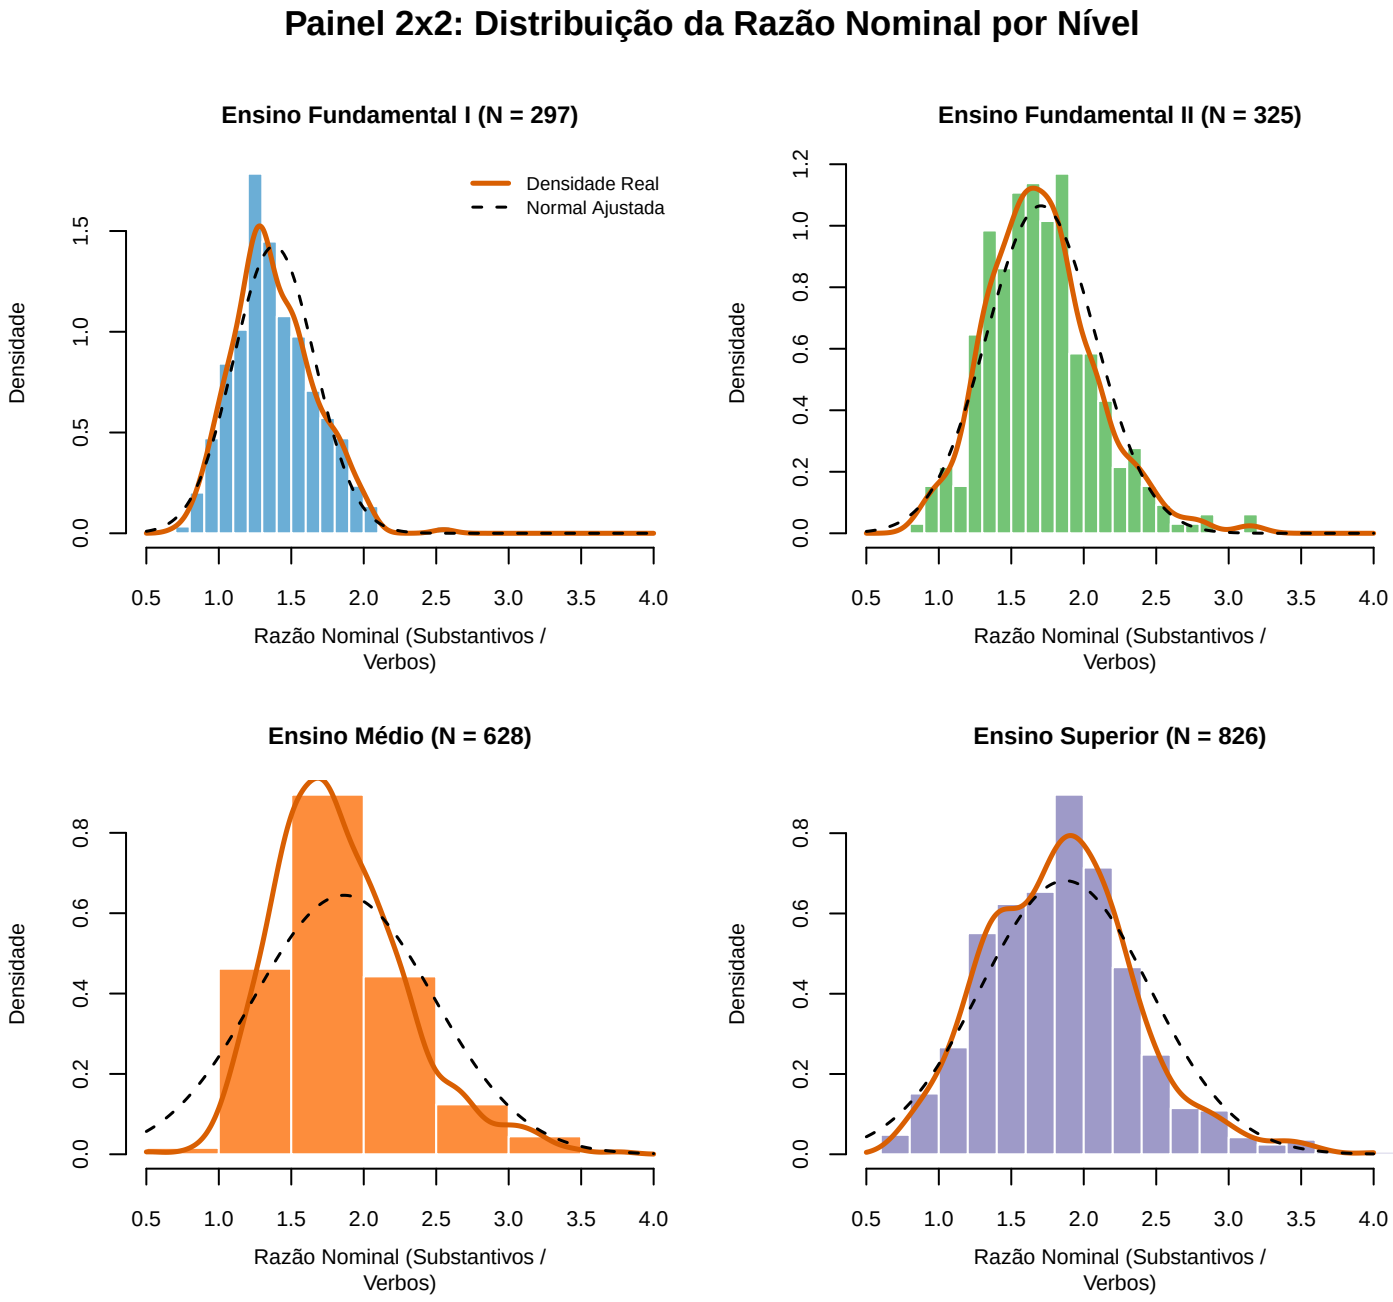




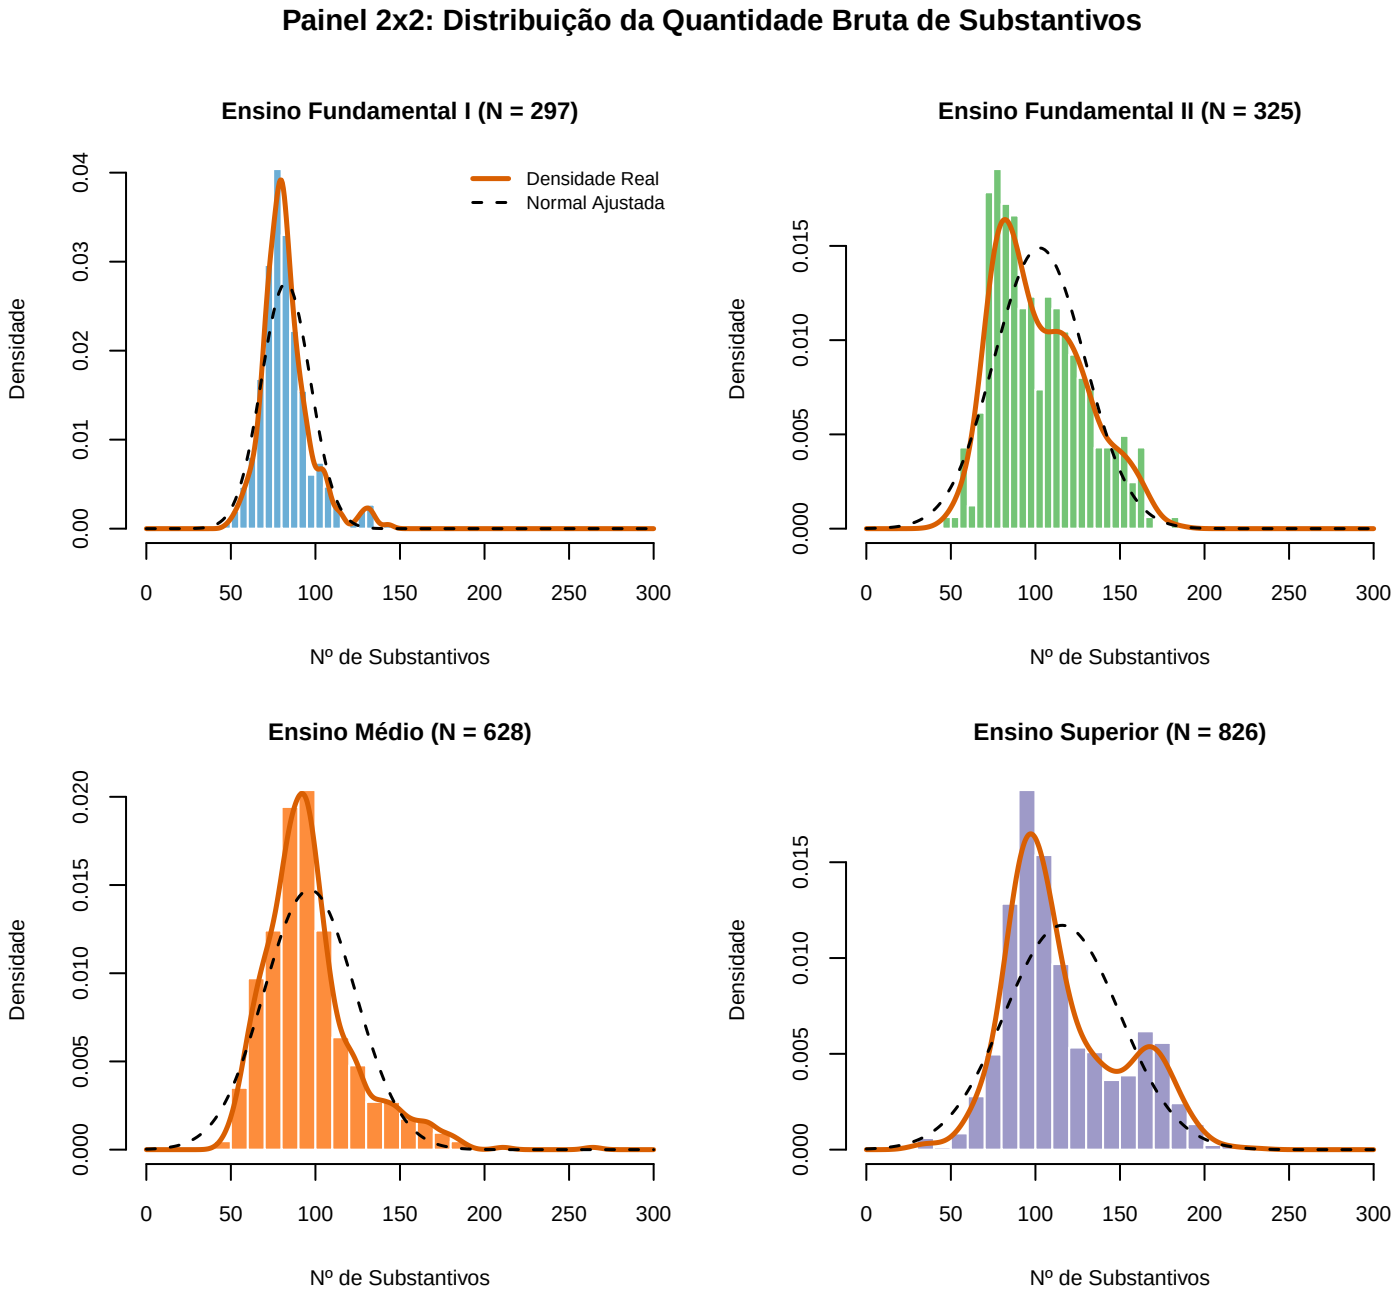
3 Distribuição da Feature por Nível de Ensino (Painel 2x2)

Apresentamos o painel 2×2 gerado estritamente com `par(mfrow = c(2, 2))` e `hist(freq = FALSE)` para os 4 níveis educacionais.

3.1 Razão Nominal (`razao_nominal`)



3.2 Quantidade Absoluta de Substantivos (`substantivos_qtd`)



4 Comparação Fundamental: Ensino Médio vs. Outros Níveis

Verificamos se **existe diferença estatisticamente significativa na Razão Nominal dos textos de Ensino Médio quando comparados com Ensino Fundamental I, Fundamental II e Ensino Superior**.

4.1 Teste Global de Kruskal-Wallis

Table 2: Teste Global de Kruskal-Wallis para a Razão Nominal entre Níveis

Variável	Estatística Chi²	Graus de Liberdade	p-valor	Significância Global
Razão Nominal	275.1382	3	2.387e-59	Altamente Significativo (p < 0.001)
Quantidade de Substantivos	350.9500	3	9.289e-76	Altamente Significativo (p < 0.001)

O teste de Kruskal-Wallis confirma variações intergrupos altamente significativas ($\chi^2 = 275,14$, $p = 2,39 \times 10^{-59}$).

4.2 Comparações Pareadas do Ensino Médio

Aplicamos o **Teste U de Wilcoxon / Mann-Whitney** com correção de Bonferroni e cálculo do tamanho de efeito (*Cohen's d*).

4.2.1 Contrastes Pareados na Razão Nominal (`razao_nominal`)

Table 3: Comparações Pareadas: Ensino Médio vs. Demais Níveis (Razão Nominal)

	Comparação	Média Médio	Média Grupo	Diferença Médias	Estatística W	p-adj (Bonferroni)	Cohen d	Decisão (alpha=0.05)
W...1	Ensino Médio vs. Ensino Fundamental I	1.8641	1.3822	+0.4820	150500	5.82e-51	+0.902	Rejeita H0 (Diferença Sig.)
W...2	Ensino Médio vs. Ensino Fundamental II	1.8641	1.7050	+0.1591	118463	1.38e-04	+0.290	Rejeita H0 (Diferença Sig.)
W...3	Ensino Médio vs. Ensino Superior	1.8641	1.8723	-0.0081	252928	1.00e+00	-0.014	Não Rejeita H0 (Sem Diferença)

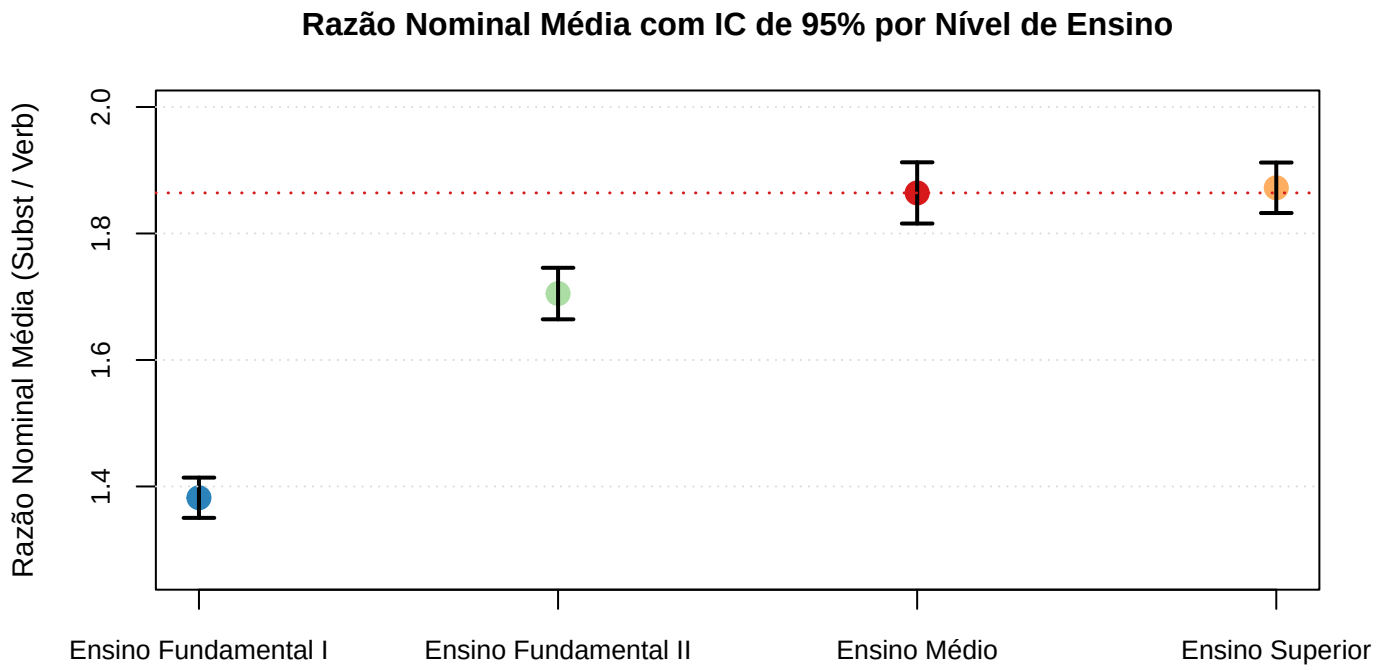
4.2.2 Contrastes Pareados na Quantidade Absoluta (`substantivos_qtd`)

Table 4: Comparações Pareadas: Ensino Médio vs. Demais Níveis (Quantidade de Substantivos)

	Comparação	Média Médio	Média Grupo	Diferença Médias	Estatística W	p-adj (Bonferroni)	Cohen d	Decisão (alpha=0.05)
W...1	Ensino Médio vs. Ensino Fundamental I	96.61	82.55	+14.07	126637	4.12e-18	+0.592	Rejeita H0 (Diferença Sig.)
W...2	Ensino Médio vs. Ensino Fundamental II	96.61	102.41	-5.79	89210	4.30e-03	-0.215	Rejeita H0 (Diferença Sig.)
W...3	Ensino Médio vs. Ensino Superior	96.61	115.82	-19.21	166703	4.57e-31	-0.615	Rejeita H0 (Diferença Sig.)

4.3 Gráfico de Médias com Intervalos de Confiança (95%)

A Figura 2 ilustra as médias da Razão Nominal com intervalos de confiança de 95% para cada nível educacional. A linha tracejada em vermelho destaca a média do Ensino Médio $(1,86)$.



5 Conclusões e Implicações para o Modelo Classificador

A análise da Razão Nominal revelou um **nítido gradiente de condensação informacional**:

1. **Ensino Fundamental I** $(1,38)$**:**
   Textos com forte predomínio de verbos de ação e narrativa, gerando uma razão substantivo/verbo substancialmente menor. A comparação com o Ensino Médio revela uma **diferença massiva** ($p = 5,82 \times 10^{-51}$, **Cohen's** $d = +0,90$).
2. **Ensino Fundamental II** $(1,71)$**:**
   Fase de transição textual. Embora comece a introduzir termos conceituais, ainda preserva maior dinâmica verbal que o Ensino Médio. A diferença para o Ensino Médio é **altamente significativa** ($p = 1,38 \times 10^{-4}$, **Cohen's** $d = +0,29$), fornecendo o separador que faltava nos modelos anteriores.
3. **Ensino Médio** $(1,86)$ **e Ensino Superior** $(1,87)$**:**
   Ambos atingem o platô de estilo nominal maduro, com quase o dobro de substantivos em relação a verbos ($p = 1,00$, sem diferença significativa entre si). Essa invariância entre Médio e Superior é benéfica, pois ancora a classe do Ensino Médio e delega a separação do Superior às features de fórmulas e metadiscurso.

Nível Comparado	Decisão Estatística	Tamanho de Efeito	Utilidade no Classificador ALFA-Gen
Médio vs. Fund. I	**Diferença Massiva**	Alto $(+0,90)$	Separação categórica de estilo narrativo vs. expositivo.
Médio vs. Fund. II	**Diferença Significativa**	Moderado $(+0,29)$	**Desempata o Fundamental II frente ao Ensino Médio!**

Nível Comparado	Decisão Estatística	Tamanho de Efeito	Utilidade no Classificador ALFA-Gen
Médio vs. Superior	**Sem Diferença**	Inexpressivo $(-0,01)$	Consolida o patamar de maturidade nominal compartilhada.

A Apêndice: Arquitetura Modular e Códigos das Funções

- `extrair_novas_features.py`: Extração das classes gramaticais `NOUN` e `VERB`/`AUX` via spaCy em lote sobre os 2.076 arquivos.
- `R/funcoes_estatistica.R`: Rotinas modulares de análise descritiva, teste de Kruskal-Wallis e contrastes de Wilcoxon com correção de Bonferroni.
- `R/funcoes_tabelas.R`: Renderização padronizada de tabelas LaTeX via `knitr::kable`.
- `R/funcoes_graficos.R`: Painéis gráficos 2×2 e gráficos de médias com IC de 95%.