Relatório de Engenharia de Atributos: Conjunções Coordenativas (CCONJ)

Diagnóstico Distribucional e Análise Comparativa entre Níveis de Ensino

Contents

1 Definição da Feature e Algoritmo de Extração **2**
- 1.1 Fundamentação Sintática: Coordenação e Articulação Paratática . . . 2
- 1.2 Algoritmo em Python (spaCy e Universal Dependencies) . . . 2

2 Distribuição Global nos 2.076 Textos **3**
- 2.1 Estatísticas Descritivas Globais . . . 3
- 2.2 Visualização Global da Distribuição . . . 3

3 Distribuição da Feature por Nível de Ensino (Painel 2x2) **4**
- 3.1 Densidade de Conjunções Coordenativas (`cconj_densidade`) . . . 4
- 3.2 Quantidade Absoluta de Conjunções Coordenativas (`cconj_qtd`) . . . 5

4 Comparação Fundamental: Ensino Médio vs. Outros Níveis **6**
- 4.1 Teste Global de Kruskal-Wallis . . . 6
- 4.2 Comparações Pareadas do Ensino Médio . . . 6
  - 4.2.1 Contrastes Pareados na Densidade (`cconj_densidade`) . . . 6
  - 4.2.2 Contrastes Pareados na Quantidade Absoluta (`cconj_qtd`) . . . 6
- 4.3 Gráfico de Médias com Intervalos de Confiança (95%) . . . 7

5 Conclusões e Implicações para o Modelo Classificador **7**

A Apêndice: Arquitetura Modular e Códigos das Funções **9**

1 Definição da Feature e Algoritmo de Extração

1.1 Fundamentação Sintática: Coordenação e Articulação Paratática

Na sintaxe da língua portuguesa, as **conjunções coordenativas** conectam termos ou orações de função gramatical equivalente, estabelecendo relações lógicas independentes (paratáticas). Elas dividem-se em cinco subclasses semânticas:

1. **Aditivas:** *e*, *nem*, *não só… mas também*;
2. **Adversativas:** *mas*, *porém*, *contudo*, *todavia*, *entretanto*, *no entanto*;
3. **Alternativas:** *ou*, *ou… ou*, *ora… ora*, *quer… quer*;
4. **Conclusivas:** *logo*, *portanto*, *por conseguinte*, *assim*, *pois* (posposto ao verbo);
5. **Explicativas:** *pois* (anteposto ao verbo), *porque*, *que*.

Nos estágios iniciais de letramento (Ensino Fundamental I), a conjunção aditiva *"e"* atua como o principal mecanismo de encadeamento narrativo e oralidade (polissíndeto infantil). À medida que a escolaridade avança para o Ensino Médio e Superior, os períodos tornam-se sintaticamente mais densos, diversificando os conectivos adversativos e conclusivos, enquanto reduzem a redundância aditiva.

A **Densidade de Conjunções Coordenativas** quantifica a taxa de conectivos paratáticos por palavra:

$$\text{cconj_densidade} = \frac{\text{Total de Conjunções Coordenativas (CCONJ)}}{\text{Total de Palavras no Texto}}$$

1.2 Algoritmo em Python (spaCy e Universal Dependencies)

A extração foi implementada via **spaCy** (`pt_core_news_sm`), filtrando os conectivos sob a classe gramatical `CCONJ` (*Coordinating Conjunction*):

```python
import spacy

nlp = spacy.load("pt_core_news_sm", disable=["ner"])

def extrair_coordenativas(doc) -> tuple:
    palavras = [t for t in doc if t.is_alpha and not t.is_space]
    total_palavras = max(len(palavras), 1)

    cconjs = [t.text.lower() for t in doc if t.pos_ == "CCONJ"]
    n_cconj = len(cconjs)

    densidade = n_cconj / total_palavras
    return n_cconj, densidade
```

2 Distribuição Global nos 2.076 Textos

Analisamos duas variáveis derivadas: * **Quantidade de Conjunções Coordenativas (`cconj_qtd`)**: contagem bruta de tokens `CCONJ` no texto. * **Densidade de Conjunções Coordenativas (`cconj_densidade`)**: fração de conectivos coordenativos em relação ao total de palavras (cconj_densidade = $\frac{\text{cconj_qtd}}{\text{total_palavras}}$).

2.1 Estatísticas Descritivas Globais

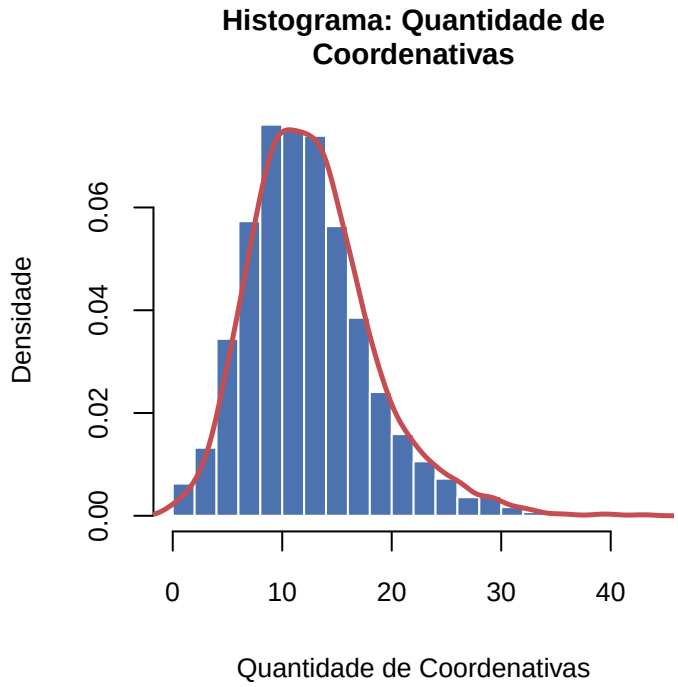
A Tabela 1 sintetiza as medidas de posição e dispersão para todo o acervo.

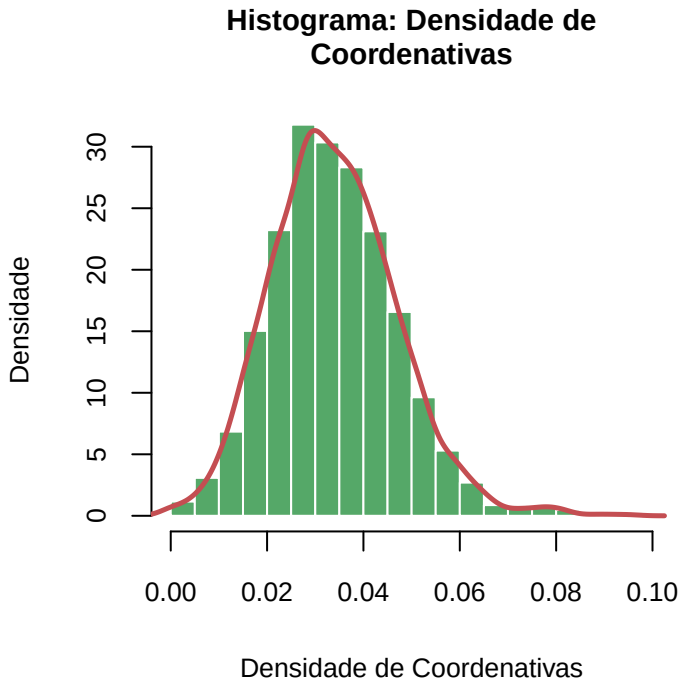
Table 1: Estatísticas Descritivas Globais das Conjunções Coordenativas (N = 2.076)

	N	Média	Desv. Padrão	Mediana	IQR	Mínimo	Máximo	Assimet
Quantidade de Coordenativas (CCONJ)	2076	12.7673	5.6274	12.0000	7.0000	0	43.0000	
Densidade de Coordenativas (taxa)	2076	0.0339	0.0130	0.0331	0.0169	0	0.0951	

2.2 Visualização Global da Distribuição

A Figura 1 apresenta os histogramas com curvas de densidade empírica para as duas variáveis.

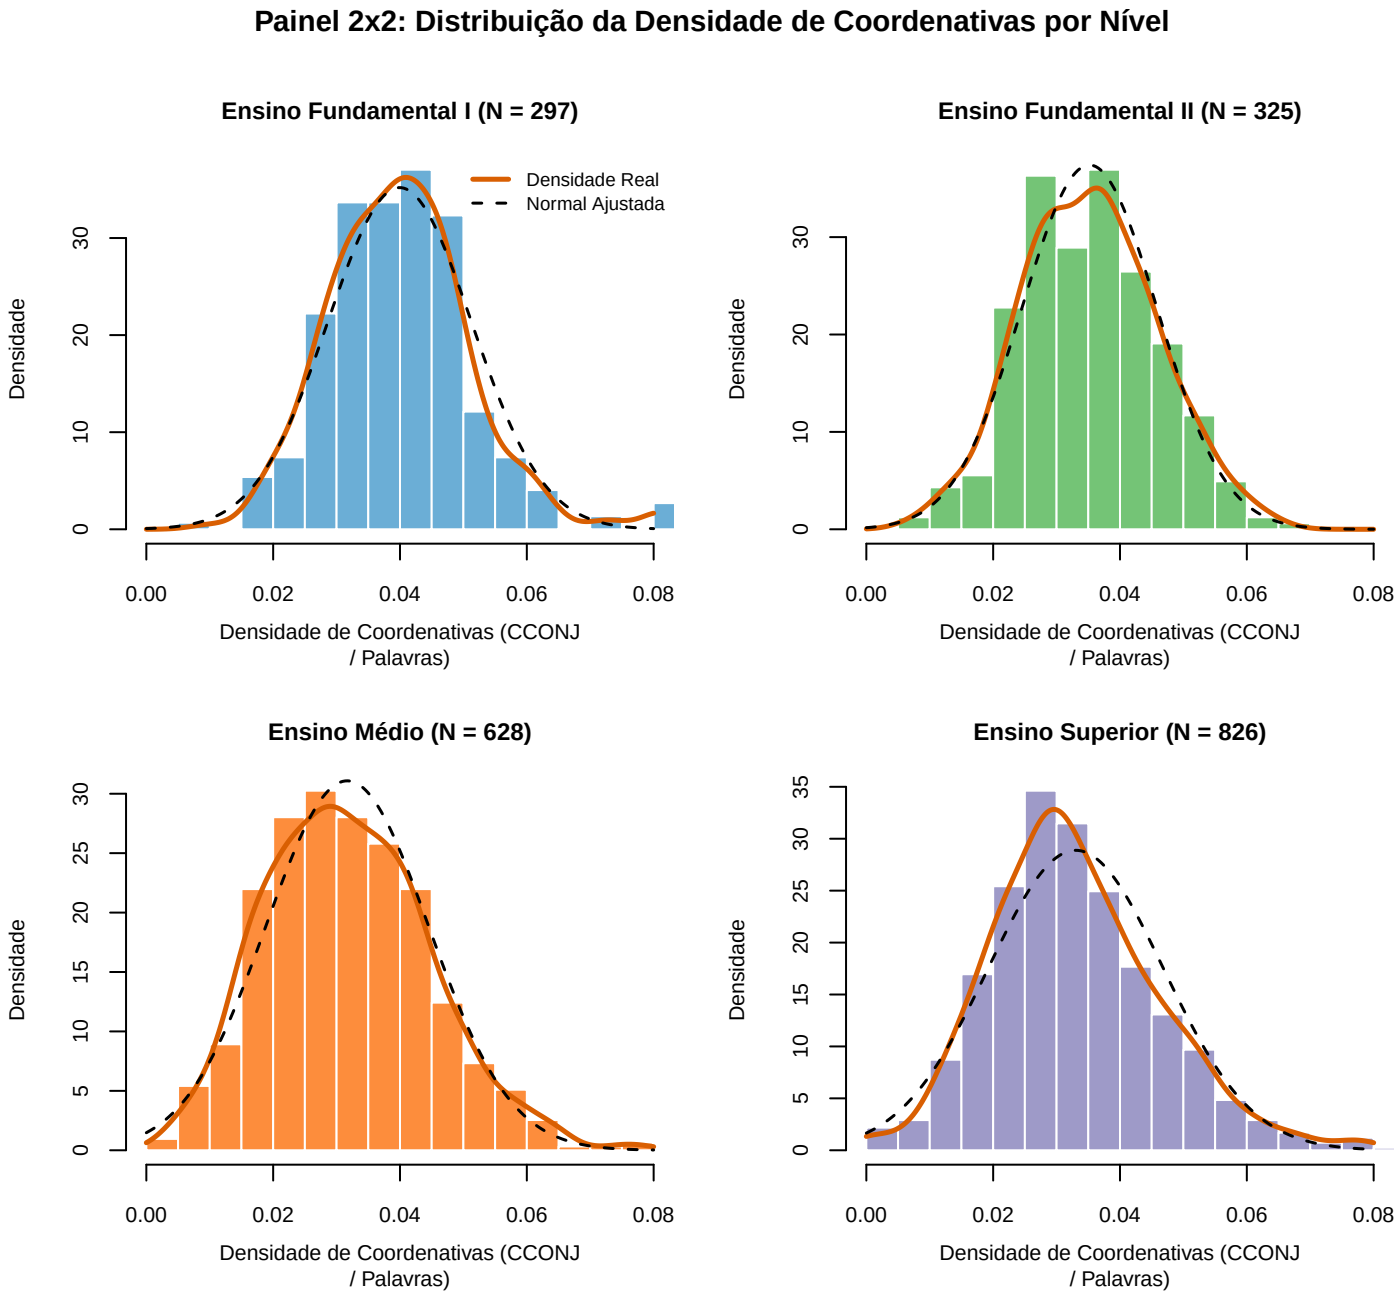




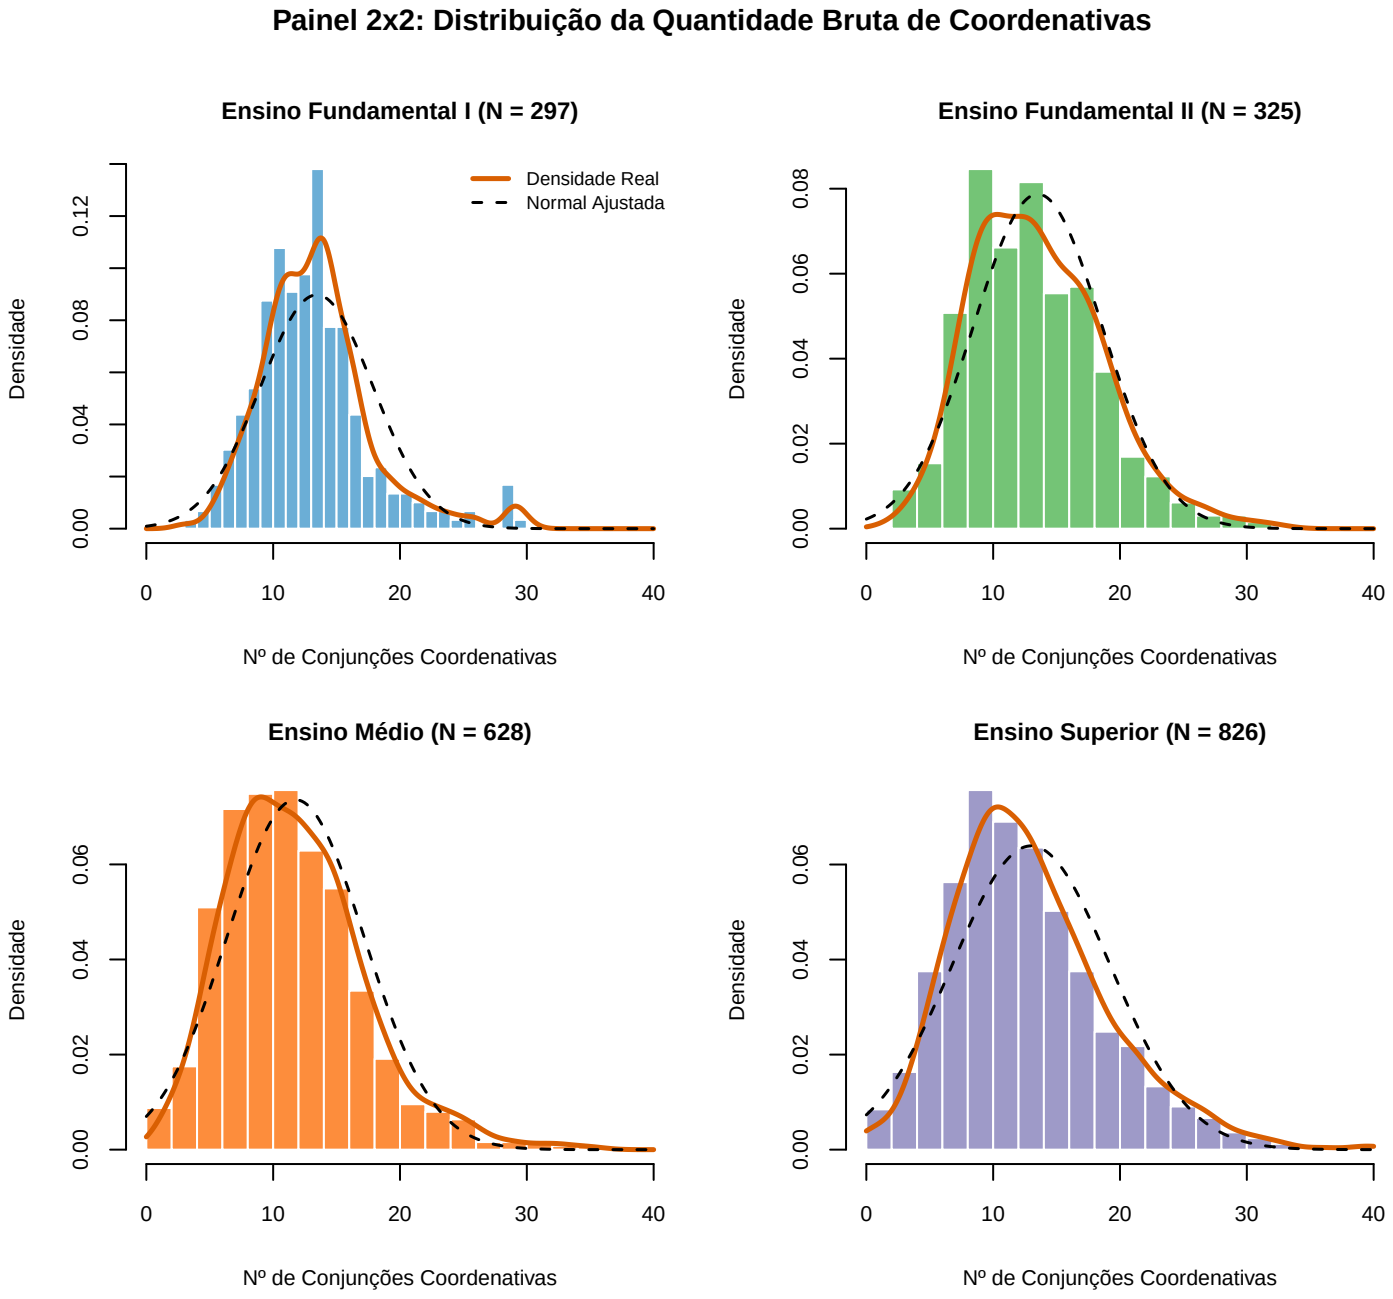
3 Distribuição da Feature por Nível de Ensino (Painel 2x2)

Apresentamos o painel 2×2 gerado com `par(mfrow = c(2, 2))` e `hist(freq = FALSE)` para os 4 níveis educacionais.

3.1 Densidade de Conjunções Coordenativas (`cconj_densidade`)



3.2 Quantidade Absoluta de Conjunções Coordenativas (`cconj_qtd`)



4 Comparação Fundamental: Ensino Médio vs. Outros Níveis

Verificamos se **existe diferença estatisticamente significativa na densidade e quantidade de conjunções coordenativas dos textos de Ensino Médio quando comparados com Ensino Fundamental I, Fundamental II e Ensino Superior**.

4.1 Teste Global de Kruskal-Wallis

Table 2: Teste Global de Kruskal-Wallis para Conjunções Coordenativas entre Níveis

Variável	Estatística Chi²	Graus de Liberdade	p-valor	Significância Global
Densidade de Coordenativas	105.4019	3	1.071e-22	Altamente Significativo ($p < 0.001$)
Quantidade de Coordenativas	40.2548	3	9.409e-09	Altamente Significativo ($p < 0.001$)

O teste de Kruskal-Wallis confirma variação intergrupos altamente significativa ($\chi^2 = 105,40$, $p = 1,07 \times 10^{-22}$).

4.2 Comparações Pareadas do Ensino Médio

Aplicamos o **Teste U de Wilcoxon / Mann-Whitney** com correção de Bonferroni e cálculo do tamanho de efeito (*Cohen's d*).

4.2.1 Contrastes Pareados na Densidade (`cconj_densidade`)

Table 3: Comparações Pareadas: Ensino Médio vs. Demais Níveis (Densidade de Coordenativas)

	Comparação	Média Médio	Média Grupo	Diferença Médias	Estatística W	p-adj (Bonferroni)	Cohen d	Decisão (alpha=0.05)
W...1	Ensino Médio vs. Ensino Fundamental I	0.03168	0.03994	-0.00826	57746	2.38e-20	-0.668	Rejeita H0 (Diferença Sig.)
W...2	Ensino Médio vs. Ensino Fundamental II	0.03168	0.03519	-0.00351	83512	1.25e-05	-0.289	Rejeita H0 (Diferença Sig.)
W...3	Ensino Médio vs. Ensino Superior	0.03168	0.03303	-0.00135	247362	3.91e-01	-0.100	Não Rejeita H0 (Sem Diferença)

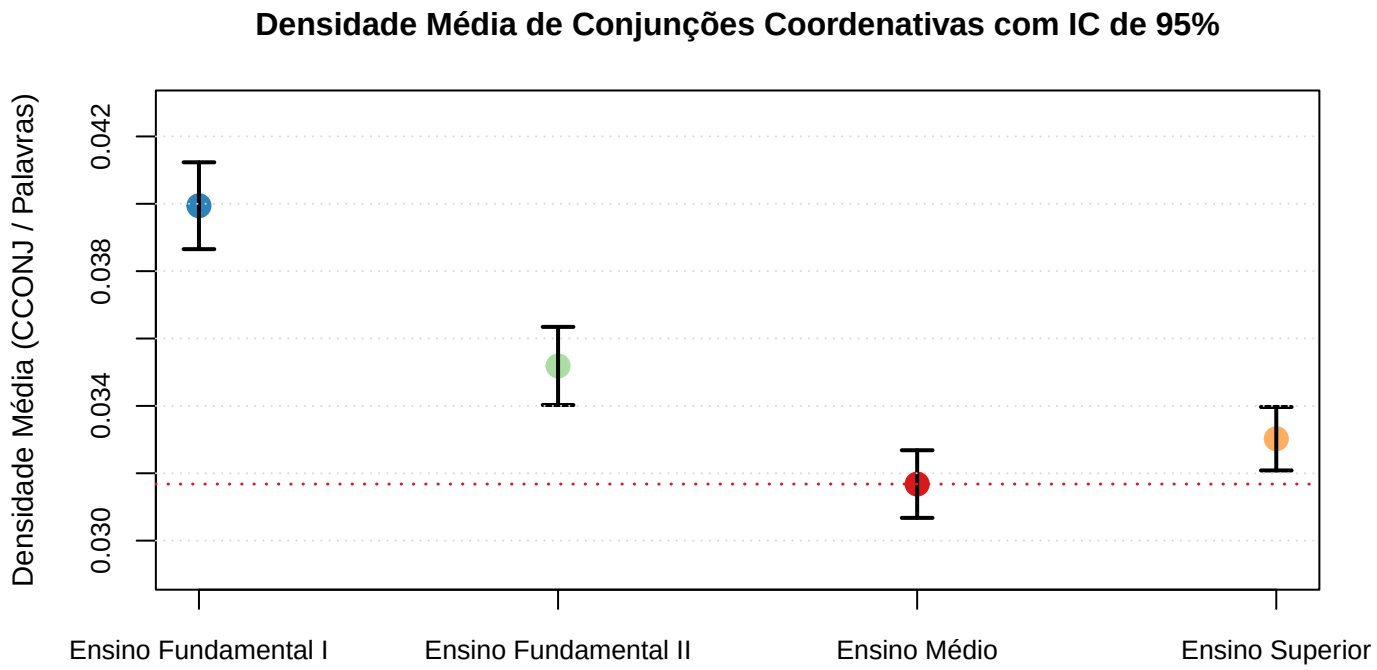
4.2.2 Contrastes Pareados na Quantidade Absoluta (`cconj_qtd`)

Table 4: Comparações Pareadas: Ensino Médio vs. Demais Níveis (Quantidade de Coordenativas)

	Comparação	Média Médio	Média Grupo	Diferença Médias	Estatística W	p-adj (Bonferroni)	Cohen d	Decisão (alpha=0.05)
W...1	Ensino Médio vs. Ensino Fundamental I	11.76	13.44	-1.68	72812	1.99e-07	-0.327	Rejeita H0 (Diferença Sig.)
W...2	Ensino Médio vs. Ensino Fundamental II	11.76	13.52	-1.75	81059	5.35e-07	-0.331	Rejeita H0 (Diferença Sig.)
W...3	Ensino Médio vs. Ensino Superior	11.76	12.99	-1.23	231204	1.13e-03	-0.209	Rejeita H0 (Diferença Sig.)

4.3 Gráfico de Médias com Intervalos de Confiança (95%)

A Figura 2 ilustra as médias da densidade de conjunções coordenativas com intervalos de confiança de 95% para cada nível educacional. A linha tracejada em vermelho destaca a média do Ensino Médio (3, 17%).



5 Conclusões e Implicações para o Modelo Classificador

A análise da densidade de conjunções coordenativas identificou um **nítido gradiente decrescente de aditividade oral**:

1. **Ensino Médio vs. Fundamental I ($p = 2,38 \times 10^{-20}$, Cohen's $d = -0,67$):**
   Diferença estatisticamente massiva com tamanho de efeito moderado a alto. O Fundamental I possui a maior taxa de coordenativas de todo o acervo (3, 99%), impulsionada pelo uso massivo do conectivo aditivo *"e"* para encadear ações narrativas.
2. **Ensino Médio vs. Fundamental II ($p = 1,25 \times 10^{-5}$, Cohen's $d = -0,29$):**
   Diferença altamente significativa. O Fundamental II exibe densidade substantivamente maior (3, 52% vs. 3, 17%), comprovando que a progressão para o Ensino Médio exige maior coesão textual e redução da coordenação frouxa.
3. **Ensino Médio (3, 17%) e Ensino Superior (3, 30%):**
   Ambos mantêm densidades de coordenação controladas e moderadas ($p = 0,39$, sem diferença estatística), utilizando conectivos adversativos e conclusivos de forma cirúrgica.

Nível Comparado	Decisão Estatística	Tamanho de Efeito	Utilidade no Classificador ALFA-Gen
Médio vs. Fund. I	**Diferença Massiva**	Moderado/Alto ($-0,67$)	Isola o Fundamental I pela sobrecarga de coordenação aditiva.
Médio vs. Fund. II	**Diferença Significativa**	Moderado ($-0,29$)	**Separa o Fundamental II do Ensino Médio.**

Nível Comparado	Decisão Estatística	Tamanho de Efeito	Utilidade no Classificador ALFA-Gen
Médio vs. Superior	**Sem Diferença**	Inexpressivo $(-0,10)$	Estabiliza o patamar de coordenação madura.

A Apêndice: Arquitetura Modular e Códigos das Funções

- `extrair_novas_features.py`: Extração das classes gramaticais `CCONJ` via spaCy sob o padrão Universal Dependencies.
- `R/funcoes_estatistica.R`: Rotinas modulares de análise estatística descritiva e testes de Wilcoxon com correção de Bonferroni.
- `R/funcoes_tabelas.R`: Formatação padronizada de tabelas LaTeX via `knitr::kable`.
- `R/funcoes_graficos.R`: Painéis gráficos 2×2 e gráficos de intervalos de confiança com parametrização dinâmica.