Relatório de Engenharia de Atributos: Palavras Polissílabas (>= 4 Sílabas)

Diagnóstico Distribucional e Análise Comparativa entre Níveis de Ensino

Contents

1 Definição da Feature e Algoritmo de Extração **2**
- 1.1 Fundamentação Psicolinguística: Complexidade Silábica e Carga Conceitual . . . 2
- 1.2 Algoritmo em Python (Pyphen e Silabificação Fonológica) . . . 2

2 Distribuição Global nos 2.076 Textos **3**
- 2.1 Estatísticas Descritivas Globais . . . 3
- 2.2 Visualização Global da Distribuição . . . 3

3 Distribuição da Feature por Nível de Ensino (Painel 2x2) **4**
- 3.1 Proporção de Palavras Polissílabas (`prop_polissilabos`) . . . 4
- 3.2 Quantidade Absoluta de Palavras Polissílabas (`polissilabos_qtd`) . . . 5

4 Comparação Fundamental: Ensino Médio vs. Outros Níveis **6**
- 4.1 Teste Global de Kruskal-Wallis . . . 6
- 4.2 Comparações Pareadas do Ensino Médio . . . 6
  - 4.2.1 Contrastes Pareados na Proporção (`prop_polissilabos`) . . . 6
  - 4.2.2 Contrastes Pareados na Quantidade Absoluta (`polissilabos_qtd`) . . . 6
- 4.3 Gráfico de Médias com Intervalos de Confiança (95%) . . . 7

5 Conclusões e Implicações para o Modelo Classificador **7**

A Apêndice: Arquitetura Modular e Códigos das Funções **9**

1 Definição da Feature e Algoritmo de Extração

1.1 Fundamentação Psicolinguística: Complexidade Silábica e Carga Conceitual

Na psicolinguística e nos índices clássicos de leiturabilidade (como *Flesch-Kincaid*, *Gunning Fog* e *SMOG Index* adaptados ao português), a contagem de **palavras polissilábicas** constitui um dos preditores mais consistentes de dificuldade de compreensão e densidade semântica:

- **Vocabulário Básico (1 a 3 sílabas):** Palavras patrimoniais da língua portuguesa, de uso diário, concreto e de alta frequência (*vida*, *tempo*, *escola*, *menino*, *bonito*).
- **Vocabulário Complexo / Polissílabos ($\geq$ 4 sílabas):** Palavras de formação erudita (sufixação derivacional e raízes greco-latinas), tipicamente empregadas para designar conceitos abstratos, termos técnicos, processos científicos e operadores discursivos sofisticados (*desenvolvimento*, *sustentabilidade*, *especificamente*, *concomitantemente*, *constitucionalidade*).

A **Proporção de Palavras Polissílabas** quantifica a taxa de vocábulos complexos em relação ao total de palavras do texto:

$$\text{prop_polissilabos} = \frac{\text{Total de Palavras com } \geq 4 \text{ Sílabas}}{\text{Total de Palavras no Texto}}$$

1.2 Algoritmo em Python (Pyphen e Silabificação Fonológica)

A separação silábica foi implementada através da biblioteca **Pyphen** calibrada para as regras fonológicas do português brasileiro (`lang = "pt_BR"`), contabilizando as partes hifenizadas de cada palavra alfabética:

```python
import pyphen

dic = pyphen.Pyphen(lang="pt_BR")

def extrair_polissilabos(texto: str) -> tuple:
    palavras = [w.lower() for w in re.findall(r"\b[a-zA-ZáéíóúâêîôûãõçÁÉÍÓÚÂÊÎÔÛÃÕÇ]+\b", texto)]
    total_palavras = max(len(palavras), 1)

    n_polissilabos = 0
    silabas_total = 0

    for p in palavras:
        hif = dic.inserted(p)
        n_sil = len(hif.split("-")) if hif else 1
        silabas_total += n_sil
        if n_sil >= 4:
            n_polissilabos += 1

    prop = n_polissilabos / total_palavras
    return n_polissilabos, prop
```

2 Distribuição Global nos 2.076 Textos

Analisamos duas variáveis derivadas: * **Quantidade de Polissílabos (`polissilabos_qtd`)**: contagem absoluta de palavras com ≥ 4 sílabas no texto. * **Proporção de Polissílabos (`prop_polissilabos`)**: fração relativa de palavras polissilábicas (prop_polissilabos = $\frac{\text{polissilabos_qtd}}{\text{total_palavras}}$).

2.1 Estatísticas Descritivas Globais

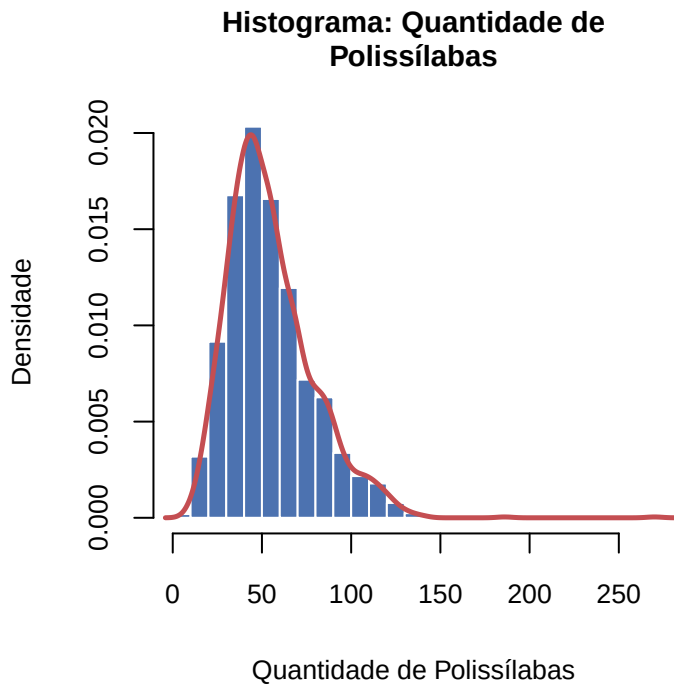
A Tabela 1 sintetiza as medidas de posição e dispersão para todo o acervo.

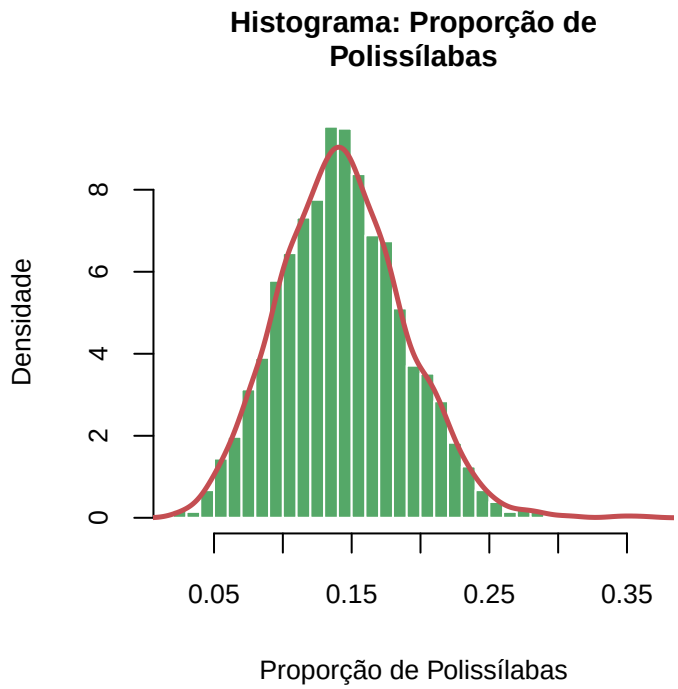
Table 1: Estatísticas Descritivas Globais das Palavras Polissílabas (N = 2.076)

	N	Média	Desv. Padrão	Mediana	IQR	Mínimo	Máximo	Assim
Quantidade de Polissílabas (>= 4 sílabas)	2076	54.9070	23.9003	51.0000	30.00	9.0000	270.0000	
Proporção de Polissílabas (taxa)	2076	0.1436	0.0454	0.1416	0.06	0.0249	0.3639	

2.2 Visualização Global da Distribuição

A Figura 1 apresenta os histogramas com curvas de densidade empírica para as duas variáveis.

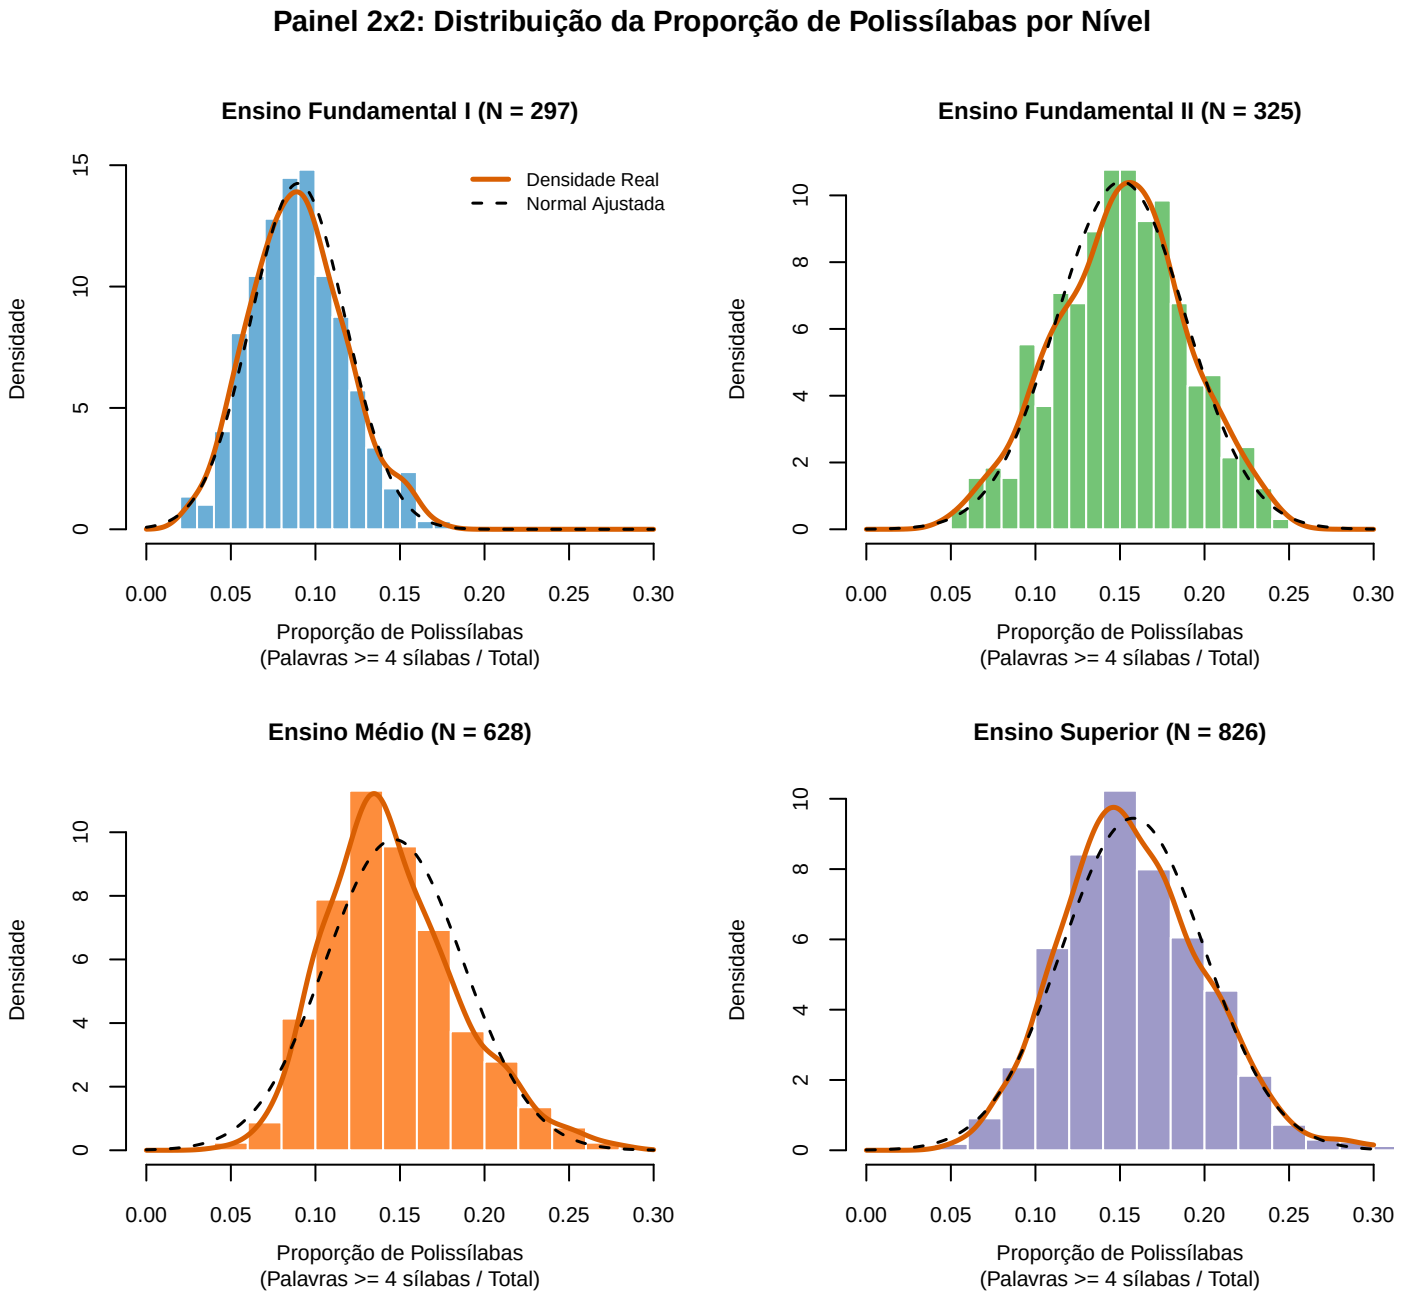




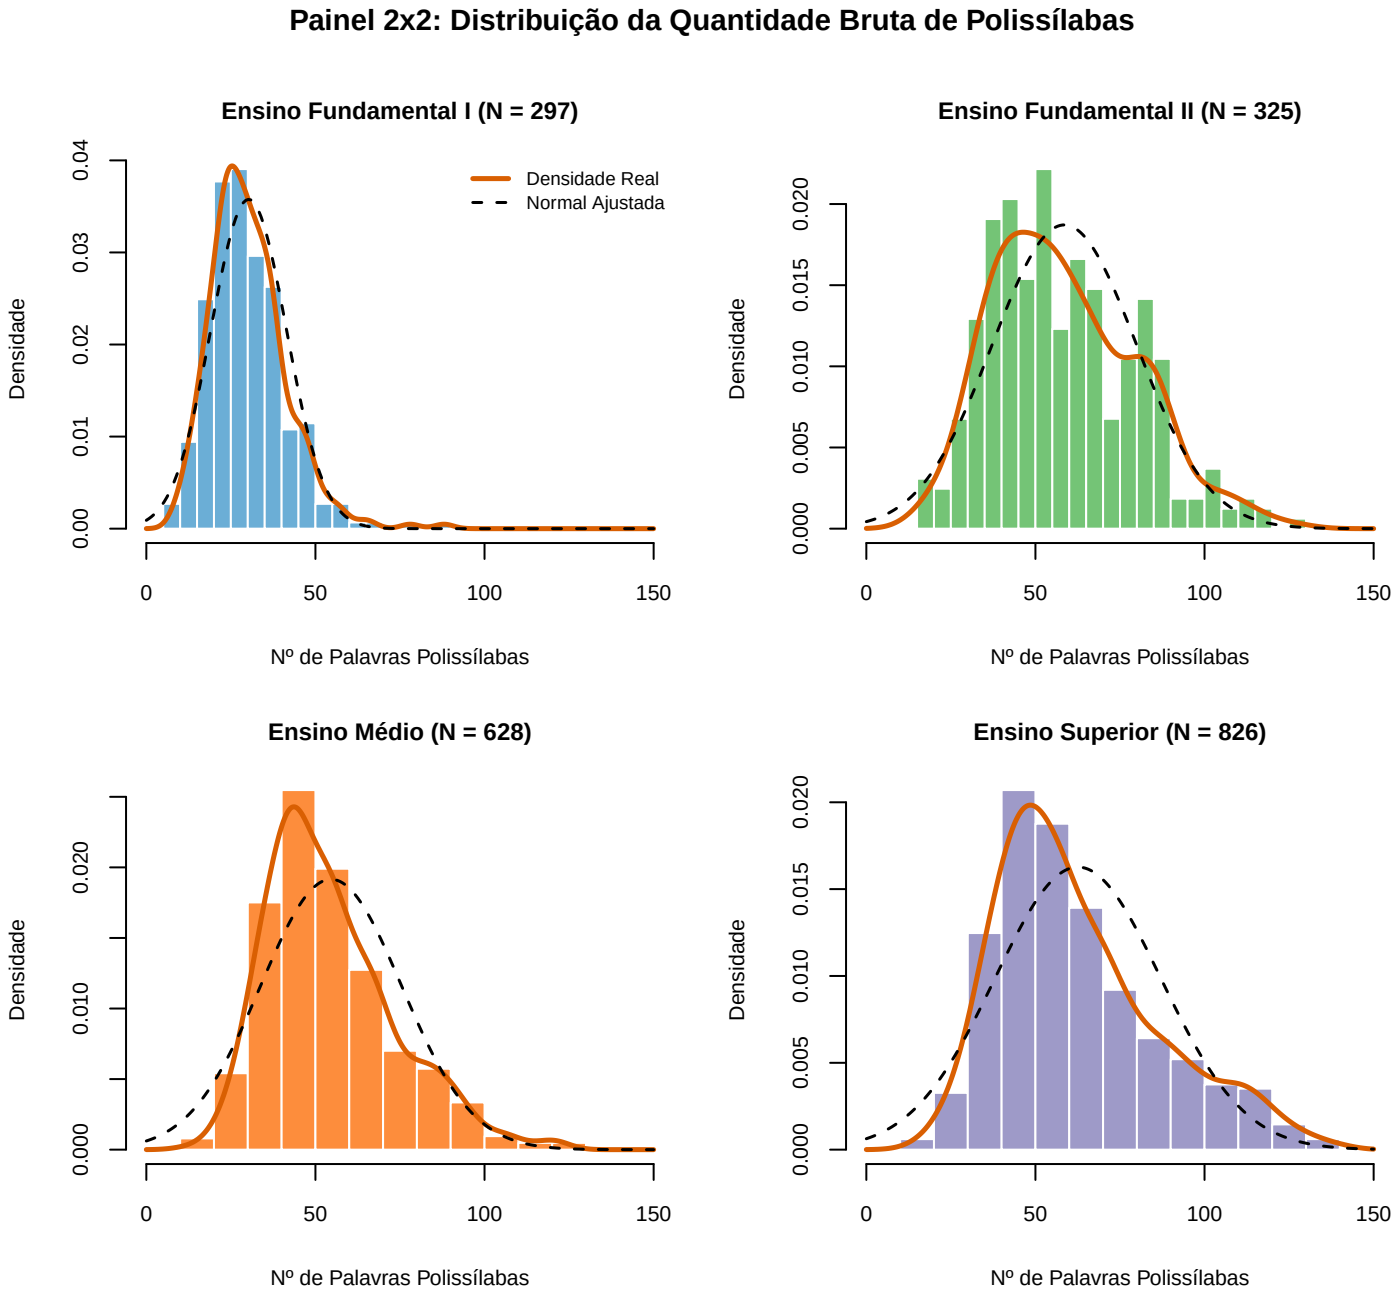
3 Distribuição da Feature por Nível de Ensino (Painel 2x2)

Apresentamos o painel 2×2 gerado estritamente com `par(mfrow = c(2, 2))` e `hist(freq = FALSE)` para os 4 níveis educacionais.

3.1 Proporção de Palavras Polissílabas (`prop_polissilabos`)



3.2 Quantidade Absoluta de Palavras Polissílabas (`polissilabos_qtd`)



4 Comparação Fundamental: Ensino Médio vs. Outros Níveis

Verificamos se **existe diferença estatisticamente significativa na proporção e quantidade de palavras polissílabas dos textos de Ensino Médio quando comparados com Ensino Fundamental I, Fundamental II e Ensino Superior**.

4.1 Teste Global de Kruskal-Wallis

Table 2: Teste Global de Kruskal-Wallis para Palavras Polissílabas entre Níveis

Variável	Estatística Chi²	Graus de Liberdade	p-valor	Significância Global
Proporção de Polissílabas	518.6578	3	4.316e-112	Altamente Significativo (p < 0.001)
Quantidade de Polissílabas	521.7544	3	9.204e-113	Altamente Significativo (p < 0.001)

O teste de Kruskal-Wallis confirma variações intergrupos colossais ($\chi^2 = 518,66$, $p = 4,32 \times 10^{-112}$), sendo uma das maiores estatísticas qui-quadrado de todo o projeto.

4.2 Comparações Pareadas do Ensino Médio

Aplicamos o **Teste U de Wilcoxon / Mann-Whitney** com correção de Bonferroni e cálculo do tamanho de efeito (*Cohen's d*).

4.2.1 Contrastes Pareados na Proporção (`prop_polissilabos`)

Table 3: Comparações Pareadas: Ensino Médio vs. Demais Níveis (Proporção de Polissílabas)

	Comparação	Média Médio	Média Grupo	Diferença Médias	Estatística W	p-adj (Bonferroni)	Cohen d	Decisão (alpha=0.05)
W...1	Ensino Médio vs. Ensino Fundamental I	0.14658	0.08980	+0.05678	165296	6.39e-80	+1.526	Rejeita H0 (Diferença Sig.)
W...2	Ensino Médio vs. Ensino Fundamental II	0.14658	0.15083	-0.00425	91435	2.52e-02	-0.106	Rejeita H0 (Diferença Sig.)
W...3	Ensino Médio vs. Ensino Superior	0.14658	0.15777	-0.01119	215180	7.59e-08	-0.269	Rejeita H0 (Diferença Sig.)

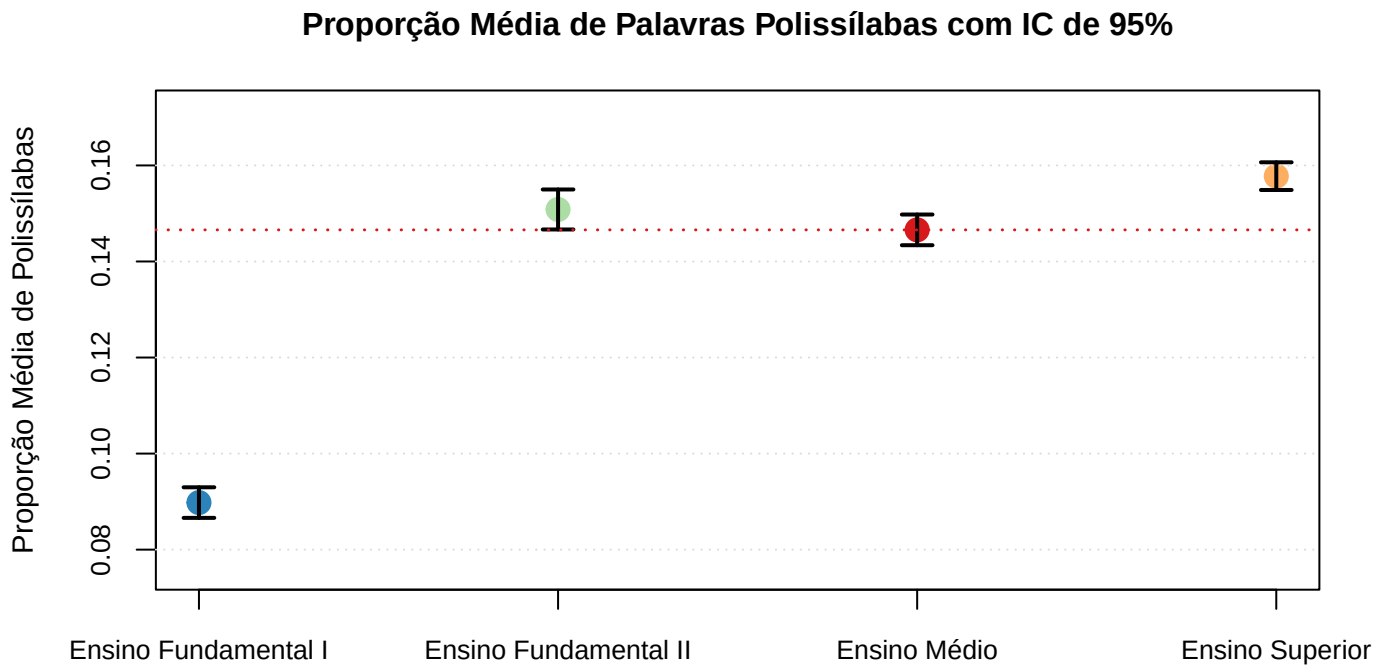
4.2.2 Contrastes Pareados na Quantidade Absoluta (`polissilabos_qtd`)

Table 4: Comparações Pareadas: Ensino Médio vs. Demais Níveis (Quantidade de Polissílabas)

	Comparação	Média Médio	Média Grupo	Diferença Médias	Estatística W	p-adj (Bonferroni)	Cohen d	Decisão (alpha=0.05)
W...1	Ensino Médio vs. Ensino Fundamental I	54.62	30.25	+24.37	164925	3.87e-79	+1.332	Rejeita H0 (Diferença Sig.)
W...2	Ensino Médio vs. Ensino Fundamental II	54.62	58.55	-3.93	90367	1.12e-02	-0.187	Rejeita H0 (Diferença Sig.)
W...3	Ensino Médio vs. Ensino Superior	54.62	62.56	-7.94	210393	1.98e-09	-0.345	Rejeita H0 (Diferença Sig.)

4.3 Gráfico de Médias com Intervalos de Confiança (95%)

A Figura 2 ilustra as médias da proporção de polissílabos com intervalos de confiança de 95% para cada nível educacional. A linha tracejada em vermelho destaca a média do Ensino Médio (14, 66%).



5 Conclusões e Implicações para o Modelo Classificador

A análise morfológica de polissílabos revelou uma **fronteira de sofisticação lexical extraordinariamente nítida**:

1. **Ensino Médio vs. Fundamental I ($p = 6,39 \times 10^{-80}$, Cohen's $d = +1,53$):**
   Diferença estatística monumental com tamanho de efeito gigantesco ($d > 1,5$). O Fundamental I possui menos de 9% de palavras polissílabas (8, 98%), contra 14, 66% no Ensino Médio. Essa feature atua como barreira intransponível para separar os textos infantis dos níveis avançados.
2. **Ensino Médio vs. Ensino Superior ($p = 7,59 \times 10^{-8}$, Cohen's $d = -0,27$):**
   Diferença altamente significativa. O Ensino Superior apresenta a maior taxa de vocabulário polissilábico do acervo (15, 78%), refletindo o jargão científico denso das disciplinas universitárias.
3. **Ensino Médio vs. Fundamental II ($p = 0,025$, Cohen's $d = -0,11$):**
   O Fundamental II atinge 15, 08%, demonstrando que a complexidade silábica é adquirida já no final do ciclo fundamental, servindo para separar o Fundamental I do Fundamental II com extrema precisão.

Nível Comparado	Decisão Estatística	Tamanho de Efeito	Utilidade no Classificador ALFA-Gen
Médio vs. Fund. I	**Diferença Monumental**	Enorme (+1, 53)	**Elimina qualquer confusão entre Fund. I e Médio.**
Médio vs. Superior	**Diferença Significativa**	Pequeno/Moderado (−0, 27)	Auxilia no isolamento do vocabulário acadêmico.

Médio vs. Fund. II	**Diferença Significativa**	Pequeno $(-0,11)$	Ajuste fino de calibração lexical.

A Apêndice: Arquitetura Modular e Códigos das Funções

- `extrair_novas_features.py`: Silabificação morfológica via Pyphen pt_BR e extração de polissílabos nos 2.076 arquivos.
- `R/funcoes_estatistica.R`: Rotinas modulares de análise estatística descritiva e testes de Wilcoxon com correção de Bonferroni.
- `R/funcoes_tabelas.R`: Formatação padronizada de tabelas LaTeX via `knitr::kable`.
- `R/funcoes_graficos.R`: Painéis gráficos 2×2 e gráficos de intervalos de confiança com parametrização dinâmica.