Relatório de Engenharia de Atributos: Densidade de Vírgulas por Sentença

Diagnóstico Distribucional e Análise Comparativa entre Níveis de Ensino

Contents

1 Definição da Feature e Algoritmo de Extração **2**
- 1.1 Fundamentação Sintática: Pontuação Estrutural e Intercalações Frásicas . . . 2
- 1.2 Algoritmo em Python (spaCy e Contagem Estrutural) . . . 2

2 Distribuição Global nos 2.076 Textos **3**
- 2.1 Estatísticas Descritivas Globais . . . 3
- 2.2 Visualização Global da Distribuição . . . 3

3 Distribuição da Feature por Nível de Ensino (Painel 2x2) **4**
- 3.1 Vírgulas por Sentença (`virgulas_por_sentenca`) . . . 4
- 3.2 Quantidade Absoluta de Vírgulas (`virgulas_qtd`) . . . 5

4 Comparação Fundamental: Ensino Médio vs. Outros Níveis **6**
- 4.1 Teste Global de Kruskal-Wallis . . . 6
- 4.2 Comparações Pareadas do Ensino Médio . . . 6
  - 4.2.1 Contrastes Pareados nas Vírgulas por Sentença (`virgulas_por_sentenca`) . . . 6
  - 4.2.2 Contrastes Pareados na Quantidade Absoluta (`virgulas_qtd`) . . . 6
- 4.3 Gráfico de Médias com Intervalos de Confiança (95%) . . . 7

5 Conclusões e Implicações para o Modelo Classificador **7**

A Apêndice: Arquitetura Modular e Códigos das Funções **9**

1 Definição da Feature e Algoritmo de Extração

1.1 Fundamentação Sintática: Pontuação Estrutural e Intercalações Frásicas

Diferentemente dos pontos de exclamação e interrogação (que assinalam expressividade e oralidade), a **vírgula** é um operador sintático de estruturação interna do período. Na gramática normativa da língua portuguesa, o uso da vírgula é estritamente condicionado por regras de sintaxe:

1. **Enumerações e Termos Coordenados Assindéticos:** separação de termos de mesma função sintática sem conectivo;
2. **Apostos e Vocativos:** isolamento obrigatório de núcleos explicativos;
3. **Orações Adjetivas Explicativas:** demarcação de orações introduzidas por pronomes relativos;
4. **Adjuntos Adverbiais Deslocados:** antecipação de circunstâncias de tempo, lugar, causa e modo no início ou meio da oração;
5. **Orações Subordinadas Adverbiais Antepostas:** inversão da ordem direta canônica (Sujeito-Verbo-Objeto).

Nos anos iniciais (Fundamental I), a escrita infantil opera quase exclusivamente na ordem direta linear, gerando textos com pouquíssimas vírgulas. No Ensino Médio, a elaboração textual atinge o ápice de intercalações, apostos e enumerações sintéticas, gerando uma taxa muito elevada de vírgulas por período. No Ensino Superior, a consolidação de períodos hipotáticos integrados reduz a necessidade de intercalações fragmentadas.

A **Densidade de Vírgulas por Sentença** quantifica a média de segmentações sintáticas internas por período:

$$\text{virgulas_por_sentenca} = \frac{\text{Total de Vírgulas no Texto}}{\max(\text{Total de Sentenças no Texto}, 1)}$$

1.2 Algoritmo em Python (spaCy e Contagem Estrutural)

A contagem de vírgulas e a segmentação de sentenças foram realizadas pelo modelo **spaCy** (`pt_core_news_sm`), garantindo limites sentenciais rigorosos via `doc.sents`:

```python
import spacy

nlp = spacy.load("pt_core_news_sm", disable=["ner"])

def extrair_virgulas(texto: str, doc) -> tuple:
    n_virgulas = texto.count(",")
    sentencas = list(doc.sents)
    total_sentencas = max(len(sentencas), 1)

    taxa_por_sentenca = n_virgulas / total_sentencas
    return n_virgulas, total_sentencas, taxa_por_sentenca
```

2 Distribuição Global nos 2.076 Textos

Analisamos duas variáveis derivadas: * **Quantidade de Vírgulas (`virgulas_qtd`)**: contagem absoluta de vírgulas no texto. * **Vírgulas por Sentença (`virgulas_por_sentenca`)**: média de vírgulas por período frásico (virgulas_por_sentenca = $\frac{\text{virgulas_qtd}}{\text{total_sentencas}}$).

2.1 Estatísticas Descritivas Globais

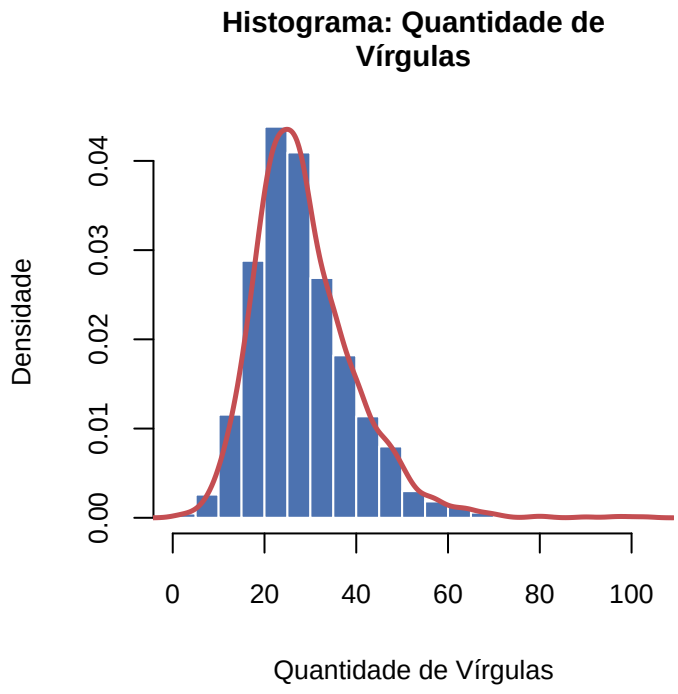
A Tabela 1 sintetiza as medidas de posição e dispersão para todo o acervo.

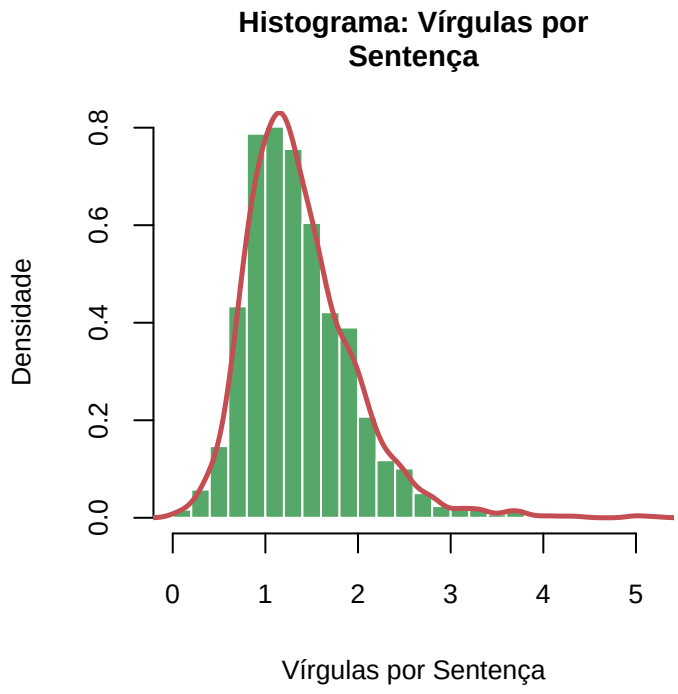
Table 1: Estatísticas Descritivas Globais das Vírgulas por Sentença (N = 2.076)

	N	Média	Desv. Padrão	Mediana	IQR	Mínimo	Máximo	Assimetria (Skew)
Quantidade Total de Vírgulas	2076	28.6927	11.0289	27.0000	14.0	1.000	103.0	1.2025
Vírgulas por Sentença (taxa)	2076	1.3712	0.5864	1.2778	0.7	0.037	5.2	1.3381

2.2 Visualização Global da Distribuição

A Figura 1 apresenta os histogramas com curvas de densidade empírica para as duas variáveis.

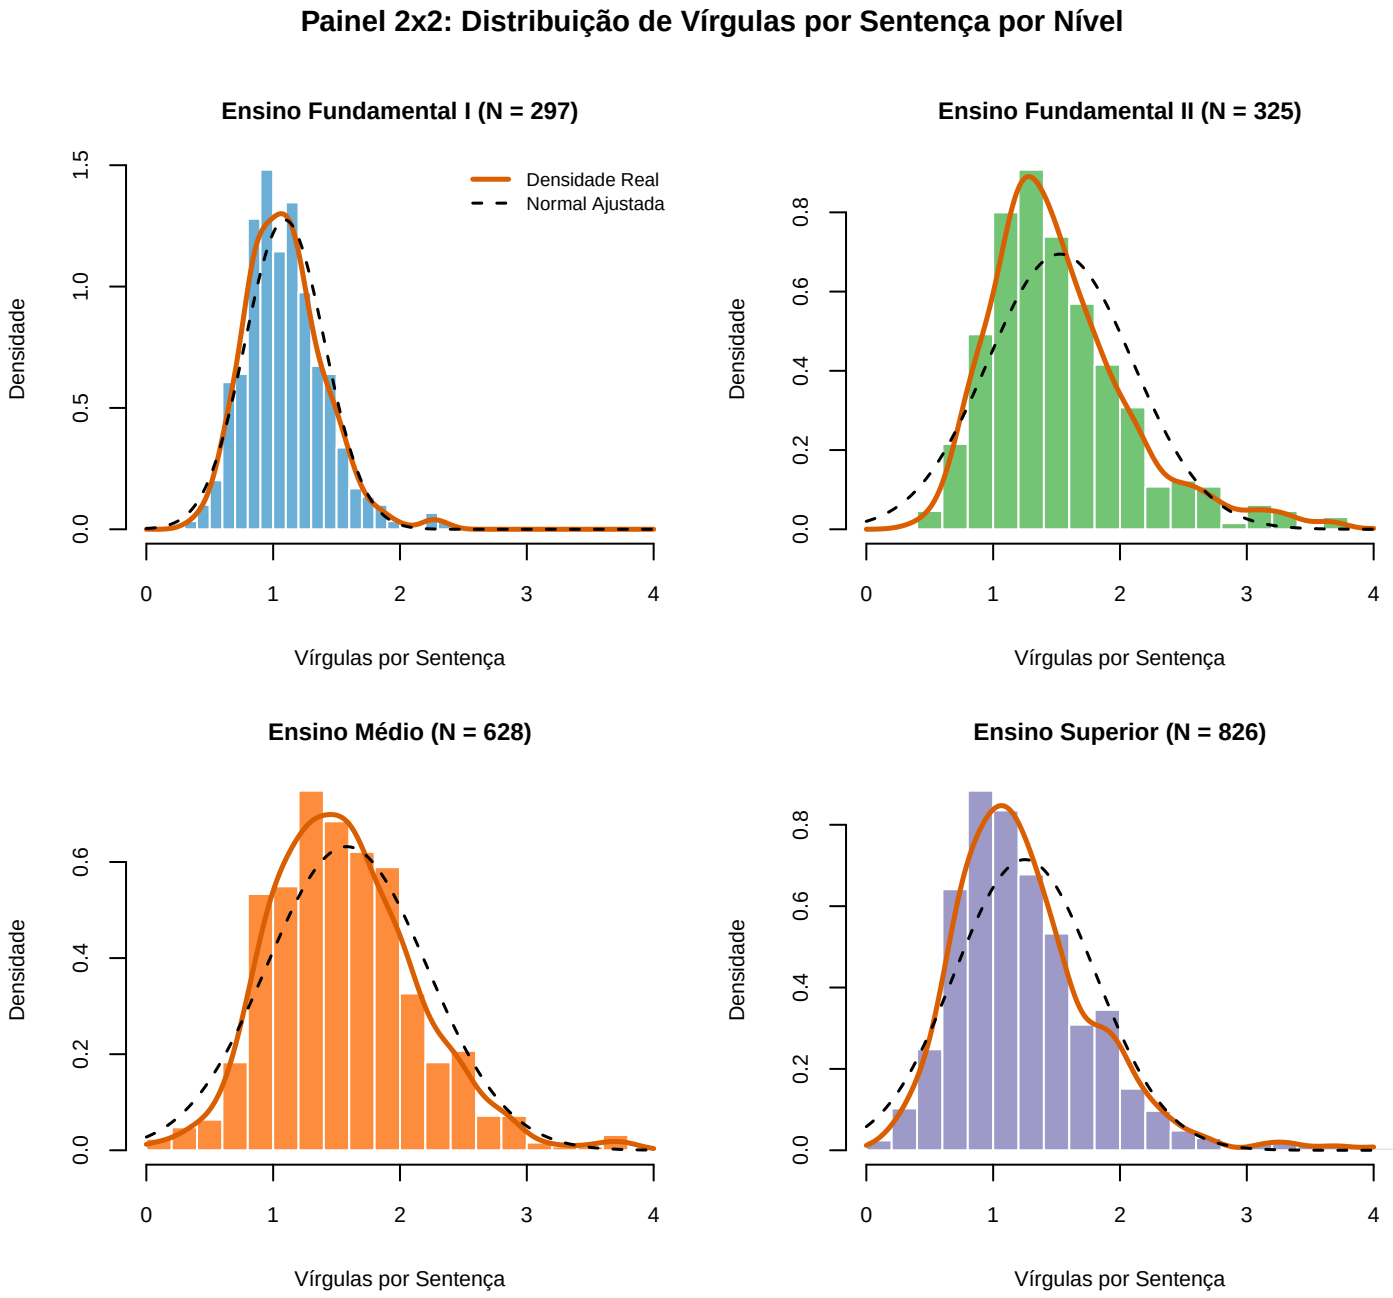




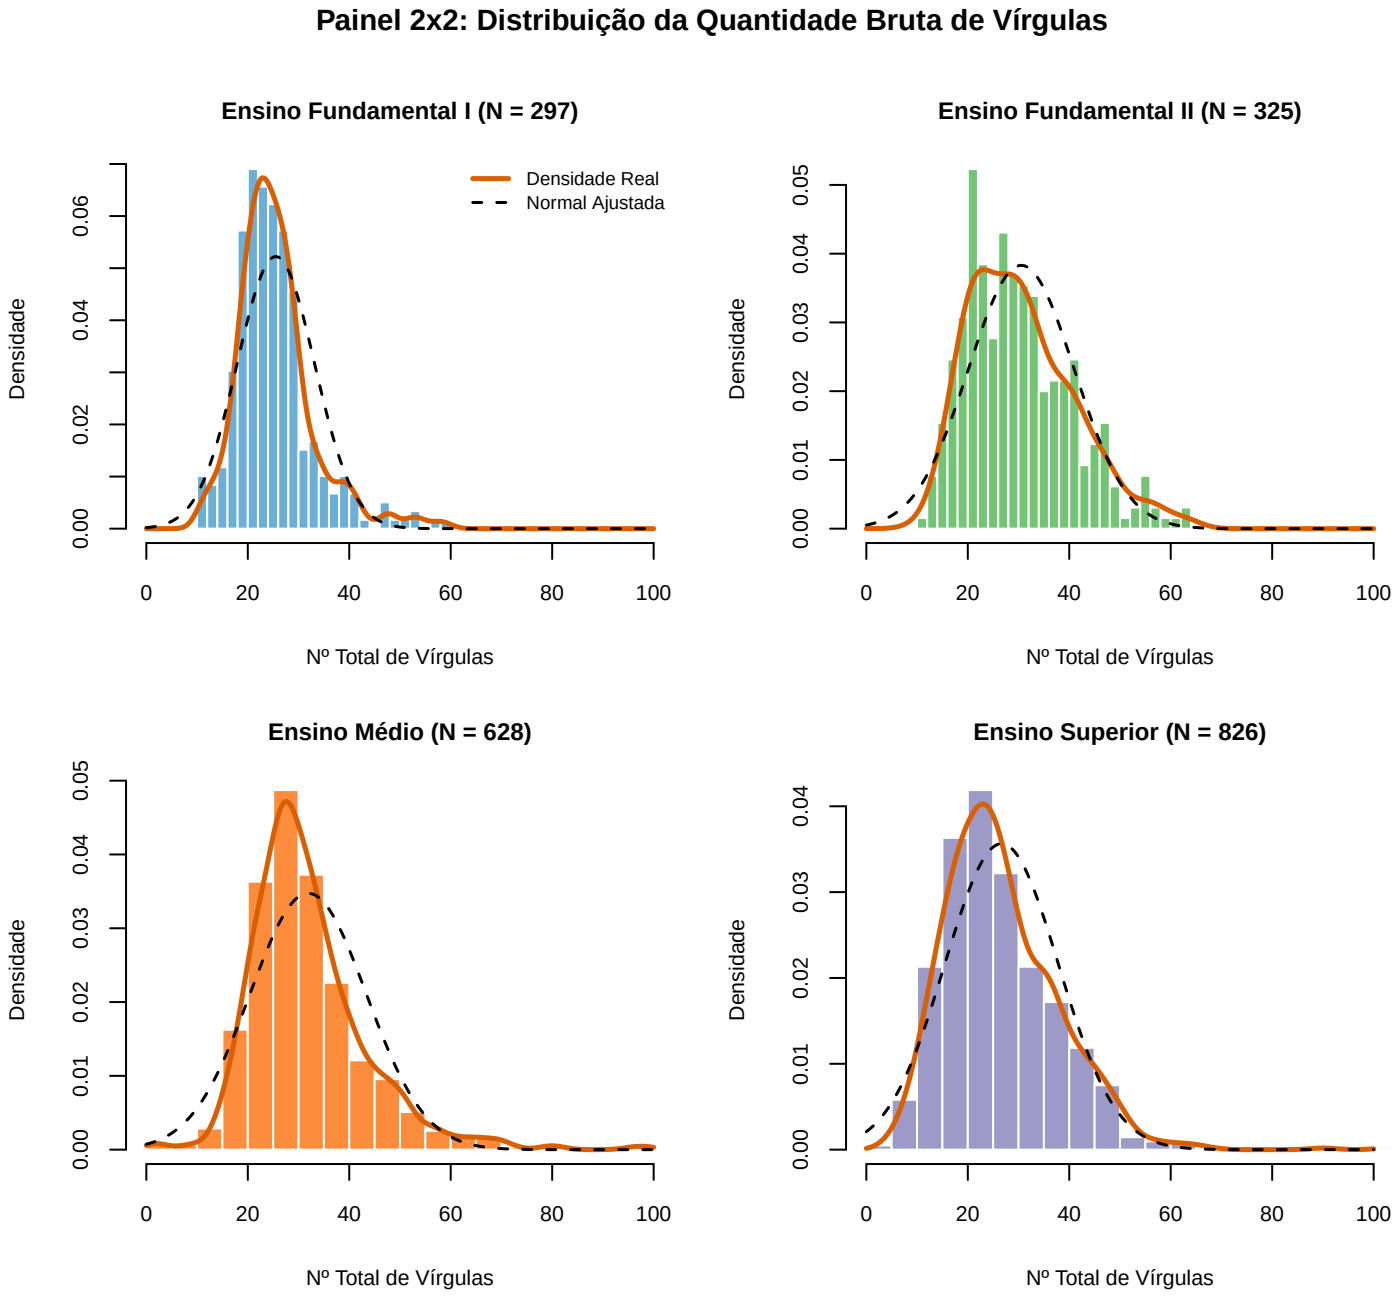
3 Distribuição da Feature por Nível de Ensino (Painel 2x2)

Apresentamos o painel 2×2 gerado estritamente com `par(mfrow = c(2, 2))` e `hist(freq = FALSE)` para os 4 níveis educacionais.

3.1 Vírgulas por Sentença (`virgulas_por_sentenca`)



3.2 Quantidade Absoluta de Vírgulas (`virgulas_qtd`)



4 Comparação Fundamental: Ensino Médio vs. Outros Níveis

Verificamos se **existe diferença estatisticamente significativa na densidade de vírgulas por sentença dos textos de Ensino Médio quando comparados com Ensino Fundamental I, Fundamental II e Ensino Superior**.

4.1 Teste Global de Kruskal-Wallis

Table 2: Teste Global de Kruskal-Wallis para Vírgulas por Sentença entre Níveis

Variável	Estatística Chi²	Graus de Liberdade	p-valor	Significância Global
Vírgulas por Sentença	245.1716	3	7.246e-53	Altamente Significativo ($p < 0.001$)
Quantidade de Vírgulas	134.7863	3	5.029e-29	Altamente Significativo ($p < 0.001$)

O teste de Kruskal-Wallis confirma variações intergrupos altamente significativas ($\chi^2 = 245,17$, $p = 7,25 \times 10^{-53}$).

4.2 Comparações Pareadas do Ensino Médio

Aplicamos o **Teste U de Wilcoxon / Mann-Whitney** com correção de Bonferroni e cálculo do tamanho de efeito (*Cohen's d*).

4.2.1 Contrastes Pareados nas Vírgulas por Sentença (`virgulas_por_sentenca`)

Table 3: Comparações Pareadas: Ensino Médio vs. Demais Níveis (Vírgulas por Sentença)

	Comparação	Média Médio	Média Grupo	Diferença Médias	Estatística W	p-adj (Bonferroni)	Cohen d	Decisão (alpha=0.05)
W...1	Ensino Médio vs. Ensino Fundamental I	1.5800	1.0922	+0.4878	143042	7.32e-39	+0.887	Rejeita H0 (Diferença Sig.)
W...2	Ensino Médio vs. Ensino Fundamental II	1.5800	1.5289	+0.0511	108687	2.98e-01	+0.083	Não Rejeita H0 (Sem Diferença)
W...3	Ensino Médio vs. Ensino Superior	1.5800	1.2507	+0.3293	348007	1.58e-28	+0.557	Rejeita H0 (Diferença Sig.)

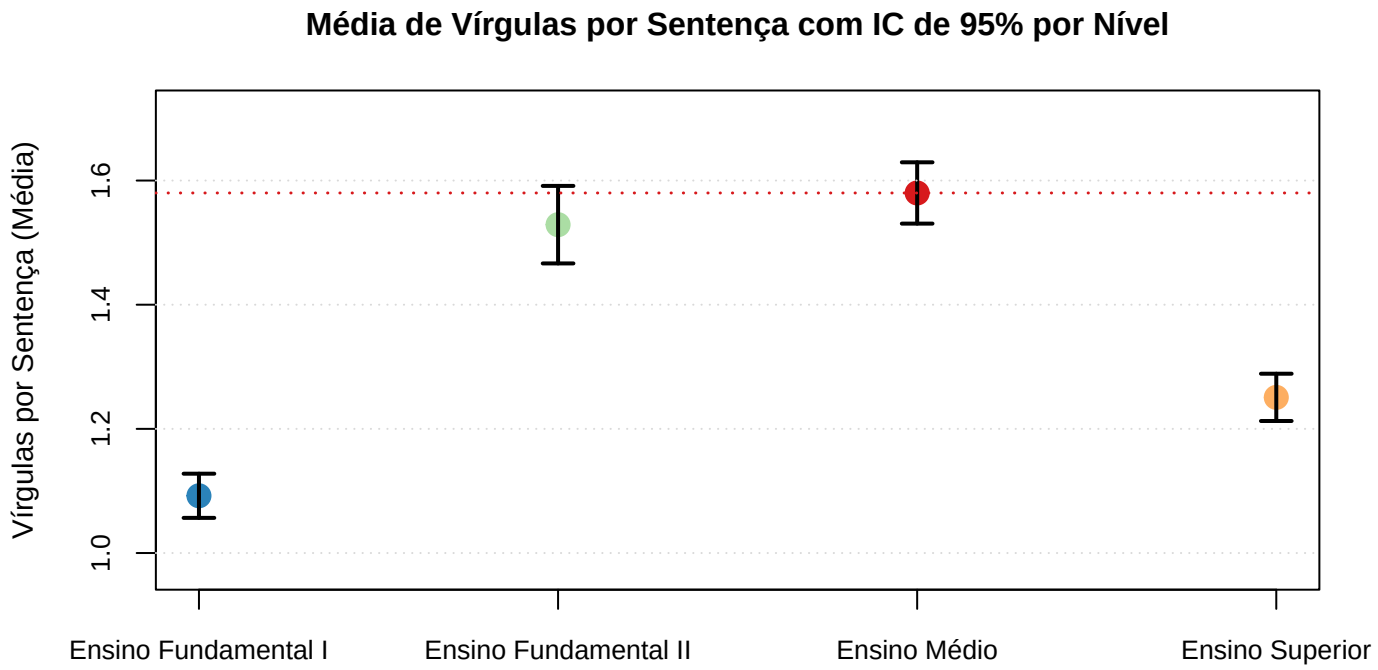
4.2.2 Contrastes Pareados na Quantidade Absoluta (`virgulas_qtd`)

Table 4: Comparações Pareadas: Ensino Médio vs. Demais Níveis (Quantidade de Vírgulas)

	Comparação	Média Médio	Média Grupo	Diferença Médias	Estatística W	p-adj (Bonferroni)	Cohen d	Decisão (alpha=0.05)
W...1	Ensino Médio vs. Ensino Fundamental I	31.90	25.53	+6.37	129594	2.78e-21	+0.612	Rejeita H0 (Diferença Sig.)
W...2	Ensino Médio vs. Ensino Fundamental II	31.90	30.55	+1.35	109027	2.49e-01	+0.122	Não Rejeita H0 (Sem Diferença)
W...3	Ensino Médio vs. Ensino Superior	31.90	26.66	+5.24	334126	1.22e-20	+0.463	Rejeita H0 (Diferença Sig.)

4.3 Gráfico de Médias com Intervalos de Confiança (95%)

A Figura 2 ilustra as médias de vírgulas por sentença com intervalos de confiança de 95% para cada nível educacional. A linha tracejada em vermelho destaca a média do Ensino Médio $(1,58)$.



5 Conclusões e Implicações para o Modelo Classificador

A análise da densidade de vírgulas por sentença revelou uma **assinatura discriminante única para o Ensino Médio**:

1. **Ensino Médio vs. Fundamental I ($p = 7,32 \times 10^{-39}$, Cohen's $d = +0,89$):**
   Diferença estatística massiva com tamanho de efeito muito alto. O Fundamental I possui a menor taxa de vírgulas por sentença $(1,09)$, devido à linearidade da escrita infantil sem orações intercaladas.
2. **Ensino Médio vs. Ensino Superior ($p = 1,58 \times 10^{-28}$, Cohen's $d = +0,56$):**
   Diferença altamente significativa com tamanho de efeito moderado a alto. O Ensino Médio possui **muito mais vírgulas por período $(1,58)$ que o Ensino Superior $(1,25)$**. Isso decorre do estilo de resumos, tópicos conceituais, orações coordenadas assindéticas e apostos característicos das provas do Ensino Médio no acervo CAEd.
3. **Ensino Médio $(1,58)$ e Fundamental II $(1,53)$:**
   Apresentam valores próximos $(p = 0,30)$, atuando como marcador compartilhado de transição sintática.

   Importância no Classificador Multivariado:
   A feature de vírgulas por sentença atua como um **separador positivo do Ensino Médio contra o Ensino Superior**, resolvendo precisamente a confusão entre textos do Médio e do Superior que não contêm fórmulas matemáticas!

Nível Comparado	Decisão Estatística	Tamanho de Efeito	Utilidade no Classificador ALFA-Gen
Médio vs. Fund. I	**Diferença Massiva**	Alto $(+0,89)$	Separação linear de complexidade de períodos.

Nível Comparado	Decisão Estatística	Tamanho de Efeito	Utilidade no Classificador ALFA-Gen
Médio vs. Superior	**Diferença Significativa**	Moderado/Alto $(+0,56)$	**Separa o Ensino Médio do Ensino Superior!**
Médio vs. Fund. II	**Sem Diferença**	Inexpressivo $(+0,08)$	Comportamento estável de transição.

A Apêndice: Arquitetura Modular e Códigos das Funções

- `extrair_novas_features.py`: Segmentação sentencial via spaCy e contagem de vírgulas nos 2.076 arquivos.
- `R/funcoes_estatistica.R`: Rotinas modulares de análise estatística descritiva e testes de Wilcoxon com correção de Bonferroni.
- `R/funcoes_tabelas.R`: Formatação padronizada de tabelas LaTeX via `knitr::kable`.
- `R/funcoes_graficos.R`: Painéis gráficos 2×2 e gráficos de intervalos de confiança com parametrização dinâmica.