Relatório de Engenharia de Atributos: Metadiscurso e Léxico Acadêmico

Diagnóstico Distribucional e Análise Comparativa entre Níveis de Ensino

Contents

1 Definição da Feature e Algoritmo de Extração **2**
- 1.1 Fundamentação Pragmática: O Metadiscurso Científico e Acadêmico . . . 2
- 1.2 Algoritmo em Python (Léxico Calibrado e Normalização) . . . 2

2 Distribuição Global nos 2.076 Textos **3**
- 2.1 Estatísticas Descritivas Globais . . . 3
- 2.2 Visualização Global da Distribuição . . . 3

3 Distribuição da Feature por Nível de Ensino (Painel 2x2) **4**
- 3.1 Densidade de Metadiscurso (`metadiscurso_prop`) . . . 4
- 3.2 Quantidade Absoluta de Termos Metadiscursivos (`metadiscurso_qtd`) . . . 5

4 Comparação Fundamental: Ensino Médio vs. Outros Níveis **6**
- 4.1 Teste Global de Kruskal-Wallis . . . 6
- 4.2 Comparações Pareadas do Ensino Médio . . . 6
  - 4.2.1 Contrastes Pareados na Densidade (`metadiscurso_prop`) . . . 6
  - 4.2.2 Contrastes Pareados na Quantidade Absoluta (`metadiscurso_qtd`) . . . 6
- 4.3 Gráfico de Médias com Intervalos de Confiança (95%) . . . 7

5 Conclusões e Implicações para o Modelo Classificador **7**

A Apêndice: Arquitetura Modular e Códigos das Funções **9**

1 Definição da Feature e Algoritmo de Extração

1.1 Fundamentação Pragmática: O Metadiscurso Científico e Acadêmico

Na análise do discurso e na linguística aplicada (Hyland, 2005), o **metadiscurso** refere-se aos recursos linguísticos que organizam o próprio texto, explicitam a postura metodológica do pesquisador e guiam a interpretação do leitor no ambiente acadêmico:

- **Discurso Escolar Básico:** Centrado no conteúdo empírico imediato, em histórias, instruções diretas ou descrições cotidianas. Não há menção a métodos de investigação, revisão bibliográfica ou hipóteses.
- **Discurso Acadêmico-Científico (Ensino Superior):** É intrinsecamente metadiscursivo. Os textos debatem a própria produção do conhecimento, citando fontes (*segundo o autor*, *estudos recentes*), explicitando a arquitetura empírica (*metodologia*, *dados coletados*, *amostra analisada*), referenciando artefatos de representação (*tabela*, *figura*, *gráfico*) e formulando conclusões qualificadas (*os resultados evidenciam*, *a hipótese formulada*).

Muitos textos universitários (em especial nas áreas de Humanas, Ciências Sociais, Educação e Letras) **não contêm fórmulas matemáticas**. O metadiscurso atua como o principal marcador para identificar esses textos acadêmicos não exatos.

A **Densidade de Metadiscurso Acadêmico** quantifica a taxa de termos epistemológicos por palavra:

$$\text{metadiscurso_prop} = \frac{\text{Ocorrências de Termos de Metadiscurso Acadêmico}}{\text{Total de Palavras no Texto}}$$

1.2 Algoritmo em Python (Léxico Calibrado e Normalização)

A extração utiliza um conjunto controlado de lemas acadêmicos da língua portuguesa (*autor*, *pesquisa*, *metodologia*, *dados*, *análise*, *conclusão*, *tabela*, *artigo*, *evidência*, *hipótese*, *teoria*, etc.), processando as palavras com normalização Unicode:

```python
METADISCURSO_TERMOS = {
    "autor", "autores", "pesquisa", "pesquisas", "pesquisador", "metodologia",
    "dados", "analise", "conclusao", "tabela", "figura", "grafico", "artigo",
    "evidencia", "hipotese", "resultado", "resultados", "teoria", "referencia",
    "cientifico", "cientifica", "academico", "academica", "experimento"
}

def extrair_metadiscurso(doc) -> tuple:
    palavras = [t.text.lower() for t in doc if t.is_alpha]
    total_palavras = max(len(palavras), 1)

    n_meta = sum(1 for p in palavras if normalizar_texto(p) in METADISCURSO_TERMOS)
    prop = n_meta / total_palavras
    return n_meta, prop
```

2 Distribuição Global nos 2.076 Textos

Analisamos duas variáveis derivadas: * **Quantidade de Termos Metadiscursivos (`metadiscurso_qtd`)**: contagem absoluta de ocorrências no texto. * **Densidade de Metadiscurso (`metadiscurso_prop`)**: fração relativa de termos acadêmicos (metadiscurso_prop = $\frac{\text{metadiscurso_qtd}}{\text{total_palavras}}$).

2.1 Estatísticas Descritivas Globais

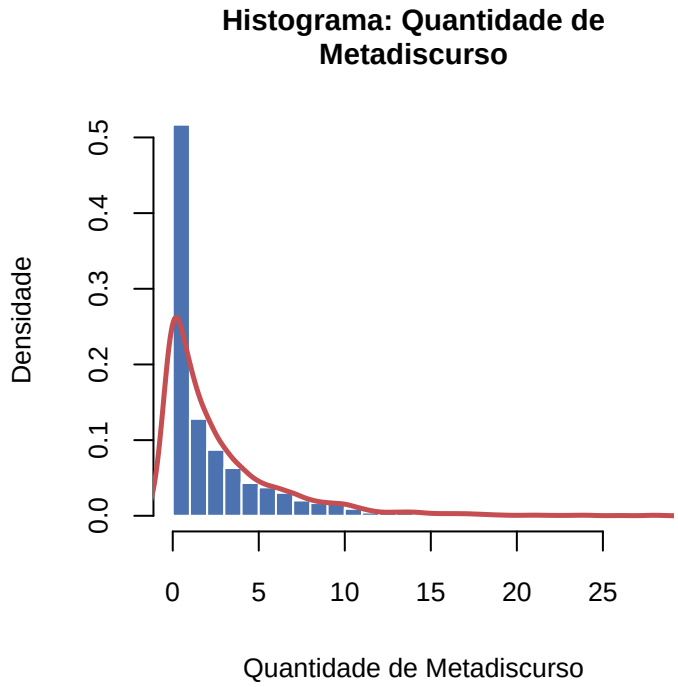
A Tabela 1 sintetiza as medidas de posição e dispersão para todo o acervo.

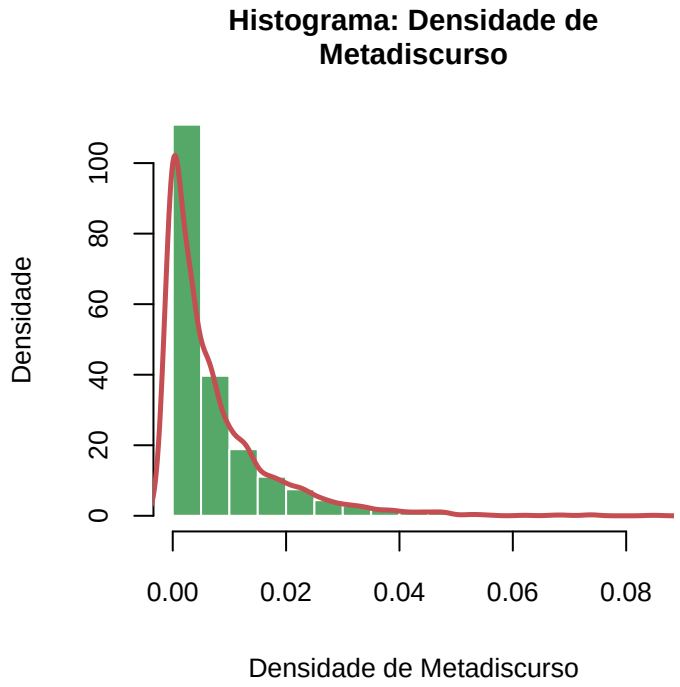
Table 1: Estatísticas Descritivas Globais do Metadiscurso Acadêmico (N = 2.076)

	N	Média	Desv. Padrão	Mediana	IQR	Mínimo	Máximo	Assimetria (Ske
Quantidade de Termos Acadêmicos	2076	2.6869	3.6094	1.0000	4.00	0	28.0000	2.36
Densidade de Metadiscurso (taxa)	2076	0.0072	0.0097	0.0033	0.01	0	0.0848	2.43

2.2 Visualização Global da Distribuição

A Figura 1 apresenta os histogramas com curvas de densidade empírica para as duas variáveis.

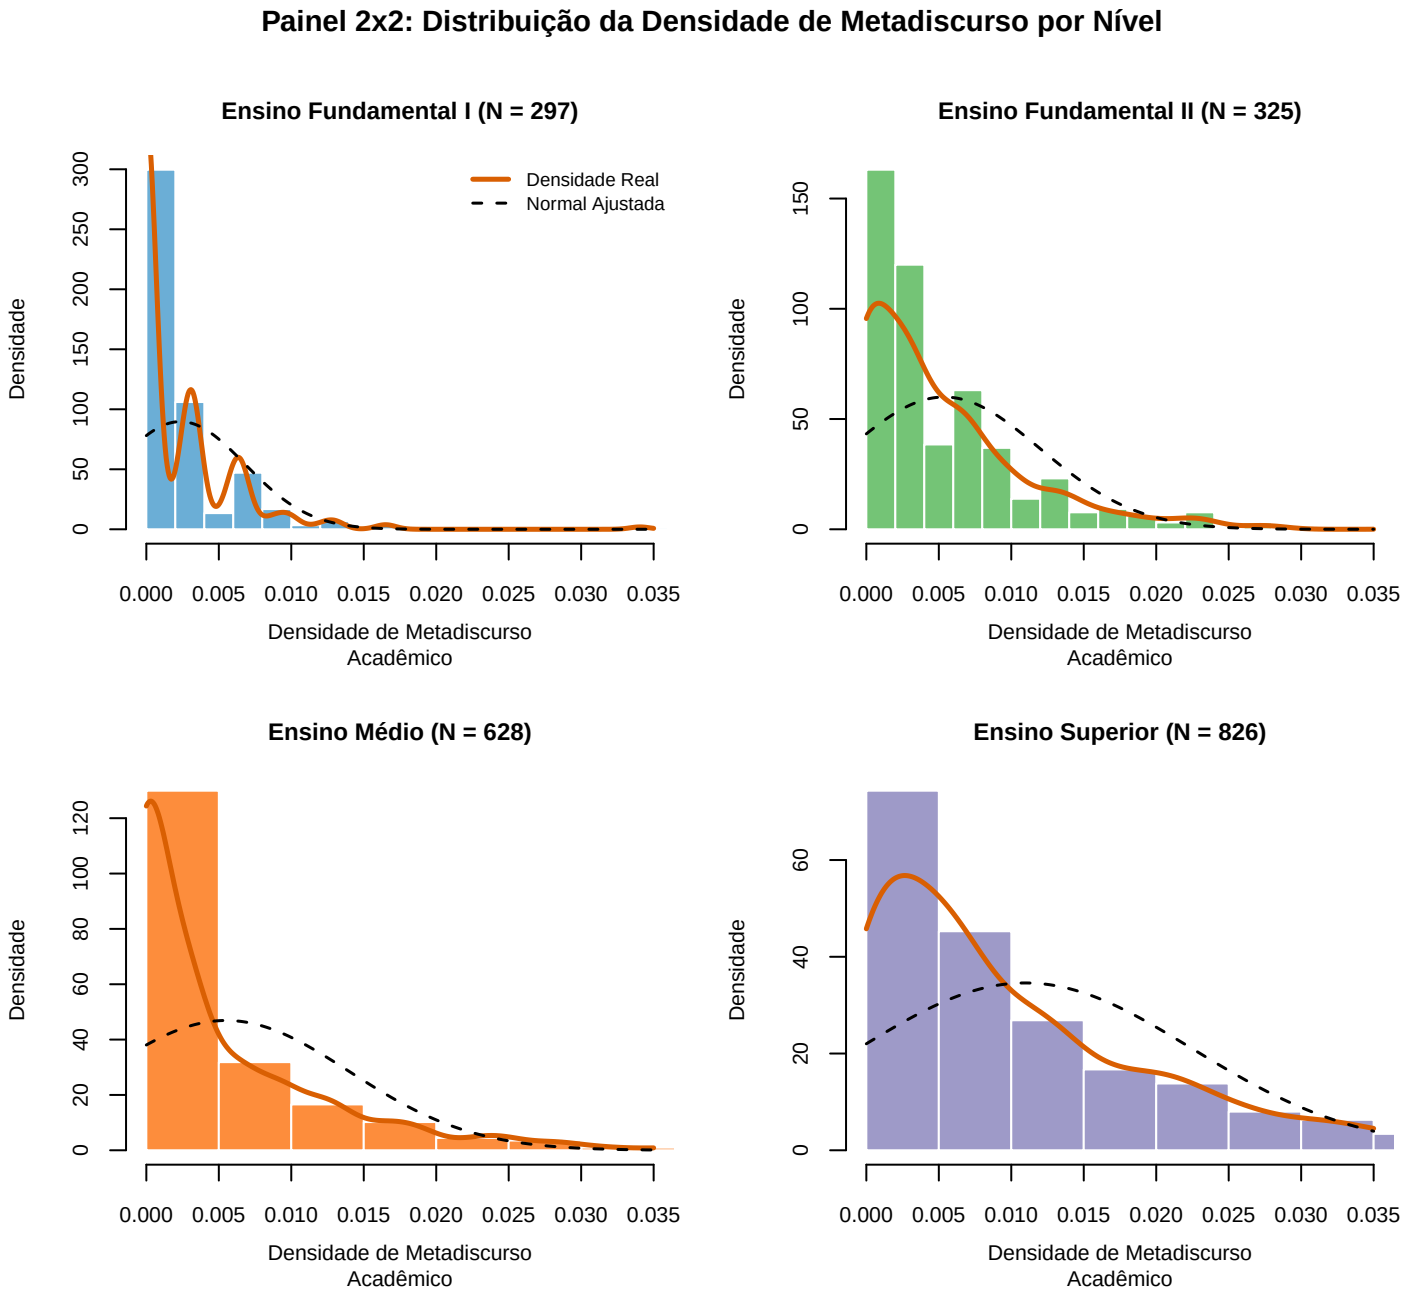




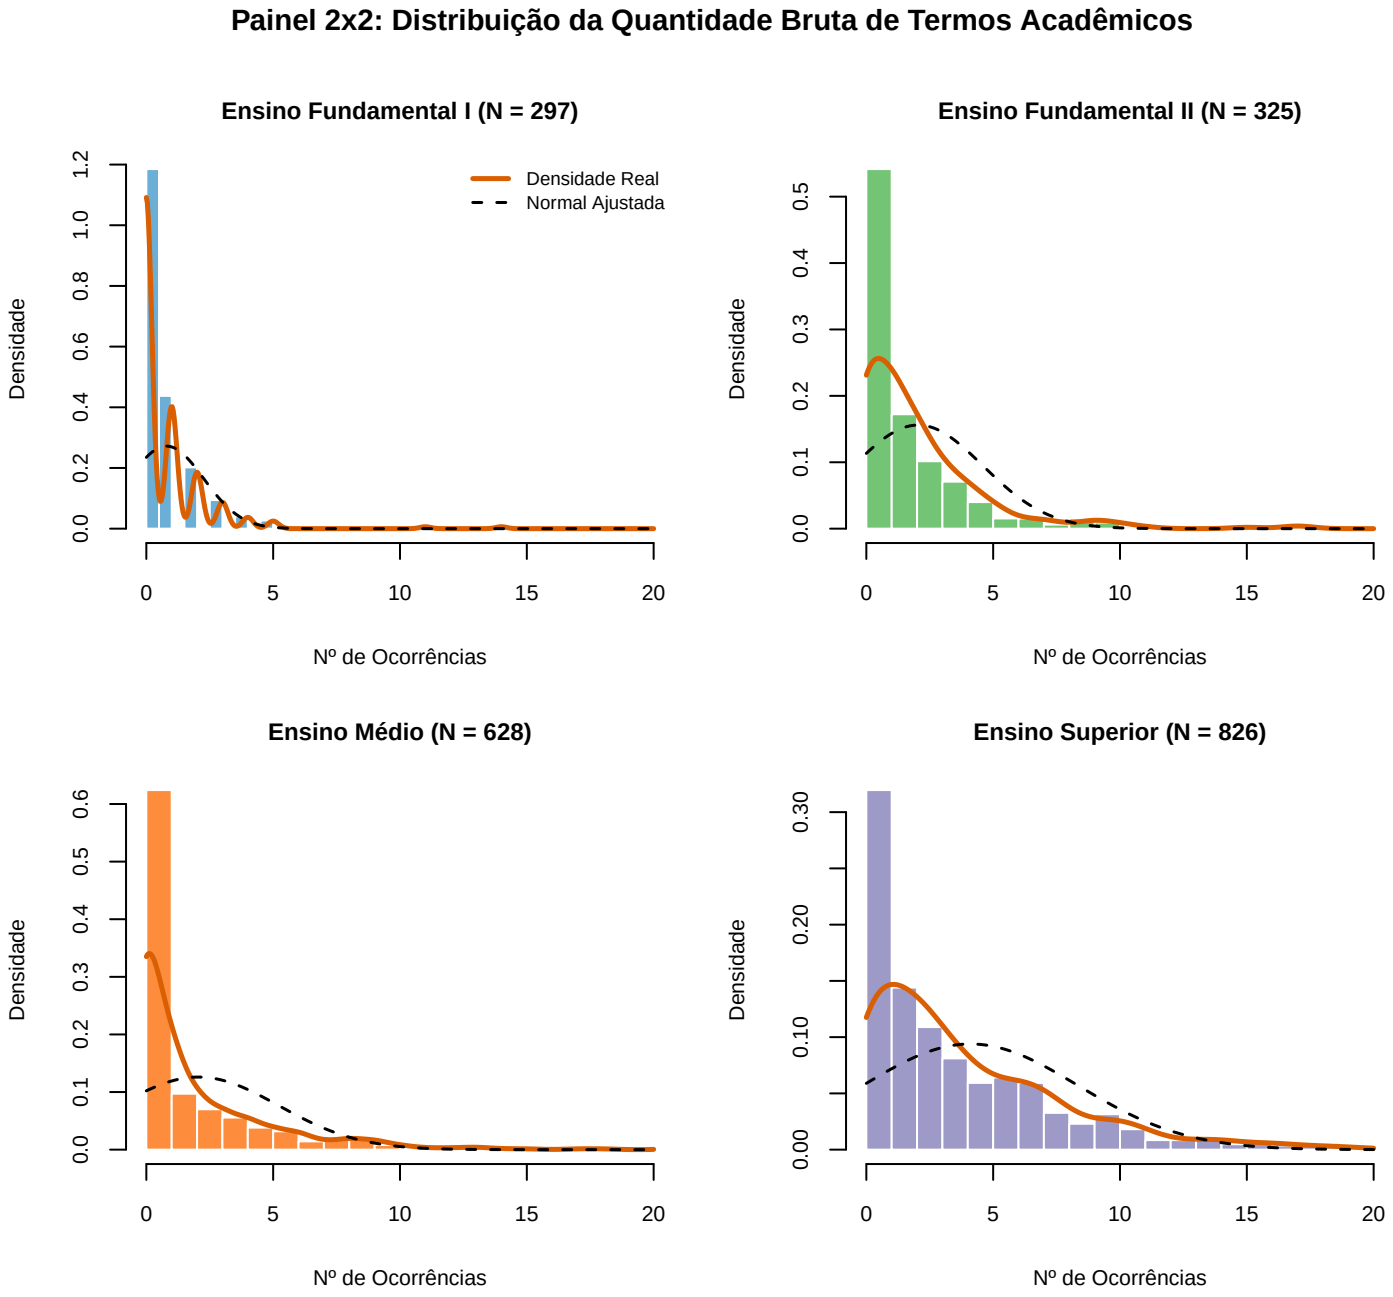
3 Distribuição da Feature por Nível de Ensino (Painel 2x2)

Apresentamos o painel 2×2 gerado estritamente com `par(mfrow = c(2, 2))` e `hist(freq = FALSE)` para os 4 níveis educacionais.

3.1 Densidade de Metadiscurso (`metadiscurso_prop`)



3.2 Quantidade Absoluta de Termos Metadiscursivos (`metadiscurso_qtd`)



4 Comparação Fundamental: Ensino Médio vs. Outros Níveis

Verificamos se **existe diferença estatisticamente significativa na densidade de metadiscurso dos textos de Ensino Médio quando comparados com Ensino Fundamental I, Fundamental II e Ensino Superior**.

4.1 Teste Global de Kruskal-Wallis

Table 2: Teste Global de Kruskal-Wallis para Metadiscurso Acadêmico entre Níveis

Variável	Estatística Chi²	Graus de Liberdade	p-valor	Significância Global
Densidade de Metadiscurso	298.7648	3	1.841e-64	Altamente Significativo ($p < 0.001$)
Quantidade de Metadiscurso	325.1388	3	3.600e-70	Altamente Significativo ($p < 0.001$)

O teste de Kruskal-Wallis confirma variações intergrupos colossais ($\chi^2 = 298,76$, $p = 1,84 \times 10^{-64}$).

4.2 Comparações Pareadas do Ensino Médio

Aplicamos o **Teste U de Wilcoxon / Mann-Whitney** com correção de Bonferroni e cálculo do tamanho de efeito (*Cohen's d*).

4.2.1 Contrastes Pareados na Densidade (`metadiscurso_prop`)

Table 3: Comparações Pareadas: Ensino Médio vs. Demais Níveis (Densidade de Metadiscurso)

	Comparação	Média Médio	Média Grupo	Diferença Médias	Estatística W	p-adj (Bonferroni)	Cohen d	Decisão (alpha=0.05)
W...1	Ensino Médio vs. Ensino Fundamental I	0.00550	0.00235	+0.00316	113513	4.45e-08	+0.424	Rejeita H0 (Diferença Sig.)
W...2	Ensino Médio vs. Ensino Fundamental II	0.00550	0.00537	+0.00013	93154	6.91e-02	+0.016	Não Rejeita H0 (Sem Diferença)
W...3	Ensino Médio vs. Ensino Superior	0.00550	0.01096	-0.00546	165587	1.78e-32	-0.528	Rejeita H0 (Diferença Sig.)

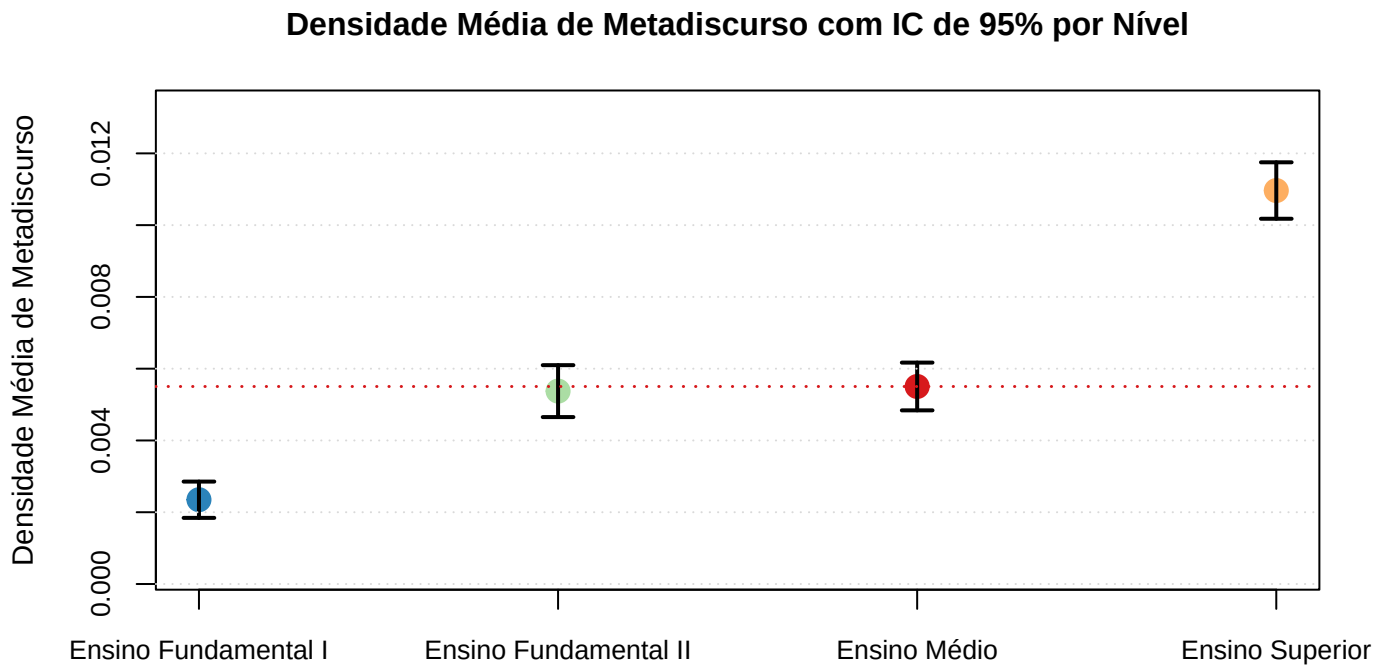
4.2.2 Contrastes Pareados na Quantidade Absoluta (`metadiscurso_qtd`)

Table 4: Comparações Pareadas: Ensino Médio vs. Demais Níveis (Quantidade de Metadiscurso)

	Comparação	Média Médio	Média Grupo	Diferença Médias	Estatística W	p-adj (Bonferroni)	Cohen d	Decisão (alpha=0.05)
W...1	Ensino Médio vs. Ensino Fundamental I	2.05	0.79	+1.26	115537	1.13e-09	+0.460	Rejeita H0 (Diferença Sig.)
W...2	Ensino Médio vs. Ensino Fundamental II	2.05	2.04	+0.01	92256	3.53e-02	+0.004	Rejeita H0 (Diferença Sig.)
W...3	Ensino Médio vs. Ensino Superior	2.05	4.10	-2.05	163702	5.03e-34	-0.536	Rejeita H0 (Diferença Sig.)

4.3 Gráfico de Médias com Intervalos de Confiança (95%)

A Figura 2 ilustra as médias da densidade de metadiscurso com intervalos de confiança de 95% para cada nível educacional. A linha tracejada em vermelho destaca a média do Ensino Médio (0, 55%).



5 Conclusões e Implicações para o Modelo Classificador

A análise da densidade de metadiscurso acadêmico confirmou um **salto exponencial no Ensino Superior**:

1. **Ensino Médio vs. Ensino Superior ($p = 1,78 \times 10^{-32}$, Cohen's $d = -0,53$):**
   Diferença altamente significativa com tamanho de efeito moderado. A densidade média de metadiscurso no Ensino Superior é de 1, 10% (4, 10 **termos por texto**) — exatamente o **dobro** da média observada no Ensino Médio (0, 55%, 2, 05 termos). Essa feature atua como o atrator definidor para classificar textos do Ensino Superior que não possuem fórmulas matemáticas!
2. **Ensino Médio vs. Fundamental I ($p = 4,45 \times 10^{-8}$, Cohen's $d = +0,42$):**
   Diferença altamente significativa. No Fundamental I, termos de pesquisa e metodologia são quase inexistentes (0, 23%).
3. **Ensino Médio (0, 55%) e Fundamental II (0, 54%):**
   Apresentam frequências basais idênticas ($p = 0,069$, sem diferença significativa), confirmando que o salto de metadiscurso ocorre exclusivamente na transição para a universidade.

   Resolução do Gargalo de Classificação:
   A feature de metadiscurso resolve o ponto cego da feature `formula_prop`: enquanto as fórmulas separam os textos de Exatas/Biológicas do Superior, o metadiscurso resgata os textos acadêmicos de Humanas e Sociais Aplicadas.

Nível Comparado	Decisão Estatística	Tamanho de Efeito	Utilidade no Classificador ALFA-Gen
Médio vs. Superior	**Diferença Significativa**	Moderado ($-0,53$)	**Isola os textos do Superior que não contêm fórmulas!**
Médio vs. Fund. I	**Diferença Significativa**	Moderado ($+0,42$)	Separação adicional do Fundamental I.
Médio vs. Fund. II	**Sem Diferença**	Inexpressivo ($+0,02$)	Patamar estável do ensino básico.

A Apêndice: Arquitetura Modular e Códigos das Funções

- `extrair_novas_features.py`: Mapeamento léxico normalizado de termos acadêmicos via spaCy nos 2.076 arquivos.
- `R/funcoes_estatistica.R`: Rotinas modulares de análise estatística descritiva e testes de Wilcoxon com correção de Bonferroni.
- `R/funcoes_tabelas.R`: Formatação padronizada de tabelas LaTeX via `knitr::kable`.
- `R/funcoes_graficos.R`: Painéis gráficos 2×2 e gráficos de intervalos de confiança com parametrização dinâmica.