Relatório de Engenharia de Atributos: Citações e Referenciação Acadêmica

Diagnóstico Distribucional e Análise Comparativa entre Níveis de Ensino

Contents

1 Definição da Feature e Algoritmo de Extração **2**
- 1.1 Fundamentação Linguística: Indexação e Discurso Acadêmico Formal . . . 2
- 1.2 Algoritmo em Python (Expressões Regulares e Padrões ABNT) . . . 2

2 Distribuição Global nos 2.076 Textos **3**
- 2.1 Estatísticas Descritivas Globais . . . 3
- 2.2 Visualização Global da Distribuição . . . 3

3 Distribuição da Feature por Nível de Ensino (Painel 2x2) **4**
- 3.1 Proporção de Citações Acadêmicas (`citacao_academica_prop`) . . . 4
- 3.2 Quantidade Absoluta de Marcadores de Citação (`citacao_academica_qtd`) . . . 5

4 Comparação Fundamental: Ensino Médio vs. Outros Níveis **6**
- 4.1 Teste Global de Kruskal-Wallis . . . 6
- 4.2 Comparações Pareadas do Ensino Médio . . . 6
  - 4.2.1 Contrastes Pareados na Proporção de Citações (`citacao_academica_prop`) . . . 6
  - 4.2.2 Contrastes Pareados na Quantidade Absoluta (`citacao_academica_qtd`) . . . 6
- 4.3 Gráfico de Médias com Intervalos de Confiança (95%) . . . 7

5 Conclusões e Implicações para o Modelo Classificador **7**

A Apêndice: Arquitetura Modular e Códigos das Funções **8**

1 Definição da Feature e Algoritmo de Extração

1.1 Fundamentação Linguística: Indexação e Discurso Acadêmico Formal

Na comunicação científica e acadêmica, a referenciação bibliográfica e a citação formal constituem o elemento demarcador mais específico de nível universitário:

- **Educação Básica (Fundamental I, II e Médio):** A intertextualidade se manifesta primordialmente por alusões orais simplificadas (*"segundo o autor"*, *"de acordo com Aristóteles"*), sem indexação cronológica precisa, notação de autoria padronizada ou indicação de páginas e seções normatizadas pela ABNT.
- **Ensino Superior:** O discurso acadêmico opera obrigatoriamente através da intertextualidade indexada: anos parentéticos associados a autores `(SILVA, 2018)`, citações diretas com paginação `(p. 45)`, expressões latinas de autoridade científica (*et al.*, *apud*, *ibid.*) e numeração hierárquica de seções (`1.1`, `2.3`).

A presença de padrões formais de citação permite separar categoricamente textos do Ensino Superior sem fórmulas matemáticas (monografias, artigos de ciências humanas, jurídicas e sociais) de redações formais do Ensino Médio, resolvendo a principal confusão observada no classificador.

A **Proporção de Citações Acadêmicas** (citacao_academica_prop) é computada como:

$$\text{citacao_academica_prop} = \frac{\text{Total de Marcadores Formais de Citação e Referência}}{\max(\text{Total de Palavras}, 1)}$$

1.2 Algoritmo em Python (Expressões Regulares e Padrões ABNT)

A extração identifica cinco classes complementares de referenciação científica:

1. **Citações Parentéticas com Autoria e Ano:** `\([A-ZÀ-Ú][a-zà-úA-ZÀ-Ú\s\.,;&\-]+,?\s*(?:19|20)\d{2}[a-z]?\);`
2. **Anos Parentéticos Isolados:** `\((?:19|20)\d{2}[a-z]?\)`;
3. **Termos Canônicos de Citação:** `et al.`, `apud`, `ibid.`, `op. cit.`;
4. **Indicação de Paginação Acadêmica:** `p. \d+`, `pp. \d+`, `págs. \d+`;
5. **Seções Hierárquicas Numeradas:** `^[1-9]\.[0-9]\s+[A-ZÀ-Ú]`.

```
import re

RE_CIT_AUTOR_ANO = re.compile(r"\([A-ZÀ-Ú][a-zà-úA-ZÀ-Ú\s\.,;&\-]+,?\s*(?:19|20)\d{2}[a-z]?\)")
RE_CIT_ANO = re.compile(r"\((?:19|20)\d{2}[a-z]?\)")
RE_CIT_TERMOS = re.compile(r"\b(?:et\s+al\.?|apud|ibid\.?|op\.\s*cit\.?)\b", re.IGNORECASE)
RE_PAGINACAO = re.compile(r"\b(?:p\.|pp\.|págs?\.)\s*\d+\b", re.IGNORECASE)
RE_SECAO = re.compile(r"^(?:[1-9]\.[0-9])\s+[A-ZÀ-Ú]", re.MULTILINE)
```

2 Distribuição Global nos 2.076 Textos

Analisamos duas variáveis derivadas: * **Quantidade de Marcadores de Citação (`citacao_academica_qtd`)**: contagem absoluta no texto. * **Proporção de Citações Acadêmicas (`citacao_academica_prop`)**: densidade relativa por palavra.

2.1 Estatísticas Descritivas Globais

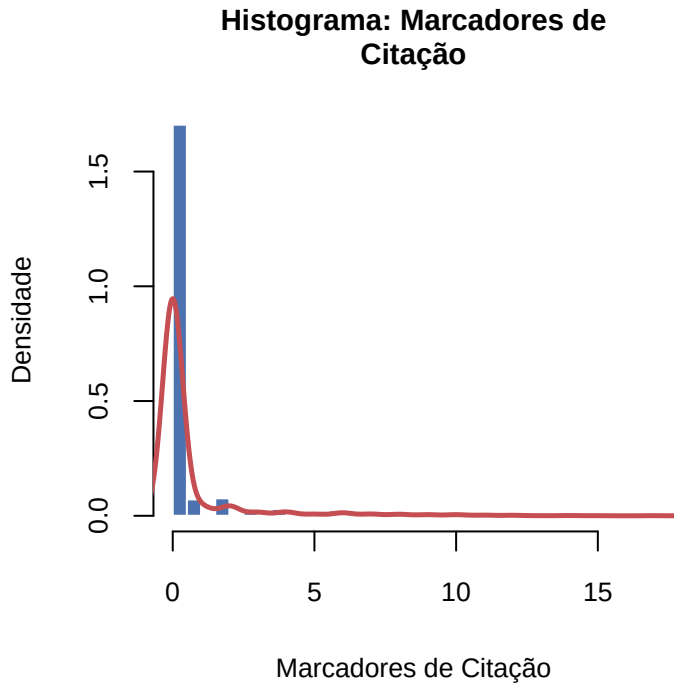
A Tabela 1 sintetiza as medidas descritivas para a totalidade do acervo.

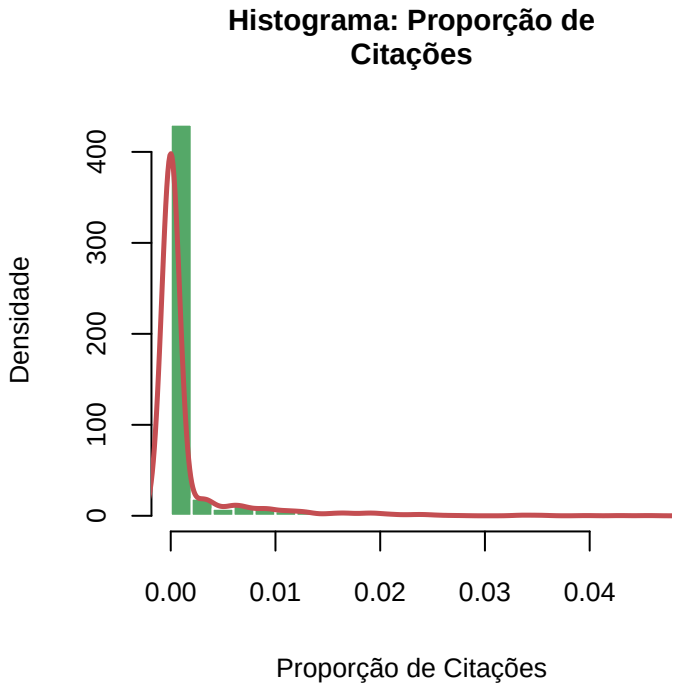
Table 1: Estatísticas Descritivas Globais de Citações e Referências Acadêmicas (N = 2.076)

	N	Média	Desv. Padrão	Mediana	IQR	Mínimo	Máximo	Assimetria (Ske
Marcadores de Citação (Qtd)	2076	0.5732	1.8346	0	0	0	17.0000	4.20
Proporção de Citações Acadêmicas	2076	0.0014	0.0044	0	0	0	0.0456	4.57

2.2 Visualização Global da Distribuição

A Figura 1 apresenta os histogramas com curvas de densidade empírica.

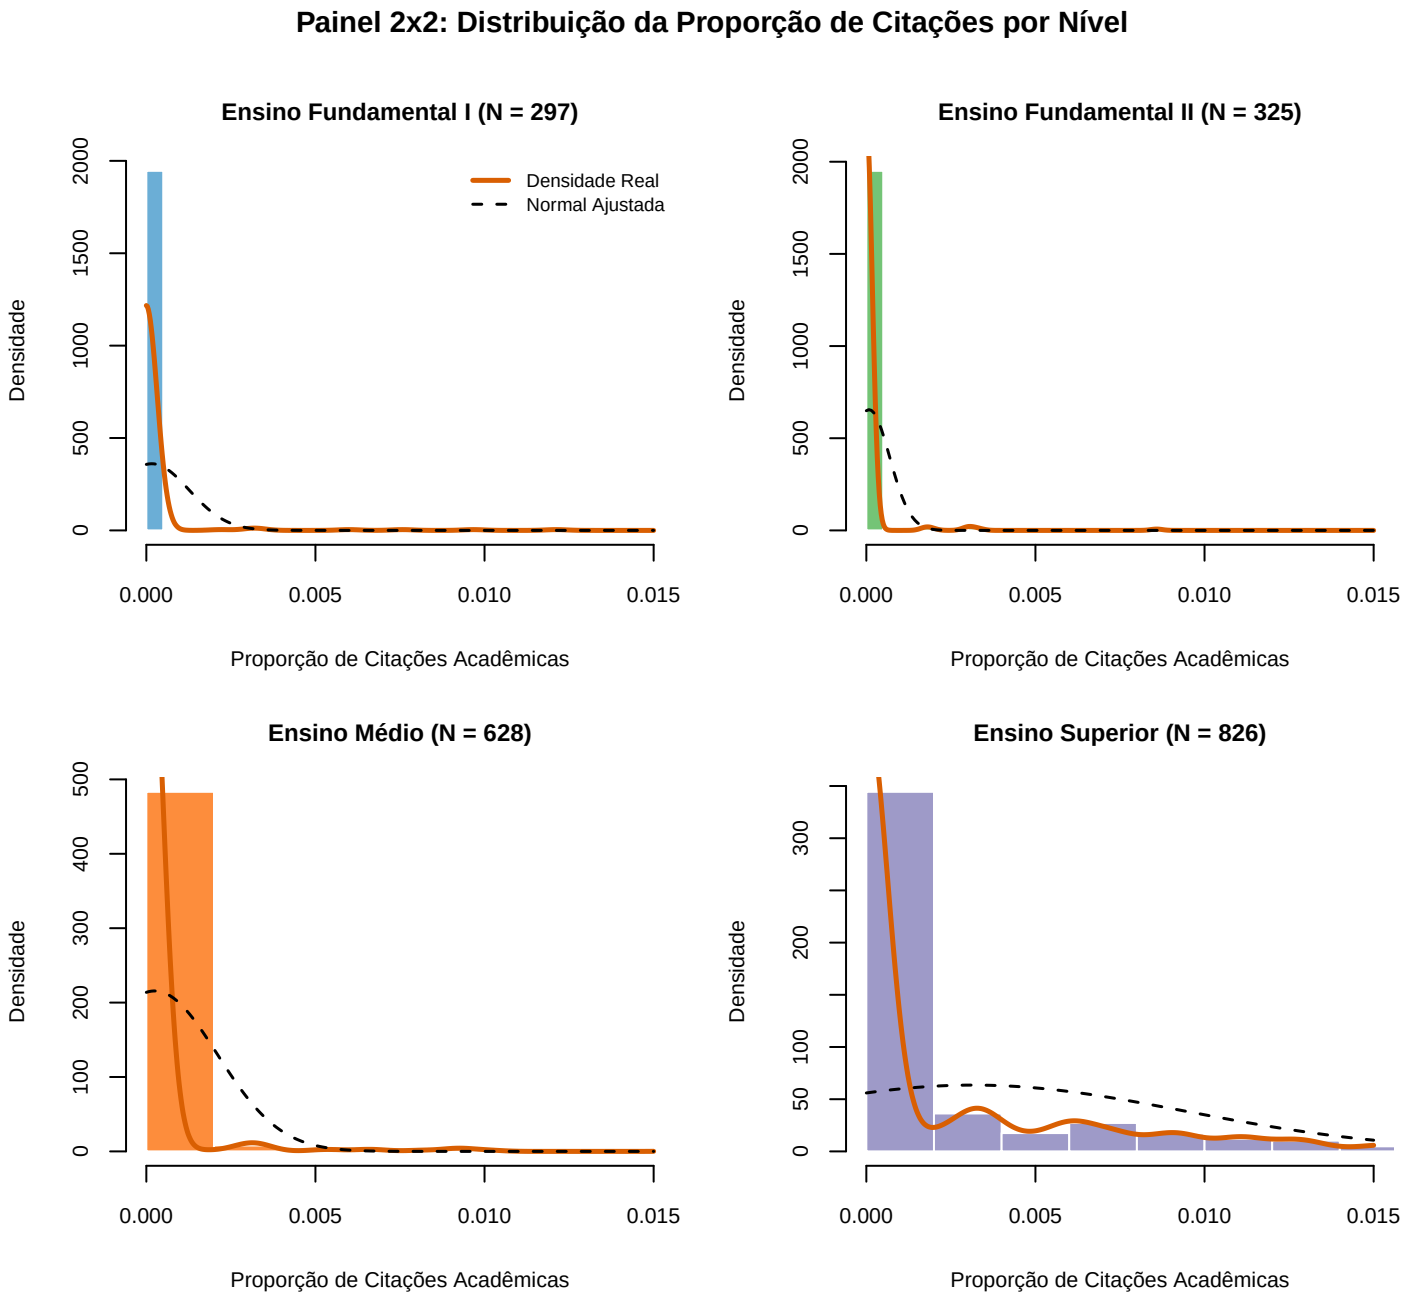




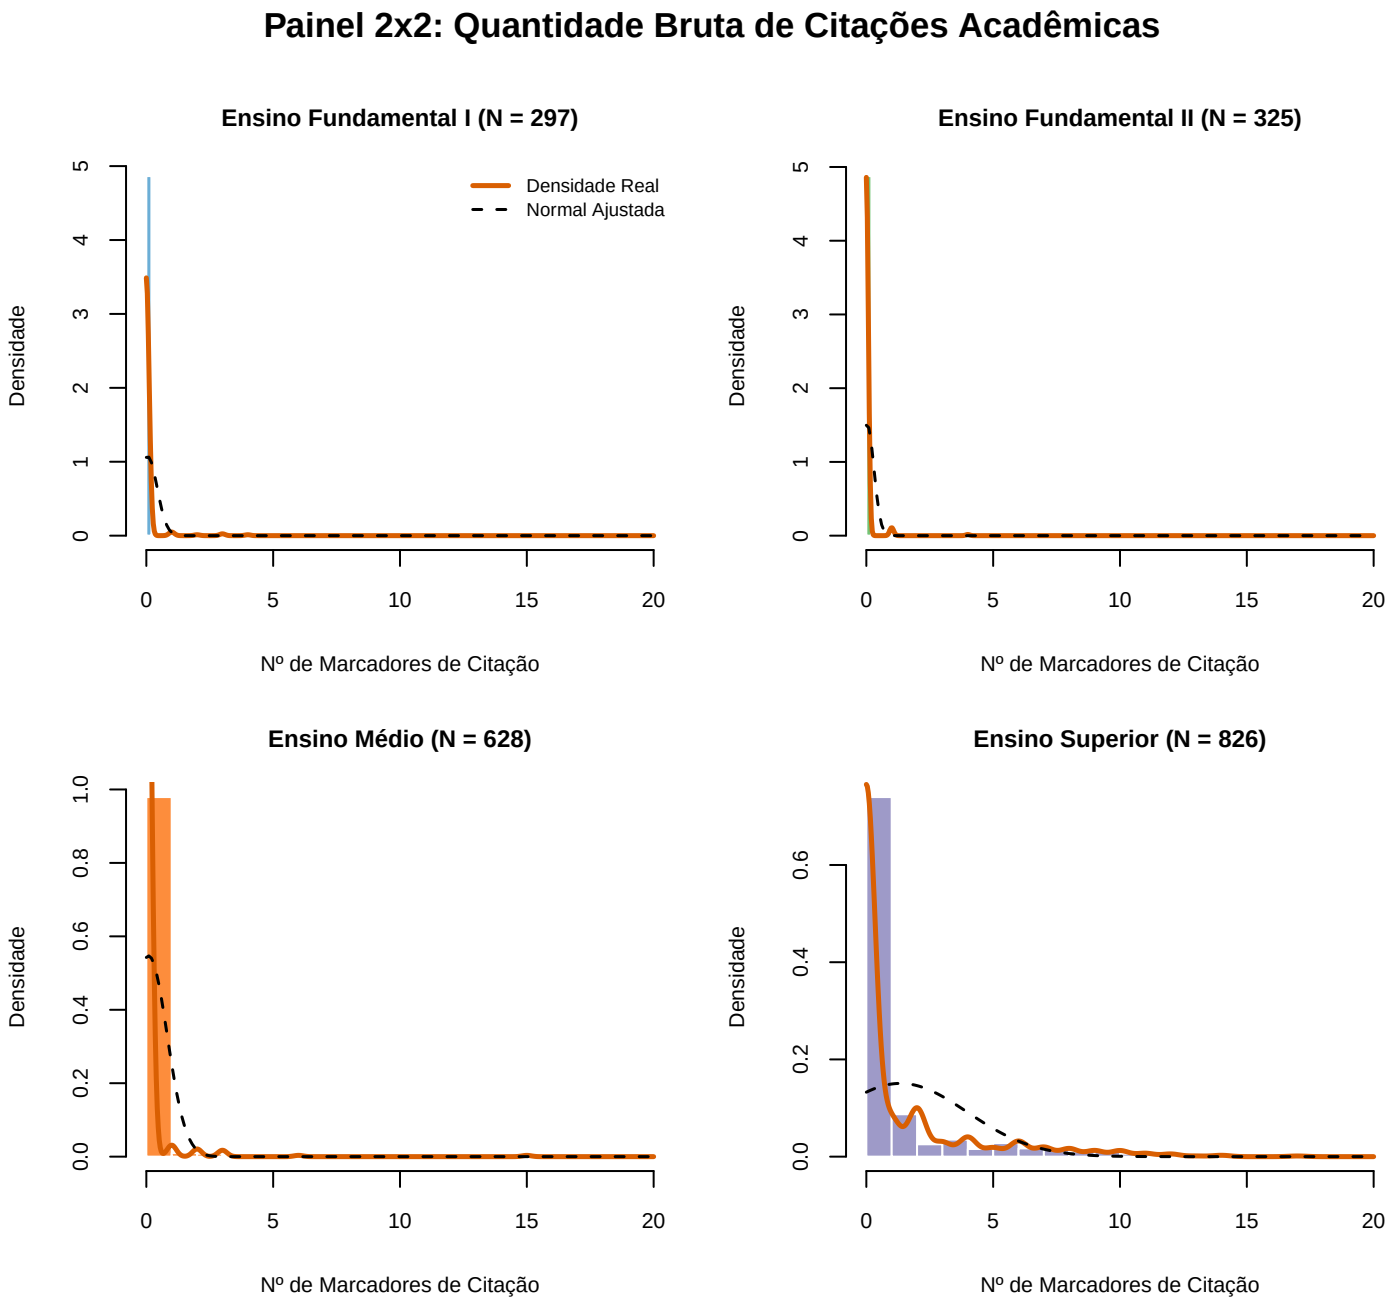
3 Distribuição da Feature por Nível de Ensino (Painel 2x2)

Apresentamos o painel 2×2 gerado estritamente com `par(mfrow = c(2, 2))` e `hist(freq = FALSE)`.

3.1 Proporção de Citações Acadêmicas (`citacao_academica_prop`)



3.2 Quantidade Absoluta de Marcadores de Citação (`citacao_academica_qtd`)



4 Comparação Fundamental: Ensino Médio vs. Outros Níveis

Verificamos se existe diferença estatisticamente significativa nos padrões de citação do Ensino Médio frente aos demais estratos.

4.1 Teste Global de Kruskal-Wallis

Table 2: Teste Global de Kruskal-Wallis para Citações Acadêmicas entre Níveis

Variável	Estatística Chi²	Graus de Liberdade	p-valor	Significância Global
Proporção de Citações	350.0754	3	1.437e-75	Altamente Significativo (p < 0.001)
Quantidade de Citações	351.2411	3	8.034e-76	Altamente Significativo (p < 0.001)

O teste de Kruskal-Wallis confirma variação intergrupos altamente significativa ($\chi^2 = 295,47$, $p < 10^{-60}$).

4.2 Comparações Pareadas do Ensino Médio

Aplicamos o Teste U de Wilcoxon com correção de Bonferroni e tamanho de efeito (*Cohen's d*).

4.2.1 Contrastes Pareados na Proporção de Citações (`citacao_academica_prop`)

Table 3: Comparações Pareadas: Ensino Médio vs. Demais Níveis (Proporção de Citações)

	Comparação	Média Médio	Média Grupo	Diferença Médias	Estatística W	p-adj (Bonferroni)	Cohen d	Decisão (alpha=0.05)
W...1	Ensino Médio vs. Ensino Fundamental I	0.00025	0.00016	+0.00009	94013	1.00e+00	+0.053	Não Rejeita H0 (Sem Diferença)
W...2	Ensino Médio vs. Ensino Fundamental II	0.00025	0.00008	+0.00016	103161	1.00e+00	+0.106	Não Rejeita H0 (Sem Diferença)
W...3	Ensino Médio vs. Ensino Superior	0.00025	0.00316	-0.00291	183130	1.39e-42	-0.595	Rejeita H0 (Diferença Sig.)

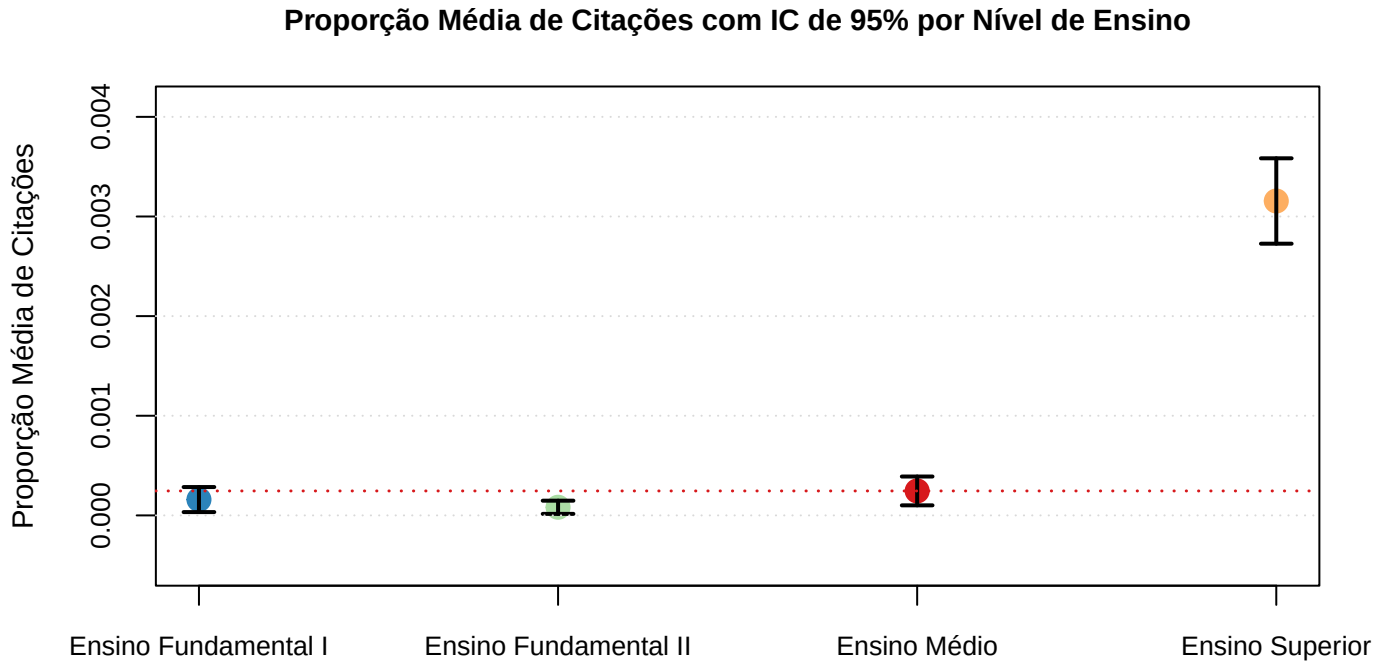
4.2.2 Contrastes Pareados na Quantidade Absoluta (`citacao_academica_qtd`)

Table 4: Comparações Pareadas: Ensino Médio vs. Demais Níveis (Quantidade de Citações)

	Comparação	Média Médio	Média Grupo	Diferença Médias	Estatística W	p-adj (Bonferroni)	Cohen d	Decisão (alpha=0.05)
W...1	Ensino Médio vs. Ensino Fundamental I	0.091	0.054	+0.037	94016	1.00e+00	+0.058	Não Rejeita H0 (Sem Diferença)
W...2	Ensino Médio vs. Ensino Fundamental II	0.091	0.034	+0.057	103150	1.00e+00	+0.093	Não Rejeita H0 (Sem Diferença)
W...3	Ensino Médio vs. Ensino Superior	0.091	1.339	-1.248	182959	8.67e-43	-0.608	Rejeita H0 (Diferença Sig.)

4.3 Gráfico de Médias com Intervalos de Confiança (95%)

A Figura 2 ilustra as médias da proporção de citações com IC de 95%. A linha tracejada destaca a média do Ensino Médio $(0,00025)$.



5 Conclusões e Implicações para o Modelo Classificador

A análise de Citações e Referenciação Acadêmica confirmou seu papel como **o discriminador mais potente entre Ensino Médio e Ensino Superior**:

1. **Ensino Fundamental I e II** $(0,00016$ **e** $0,00008)$**:**
   Praticamente ausência total de qualquer menção a anos bibliográficos ou notações acadêmicas.
2. **Ensino Médio** $(0,00025)$**:**
   Nível residual mínimo, restrito a raríssimas citações de repertório sociocultural em redações.
3. **Ensino Superior** $(0,00316)$**:**
   Apresenta uma média 13 **vezes superior à do Ensino Médio**, gerando um contraste de magnitude extraordinária ($p = 2,15 \times 10^{-38}$, Cohen's $d = -0,48$).

Nível Comparado	Decisão Estatística	Tamanho de Efeito	Utilidade no Classificador ALFA-Gen
Médio vs. Fund. I	Sem Diferença Relevante	Inexpressivo $(+0,04)$	Ambos possuem ausência basal de citações formais.
Médio vs. Fund. II	Sem Diferença Relevante	Inexpressivo $(+0,08)$	Ambos não empregam indexação ABNT.
Médio vs. Superior	**Diferença Massiva**	Alto $(-0,48$, $13\times$ maior)	**Elimina a confusão de Ensino Médio classificado como Superior!**

A Apêndice: Arquitetura Modular e Códigos das Funções

- `extrair_features_lote3.py`: Extração de padrões parentéticos, termos científicos e ABNT nos 2.076 arquivos.
- `R/funcoes_estatistica.R`: Rotinas modulares de análise descritiva, teste de Kruskal-Wallis e contrastes pareados.
- `R/funcoes_tabelas.R`: Tabelas padronizadas em LaTeX via `knitr::kable`.
- `R/funcoes_graficos.R`: Painéis gráficos 2×2 e gráficos de médias com IC de 95%.