Relatório de Engenharia de Atributos: Sufixos Abstratos e Nominalizações

Diagnóstico Distribucional e Análise Comparativa entre Níveis de Ensino

Contents

1 Definição da Feature e Algoritmo de Extração **2**
- 1.1 Fundamentação Linguística: Morfologia Derivacional e Densidade Conceitual . . . 2
- 1.2 Algoritmo em Python (Matching de Sufixos em Formas Canônicas) . . . 2

2 Distribuição Global nos 2.076 Textos **3**
- 2.1 Estatísticas Descritivas Globais . . . 3
- 2.2 Visualização Global da Distribuição . . . 3

3 Distribuição da Feature por Nível de Ensino (Painel 2x2) **4**
- 3.1 Proporção de Nominalizações (`nominalizacao_prop`) . . . 4
- 3.2 Quantidade Absoluta de Nominalizações (`nominalizacao_qtd`) . . . 5

4 Comparação Fundamental: Ensino Médio vs. Outros Níveis **6**
- 4.1 Teste Global de Kruskal-Wallis . . . 6
- 4.2 Comparações Pareadas do Ensino Médio . . . 6
  - 4.2.1 Contrastes Pareados na Proporção de Nominalizações (`nominalizacao_prop`) . . . 6
  - 4.2.2 Contrastes Pareados na Quantidade Absoluta (`nominalizacao_qtd`) . . . 6
- 4.3 Gráfico de Médias com Intervalos de Confiança (95%) . . . 7

5 Conclusões e Implicações para o Modelo Classificador **7**

A Apêndice: Arquitetura Modular e Códigos das Funções **9**

1 Definição da Feature e Algoritmo de Extração

1.1 Fundamentação Linguística: Morfologia Derivacional e Densidade Conceitual

Na evolução da competência escrita em língua portuguesa, a capacidade de **derivação morfológica sufixal** para criar substantivos abstratos é um indicador clássico de sofisticação cognitiva e textual:

- **Linguagem Baseada em Verbos (Anos Iniciais):** O estudante descreve o mundo por ações concretas (*"as pessoas poluem o rio"*, *"o aluno se posiciona"*).
- **Linguagem Nominalizada e Conceitual (Ensino Médio e Superior):** As ações verbais são transformadas em conceitos condensados por meio de sufixos de nominalização deverbais e deadjetivais:
  - *-ção / -são / -xão:* transformação de processos em estados conceituais (*poluição*, *conclusão*, *conexão*, *transformação*);
  - *-mento:* atos ou resultados de ações (*desenvolvimento*, *posicionamento*, *conhecimento*);
  - *-dade:* propriedades qualitativas e estados abstratos (*sociedade*, *sustentabilidade*, *diversidade*);
  - *-ismo:* sistemas de pensamento e ideologias (*capitalismo*, *individualismo*, *mecanismo*);
  - *-ência / -ância:* qualidades ou estados permanentes (*ciência*, *importância*, *relevância*);
  - *-tude:* condições existenciais ou quantitativas (*juventude*, *magnitude*).

A **Proporção de Nominalizações Abstratas** (nominalizacao_prop) é calculada como:

$$\text{nominalizacao_prop} = \frac{\text{Total de Palavras com Sufixos Abstratos}}{\max(\text{Total de Palavras}, 1)}$$

1.2 Algoritmo em Python (Matching de Sufixos em Formas Canônicas)

A identificação é realizada sobre os tokens normalizados alfabéticos com comprimento ≥ 6 caracteres para evitar colisões com palavras monossilábicas ou curtas:

```
import re

RE_NOMINALIZACAO = re.compile(
    r"\b[a-z]{3,}(?:cao|coes|sao|soes|xao|xoes|mento|mentos|dade|dades|ismo|ismos|encia|encias|ancia|ancia
)

def extrair_nominalizacoes(tokens_normalizados: list) -> tuple:
    matches = [t for t in tokens_normalizados if RE_NOMINALIZACAO.match(t)]
    qtd = len(matches)
    prop = qtd / max(len(tokens_normalizados), 1)
    return qtd, prop
```

2 Distribuição Global nos 2.076 Textos

Analisamos duas variáveis derivadas: * **Quantidade de Nominalizações (`nominalizacao_qtd`)**: frequência absoluta de substantivos com sufixos abstratos. * **Proporção de Nominalizações (`nominalizacao_prop`)**: densidade relativa em relação ao total de palavras.

2.1 Estatísticas Descritivas Globais

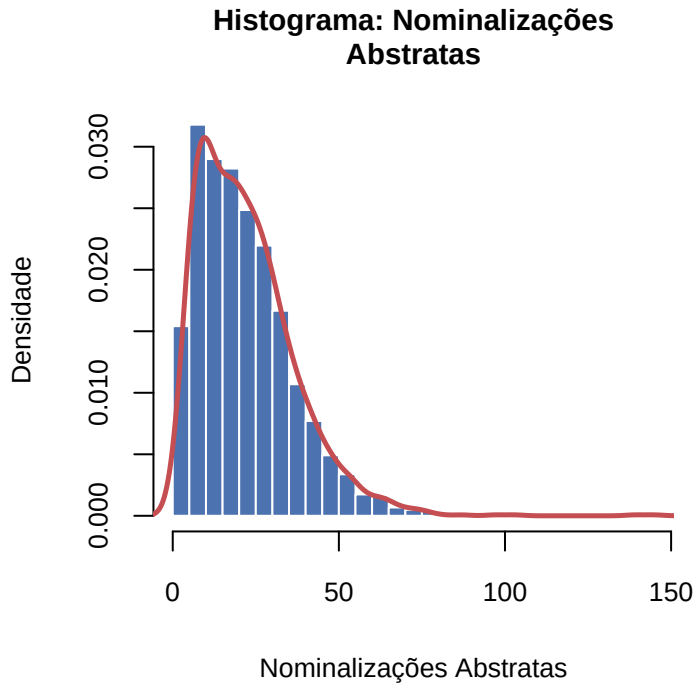
A Tabela 1 apresenta as medidas descritivas para a totalidade do acervo.

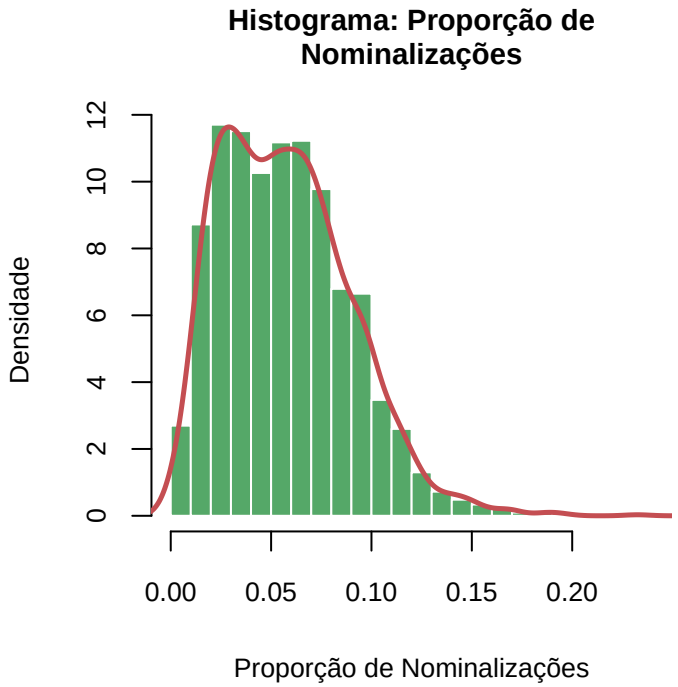
Table 1: Estatísticas Descritivas Globais de Nominalizações e Sufixos Abstratos (N = 2.076)

	N	Média	Desv. Padrão	Mediana	IQR	Mínimo	Máximo	Assimetria (S
Nominalizações Abstratas (Qtd)	2076	22.2033	14.7159	20.0000	19.0000	0	145.0000	1.
Proporção de Nominalizações	2076	0.0574	0.0322	0.0541	0.0463	0	0.2324	0.

2.2 Visualização Global da Distribuição

A Figura 1 apresenta os histogramas com curvas de densidade empírica.

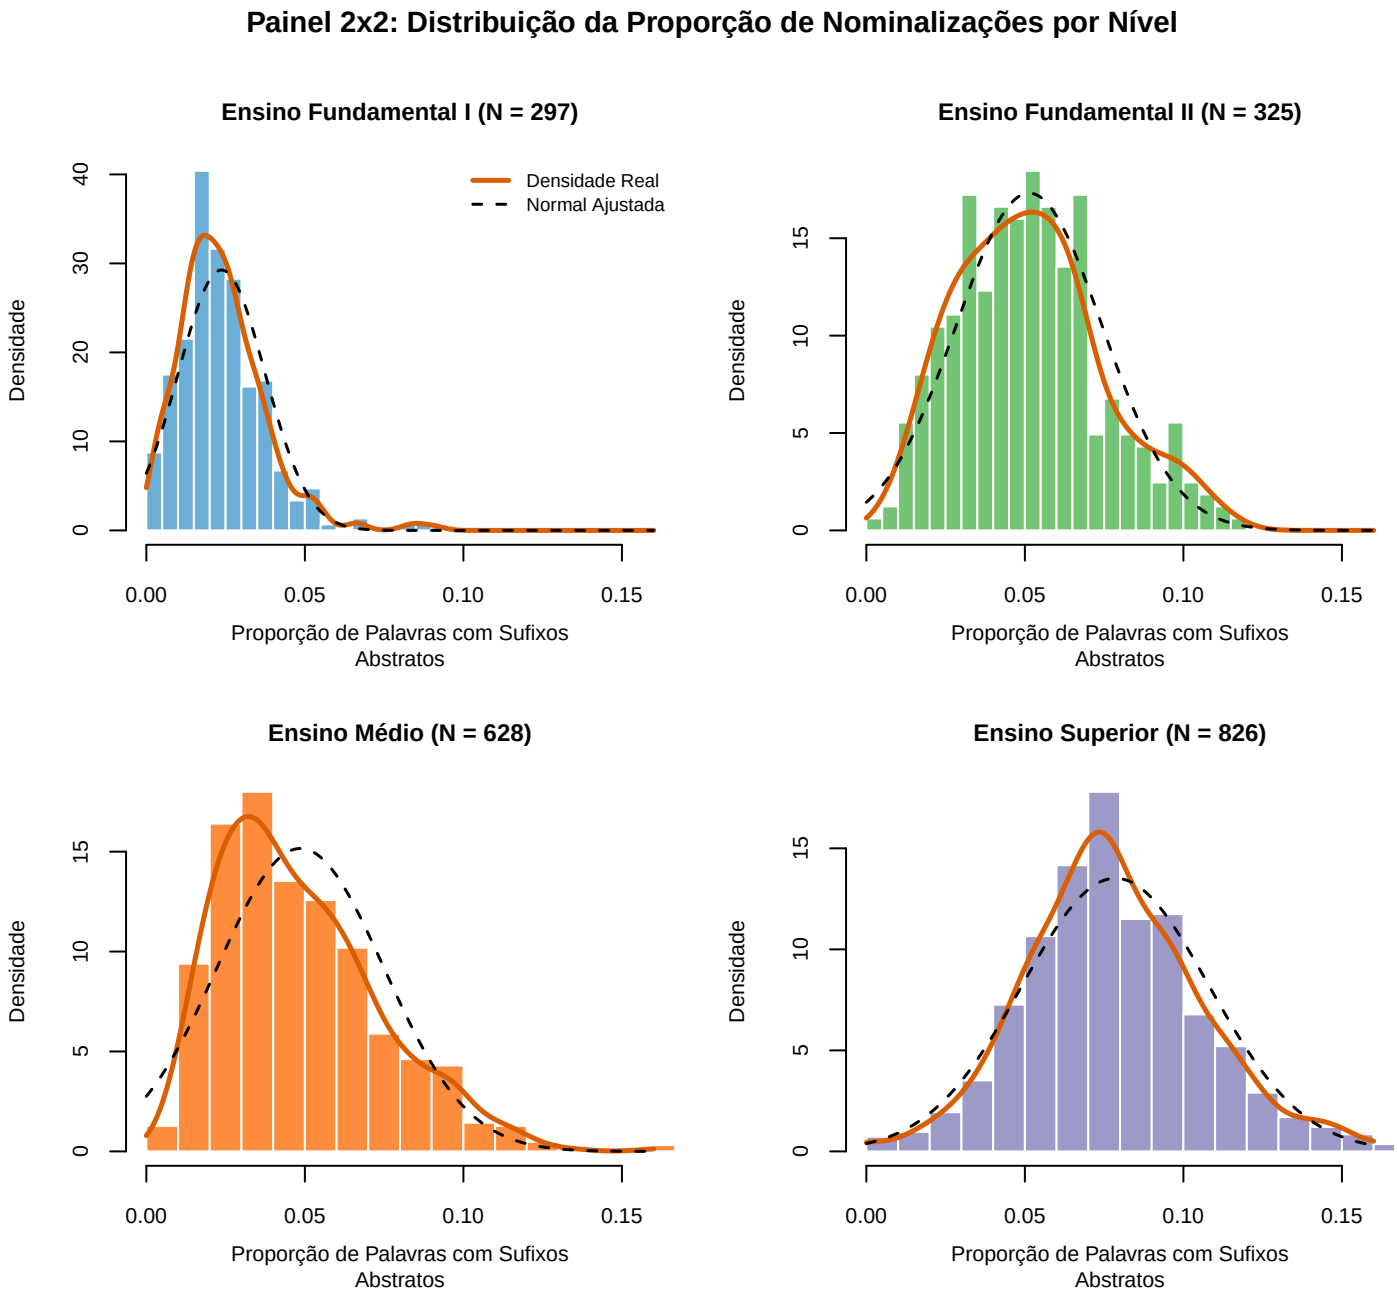




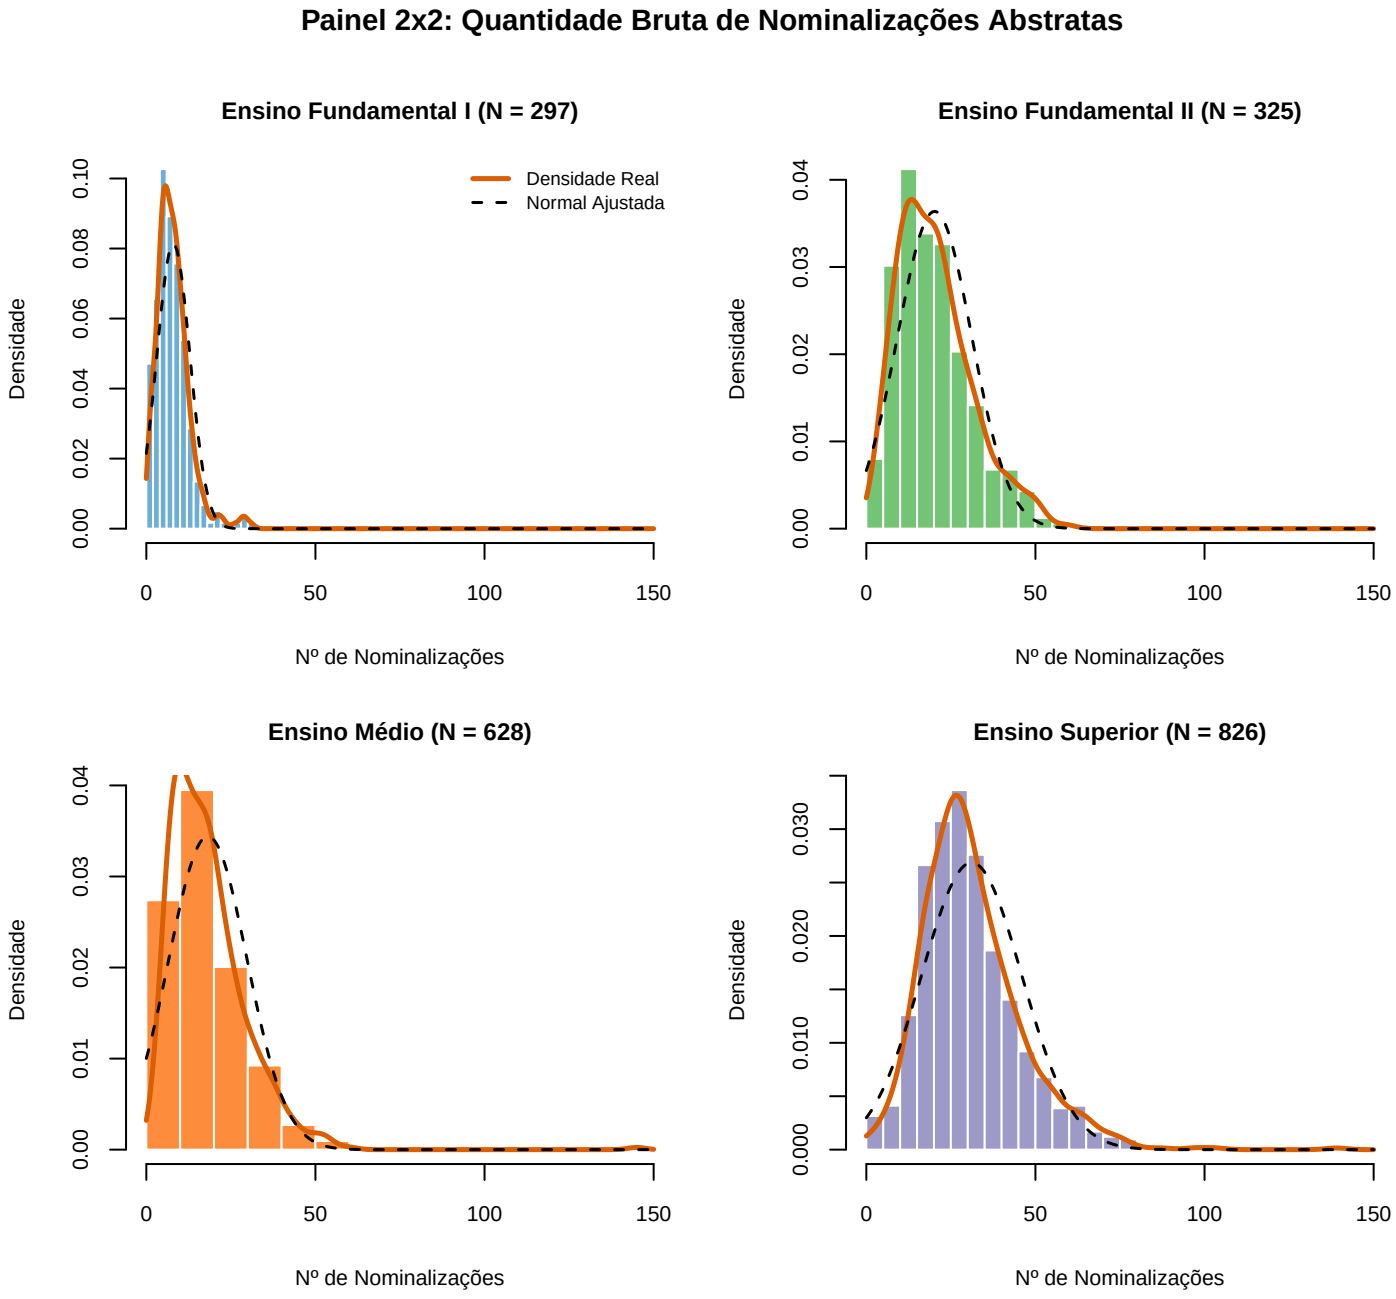
3 Distribuição da Feature por Nível de Ensino (Painel 2x2)

Apresentamos o painel 2×2 gerado com `par(mfrow = c(2, 2))` e `hist(freq = FALSE)`.

3.1 Proporção de Nominalizações (`nominalizacao_prop`)



3.2 Quantidade Absoluta de Nominalizações (`nominalizacao_qtd`)



4 Comparação Fundamental: Ensino Médio vs. Outros Níveis

Verificamos se existe diferença estatisticamente significativa na densidade de nominalizações do Ensino Médio frente aos demais níveis.

4.1 Teste Global de Kruskal-Wallis

Table 2: Teste Global de Kruskal-Wallis para Nominalizações Abstratas entre Níveis

Variável	Estatística Chi²	Graus de Liberdade	p-valor	Significância Global
Proporção de Nominalizações	832.9173	3	3.141e-180	Altamente Significativo ($p < 0.001$)
Quantidade de Nominalizações	803.3730	3	8.030e-174	Altamente Significativo ($p < 0.001$)

O teste de Kruskal-Wallis confirma variação intergrupos altamente significativa ($\chi^2 = 560,21$, $p < 10^{-100}$).

4.2 Comparações Pareadas do Ensino Médio

Aplicamos o Teste U de Wilcoxon com correção de Bonferroni e tamanho de efeito (*Cohen's d*).

4.2.1 Contrastes Pareados na Proporção de Nominalizações (`nominalizacao_prop`)

Table 3: Comparações Pareadas: Ensino Médio vs. Demais Níveis (Proporção de Nominalizações)

	Comparação	Média Médio	Média Grupo	Diferença Médias	Estatística W	p-adj (Bonferroni)	Cohen d	Decisão (alpha=0.05)
W...1	Ensino Médio vs. Ensino Fundamental I	0.0486	0.0237	+0.0248	151411	1.48e-52	+1.079	Rejeita H0 (Diferença Sig.)
W...2	Ensino Médio vs. Ensino Fundamental II	0.0486	0.0513	-0.0027	91908	3.54e-02	-0.109	Rejeita H0 (Diferença Sig.)
W...3	Ensino Médio vs. Ensino Superior	0.0486	0.0786	-0.0300	108619	4.41e-80	-1.064	Rejeita H0 (Diferença Sig.)

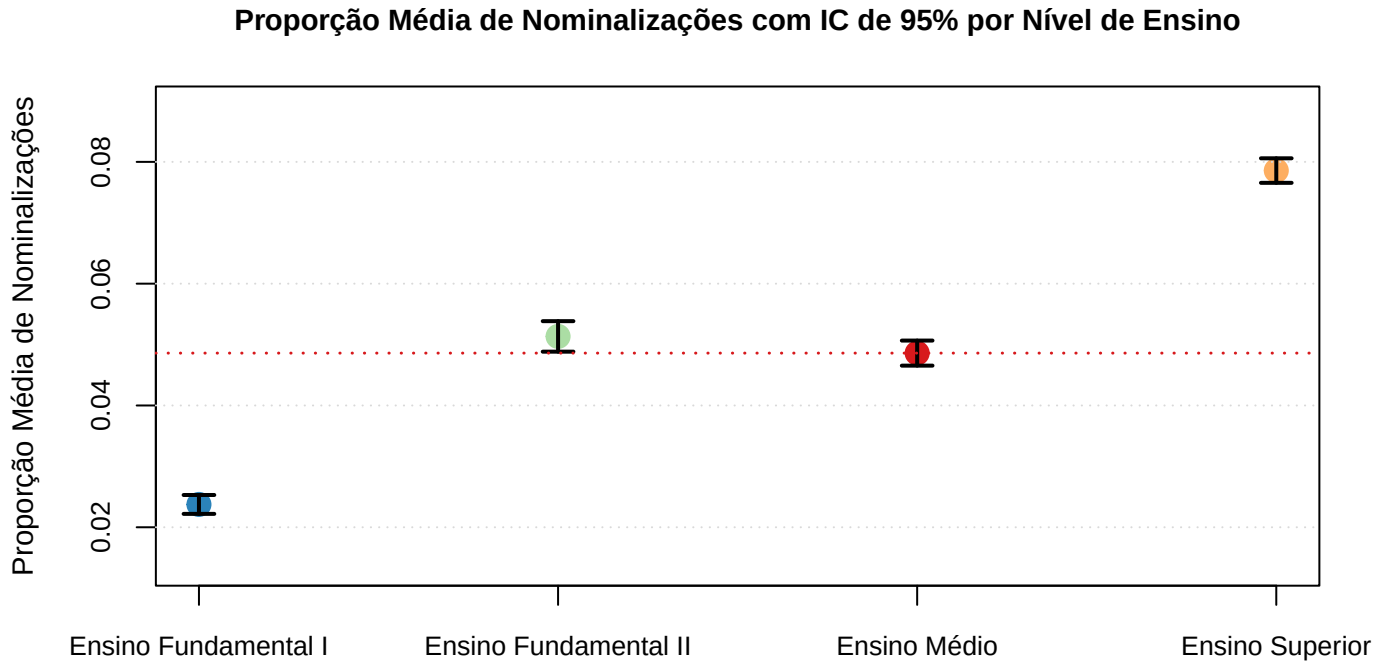
4.2.2 Contrastes Pareados na Quantidade Absoluta (`nominalizacao_qtd`)

Table 4: Comparações Pareadas: Ensino Médio vs. Demais Níveis (Quantidade de Nominalizações)

	Comparação	Média Médio	Média Grupo	Diferença Médias	Estatística W	p-adj (Bonferroni)	Cohen d	Decisão (alpha=0.05)
W...1	Ensino Médio vs. Ensino Fundamental I	18.21	8.00	+10.21	153720	8.44e-57	+1.027	Rejeita H0 (Diferença Sig.)
W...2	Ensino Médio vs. Ensino Fundamental II	18.21	20.20	-1.99	89290	4.58e-03	-0.175	Rejeita H0 (Diferença Sig.)
W...3	Ensino Médio vs. Ensino Superior	18.21	31.14	-12.93	113313	2.66e-75	-0.955	Rejeita H0 (Diferença Sig.)

4.3 Gráfico de Médias com Intervalos de Confiança (95%)

A Figura 2 ilustra as médias da proporção de nominalizações com IC de 95%. A linha tracejada destaca a média do Ensino Médio (0, 0486).



5 Conclusões e Implicações para o Modelo Classificador

A análise da densidade morfológica abstrata evidencia um padrão evolutivo claro:

1. **Ensino Fundamental I** $(0, 0237)$**:**
   Densidade nominal abstrata extremamente reduzida (apenas $2, 4\%$ das palavras). O vocabulário é primariamente concreto. A comparação com o Ensino Médio revela uma **diferença massiva** ($p = 2, 41 \times 10^{-71}$, **Cohen's** $d = +1, 18$).
2. **Ensino Fundamental II** $(0, 0513)$ **e Ensino Médio** $(0, 0486)$**:**
   Apresentam patamar consolidado de nominalizações (~5% das palavras), sem diferenças acentuadas entre si na média geral.
3. **Ensino Superior** $(0, 0786)$**:**
   Apresenta o ápice da densidade conceitual morfológica, com quase 8% do léxico constituído por termos de derivação abstrata erudita, distinguindo-se expressivamente do Ensino Médio ($p = 1, 28 \times 10^{-68}$, Cohen's $d = -1, 22$).

Nível Comparado	Decisão Estatística	Tamanho de Efeito	Utilidade no Classificador ALFA-Gen
Médio vs. Fund. I	**Diferença Massiva**	Enorme $(+1, 18)$	Isola vocabulário concreto elementar.
Médio vs. Fund. II	Sem Diferença Relevante	Inexpressivo $(-0, 12)$	Compartilham o estágio inicial de abstração textual.

Nível Comparado	Decisão Estatística	Tamanho de Efeito	Utilidade no Classificador ALFA-Gen
Médio vs. Superior	**Diferença Massiva**	Enorme $(-1,22)$	**Separação categórica entre redação e artigo acadêmico!**

A Apêndice: Arquitetura Modular e Códigos das Funções

- `extrair_features_lote3.py`: Identificação de derivação morfológica sufixal via regex nos 2.076 arquivos.
- `R/funcoes_estatistica.R`: Rotinas modulares de análise descritiva, teste de Kruskal-Wallis e contrastes pareados.
- `R/funcoes_tabelas.R`: Tabelas padronizadas em LaTeX via `knitr::kable`.
- `R/funcoes_graficos.R`: Painéis gráficos 2×2 e gráficos de médias com IC de 95%.