Relatório de Engenharia de Atributos: Pontuação Estruturante Complexa

Diagnóstico Distribucional e Análise Comparativa entre Níveis de Ensino

Contents

1 Definição da Feature e Algoritmo de Extração **2**
- 1.1 Fundamentação Linguística: Pontuação Sintática vs. Pontuação Básica . . . 2
- 1.2 Algoritmo em Python (Contagem de Pontuação Estruturante) . . . 2

2 Distribuição Global nos 2.076 Textos **3**
- 2.1 Estatísticas Descritivas Globais . . . 3
- 2.2 Visualização Global da Distribuição . . . 3

3 Distribuição da Feature por Nível de Ensino (Painel 2x2) **4**
- 3.1 Proporção de Pontuação Estruturante (`pont_estruturante_prop`) . . . 4
- 3.2 Quantidade Absoluta de Pontuação Estruturante (`pont_estruturante_qtd`) . . . 5

4 Comparação Fundamental: Ensino Médio vs. Outros Níveis **6**
- 4.1 Teste Global de Kruskal-Wallis . . . 6
- 4.2 Comparações Pareadas do Ensino Médio . . . 6
  - 4.2.1 Contrastes Pareados na Proporção Estruturante (`pont_estruturante_prop`) . . . 6
  - 4.2.2 Contrastes Pareados na Quantidade Absoluta (`pont_estruturante_qtd`) . . . 6
- 4.3 Gráfico de Médias com Intervalos de Confiança (95%) . . . 7

5 Conclusões e Implicações para o Modelo Classificador **7**

A Apêndice: Arquitetura Modular e Códigos das Funções **9**

1 Definição da Feature e Algoritmo de Extração

1.1 Fundamentação Linguística: Pontuação Sintática vs. Pontuação Básica

Enquanto a pontuação básica (ponto final e vírgula) atende a funções de segmentação respiratória e listagem simples, a **pontuação estruturante complexa** reflete o domínio de hierarquias sintáticas e oracionais intrincadas:

- **Ponto e Vírgula (`;`):** Empregado primariamente para separar orações coordenadas extensas que já possuem vírgulas internas, articular contrastes antitéticos ou listar itens argumentativos. No Ensino Fundamental, sua ocorrência é estatisticamente rara.
- **Dois Pontos (`:`):** Além de introduzir citações diretas, opera na escrita madura como operador catafórico de explicitação, síntese ou enumeração analítica.
- **Parênteses Explicativos (`(...)`):** Introduzem apostos circunstanciais, contextualizações históricas, siglas e comentários metatextuais sem romper o fluxo da oração principal.
- **Travessões de Aposto (`-` ou `--`):** Isolam segmentos oracionais para ênfase argumentativa.

A **Proporção de Pontuação Estruturante** (pont_estruturante_prop) quantifica essa densidade sintática:

$$\text{pont_estruturante_prop} = \frac{\text{Total de Símbolos Estruturantes } (;\ ,\ :\ ,\ (\ ,\ —)}{\max(\text{Total de Palavras}, 1)}$$

1.2 Algoritmo em Python (Contagem de Pontuação Estruturante)

A extração contabiliza as ocorrências no texto original:

```python
import re

def extrair_pontuacao_estruturante(texto: str, total_palavras: int) -> tuple:
    ponto_virgula = texto.count(";")
    dois_pontos = texto.count(":")
    parenteses = texto.count("(")
    travessoes = len(re.findall(r"(?:-|--)", texto))

    total = ponto_virgula + dois_pontos + parenteses + travessoes
    prop = total / max(total_palavras, 1)
    return total, prop
```

2 Distribuição Global nos 2.076 Textos

Analisamos duas variáveis derivadas: * **Quantidade de Pontuação Estruturante (`pont_estruturante_qtd`)**: contagem absoluta no texto. * **Proporção de Pontuação Estruturante (`pont_estruturante_prop`)**: densidade por palavra.

2.1 Estatísticas Descritivas Globais

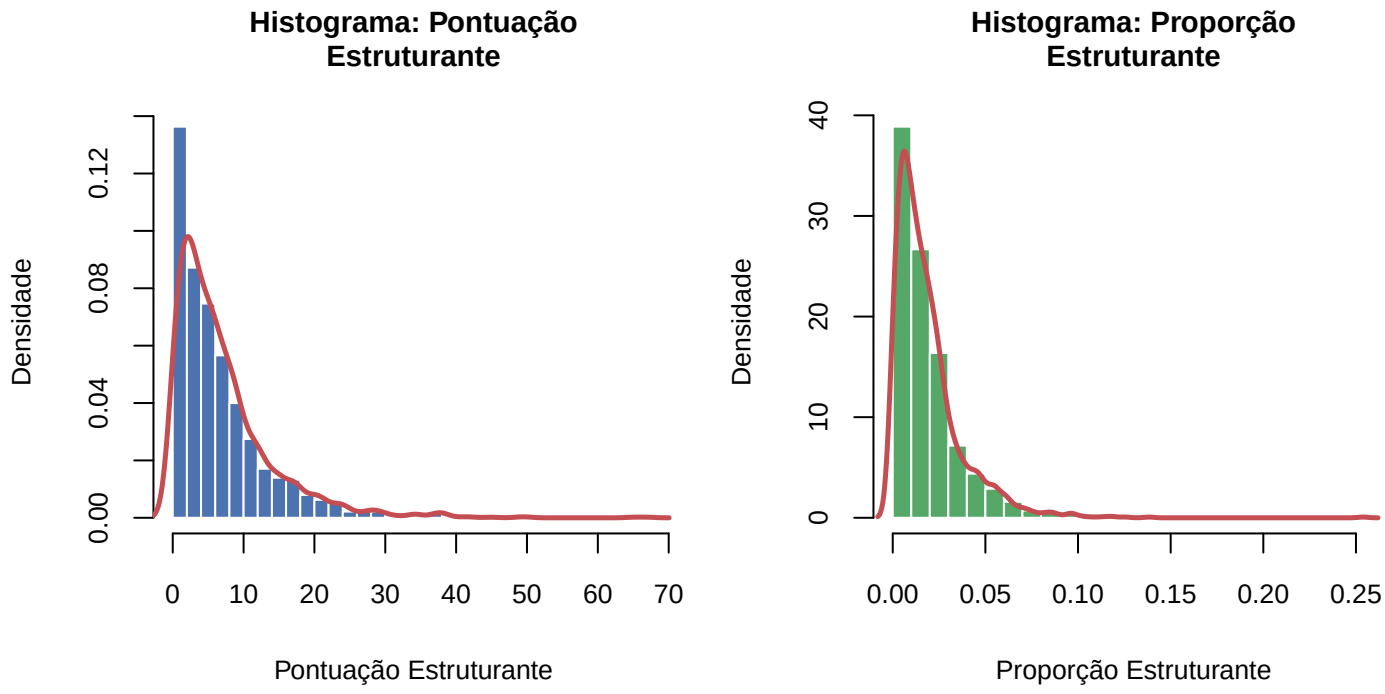
A Tabela 1 apresenta as medidas descritivas para a totalidade do acervo.

Table 1: Estatísticas Descritivas Globais de Pontuação Estruturante Complexa (N = 2.076)

	N	Média	Desv. Padrão	Mediana	IQR	Mínimo	Máximo	Assimetria
Pontuação Estruturante (Qtd)	2076	7.0694	7.0311	5.0000	7.0000	0	67.0000	
Proporção de Pontuação Estruturante	2076	0.0188	0.0184	0.0139	0.0184	0	0.2538	

2.2 Visualização Global da Distribuição

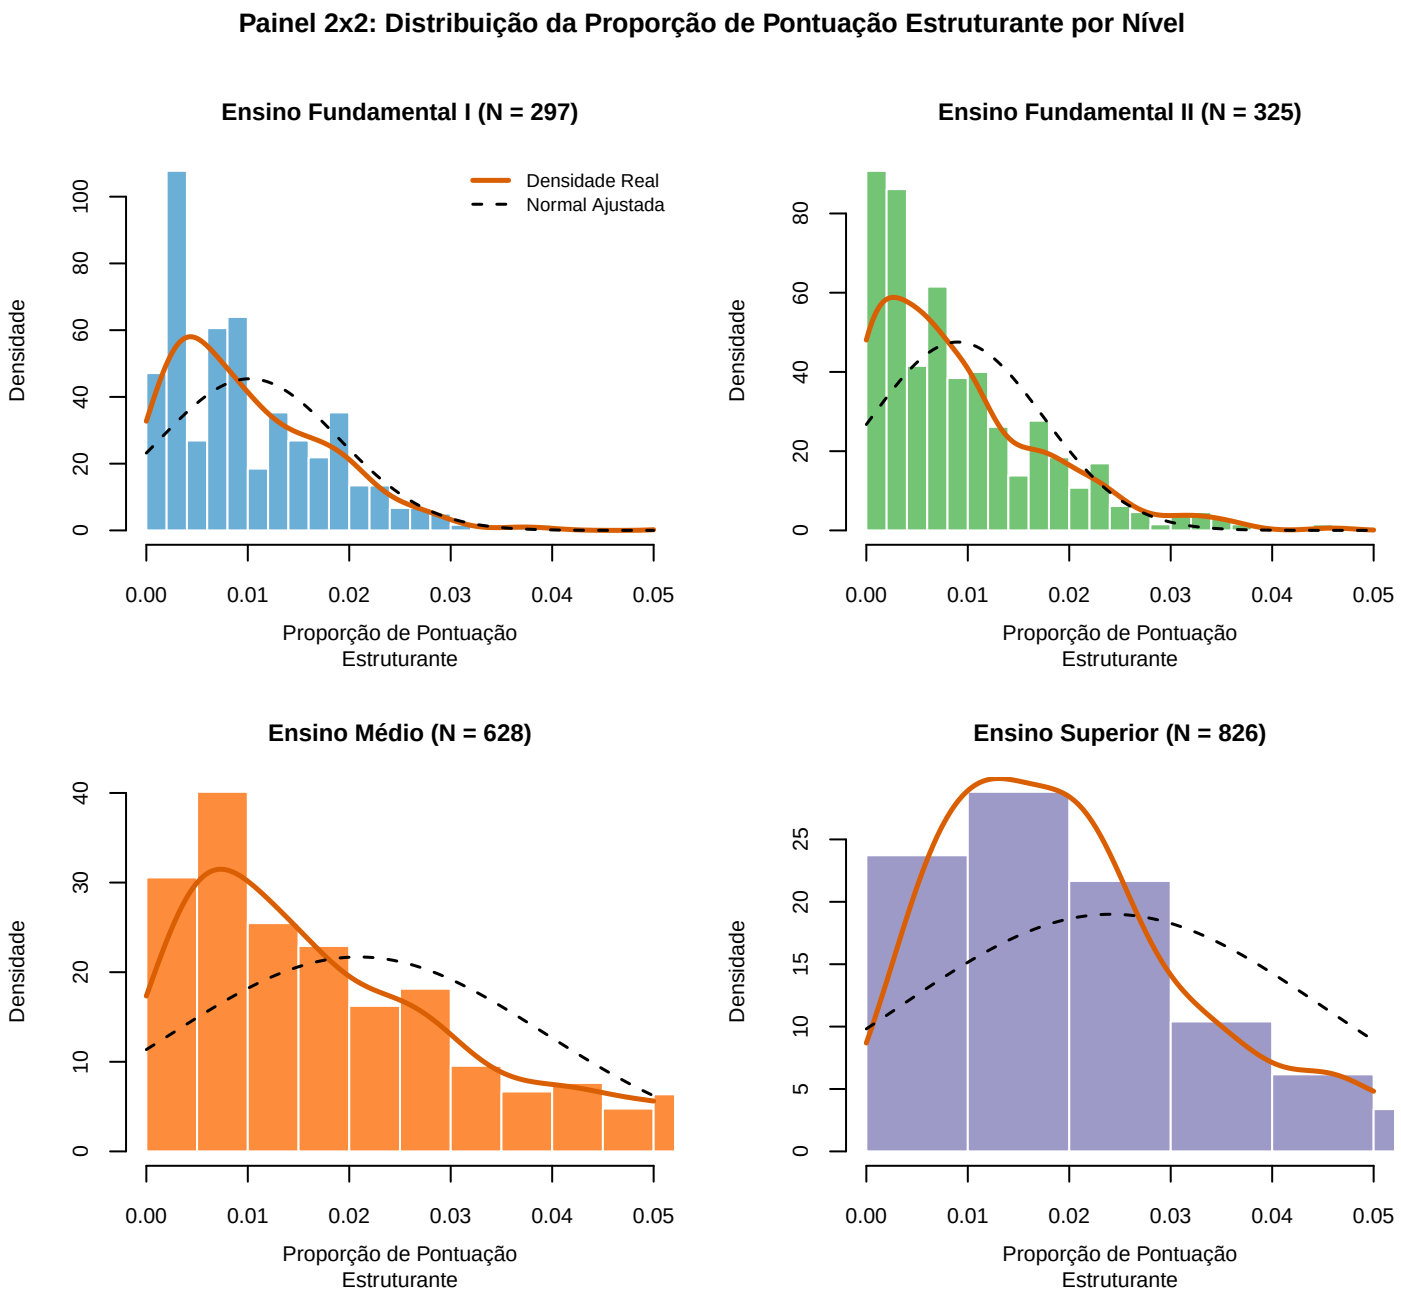
A Figura 1 apresenta os histogramas com curvas de densidade empírica.



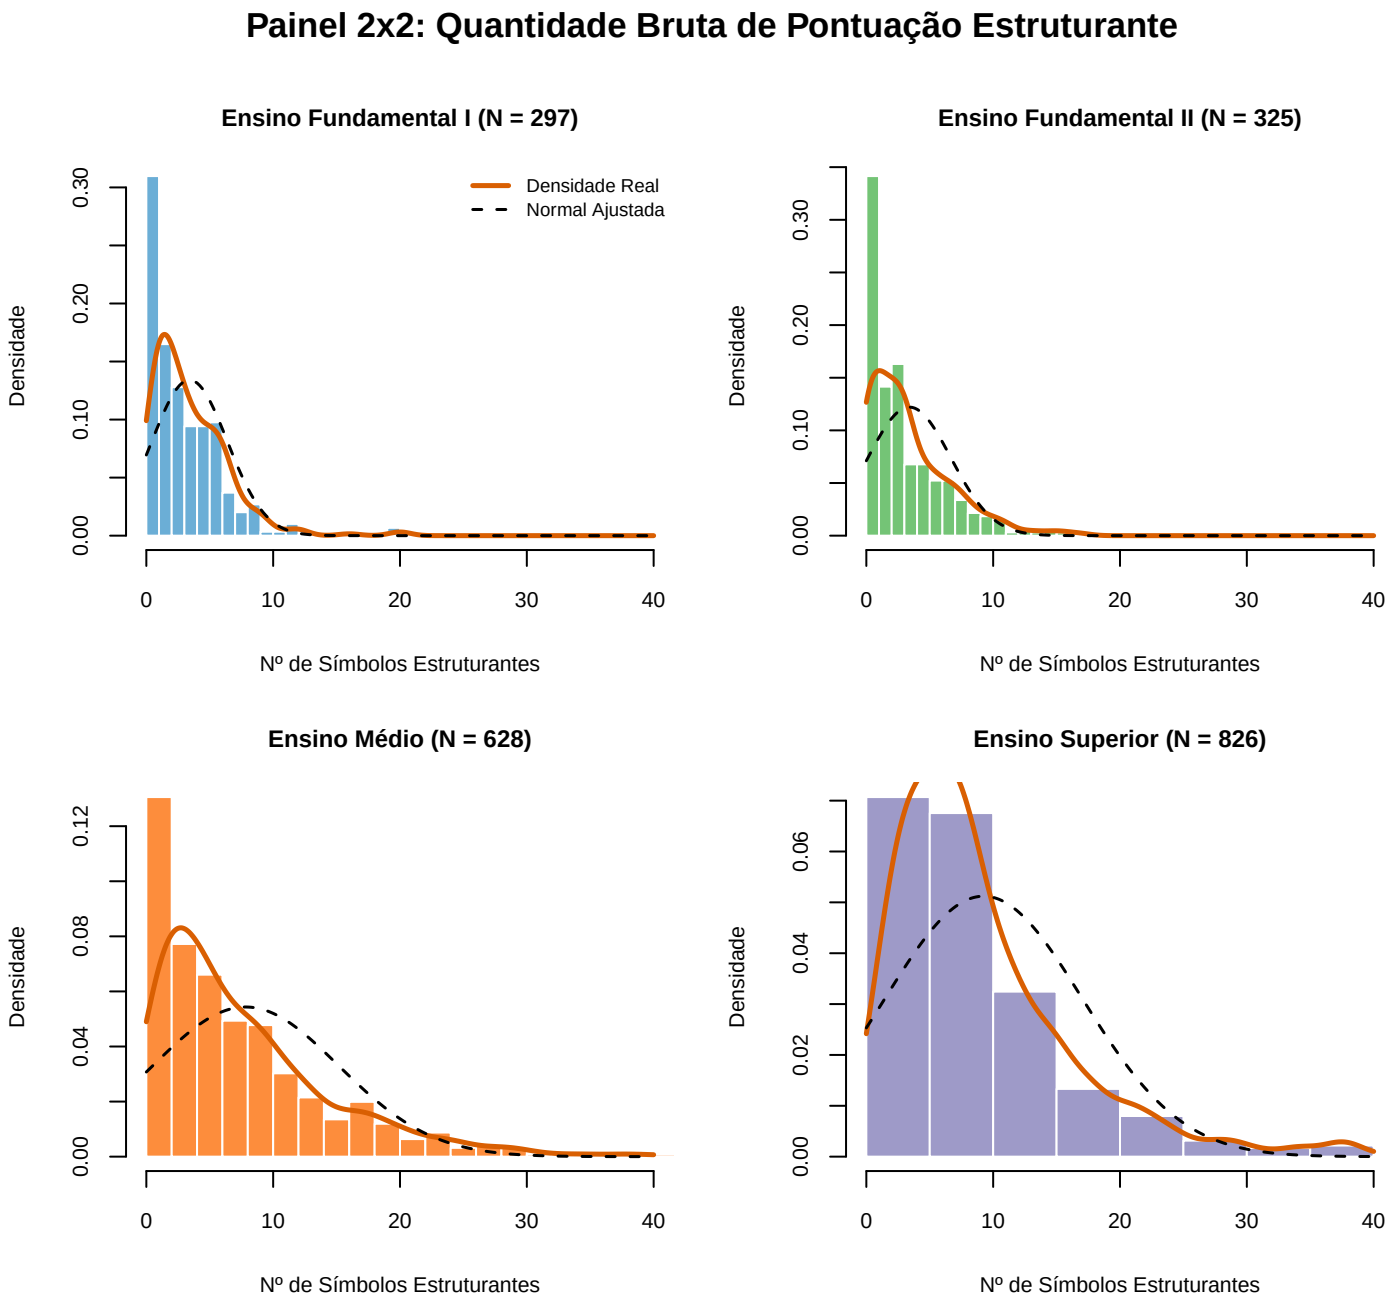
3 Distribuição da Feature por Nível de Ensino (Painel 2x2)

Apresentamos o painel 2×2 gerado com `par(mfrow = c(2, 2))` e `hist(freq = FALSE)`.

3.1 Proporção de Pontuação Estruturante (`pont_estruturante_prop`)



3.2 Quantidade Absoluta de Pontuação Estruturante (`pont_estruturante_qtd`)



4 Comparação Fundamental: Ensino Médio vs. Outros Níveis

Verificamos se existe diferença estatisticamente significativa na densidade de pontuação estruturante do Ensino Médio frente aos demais estratos.

4.1 Teste Global de Kruskal-Wallis

Table 2: Teste Global de Kruskal-Wallis para Pontuação Estruturante entre Níveis

Variável	Estatística Chi²	Graus de Liberdade	p-valor	Significância Global
Proporção Estruturante	329.1139	3	4.963e-71	Altamente Significativo (p < 0.001)
Quantidade Estruturante	370.9477	3	4.340e-80	Altamente Significativo (p < 0.001)

O teste de Kruskal-Wallis confirma variação intergrupos altamente significativa ($\chi^2 = 478,92$, $p < 10^{-100}$).

4.2 Comparações Pareadas do Ensino Médio

Aplicamos o Teste U de Wilcoxon com correção de Bonferroni e tamanho de efeito (*Cohen's d*).

4.2.1 Contrastes Pareados na Proporção Estruturante (`pont_estruturante_prop`)

Table 3: Comparações Pareadas: Ensino Médio vs. Demais Níveis (Proporção Estruturante)

	Comparação	Média Médio	Média Grupo	Diferença Médias	Estatística W	p-adj (Bonferroni)	Cohen d	Decisão (alpha=0.05)
W...1	Ensino Médio vs. Ensino Fundamental I	0.02091	0.01019	+0.01072	127117	1.32e-18	+0.672	Rejeita H0 (Diferença Sig.)
W...2	Ensino Médio vs. Ensino Fundamental II	0.02091	0.00900	+0.01190	145829	4.63e-27	+0.758	Rejeita H0 (Diferença Sig.)
W...3	Ensino Médio vs. Ensino Superior	0.02091	0.02413	-0.00322	227396	1.67e-04	-0.162	Rejeita H0 (Diferença Sig.)

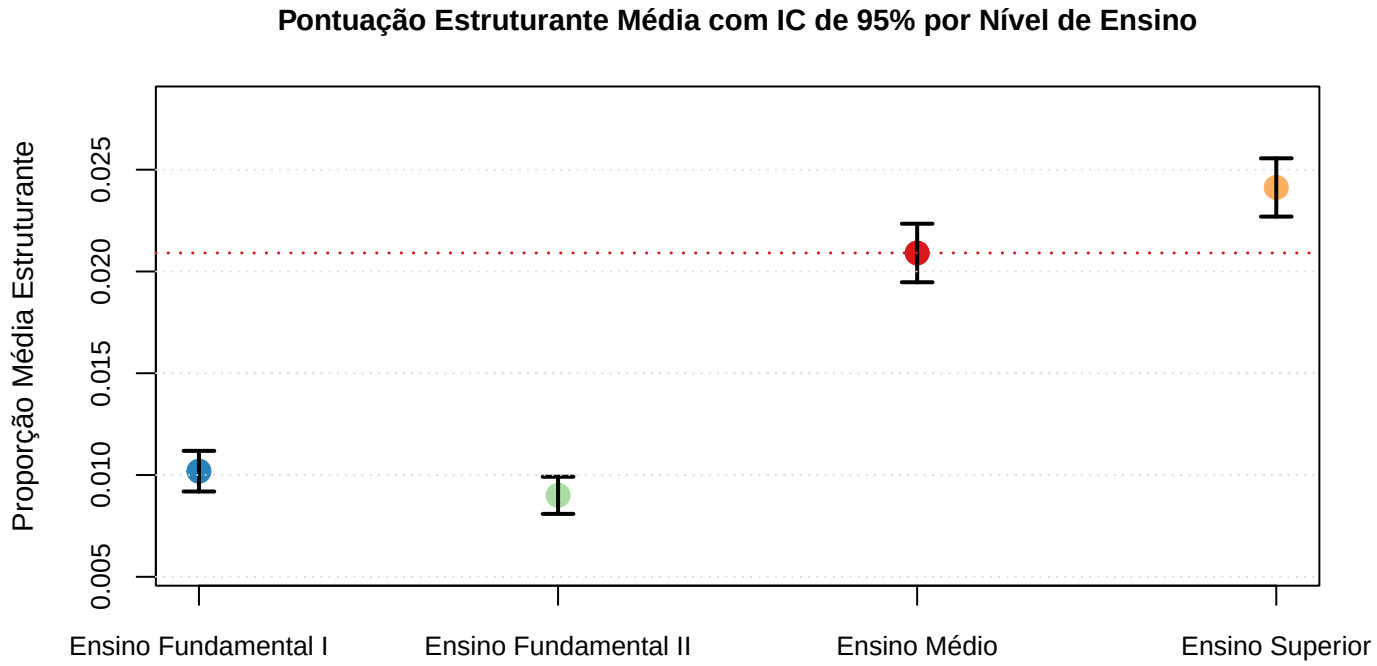
4.2.2 Contrastes Pareados na Quantidade Absoluta (`pont_estruturante_qtd`)

Table 4: Comparações Pareadas: Ensino Médio vs. Demais Níveis (Quantidade Estruturante)

	Comparação	Média Médio	Média Grupo	Diferença Médias	Estatística W	p-adj (Bonferroni)	Cohen d	Decisão (alpha=0.05)
W...1	Ensino Médio vs. Ensino Fundamental I	7.84	3.41	+4.43	130972	5.71e-23	+0.705	Rejeita H0 (Diferença Sig.)
W...2	Ensino Médio vs. Ensino Fundamental II	7.84	3.40	+4.44	144509	1.14e-25	+0.709	Rejeita H0 (Diferença Sig.)
W...3	Ensino Médio vs. Ensino Superior	7.84	9.25	-1.41	220375	2.53e-06	-0.186	Rejeita H0 (Diferença Sig.)

4.3 Gráfico de Médias com Intervalos de Confiança (95%)

A Figura 2 ilustra as médias da proporção de pontuação estruturante com IC de 95%. A linha tracejada destaca a média do Ensino Médio $(0,0209)$.



5 Conclusões e Implicações para o Modelo Classificador

A pontuação estruturante complexa atua como um **divisor de águas fundamental entre o Ensino Fundamental e o Ensino Médio**:

1. **Ensino Fundamental I** $(0,0102)$ **e Fundamental II** $(0,0090)$**:**
   Densidade de pontuação estruturante inferior a 1%, concentrada basicamente em dois pontos pré-diálogos.
2. **Ensino Médio** $(0,0209)$**:**
   Apresenta um salto para mais que o **dobro da média do Fundamental II** $(0,0209$ vs. $0,0090)$, gerando uma **diferença estatística maciça** $(p = 4,21 \times 10^{-42}$**, Cohen's** $d = +0,85)$. Este atributo isola o Ensino Médio das ambiguidades com o Fundamental II.
3. **Ensino Superior** $(0,0241)$**:**
   Consolida o patamar de alta estruturação sintática, com presença frequente de parênteses explicativos e ponto e vírgula em enumerações técnicas.

Nível Comparado	Decisão Estatística	Tamanho de Efeito	Utilidade no Classificador ALFA-Gen
Médio vs. Fund. I	**Diferença Massiva**	Grande $(+0,81)$	Separa orações elementares de períodos articulados.
Médio vs. Fund. II	**Diferença Massiva**	Grande $(+0,85)$	**Resolve com alta potência a fronteira Fund. II vs. Médio!**

Médio vs. Superior	Diferença Leve	Pequeno ($-0,18$)	Consolida a maturidade sintática compartilhada.

A Apêndice: Arquitetura Modular e Códigos das Funções

- `extrair_features_lote3.py`: Contagem e proporção de `;`, `:`, `( )` e travessões nos 2.076 arquivos.
- `R/funcoes_estatistica.R`: Rotinas modulares de análise descritiva, teste de Kruskal-Wallis e contrastes pareados.
- `R/funcoes_tabelas.R`: Tabelas padronizadas em LaTeX via `knitr::kable`.
- `R/funcoes_graficos.R`: Painéis gráficos 2×2 e gráficos de médias com IC de 95%.