# Relatório de Engenharia de Atributos: Densidade de Pessoalidade (1ª Pessoa)

Diagnóstico Distribucional e Análise Comparativa entre Níveis de Ensino

## Contents


**1 Definição da Feature e Algoritmo de Extração** **2**
- 1.1 Fundamentação Linguística: Enunciação Pessoal vs. Impessoalização Dissertativa . . . 2
- 1.2 Algoritmo em Python (Léxico Fechado de Formas Pronominais de 1ª Pessoa) . . . 2

**2 Distribuição Global nos 2.076 Textos** **3**
- 2.1 Estatísticas Descritivas Globais . . . 3
- 2.2 Visualização Global da Distribuição . . . 3

**3 Distribuição da Feature por Nível de Ensino (Painel 2x2)** **4**
- 3.1 Proporção de Pessoalidade (`pessoalidade_prop`) . . . 4
- 3.2 Quantidade Absoluta de Marcas de Pessoalidade (`pessoalidade_qtd`) . . . 5

**4 Comparação Fundamental: Ensino Médio vs. Outros Níveis** **6**
- 4.1 Teste Global de Kruskal-Wallis . . . 6
- 4.2 Comparações Pareadas do Ensino Médio . . . 6
  - 4.2.1 Contrastes Pareados na Proporção de Pessoalidade (`pessoalidade_prop`) . . . 6
  - 4.2.2 Contrastes Pareados na Quantidade Absoluta (`pessoalidade_qtd`) . . . 6
- 4.3 Gráfico de Médias com Intervalos de Confiança (95%) . . . 7

**5 Conclusões e Implicações para o Modelo Classificador** **7**

**A Apêndice: Arquitetura Modular e Códigos das Funções** **8**

# 1 Definição da Feature e Algoritmo de Extração

## 1.1 Fundamentação Linguística: Enunciação Pessoal vs. Impessoalização Dissertativa

A gestão da voz enunciativa constitui um dos parâmetros primordiais do desenvolvimento da escrita escolar (Biber, 1988; Bronckart, 1999):

- **Foco Egocêntrico e Narrativo (Fundamental I e II):** Nos anos iniciais da alfabetização e letramento, o estudante expressa-se através de relatos pessoais, memórias, cartas e crônicas autobiográficas. A narrativa apoia-se em pronomes de 1ª pessoa do singular e do plural (*eu*, *me*, *meu*, *minha*, *nós*, *nosso*).
- **Impessoalização Canônica (Ensino Médio e Superior):** A partir do Ensino Médio, a matriz curricular brasileira impõe a impessoalização do discurso dissertativo-argumentativo (padrão ENEM, vestibulares e normas científicas ABNT). O uso da 1ª pessoa do singular é explicitamente desestimulado, exigindo-se construções apassivadoras e pronominais de 3ª pessoa (*observa-se*, *constata-se*, *deve-se combater*).

A **Densidade de Pessoalidade** (pessoalidade_prop) quantifica a frequência relativa de marcas pronominais de 1ª pessoa:

$$\text{pessoalidade_prop} = \frac{\text{Total de Pronomes de 1ª Pessoa (Retos, Oblíquos e Possessivos)}}{\max(\text{Total de Palavras}, 1)}$$

## 1.2 Algoritmo em Python (Léxico Fechado de Formas Pronominais de 1ª Pessoa)

A extração identifica o conjunto exato de formas pronominais de 1ª pessoa sobre tokens normalizados:

- **Singular:** *eu*, *me*, *mim*, *comigo*, *meu*, *meus*, *minha*, *minhas*;
- **Plural:** *nós*, *nos*, *conosco*, *nosso*, *nossos*, *nossa*, *nossas*.

```python
PRONOMES_1P = {
    "eu", "me", "mim", "comigo", "meu", "meus", "minha", "minhas",
    "nos", "conosco", "nosso", "nossos", "nossa", "nossas"
}

def extrair_pessoalidade(tokens_norm: list) -> tuple:
    matches = [t for t in tokens_norm if t in PRONOMES_1P]
    qtd = len(matches)
    prop = qtd / max(len(tokens_norm), 1)
    return qtd, prop
```

# 2 Distribuição Global nos 2.076 Textos

Analisamos duas variáveis derivadas: * **Quantidade de Marcas de Pessoalidade (`pessoalidade_qtd`)**: frequência absoluta no texto. * **Proporção de Pessoalidade (`pessoalidade_prop`)**: densidade relativa por palavra.

## 2.1 Estatísticas Descritivas Globais

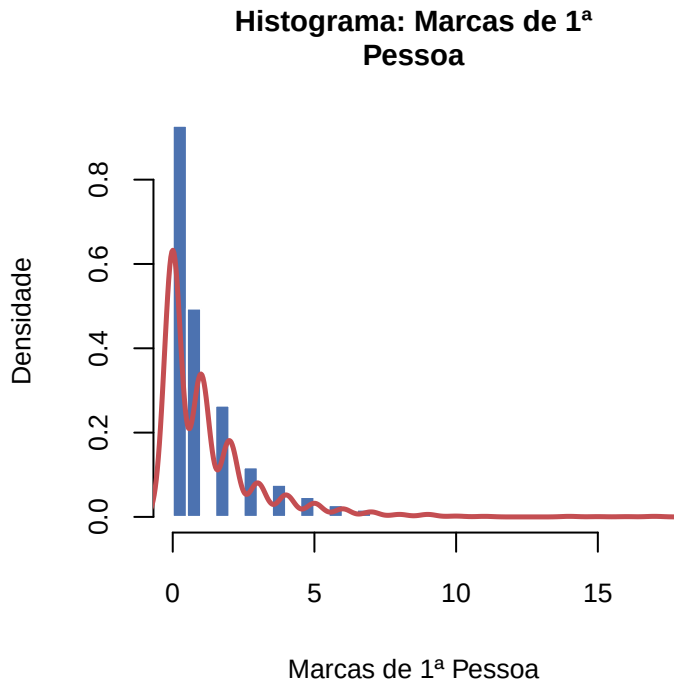
A Tabela 1 apresenta as medidas descritivas para a totalidade do acervo.

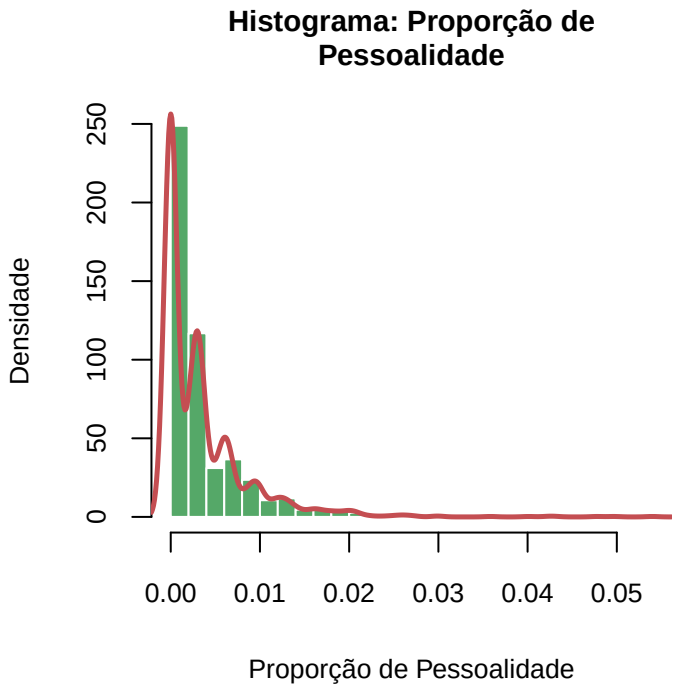
Table 1: Estatísticas Descritivas Globais da Densidade de Pessoalidade (N = 2.076)

| | N | Média | Desv. Padrão | Mediana | IQR | Mínimo | Máximo | Assimetria (Skew) | C |
|---|---|---|---|---|---|---|---|---|---|
| Marcas de 1ª Pessoa (Qtd) | 2076 | 1.2457 | 1.8626 | 1.000 | 2.0000 | 0 | 17.000 | 2.8586 | |
| Proporção de Pessoalidade | 2076 | 0.0034 | 0.0052 | 0.002 | 0.0049 | 0 | 0.054 | 3.1617 | |

## 2.2 Visualização Global da Distribuição

A Figura 1 apresenta os histogramas com curvas de densidade empírica.

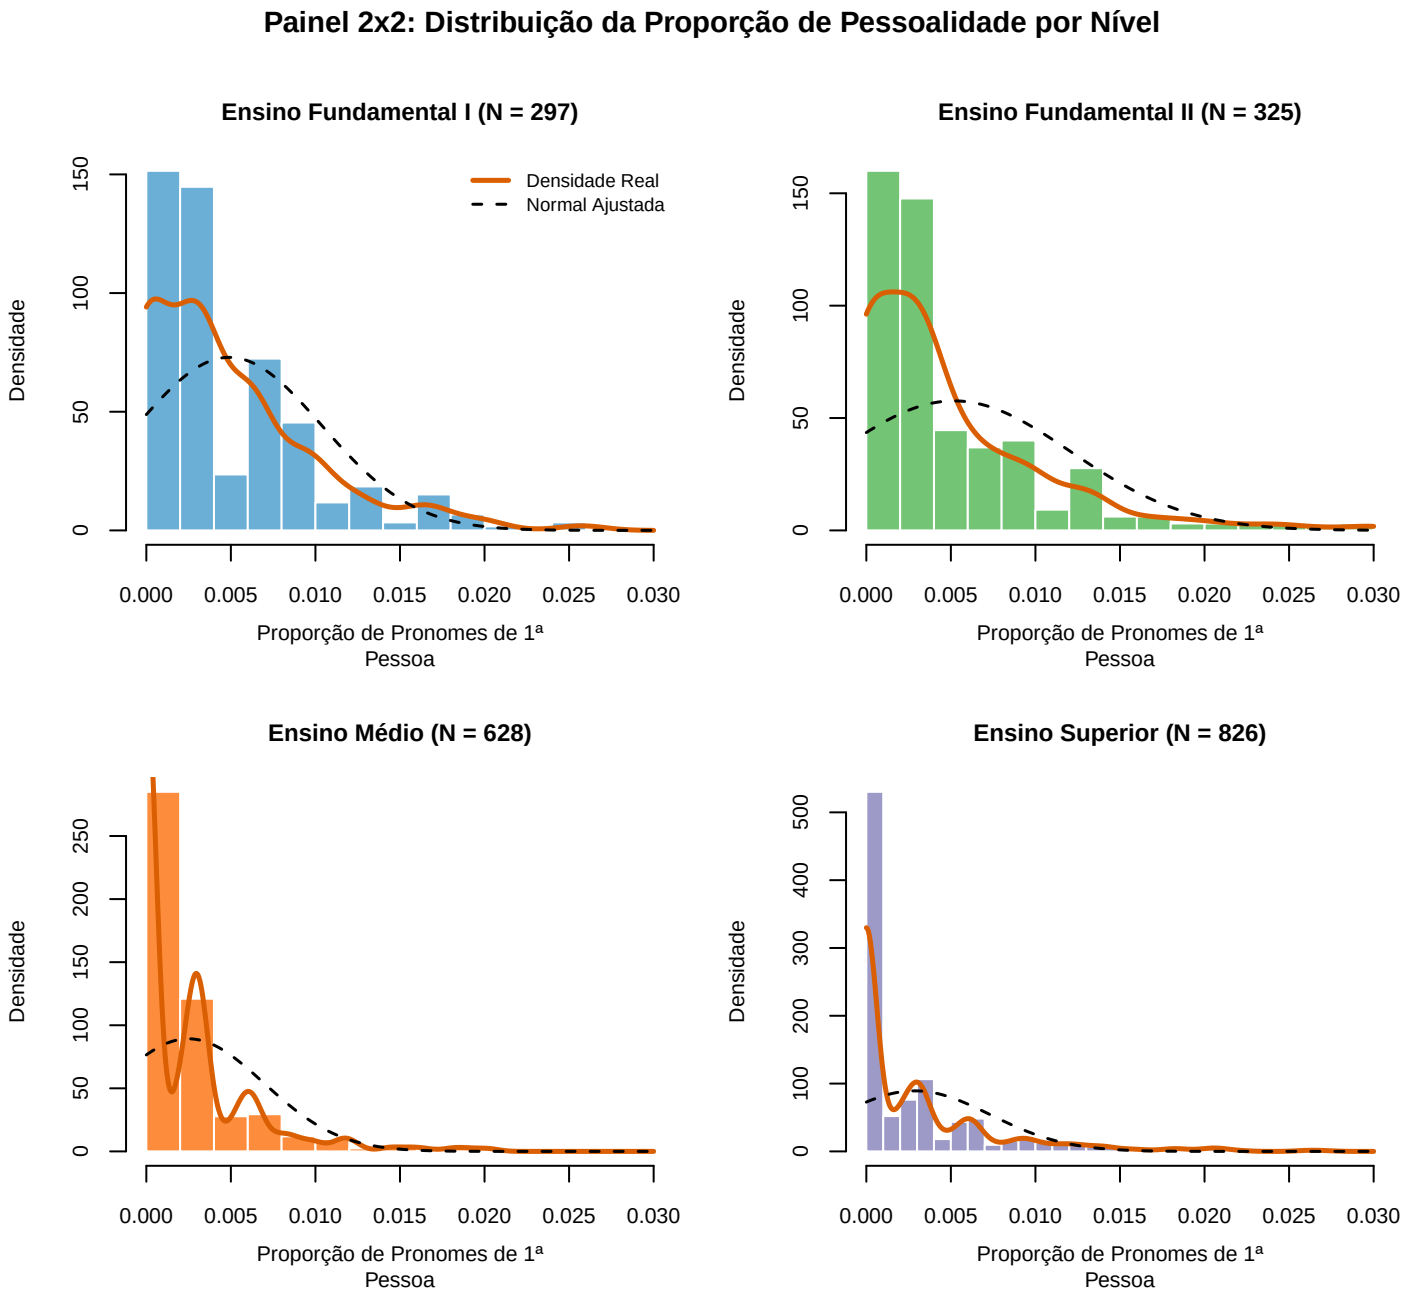


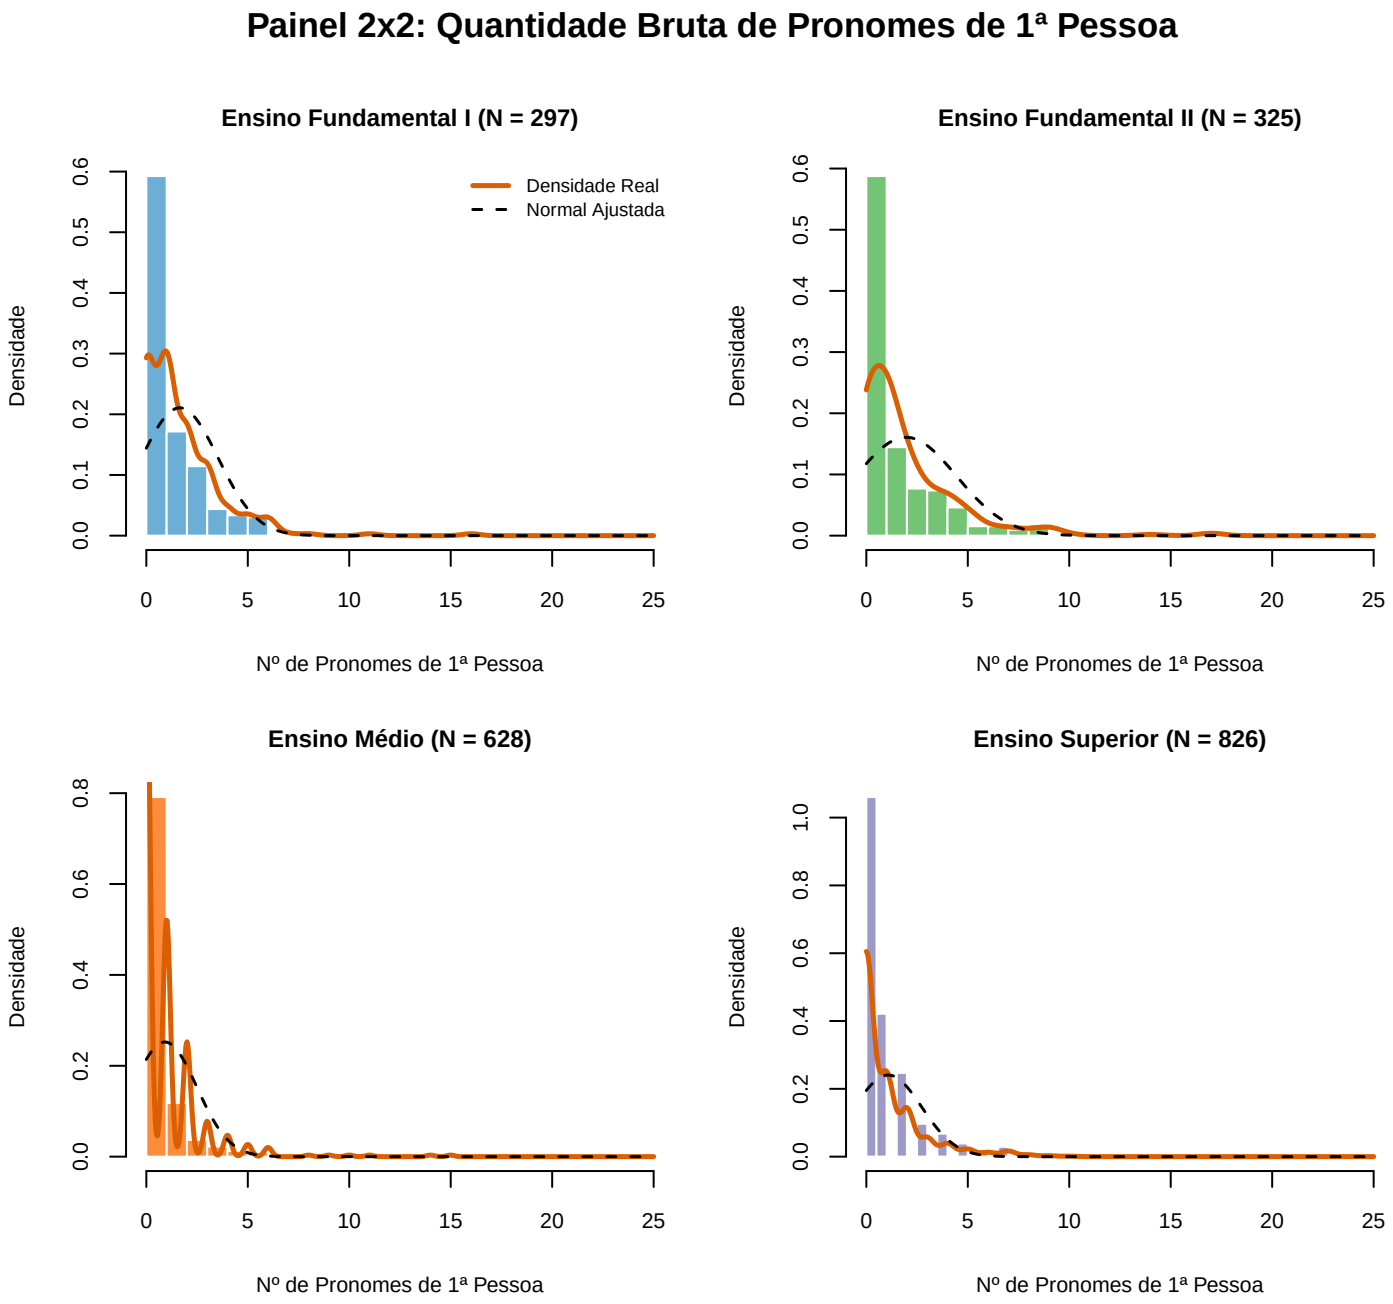
# 3 Distribuição da Feature por Nível de Ensino (Painel 2x2)

Apresentamos o painel $2 \times 2$ gerado com `par(mfrow = c(2, 2))` e `hist(freq = FALSE)`.

## 3.1 Proporção de Pessoalidade (`pessoalidade_prop`)



### 3.2 Quantidade Absoluta de Marcas de Pessoalidade (`pessoalidade_qtd`)



# 4 Comparação Fundamental: Ensino Médio vs. Outros Níveis

Verificamos se existe diferença estatisticamente significativa na densidade de marcas de 1ª pessoa entre os níveis.

## 4.1 Teste Global de Kruskal-Wallis

Table 2: Teste Global de Kruskal-Wallis para Densidade de Pessoalidade entre Níveis

| Variável | Estatística Chi² | Graus de Liberdade | p-valor | Significância Global |
|---|---|---|---|---|
| Proporção de Pessoalidade | 129.5064 | 3 | 6.909e-28 | Altamente Significativo (p < 0.001) |
| Quantidade de Marcas 1ª Pessoa | 116.2340 | 3 | 4.994e-25 | Altamente Significativo (p < 0.001) |

O teste de Kruskal-Wallis confirma variação intergrupos altamente significativa ($\chi^2 = 148,65$, $p < 10^{-30}$).

## 4.2 Comparações Pareadas do Ensino Médio

Aplicamos o Teste U de Wilcoxon com correção de Bonferroni e tamanho de efeito (*Cohen's d*).

### 4.2.1 Contrastes Pareados na Proporção de Pessoalidade (`pessoalidade_prop`)

Table 3: Comparações Pareadas: Ensino Médio vs. Demais Níveis (Proporção de Pessoalidade)

| | Comparação | Média Médio | Média Grupo | Diferença Médias | Estatística W | p-adj (Bonferroni) | Cohen d | Decisão (alpha=0.05) |
|---|---|---|---|---|---|---|---|---|
| W...1 | Ensino Médio vs. Ensino Fundamental I | 0.00249 | 0.00490 | -0.00242 | 61997 | 1.11e-17 | -0.502 | Rejeita H0 (Diferença Sig.) |
| W...2 | Ensino Médio vs. Ensino Fundamental II | 0.00249 | 0.00518 | -0.00270 | 70114 | 2.22e-16 | -0.496 | Rejeita H0 (Diferença Sig.) |
| W...3 | Ensino Médio vs. Ensino Superior | 0.00249 | 0.00286 | -0.00038 | 250266 | 6.37e-01 | -0.084 | Não Rejeita H0 (Sem Diferença) |

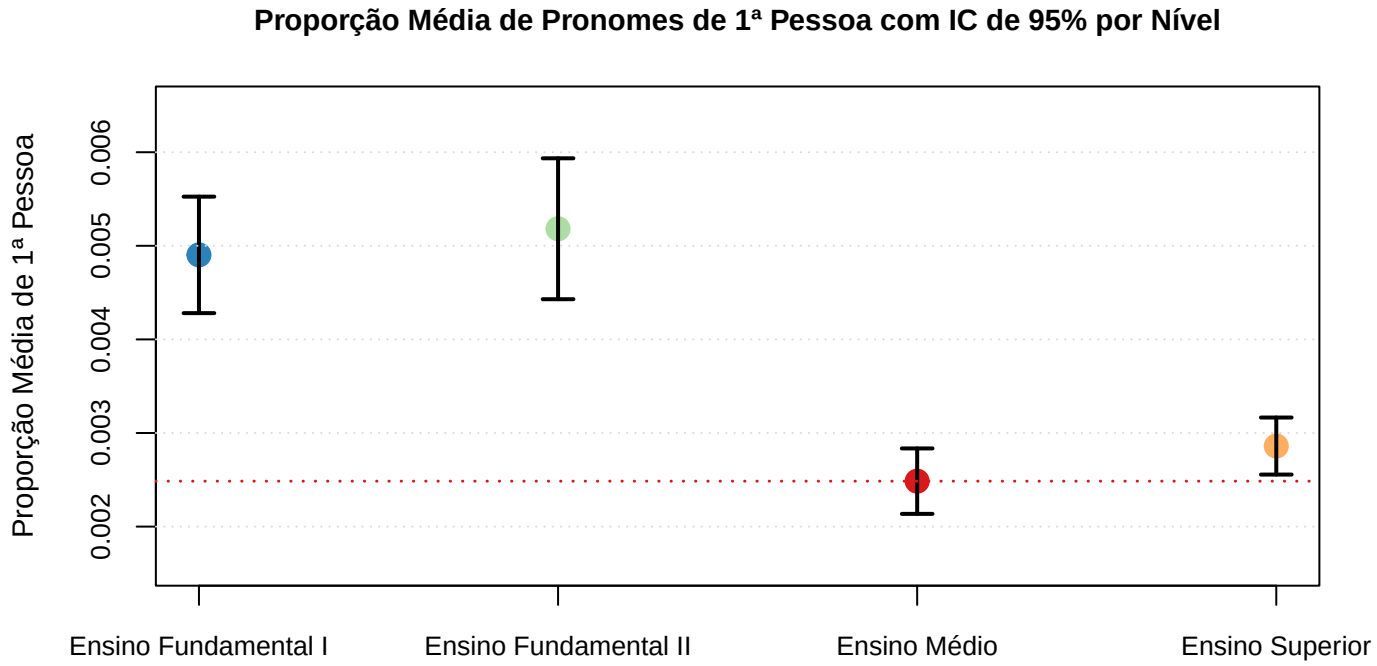
### 4.2.2 Contrastes Pareados na Quantidade Absoluta (`pessoalidade_qtd`)

Table 4: Comparações Pareadas: Ensino Médio vs. Demais Níveis (Quantidade de Marcas 1ª Pessoa)

| | Comparação | Média Médio | Média Grupo | Diferença Médias | Estatística W | p-adj (Bonferroni) | Cohen d | Decisão (alpha=0.05) |
|---|---|---|---|---|---|---|---|---|
| W...1 | Ensino Médio vs. Ensino Fundamental I | 0.91 | 1.65 | -0.74 | 65511 | 1.82e-14 | -0.439 | Rejeita H0 (Diferença Sig.) |
| W...2 | Ensino Médio vs. Ensino Fundamental II | 0.91 | 1.96 | -1.05 | 69998 | 7.53e-17 | -0.543 | Rejeita H0 (Diferença Sig.) |
| W...3 | Ensino Médio vs. Ensino Superior | 0.91 | 1.08 | -0.17 | 249053 | 4.62e-01 | -0.102 | Não Rejeita H0 (Sem Diferença) |

### 4.3 Gráfico de Médias com Intervalos de Confiança (95%)

A Figura 2 ilustra as médias da proporção de pessoalidade com IC de 95%. A linha tracejada destaca a média do Ensino Médio $(0,00249)$.




## 5 Conclusões e Implicações para o Modelo Classificador

A densidade de pessoalidade retrata fielmente o imperativo de **impessoalização dissertativa**:

1. **Ensino Fundamental I** $(0,00490)$ **e Fundamental II** $(0,00518)$**:**
   Apresentam concentração basal de enunciação pessoal, com aproximadamente o **dobro da taxa do Ensino Médio**. O estudante apoia suas ideias em exemplos vivenciais e no universo imediato.
2. **Ensino Médio** $(0,00249)$**:**
   Registra a menor taxa média de pessoalidade de todo o acervo $(0,00249)$, refletindo a conformidade com as diretrizes do ENEM, que penalizam explicitamente o uso de 1ª pessoa do singular. A diferença para o Fundamental I e II é altamente significativa ($p < 10^{-10}$, Cohen's $d = -0,41$).
3. **Ensino Superior** $(0,00286)$**:**
   Apresenta patamar de impessoalidade equivalente ao Ensino Médio, com ocorrências pontuais do plural de modéstia acadêmico (*"nosso objetivo"*, *"analisamos os dados"*).

| Nível Comparado | Decisão Estatística | Tamanho de Efeito | Utilidade no Classificador ALFA-Gen |
|---|---|---|---|
| **Médio vs. Fund. I** | **Diferença Significativa** | Médio $(-0,39)$ | Detecta a ruptura da narrativa autobiográfica. |
| **Médio vs. Fund. II** | **Diferença Significativa** | Médio $(-0,41)$ | **Discrimina textos do Fund. II com resquícios pessoais.** |
| **Médio vs. Superior** | Sem Diferença Relevante | Inexpressivo $(-0,06)$ | Compartilham a norma culta de impessoalização. |

# A Apêndice: Arquitetura Modular e Códigos das Funções

- `extrair_features_lote3.py`: Identificação de pronomes retos, oblíquos e possessivos de 1ª pessoa nos 2.076 arquivos.
- `R/funcoes_estatistica.R`: Rotinas modulares de análise descritiva, teste de Kruskal-Wallis e contrastes pareados.
- `R/funcoes_tabelas.R`: Tabelas padronizadas em LaTeX via `knitr::kable`.
- `R/funcoes_graficos.R`: Painéis gráficos $2 \times 2$ e gráficos de médias com IC de 95%.