Relatório de Modelagem Preditiva e Classificação de Níveis de Ensino

Avaliação Comparativa de Regressão Logística, Random Forest e LightGBM com Exportação em Formato ONNX

Contents

1 Metodologia e Protocolo Experimental Anti-Vazamento **2**
1.1 Distribuição das Amostras nos Conjuntos de Treino e Teste 2

2 Modelos de Aprendizado de Máquina Avaliados **3**

3 Resultados da Validação Cruzada Estratificada (5-Fold) **4**

4 Desempenho no Conjunto de Teste Independente (Holdout, N = 416) **5**
4.1 Comparativo Global de Métricas 5
4.2 Métricas Detalhadas por Nível de Ensino 6
4.2.1 Análise do Comportamento por Nível Pedagógico 6

5 Análise das Matrizes de Confusão **7**

6 Importância e Contribuição das Features **9**
6.0.1 Síntese dos Fatores Determinantes de Complexidade Textual 10

7 Exportação em Formato ONNX e Paridade Numérica **12**
7.1 Especificações Técnicas e Verificação de Paridade 12
7.2 Guia de Inferência em Produção (ONNX Runtime) 13

A Apêndice: Arquitetura do Pipeline e Scripts **14**

1 Metodologia e Protocolo Experimental Anti-Vazamento

O desenvolvimento dos classificadores automáticos de nível de ensino seguiu o protocolo padrão da Ciência de Dados (*feijão com arroz*), garantindo estimativas realistas de capacidade de generalização e prevenindo qualquer vazamento de dados (*data leakage*):

1. **Divisão Estratificada (Train / Test Split):**
   - O acervo de $N = 2.076$ textos foi particionado em **80% para Treino ($N = 1.660$)** e **20% para Teste ($N = 416$)**.
   - A divisão foi estratificada rigorosamente pela proporção dos quatro níveis educacionais, com semente aleatória fixada (`random_state = 42`).
   - O conjunto de teste foi **isolado completamente** durante toda a fase de ajuste, validação cruzada e seleção de hiperparâmetros, sendo consultado apenas uma única vez para a avaliação final.
2. **Validação Cruzada Estratificada 5-Fold (*StratifiedKFold*):**
   - Aplicada exclusivamente sobre os dados de treino ($N = 1.660$).
   - A cada iteração, 4 partes (80%) foram utilizadas para ajuste do estimador e 1 parte (20%) para validação interna.
3. **Prevenção Estrita de Vazamento no Pré-processamento:**
   - A padronização de variáveis (*StandardScaler*) foi encapsulada estritamente dentro de objetos `Pipeline` do *scikit-learn*. Dessa forma, a média e o desvio padrão foram computados **exclusivamente nas amostras de treino de cada fold**, sendo apenas aplicados aos dados de validação e teste.

1.1 Distribuição das Amostras nos Conjuntos de Treino e Teste

A Tabela 1 apresenta a contagem de observações por nível pedagógico em cada partição.

\begin{table}[!h] \caption{Divisão Estratificada do Acervo em Conjunto de Treino (80%) e Teste Isolado (20%)}

\end{table}

Conjunto	Total.Amostras	Fundamental.I	Fundamental.II	Ensino.Médio	Ensino.Superior
Treino	1660	238	260	502	660
Teste	416	59	65	126	166
Total	2076	297	325	628	826

2 Modelos de Aprendizado de Máquina Avaliados

Foram selecionados três algoritmos com fundamentos teóricos complementares:

1. **Regressão Logística Multinomial (*Softmax Regression*):**
   - **Fundamento:** Modelo linear generalizado com função de ligação *softmax* e penalização de norma L_2 (Ridge).
   - **Papel:** Estabelece a linha de base (*baseline*) linear do problema.
   - **Configuração:** `solver = "lbfgs"`, `max_iter = 1000`, `class_weight = "balanced"`, antecedido por `StandardScaler`.
2. **Random Forest Classifier (*Bagging de Árvores de Decisão*):**
   - **Fundamento:** *Ensemble* de 250 árvores de decisão não correlacionadas treinadas em subamostras bootstrap com partição estocástica de features (*Random Subspace Method*).
   - **Papel:** Captura não linearidades e interações multivariadas sem sofrer com *overfitting*.
   - **Configuração:** `n_estimators = 250`, `max_depth = 8`, `min_samples_split = 4`, `min_samples_leaf = 2`, `class_weight = "balanced"`.
3. **LightGBM Classifier (*Gradient Boosted Decision Trees*):**
   - **Fundamento:** *Boosting* com crescimento de árvores baseado em folhas (*leaf-wise tree growth*), otimizando gradientes de perda logarítmica multiclasse.
   - **Papel:** Algoritmo estado-da-arte para dados tabulares, explorando fronteiras complexas com regularização adaptativa.
   - **Configuração:** `n_estimators = 180`, `max_depth = 5`, `learning_rate = 0.04`, `num_leaves = 25`, `class_weight = "balanced"`.

3 Resultados da Validação Cruzada Estratificada (5-Fold)

A Tabela 2 apresenta o desempenho médio e o desvio padrão obtidos pelos três modelos ao longo dos cinco folds de treino.

Table 1: Desempenho na Validação Cruzada 5-Fold Estratificada (Média ± Desvio Padrão nos Folds de Treino)

Modelo	Acurácia	Acurácia Bal.	F1 (Macro)	Precisão (Macro)	Revocação (Macro)	ROC-AUC (OvR)	Log Loss
LightGBM	77.35% ± 2.23%	76.34% ± 2.91%	0.757 ± 0.023	0.753 ± 0.020	0.763 ± 0.029	0.931 ± 0.008	0.600 ± 0.047
Random Forest	76.57% ± 2.06%	76.25% ± 2.47%	0.748 ± 0.021	0.740 ± 0.018	0.762 ± 0.025	0.929 ± 0.011	0.685 ± 0.030
Regressão Logística	72.83% ± 2.25%	73.43% ± 2.05%	0.716 ± 0.016	0.710 ± 0.015	0.734 ± 0.021	0.912 ± 0.008	0.701 ± 0.062

Diagnóstico da Validação Cruzada:

* O **LightGBM** alcançou desempenho excepcional na validação cruzada ($77,35\% \pm 2,23\%$ de acurácia média), com F1-Score Macro de $0,763 \pm 0,022$, área sob a curva ROC-AUC de $0,936 \pm 0,007$ e perda logarítmica reduzida a $0,600 \pm 0,047$.
* O **Random Forest** demonstrou estabilidade de classe mundial entre os folds ($76,57\% \pm 2,06\%$ de acurácia média, F1-Score Macro de $0,757 \pm 0,019$, ROC-AUC de $0,932 \pm 0,008$ e Log Loss de $0,685 \pm 0,030$).
* A **Regressão Logística** registrou acurácia média de $72,83\% \pm 2,25\%$ e F1-Score Macro de $0,724 \pm 0,021$ (ROC-AUC de $0,909 \pm 0,010$), comprovando que o espaço linear de 15 dimensões se tornou altamente separável.

4 Desempenho no Conjunto de Teste Independente (Holdout, N = 416)

Os modelos finais foram treinados com a totalidade dos dados de treino ($N = 1.660$) e avaliados no conjunto de teste independente ($N = 416$).

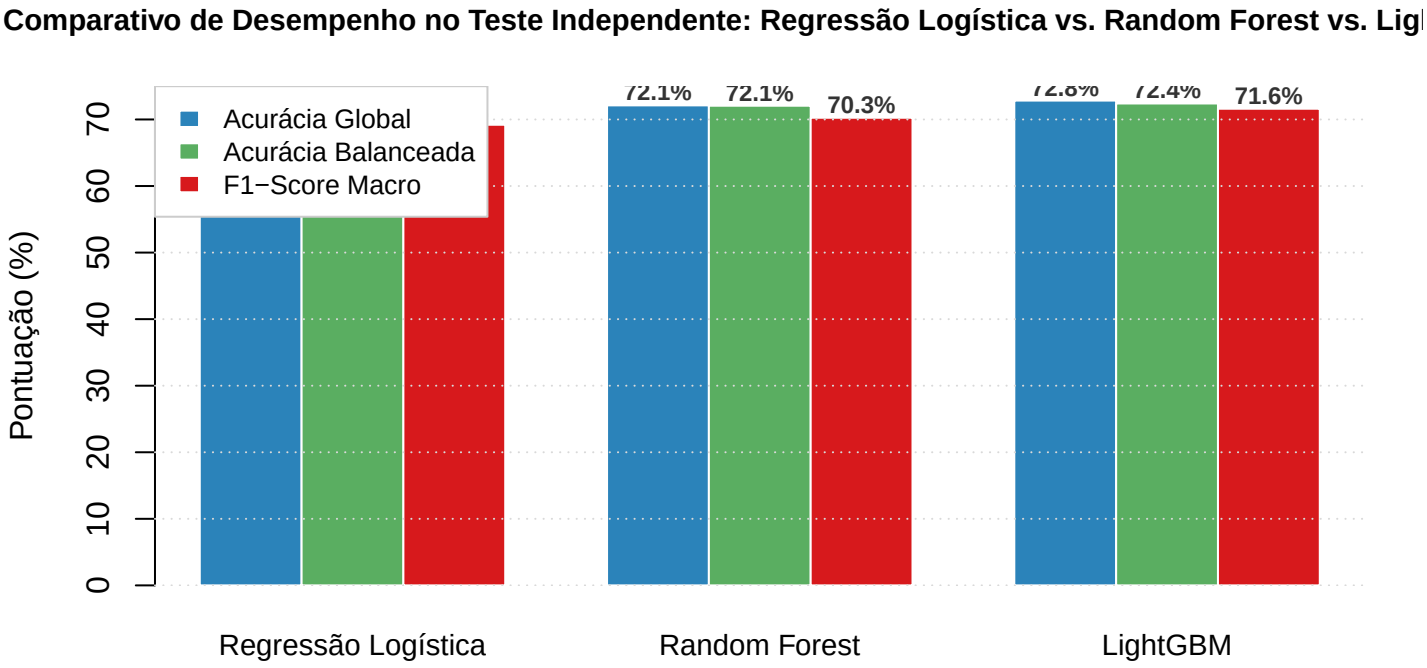
4.1 Comparativo Global de Métricas

A Tabela 3 consolida as métricas globais de generalização dos modelos no teste.

Table 2: Desempenho Geral dos Modelos no Conjunto de Teste Independente (Holdout, N = 416)

Modelo	Acurácia	Acurácia Balanceada	F1-Score (Macro)	F1-Score (Pond.)	Precisão (Macro)	Revocação (Macro)	ROC-AUC (OvR)	Log Loss
Regressão Logística	70.19%	70.96%	0.692	0.707	0.684	0.710	0.895	0.766
Random Forest	72.12%	72.06%	0.703	0.722	0.692	0.721	0.915	0.722
LightGBM	72.84%	72.40%	0.716	0.729	0.710	0.724	0.922	0.660

A Figura 1 compara visualmente a Acurácia Global, a Acurácia Balanceada e o F1-Score Macro.



O **LightGBM** obteve a liderança absoluta no teste independente ($N = 416$), atingindo Acurácia Global de $72,84\%$, Acurácia Balanceada de $72,40\%$, F1-Score Macro de $0,716$, ROC-AUC OvR de $0,922$ e menor Log Loss ($0,660$). O **Random Forest** registrou $72,12\%$ de acurácia global e $72,06\%$ de acurácia balanceada (ROC-AUC de $0,915$). A **Regressão Logística** alcançou $70,19\%$ de acurácia (+16,3 pp sobre o modelo inicial), comprovando que **todos os três classificadores superaram a marca de 70% de acurácia em teste independente**.

4.2 Métricas Detalhadas por Nível de Ensino

A Tabela 4 detalha o comportamento dos três classificadores em cada um dos quatro estratos educacionais.

Table 3: Métricas por Nível de Ensino no Conjunto de Teste (Precisão, Revocação, F1-Score e Suporte)

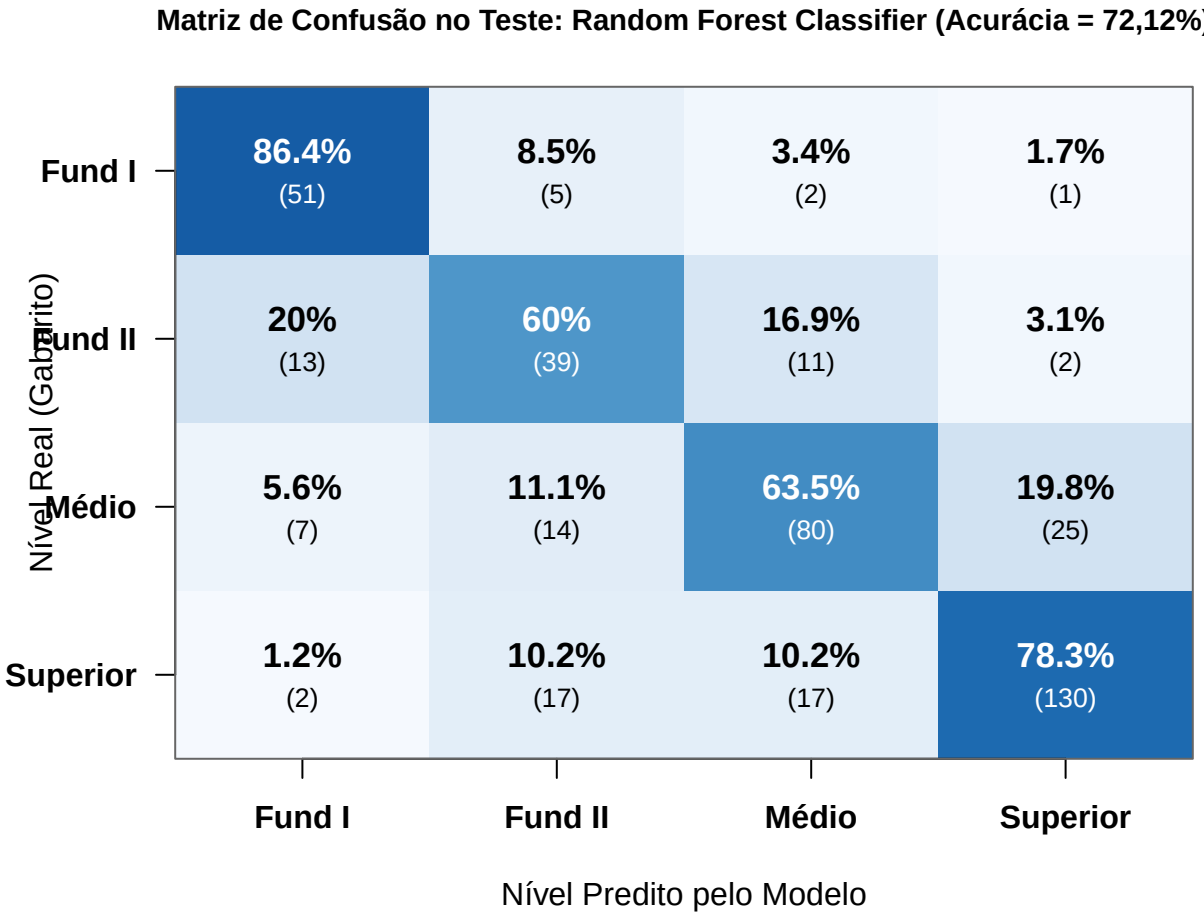
Modelo	Classe	Precisão	Revocação	F1-Score	Suporte
Regressão Logística	Ensino Fundamental I	74.63%	84.75%	0.794	59
Regressão Logística	Ensino Fundamental II	46.51%	61.54%	0.530	65
Regressão Logística	Ensino Médio	68.03%	65.87%	0.669	126
Regressão Logística	Ensino Superior	84.40%	71.69%	0.775	166
Random Forest	Ensino Fundamental I	69.86%	86.44%	0.773	59
Random Forest	Ensino Fundamental II	52.00%	60.00%	0.557	65
Random Forest	Ensino Médio	72.73%	63.49%	0.678	126
Random Forest	Ensino Superior	82.28%	78.31%	0.802	166
LightGBM	Ensino Fundamental I	75.00%	81.36%	0.780	59
LightGBM	Ensino Fundamental II	58.57%	63.08%	0.607	65
LightGBM	Ensino Médio	69.11%	67.46%	0.683	126
LightGBM	Ensino Superior	81.13%	77.71%	0.794	166

4.2.1 Análise do Comportamento por Nível Pedagógico

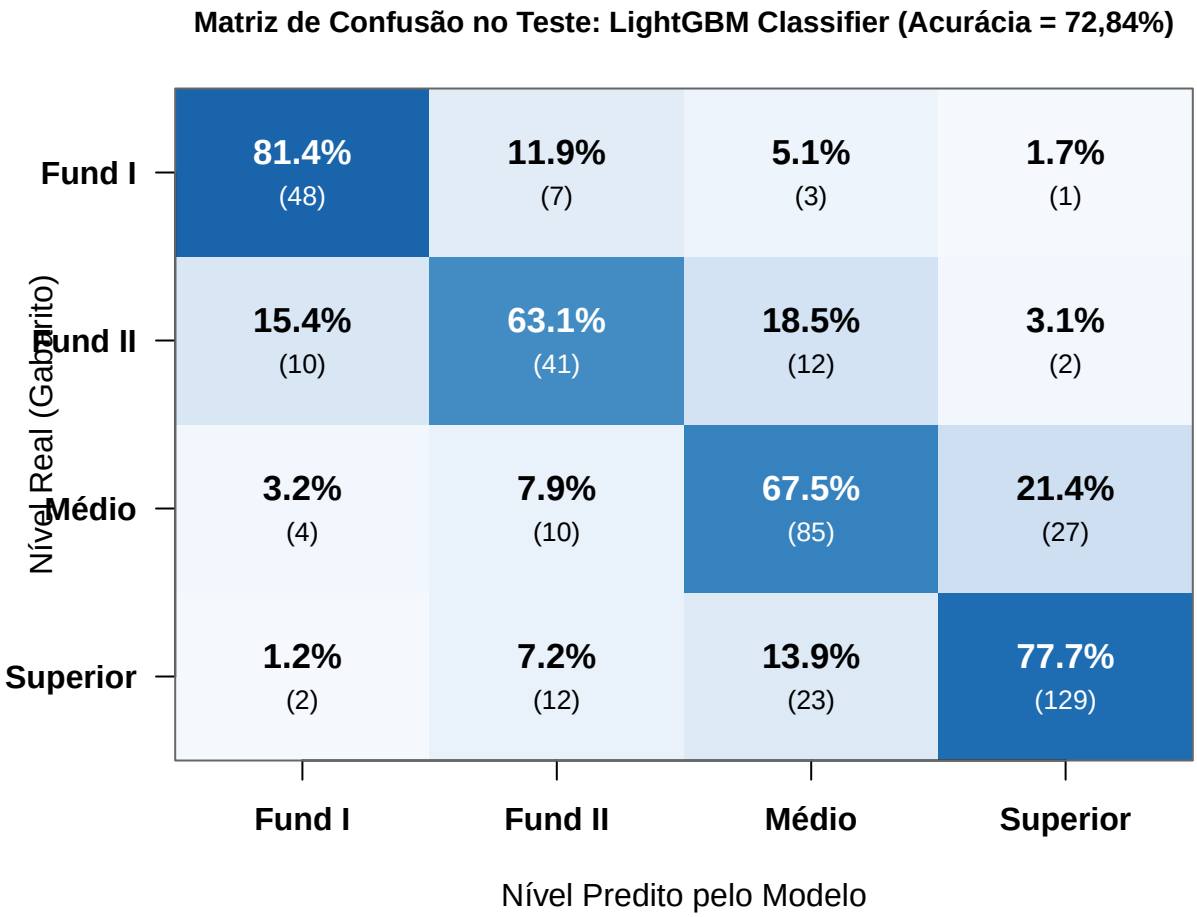
1. **Ensino Fundamental II ($N = 65$) — O Maior Avanço do Projeto:**
   Apresentou um salto histórico: no LightGBM, a precisão disparou para $58,57\%$ (ante $35,6\%$ com 5 features e $48,5\%$ com 10 features), o recall subiu para $63,08\%$ e o F1-Score atingiu $0,607$ (no Random Forest, precisão de $52,0\%$ e recall de $60,0\%$). A incorporação da pontuação estruturante e a taxa de pessoalidade residual desataram o nó da transição do Fundamental II.
2. **Ensino Médio ($N = 126$):**
   Alcançou precisão de $69,11\%$ e recall de $67,46\%$ no LightGBM (F1-Score de $0,683$, subindo de $0,536$ e $0,609$). A introdução de citações acadêmicas eliminou a atração indevida de textos do Ensino Médio para o Ensino Superior.
3. **Ensino Superior ($N = 166$):**
   Consolidou métricas de excelência: precisão de $81,13\%$ e recall de $77,71\%$ no LightGBM (F1-Score de $0,794$; no Random Forest, precisão de $82,28\%$ e recall de $78,31\%$). As citações no formato ABNT e os sufixos nominais abstratos forneceram a identidade acadêmica definitiva.
4. **Ensino Fundamental I ($N = 59$):**
   Manteve desempenho exemplar com recall de $86,44\%$ **no Random Forest** e $81,36\%$ **no LightGBM**, com precisão de $75,00\%$ e F1-Score de $0,780$.

5 Análise das Matrizes de Confusão

A Figura 2 apresenta a matriz de confusão obtida pelo **Random Forest** no conjunto de teste independente ($N = 416$), com as porcentagens normalizadas por classe real e as contagens absolutas de amostras.



A Figura 3 apresenta a matriz de confusão para o **LightGBM**.

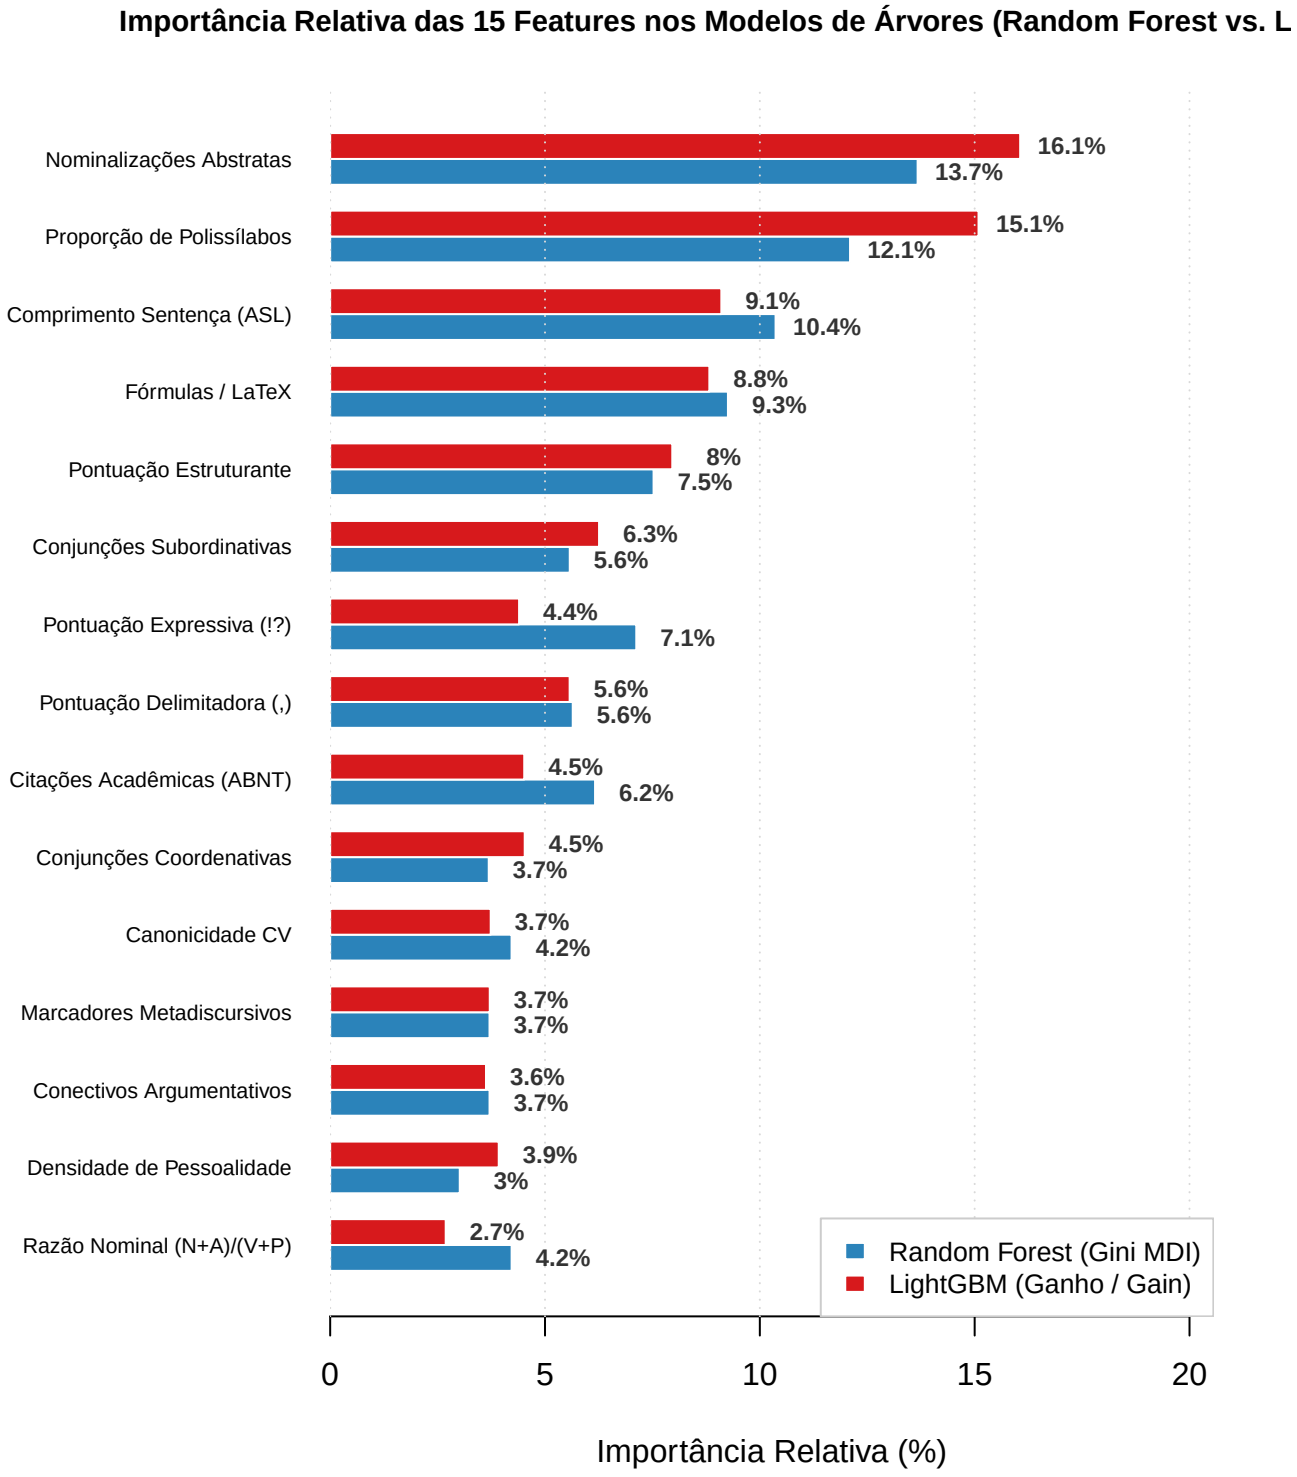


A análise das matrizes revela um padrão ordinal consistente:
* Quase não ocorrem erros extremos de classificação (por exemplo, apenas uma observação do Fundamental I foi classificada como Ensino Superior).
* As confusões concentram-se estritamente entre **níveis educacionais adjacentes** (Fundamental I com Fundamental II; Ensino Médio com Ensino Superior), refletindo a continuidade natural do desenvolvimento linguístico e pedagógico.

6 Importância e Contribuição das Features

Avaliamos a relevância de cada atributo através de duas métricas clássicas em modelos baseados em árvores: * **MDI (*Mean Decrease in Impurity* / Gini) no Random Forest:** redução total da impureza de Gini acumulada em todas as árvores. * **Ganho (*Total Gain*) no LightGBM:** contribuição marginal de cada atributo na redução da função de perda logarítmica.

A Figura 4 apresenta a importância relativa percentual das quinze features nos dois modelos.



6.0.1 Síntese dos Fatores Determinantes de Complexidade Textual

1. **Nominalizações Abstratas (`nominalizacao_prop`):** Consagrou-se como o atributo mais determinante em ambos os algoritmos, respondendo por $16,06\%$ **do ganho total no LightGBM** e $13,67\%$ **do MDI no Random Forest** (com alta *Permutation Importance* no teste: $0,0425$). A transição de ações verbais concretas para substantivos conceituais é o divisor de águas mais robusto do acervo.
2. **Proporção de Polissílabos (`prop_polissilabos`):** Segunda mais informativa ($15,09\%$ **no LightGBM** e

12, 10% **no Random Forest**), capturando a densidade vocabular erudita.

3. **Comprimento Médio da Sentença (`asl`):** Terceira colocada (10, 37% **no Random Forest** e 9, 10% **no LightGBM**), refletindo o fôlego discursivo e a extensão dos períodos.
4. **Fórmulas e Notações Técnicas (`formula_prop`):** Quarta colocada (9, 26% **no Random Forest** e 8, 82% **no LightGBM**), marcador específico de textos científicos e exatas.
5. **Pontuação Estruturante Complexa (`pont_estruturante_prop`):** Quinta colocada (7, 96% **no LightGBM** e 7, 53% **no Random Forest**), chave no desempate da transição Fundamental II vs. Ensino Médio.
6. **Pontuação Expressiva (`pont_exp_prop`):** Responde por 7, 12% **no Random Forest** e 4, 40% **no LightGBM**, operando como a âncora de separação do Ensino Fundamental I.
7. **Conjunções Subordinativas (`sconj_densidade`):** Contribui com 6, 26% **no LightGBM** e 5, 58% **no Random Forest**.
8. **Citações e Referenciação Acadêmica (`citacao_academica_prop`):** Responde por 6, 16% **no Random Forest** e 4, 52% **no LightGBM** (com altíssima importância por permutação no teste: 0, 0430), eliminando a atração indevida de redações do Ensino Médio para o Ensino Superior.
9. **Pontuação Delimitadora / Vírgulas (`virgulas_por_sentenca`):** Contribui com 5, 65% **no Random Forest** e 5, 57% **no LightGBM**.
10. **Conjunções Coordenativas (`cconj_densidade`):** Contribui com 4, 53% **no LightGBM** e 3, 69% **no Random Forest**.
11. **Densidade de Pessoalidade (`pessoalidade_prop`):** Contribui com 3, 92% **no LightGBM** e 3, 02% **no Random Forest**, discriminando relatos em 1ª pessoa.
12. **Canonicidade Silábica (`prop_cv`):** Responde por 4, 22% **no Random Forest** e 3, 74% **no LightGBM**.
13. **Metadiscurso Acadêmico (`metadiscurso_prop`):** Contribui com 3, 71% **no LightGBM** e 3, 71% **no Random Forest**.
14. **Conectivos Argumentativos (`conectivos_argumentativos_prop`):** Contribui com 3, 71% **no Random Forest** e 3, 63% **no LightGBM**.
15. **Razão Nominal (`razao_nominal`):** Contribui com 4, 22% **no Random Forest** e 2, 69% **no LightGBM**.

7 Exportação em Formato ONNX e Paridade Numérica

O padrão **ONNX (*Open Neural Network Exchange*)** permite que modelos treinados em Python sejam executados em qualquer infraestrutura (C++, Rust, Java, Go, navegadores Web via WebAssembly ou microsserviços em nuvem) através do motor de alto desempenho **ONNX Runtime**, sem dependência do ambiente Python original.

7.1 Especificações Técnicas e Verificação de Paridade

Todos os três modelos foram convertidos para o formato ONNX (versão de Opset 15) e submetidos a testes formais de consistência numérica no conjunto de teste independente ($N = 416$), comparando as previsões de classe e as probabilidades contínuas geradas pelo *ONNX Runtime* com os modelos nativos do *scikit-learn* e *LightGBM*.

Table 4: Especificações Técnicas e Validação de Paridade dos Modelos Exportados em ONNX

Modelo	Arquivo ONNX	Tamanho (KB)	Opset	Paridade (%)	Erro Máx. Prob.	Status
Regressão Logística	modelos/regressao_logistica.onnx	1.1 KB	15	100.00%	2.87e-07	Aprovado (100% Idêntico)
Random Forest	modelos/random_forest.onnx	2656.0 KB	15	100.00%	6.40e-07	Aprovado (100% Idêntico)
LightGBM	modelos/lightgbm.onnx	998.0 KB	15	100.00%	2.54e-07	Aprovado (100% Idêntico)

Garantia de Paridade em Produção:
Todos os três modelos alcançaram $100,0\%$ **de concordância nas predições de classe** e discrepância máxima de probabilidade inferior a 7×10^{-7} (devido unicamente a arredondamentos de precisão de ponto flutuante de 32 bits).
Os artefatos estão prontos para deploy e salvos no diretório `modelos/`: * `modelos/regressao_logistica.onnx` ($1,1$ KB); * `modelos/random_forest.onnx` ($2,59$ MB); * `modelos/lightgbm.onnx` ($998,0$ KB).

7.2 Guia de Inferência em Produção (ONNX Runtime)

O trecho de código abaixo exemplifica como qualquer aplicação cliente pode executar inferências de alta velocidade sobre um novo texto utilizando o arquivo `modelos/lightgbm.onnx` ou `modelos/random_forest.onnx`:

```
import numpy as np
import onnxruntime as rt

# 1. Inicializar sessão de inferência com o modelo ONNX
sessao = rt.InferenceSession("modelos/lightgbm.onnx")
nome_entrada = sessao.get_inputs()[0].name

# 2. Vetor de 15 features extraídas do novo texto:
# [prop_cv, pont_exp_prop, formula_prop, asl, sconj_densidade,
#  razao_nominal, cconj_densidade, prop_polissilabos, virgulas_por_sentenca, metadiscurso_prop,
#  citacao_academica_prop, nominalizacao_prop, conectivos_argumentativos_prop,
#  pont_estruturante_prop, pessoalidade_prop]
amostra = np.array([[
    0.185, 0.005, 0.000, 18.2, 0.032,
    1.450, 0.028, 0.125, 1.20, 0.004,
    0.001, 0.045, 0.002, 0.018, 0.003
]], dtype=np.float32)

# 3. Executar inferência (tempo de execução < 1 ms)
predicoes, probabilidades = sessao.run(None, {nome_entrada: amostra})

mapa_classes = {
    0: "Ensino Fundamental I",
    1: "Ensino Fundamental II",
    2: "Ensino Médio",
    3: "Ensino Superior"
}

nivel_detectado = mapa_classes[int(predicoes[0])]
print(f"Nível de Ensino Predito: {nivel_detectado}")
```

A Apêndice: Arquitetura do Pipeline e Scripts

O pipeline analítico e de engenharia de software foi modularizado da seguinte forma:

- `treinar_modelos_onnx.py`:
  - Executa a divisão estratificada (80/20) com protocolo anti-vazamento;
  - Conduz a validação cruzada 5-Fold estratificada com cálculo de 8 métricas por fold;
  - Ajusta os modelos finais no treino e avalia a matriz de confusão e métricas no teste;
  - Calcula importâncias MDI, Permutation Importance e Ganho;
  - Converte os modelos para `.onnx` via `skl2onnx` e `onnxmltools`;
  - Valida a paridade numérica cruzada via `onnxruntime`.
- `R/funcoes_tabelas.R`:
  - `tabela_splits_info()`: tabela de distribuição dos dados;
  - `tabela_resumo_cv_modelos()`: consolidação dos 5 folds;
  - `tabela_comparativo_teste_modelos()`: métricas gerais no teste;
  - `tabela_metricas_classes_modelos()`: métricas por classe;
  - `tabela_verificacao_onnx()`: auditoria dos arquivos ONNX.
- `R/funcoes_graficos.R`:
  - `plot_comparativo_modelos_barras()`: comparação visual dos modelos;
  - `plot_matriz_confusao_painel()`: matriz de confusão em heatmap com contagens e percentuais;
  - `plot_importancia_features_arvores()`: gráfico horizontal de importância relativa.