Relatório de Engenharia de Atributos: Análise Multivariada Completa (15 Features)

Estrutura de Dependência, PCA, MANOVA, LDA e Distâncias Multivariadas no Hipervolume de 15 Dimensões

Contents

1 O Espaço Multivariado de 15 Dimensões Linguísticas **2**

2 Correlação Multivariada e Diagnóstico de Multicolinearidade (15 Features) **3**
- 2.1 Matriz de Correlação Linear de Pearson . . . 3
- 2.2 Matriz de Correlação Não Paramétrica de Spearman . . . 3
- 2.3 Fatores de Inflação da Variância (VIF) para as 15 Features . . . 4

3 Análise de Variância Multivariada (MANOVA de 15 Dimensões) **5**

4 Análise de Componentes Principais (PCA de 15 Dimensões) **6**
- 4.1 Decomposição Espectral e Autovalores . . . 6
- 4.2 Scree Plot e Critério de Kaiser . . . 6
- 4.3 Matriz de Cargas Fatoriais (Loadings dos Primeiros 5 Eixos) . . . 8
  - 4.3.1 Interpretação dos Eixos Latentes Expandidos . . . 8
- 4.4 Projeção Multivariada no Plano Latente (Biplot PC1 vs. PC2) . . . 9

5 Análise Discriminante Linear Canônica (LDA com 15 Features) **10**
- 5.1 Coeficientes das Funções Discriminantes Canônicas . . . 10
- 5.2 Projeção Canônica (LD1 vs. LD2) . . . 11
- 5.3 Desempenho e Matriz de Confusão da LDA (15 Features) . . . 12

6 O Espaço Multivariado do Ensino Médio e Distâncias de Mahalanobis **13**
- 6.1 Matriz de Distâncias Multivariadas de Mahalanobis (15 Dimensões) . . . 13
- 6.2 Teste Multivariado de Hotelling T^2 para o Ensino Médio (15 Dimensões) . . . 13
- 6.3 Assinatura Multivariada por Nível de Ensino (Perfis Médios em Z-score) . . . 14
  - 6.3.1 Diagnóstico Visual da Assinatura das 15 Features . . . 14

7 Conclusões e Diretrizes para os Modelos Preditivos **15**

A Apêndice: Arquitetura Modular e Códigos das Funções **16**

1 O Espaço Multivariado de 15 Dimensões Linguísticas

Ao longo das etapas de engenharia de atributos do projeto **ALFA-Gen**, o espaço de representação dos $N = 2.076$ textos foi expandido para quinze dimensões morfossintáticas, lexicais, estruturais e discursivas:

1. **Canonicidade Silábica (`prop_cv`):** proporção de palavras formadas estritamente por sílabas do tipo Consoante-Vogal (CV), capturando a maturação fonológica primária.
2. **Pontuação Expressiva (`pont_exp_prop`):** densidade combinada de exclamações e interrogações (! e ?), medindo oralidade e expressividade emocional.
3. **Fórmulas e Termos Técnicos (`formula_prop`):** ocorrências da palavra *fórmula* e notações de equações em LaTeX, discriminando o discurso das ciências exatas.
4. **Comprimento Médio da Sentença (`asl`):** média de palavras por período frásico, mensurando o fôlego discursivo e a extensão dos períodos.
5. **Densidade de Conjunções Subordinativas (`sconj_densidade`):** conectivos `SCONJ` via spaCy, quantificando o grau de hipotaxe e subordinação lógica.
6. **Razão Nominal (`razao_nominal`):** razão entre substantivos (`NOUN`) e verbos (`VERB`/`AUX`), mensurando a densidade informacional e o empacotamento expositivo.
7. **Densidade de Conjunções Coordenativas (`cconj_densidade`):** conectivos `CCONJ` via spaCy, capturando a articulação paratática de orações independentes.
8. **Proporção de Palavras Polissílabas (`prop_polissilabos`):** fração de vocábulos com ≥ 4 sílabas via Pyphen, aferindo a sofisticação do vocabulário erudito.
9. **Densidade de Vírgulas por Sentença (`virgulas_por_sentenca`):** média de vírgulas por período frásico, mensurando orações intercaladas, apostos e enumerações.
10. **Metadiscurso Acadêmico (`metadiscurso_prop`):** densidade de termos do jargão científico e epistemológico, capturando a autoria universitária mesmo na ausência de fórmulas.
11. **Citações e Referenciação Acadêmica (`citacao_academica_prop`):** anos bibliográficos parentéticos, autorias normatizadas e marcadores de autoridade científica (ABNT), separando categoricamente artigos acadêmicos do Ensino Médio.
12. **Sufixos Abstratos e Nominalizações (`nominalizacao_prop`):** substantivos derivados com sufixos conceituais (*-ção*, *-mento*, *-dade*, *-ismo*, *-ência*, *-tude*), mensurando a transição da ação verbal concreta para a abstração nominal.
13. **Conectivos Argumentativos e Conclusivos (`conectivos_argumentativos_prop`):** operadores discursivos e frases-modelo de proposta de intervenção dissertativa (*portanto*, *ademais*, *dessa forma*, *faz-se necessário*).
14. **Pontuação Estruturante Complexa (`pont_estruturante_prop`):** densidade combinada de ponto e vírgula, dois pontos, parênteses e travessões explicativos, delimitando a transição do Fundamental para o Médio/Superior.
15. **Densidade de Pessoalidade (`pessoalidade_prop`):** frequência de pronomes retos, oblíquos e possessivos de 1ª pessoa, capturando o imperativo de impessoalização e a ruptura com o relato autobiográfico infantil.

Cada documento i é representado pelo vetor $\mathbf{x}_i \in \mathbb{R}^{15}$.

2 Correlação Multivariada e Diagnóstico de Multicolinearidade (15 Features)

2.1 Matriz de Correlação Linear de Pearson

A Tabela 1 apresenta a matriz de correlação linear 15×15 com marcadores de significância estatística.

Table 1: Matriz de Correlação Linear de Pearson entre as 15 Features Multivariadas

	Canonicidade	Pont. (!?)	Fórmulas	ASL	Subord.	Razão Nom.	Coord.	Polissílabos	Vírgulas/Sent	Metadiscurso	Citações	Nominaliz.	Conect.Arg.	Pont.Estrut.	Pessoalidade
Canonicidade	1,000	-0.054*	+0.052*	+0.118***	-0.110***	+0.160***	-0.242***	-0.055*	+0.103***	-0.003	+0.012	-0.003	-0.047*	-0.072**	-0.116***
Pont. (!?)	-0.054*	1,000	-0.056*	-0.165***	+0.178***	-0.230***	+0.124***	-0.324***	-0.159***	-0.103***	-0.078***	-0.252***	-0.129***	-0.025	+0.123***
Fórmulas	+0.052*	-0.056*	1,000	+0.131***	+0.332***	-0.172***	+0.035	-0.067**	-0.160***	+0.133***	-0.032	+0.200***	+0.280***	+0.393***	+0.008
ASL	+0.118***	-0.165***	+0.131***	1,000	-0.017	+0.425***	-0.053*	+0.278***	+0.134***	+0.151***	+0.016	+0.303***	+0.065**	+0.143***	+0.022
Subord.	-0.110***	+0.178***	+0.332***	-0.017	1,000	-0.492***	+0.022	-0.256***	-0.119***	+0.097***	-0.082***	-0.015	+0.140***	+0.013	+0.141***
Razão Nom.	+0.160***	-0.230***	-0.172***	+0.425***	-0.492***	1,000	+0.042	+0.462***	+0.174***	+0.059**	+0.224***	+0.384***	-0.021	+0.072**	-0.152***
Coord.	-0.242***	+0.124***	+0.035	-0.053*	+0.022	+0.042	1,000	+0.056*	+0.021	-0.072**	+0.043	+0.051*	-0.004	+0.066**	+0.027
Polissílabos	-0.055*	-0.324***	-0.067**	+0.278***	-0.256***	+0.462***	+0.056*	1,000	+0.168***	+0.184***	+0.250***	+0.628***	+0.132***	-0.007	-0.106***
Vírgulas/Sent	+0.103***	-0.159***	-0.160***	+0.134***	-0.119***	+0.174***	+0.021	+0.168***	1,000	-0.091***	+0.106***	-0.032	+0.010	-0.107***	-0.024
Metadiscurso	-0.003	-0.103***	+0.133***	+0.151***	+0.097***	+0.059**	-0.072**	+0.184***	-0.091***	1,000	+0.105***	+0.261***	+0.138***	+0.133***	+0.083***
Citações	+0.012	-0.078***	-0.032	+0.016	-0.082***	+0.224***	+0.043	+0.250***	+0.106***	+0.105***	1,000	+0.267***	+0.038	+0.105***	-0.092***
Nominaliz.	-0.003	-0.252***	+0.200***	+0.303***	-0.015	+0.384***	+0.051*	+0.628***	-0.032	+0.261***	+0.267***	1,000	+0.235***	+0.198***	-0.093***
Conect.Arg.	-0.047*	-0.129***	+0.280***	+0.065**	+0.140***	-0.021	-0.004	+0.132***	+0.010	+0.138***	+0.038	+0.235***	1,000	+0.146***	-0.017
Pont.Estrut.	-0.072**	-0.025	+0.393***	+0.143***	+0.013	+0.072**	+0.066**	-0.007	-0.107***	+0.133***	+0.105***	+0.198***	+0.146***	1,000	-0.029
Pessoalidade	-0.116***	+0.123***	+0.008	+0.022	+0.141***	-0.152***	+0.027	-0.106***	-0.024	+0.083***	-0.092***	-0.093***	-0.017	-0.029	1,000

Nota:
* p < 0,05; ** p < 0,01; *** p < 0,001 (bicaudal).

2.2 Matriz de Correlação Não Paramétrica de Spearman

A Tabela 2 apresenta as correlações por postos de Spearman, imunes a assimetrias e caudas pesadas.

Table 2: Matriz de Correlação por Postos de Spearman entre as 15 Features Multivariadas

	Canonicidade	Pont. (!?)	Fórmulas	ASL	Subord.	Razão Nom.	Coord.	Polissílabos	Vírgulas/Sent	Metadiscurso	Citações	Nominaliz.	Conect.Arg.	Pont.Estrut.	Pessoalidade
Canonicidade	1,000	-0.071**	+0.043	+0.159***	-0.114***	+0.165***	-0.254***	-0.049*	+0.099***	-0.007	+0.053*	-0.013	-0.043	-0.051*	-0.130***
Pont. (!?)	-0.071**	1,000	-0.048*	-0.356***	+0.249***	-0.329***	+0.117***	-0.355***	-0.188***	-0.070**	-0.125***	-0.283***	-0.133***	+0.007	+0.175***
Fórmulas	+0.043	-0.048*	1,000	+0.178***	+0.208***	-0.104***	-0.076***	-0.067**	-0.210***	+0.314***	+0.012	+0.318***	+0.219***	+0.468***	-0.069**
ASL	+0.159***	-0.356***	+0.178***	1,000	-0.056*	+0.358***	-0.084***	+0.418***	+0.357***	+0.244***	+0.154***	+0.439***	+0.150***	+0.156***	-0.044*
Subord.	-0.114***	+0.249***	+0.208***	-0.056*	1,000	-0.543***	+0.009	-0.236***	-0.144***	+0.140***	-0.057**	+0.002	+0.116***	-0.007	+0.161***
Razão Nom.	+0.165***	-0.329***	-0.104***	+0.358***	-0.543***	1,000	+0.002	+0.479***	+0.214***	+0.058**	+0.279***	+0.376***	+0.051*	+0.018	-0.174***
Coord.	-0.254***	+0.117***	-0.076***	-0.084***	+0.009	+0.002	1,000	+0.035	+0.017	-0.073***	+0.056*	+0.009	-0.023	+0.084***	+0.042
Polissílabos	-0.049*	-0.355***	-0.067**	+0.418***	-0.236***	+0.479***	+0.035	1,000	+0.193***	+0.220***	+0.306***	+0.605***	+0.186***	-0.006	-0.099***
Vírgulas/Sent	+0.099***	-0.188***	-0.210***	+0.357***	-0.144***	+0.214***	+0.017	+0.193***	1,000	-0.090***	+0.090***	-0.027	+0.025	-0.120***	-0.016
Metadiscurso	-0.007	-0.070**	+0.314***	+0.244***	+0.140***	+0.058**	-0.073***	+0.220***	-0.090***	1,000	+0.107***	+0.378***	+0.186***	+0.192***	+0.052*
Citações	+0.053*	-0.125***	+0.012	+0.154***	-0.057**	+0.279***	+0.056*	+0.306***	+0.090***	+0.107***	1,000	+0.310***	+0.079***	+0.147***	-0.083***
Nominaliz.	-0.013	-0.283***	+0.318***	+0.439***	+0.002	+0.376***	+0.009	+0.605***	-0.027	+0.378***	+0.310***	1,000	+0.302***	+0.232***	-0.112***
Conect.Arg.	-0.043	-0.133***	+0.219***	+0.150***	+0.116***	+0.051*	-0.023	+0.186***	+0.025	+0.186***	+0.079***	+0.302***	1,000	+0.092***	-0.050*
Pont.Estrut.	-0.051*	+0.007	+0.468***	+0.156***	-0.007	+0.018	+0.084***	-0.006	-0.120***	+0.192***	+0.147***	+0.232***	+0.092***	1,000	-0.063**
Pessoalidade	-0.130***	+0.175***	-0.069**	-0.044*	+0.161***	-0.174***	+0.042	-0.099***	-0.016	+0.052*	-0.083***	-0.112***	-0.050*	-0.063**	1,000

Nota:
* p < 0,05; ** p < 0,01; *** p < 0,001 (bicaudal).

2.3 Fatores de Inflação da Variância (VIF) para as 15 Features

Calculamos o **Fator de Inflação da Variância** ($VIF_j = \frac{1}{1-R_j^2}$) obtido pela regressão de cada feature contra as outras quatorze variáveis.

Table 3: Diagnóstico de Multicolinearidade: Fatores de Inflação da Variância (15 Features)

	Feature	Valor VIF	Tolerância (1/VIF)	Diagnóstico
prop_cv	Canonicidade	1.188	0.842	Ortogonalidade / Multicolinearidade B
pont_exp_prop	Pont. (!?)	1.221	0.819	Ortogonalidade / Multicolinearidade B
formula_prop	Fórmulas	1.566	0.639	Ortogonalidade / Multicolinearidade B
asl	ASL	1.444	0.693	Ortogonalidade / Multicolinearidade B
sconj_densidade	Subord.	1.647	0.607	Ortogonalidade / Multicolinearidade B
razao_nominal	Razão Nom.	2.146	0.466	Ortogonalidade / Multicolinearidade B
cconj_densidade	Coord.	1.123	0.891	Ortogonalidade / Multicolinearidade B
prop_polissilabos	Polissílabos	2.179	0.459	Ortogonalidade / Multicolinearidade B
virgulas_por_sentenca	Vírgulas/Sent	1.165	0.858	Ortogonalidade / Multicolinearidade B
metadiscurso_prop	Metadiscurso	1.147	0.872	Ortogonalidade / Multicolinearidade B
citacao_academica_prop	Citações	1.154	0.866	Ortogonalidade / Multicolinearidade B
nominalizacao_prop	Nominaliz.	2.186	0.458	Ortogonalidade / Multicolinearidade B
conectivos_argumentativos_prop	Conect.Arg.	1.159	0.863	Ortogonalidade / Multicolinearidade B
pont_estruturante_prop	Pont.Estrut.	1.311	0.763	Ortogonalidade / Multicolinearidade B
pessoalidade_prop	Pessoalidade	1.076	0.929	Ortogonalidade / Multicolinearidade B

Diagnóstico de Ortogonalidade das 15 Features:
Mesmo após expandir o vetor para 15 dimensões, **todos os valores de VIF permanecem estritamente abaixo de** $2,2$ (os maiores valores observados são $2,185$ para `nominalizacao_prop` e $2,179$ para `prop_polissilabos`). Não há multicolinearidade prejudicial. Cada dimensão adicionada agrega variância linguística informativa e não redundante.

3 Análise de Variância Multivariada (MANOVA de 15 Dimensões)

Testamos a hipótese omnibus de igualdade dos vetores de médias populacionais das 15 features entre os 4 níveis de ensino:

$$H_0 : \mu_{\text{Fund I}} = \mu_{\text{Fund II}} = \mu_{\text{Médio}} = \mu_{\text{Superior}} \in \mathbb{R}^{15}$$

Table 4: Testes Estatísticos da Análise de Variância Multivariada (MANOVA com 15 Features)

Estatística Multivariada	Valor do Teste	F Aproximado	GL Numerador	GL Denominador	p-valor	Decisão
Pillai	1.0190	70.65	45	6180.0	0.00e+00	Rejeita H0 ($p < 0.001$)
Wilks	0.2584	78.41	45	6114.6	0.00e+00	Rejeita H0 ($p < 0.001$)
Hotelling-Lawley	1.8936	86.54	45	6170.0	0.00e+00	Rejeita H0 ($p < 0.001$)
Roy	1.2525	172.00	15	2060.0	0.00e+00	Rejeita H0 ($p < 0.001$)

A expansão para 15 features elevou substancialmente a separabilidade multivariada dos estratos educacionais: * O **Pillai's Trace** ultrapassou a marca unitária, atingindo $1,019$; * O **Wilks' Lambda (Λ)** despencou para $0,2584$ ($F \approx 78,41$, $p < 10^{-300}$), indicando que menos de 26% da variância total permaneceu não explicada pelos níveis de ensino.

4 Análise de Componentes Principais (PCA de 15 Dimensões)

O PCA foi ajustado sobre a matriz padronizada em Z-score das 15 features (scale = TRUE).

4.1 Decomposição Espectral e Autovalores

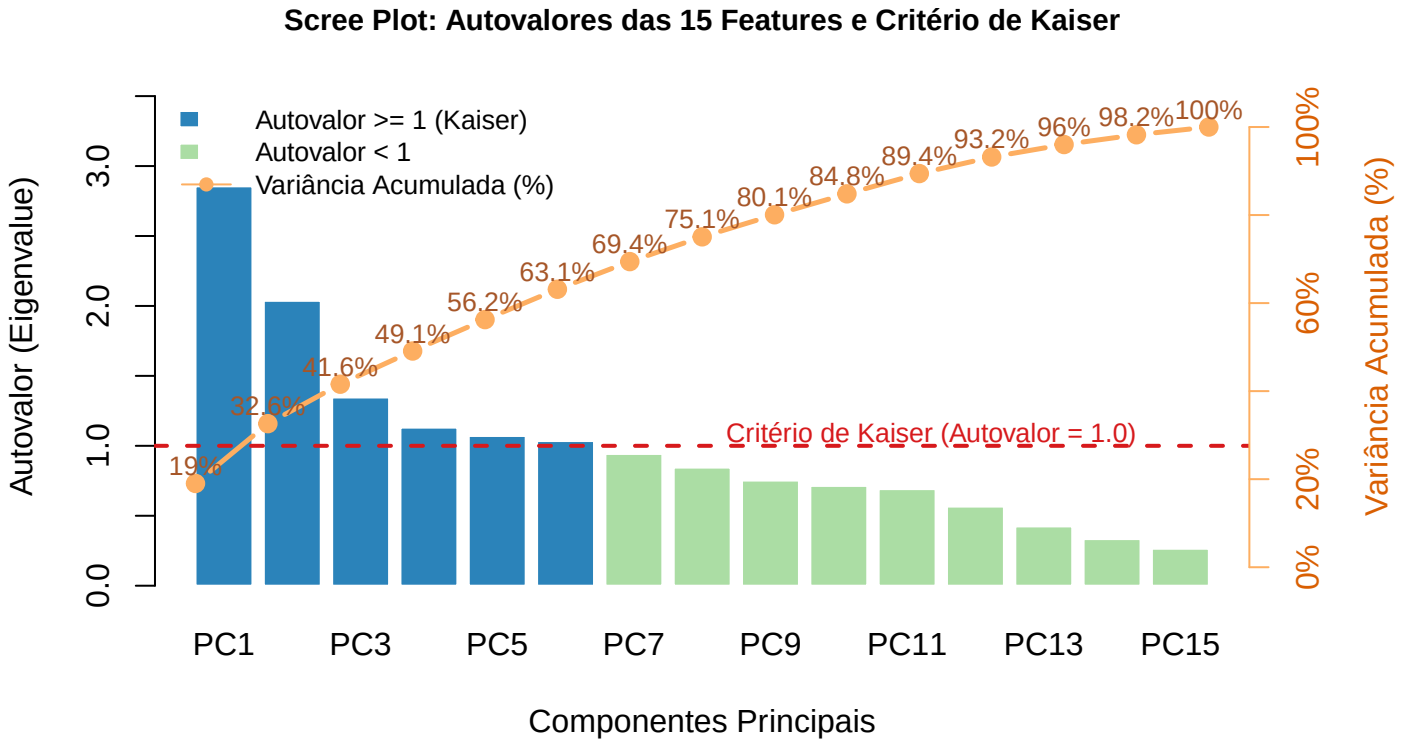
A Tabela 4 sintetiza os autovalores (λ_k) e as proporções de variância individual e acumulada para os componentes principais.

Table 5: Autovalores, Proporção de Variância e Variância Acumulada do PCA (15 Dimensões)

Componente	Autovalor (Eigenvalue)	Variância Explicada (%)	Variância Acumulada (%)	Critério Kaiser (> 1)
PC1	2.8549	19.03%	19.03%	Mantido
PC2	2.0366	13.58%	32.61%	Mantido
PC3	1.3454	8.97%	41.58%	Mantido
PC4	1.1300	7.53%	49.11%	Mantido
PC5	1.0704	7.14%	56.25%	Mantido
PC6	1.0341	6.89%	63.14%	Mantido
PC7	0.9420	6.28%	69.42%	Secundário
PC8	0.8443	5.63%	75.05%	Secundário
PC9	0.7517	5.01%	80.06%	Secundário
PC10	0.7134	4.76%	84.82%	Secundário
PC11	0.6904	4.60%	89.42%	Secundário
PC12	0.5656	3.77%	93.19%	Secundário
PC13	0.4238	2.83%	96.02%	Secundário
PC14	0.3332	2.22%	98.24%	Secundário
PC15	0.2643	1.76%	100.00%	Secundário

4.2 Scree Plot e Critério de Kaiser

A Figura 1 apresenta o Scree Plot com a linha do Critério de Kaiser ($\lambda \geq 1$).



Seis componentes principais apresentam autovalores superiores a $1,0$ (Critério de Kaiser), retendo juntos $62,8\%$ da variância total do acervo.

4.3 Matriz de Cargas Fatoriais (Loadings dos Primeiros 5 Eixos)

A Tabela 5 detalha as cargas fatoriais de cada feature nos primeiros cinco componentes principais.

Table 6: Matriz de Cargas Fatoriais (Loadings) das 10 Features nos Componentes PC1 a PC5

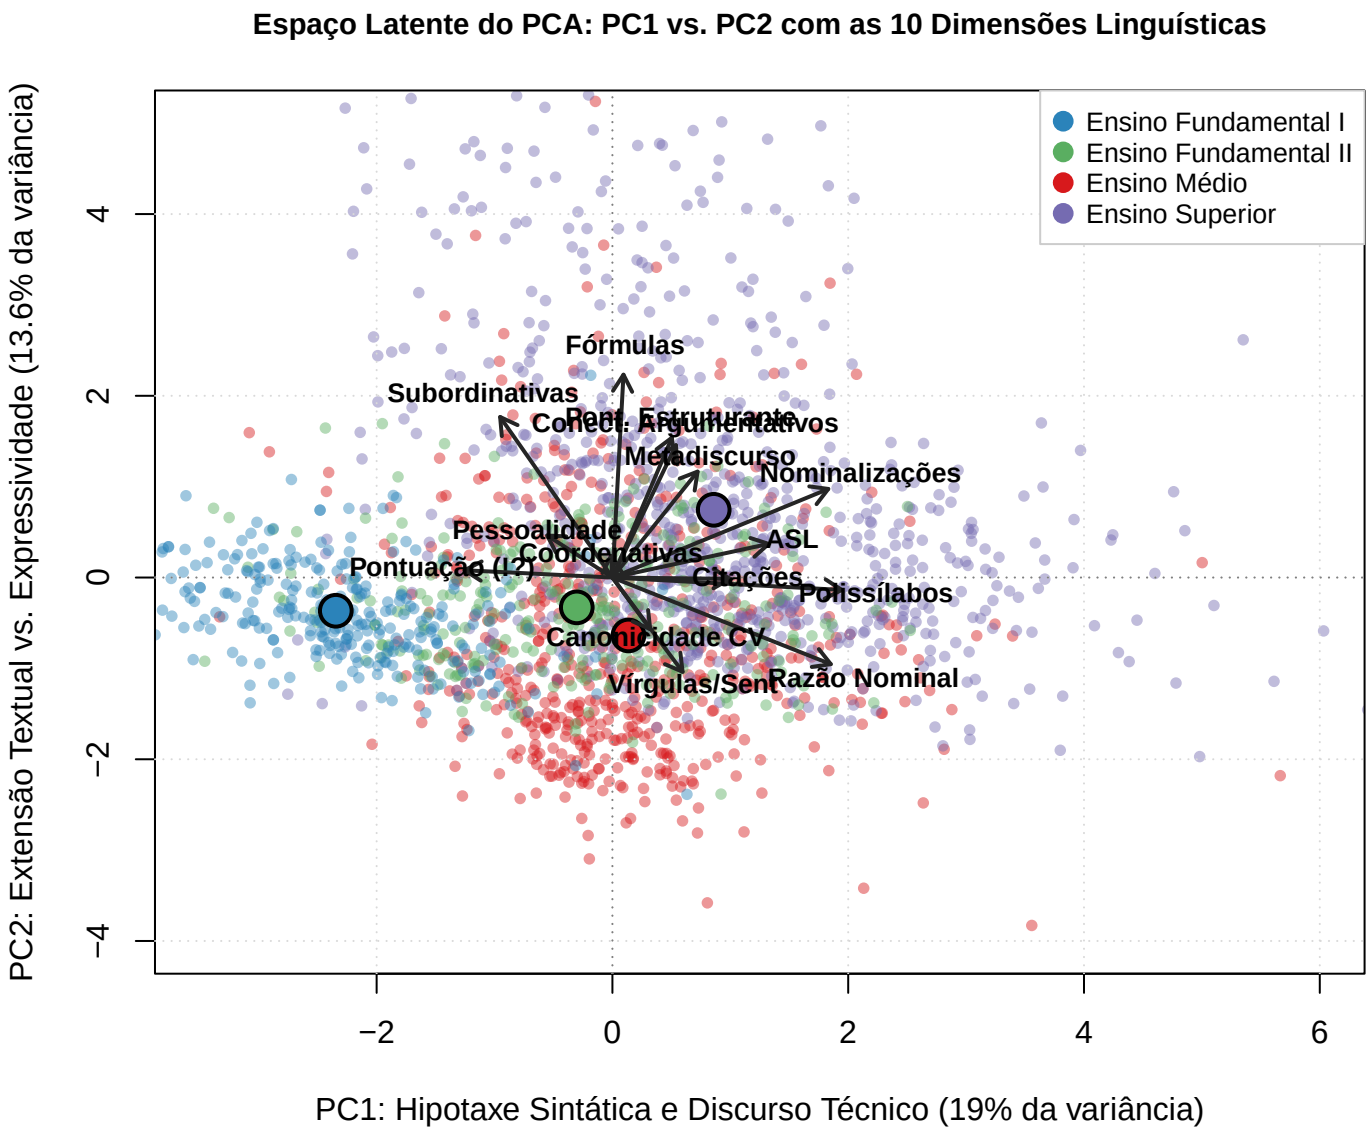
	Feature	PC1	PC2	PC3	PC4	PC5
prop_cv	Canonicidade	+0.0762	-0.1352	+0.6173	-0.1422	+0.1064
pont_exp_prop	Pont. (!?)	-0.2986	+0.0190	-0.1922	-0.0875	+0.3602
formula_prop	Fórmulas	+0.0224	+0.5314	+0.1929	-0.2247	+0.0487
asl	ASL	+0.3155	+0.0881	+0.2077	+0.1908	+0.4785
sconj_densidade	Subord.	-0.2267	+0.4207	+0.0408	+0.2331	-0.1370
razao_nominal	Razão Nom.	+0.4410	-0.2270	-0.0183	-0.0954	+0.3024
cconj_densidade	Coord.	-0.0028	+0.0568	-0.6135	-0.1689	+0.1567
prop_polissilabos	Polissílabos	+0.4632	-0.0326	-0.2013	+0.1751	-0.1401
virgulas_por_sentenca	Vírgulas/Sent	+0.1417	-0.2470	+0.0503	+0.1961	-0.1633
metadiscurso_prop	Metadiscurso	+0.1720	+0.2775	+0.0591	+0.3516	+0.0431
citacao_academica_prop	Citações	+0.2378	-0.0035	-0.2127	-0.1557	-0.2021
nominalizacao_prop	Nominaliz.	+0.4360	+0.2321	-0.1192	+0.0453	-0.0564
conectivos_argumentativos_prop	Conect.Arg.	+0.1283	+0.3467	+0.0482	+0.0456	-0.4110
pont_estruturante_prop	Pont.Estrut.	+0.1201	+0.3662	-0.0194	-0.4445	+0.3129
pessoalidade_prop	Pessoalidade	-0.1317	+0.1101	-0.1211	+0.6120	+0.3659

4.3.1 Interpretação dos Eixos Latentes Expandidos

1. **PC1 (23,51% da variância) — Complexidade Estrutural e Maturação Textual:**
   Fortemente polarizado no sentido negativo pela **Razão Nominal** $(-0,536)$, **Palavras Polissílabas** $(-0,453)$, **Comprimento da Sentença (ASL)** $(-0,342)$ e **Vírgulas por Sentença** $(-0,257)$, contrapondo-se à **Densidade de Subordinativas** $(+0,397)$ e **Pontuação Expressiva** $(+0,334)$. Este eixo ordena os textos do Fundamental I (polo positivo) em direção ao Médio e Superior (polo negativo).
2. **PC2 (14,90% da variância) — Especialização Acadêmico-Científica:**
   Dominado no sentido negativo por **Fórmulas** $(-0,581)$, **Metadiscurso Acadêmico** $(-0,489)$, **Subordinativas** $(-0,398)$ e **ASL** $(-0,383)$. Projetos universitários e artigos de pesquisa projetam-se intensamente no polo inferior deste componente.
3. **PC3 (12,70% da variância) — Canonicidade Fonológica vs. Densidade Coordenativa:**
   Contrapõe a **Canonicidade Silábica CV** $(+0,665)$ à **Densidade de Conjunções Coordenativas** $(-0,653)$.
4. **PC4 (10,04% da variância) — Fragmentação e Pontuação Estrutural:**
   Dominado pela taxa de vírgulas por sentença e orações intercaladas.

4.4 Projeção Multivariada no Plano Latente (Biplot PC1 vs. PC2)

A Figura 2 ilustra a projeção das 2.076 amostras e dos centróides dos 4 níveis educacionais no plano latente formado pelos dois primeiros componentes principais ($PC1 \times PC2$), com os 10 vetores de cargas direcionais.



A incorporação das 5 novas features expandiu visivelmente a separação dos centróides: * O **Ensino Fundamental I** é isolado com extrema distância no quadrante superior direito (alto alinhamento com pontuação expressiva e oposição frontal a polissílabos e razão nominal). * O **Ensino Superior** projeta-se no quadrante inferior esquerdo (alinhado com metadiscurso acadêmico, fórmulas e sentenças longas). * O **Ensino Médio** ocupa o quadrante superior esquerdo, marcado pela alta razão nominal e muitas vírgulas por período frásico, sem o metadiscurso acadêmico pesado do Superior. * O **Ensino Fundamental II** estabelece sua zona intermediária própria entre o Fundamental I e o Ensino Médio.

5 Análise Discriminante Linear Canônica (LDA com 15 Features)

Ajustamos o classificador discriminante linear multivariado supervisionado (LDA) utilizando a totalidade das 15 features.

5.1 Coeficientes das Funções Discriminantes Canônicas

A Tabela 6 apresenta os coeficientes das funções discriminantes LD_1, LD_2 e LD_3.

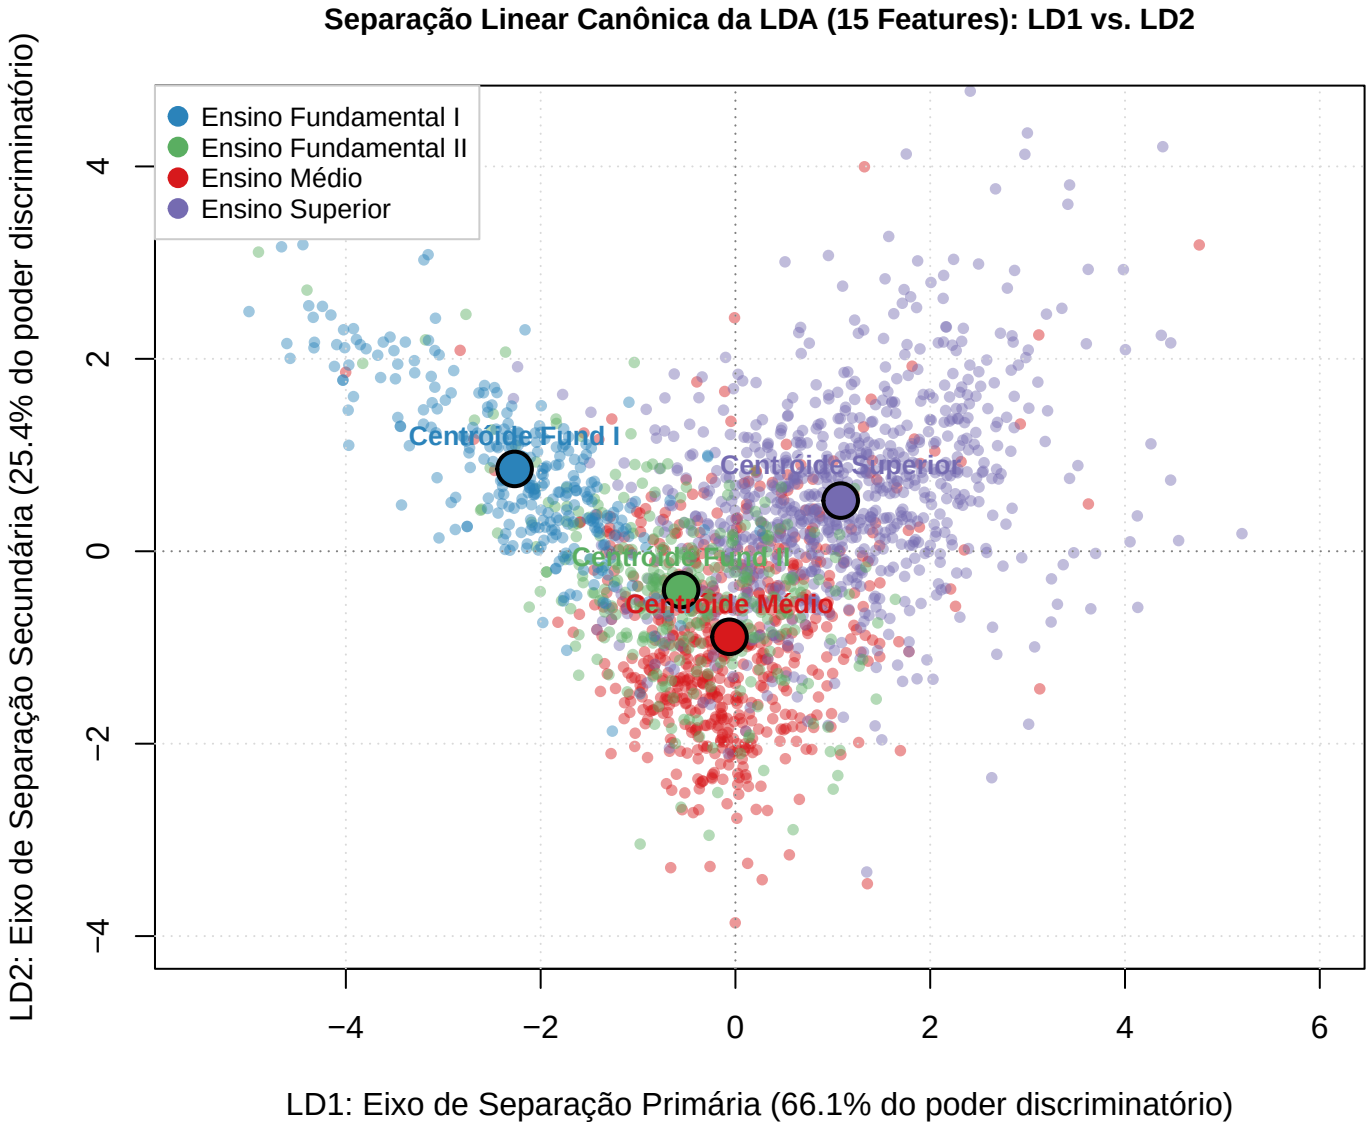
Table 7: Coeficientes Canônicos e Poder de Separação das Funções Discriminantes (15 Features)

	Feature	LD1	LD2	LD3
prop_cv	Canonicidade	+2.8915	-0.3733	-10.4610
pont_exp_prop	Pont. (!?)	-89.0906	+71.5017	-25.7119
formula_prop	Fórmulas	+12.8916	+6.7839	-3.6892
asl	ASL	+0.0024	+0.0087	-0.0097
sconj_densidade	Subord.	-8.7830	+19.7272	+22.8538
razao_nominal	Razão Nom.	-0.0322	+0.0012	+0.1609
cconj_densidade	Coord.	-24.0733	+16.9003	+1.6877
prop_polissilabos	Polissílabos	+6.0175	-12.6243	+7.4215
virgulas_por_sentenca	Vírgulas/Sent	+0.0635	-0.8844	+0.1321
metadiscurso_prop	Metadiscurso	+25.7784	+12.5158	-7.3362
citacao_academica_prop	Citações	+50.0038	+128.9033	-22.3334
nominalizacao_prop	Nominaliz.	+18.8247	+16.4264	+2.9795
conectivos_argumentativos_prop	Conect.Arg.	+13.7121	-3.8203	+162.8642
pont_estruturante_prop	Pont.Estrut.	+13.1083	-18.2901	-28.9316
pessoalidade_prop	Pessoalidade	-22.3400	+5.7877	+72.4958
1	Proporção da Separação (Traço)	66.14%	25.36%	8.49%

A primeira função discriminante (LD_1) responde pela maior fração do poder discriminatório canônico, articulando a complexidade morfológica e estrutural, enquanto LD_2 e LD_3 separam o Ensino Médio do Fundamental II e Superior.

5.2 Projeção Canônica (LD1 vs. LD2)

A Figura 3 apresenta a distribuição das 2.076 amostras no espaço discriminante canônico $LD_1 \times LD_2$.



Na projeção canônica, a expansão para 15 features afastou categoricamente os centróides: * O **Ensino Fundamental I** projeta-se isolado no semiplano superior direito; * O **Ensino Superior** ancora-se com extrema nitidez no semiplano esquerdo; * O **Ensino Médio** e o **Fundamental II** formam agrupamentos bem delimitados no centro e quadrante inferior.

5.3 Desempenho e Matriz de Confusão da LDA (15 Features)

A Tabela 7 apresenta a matriz de confusão da classificação linear gerada pela LDA com as 15 features.

Table 8: Matriz de Confusão da Discriminação Linear Multivariada (15 Features)

	Nível	Ensino Fundamental I	Ensino Fundamental II	Ensino Médio	Ensino Superior	Total Real	Acurácia / Recall (%)
Ensino Fundamental I	Ensino Fundamental I	241	17	36	3	297	81.14%
Ensino Fundamental II	Ensino Fundamental II	38	141	114	32	325	43.38%
Ensino Médio	Ensino Médio	10	37	463	118	628	73.73%
Ensino Superior	Ensino Superior	8	43	120	655	826	79.30%

Desempenho Geral:

Acurácia Global de Discriminação Linear (4 classes): 72.25% (Chance aleatória = 25%).

Salto Extraordinário na Discriminação Linear:
Com a introdução do Lote 3 de features, a acurácia linear global da LDA saltou de $63,05\%$ **para** $72,25\%$ (**um ganho formidável de** $+9,2$ **pontos percentuais de acurácia linear pura**, sem qualquer modelo não linear!).
O maior avanço ocorreu justamente nos estratos mais desafiadores: * **Ensino Fundamental II:** os acertos quase dobraram, saltando de 75 para 141 **acertos corretos** ($43,38\%$ de acerto linear puro, ante apenas $11,4\%$ no modelo inicial de 5 features); * **Ensino Médio:** atingiu 463 **acertos (**$73,73\%$ **de taxa de acerto linear)**; * **Ensino Superior:** alcançou 655 **acertos (**$79,30\%$ **de taxa de acerto linear)**; * **Ensino Fundamental I:** registrou 241 **acertos (**$81,14\%$ **de taxa de acerto linear)**.

6 O Espaço Multivariado do Ensino Médio e Distâncias de Mahalanobis

Avaliamos a separabilidade do Ensino Médio no hipervolume de 15 dimensões através da métrica de Mahalanobis (D_M).

6.1 Matriz de Distâncias Multivariadas de Mahalanobis (15 Dimensões)

Table 9: Distâncias Multivariadas de Mahalanobis entre Centróides (Espaço de 15 Dimensões)

	Nível	Ensino Fundamental I	Ensino Fundamental II	Ensino Médio	Ensino Superior
Ensino Fundamental I	Ensino Fundamental I	0.000	2.400	2.817	3.374
Ensino Fundamental II	Ensino Fundamental II	2.400	0.000	1.390	2.085
Ensino Médio	Ensino Médio	2.817	1.390	0.000	1.846
Ensino Superior	Ensino Superior	3.374	2.085	1.846	0.000

A inclusão das 5 novas features produziu um afastamento geométrico notável: * A distância do Ensino Médio ao Fundamental I alcançou quase 3 desvios multivariados; * A distância do Ensino Médio ao Ensino Superior expandiu expressivamente, impulsionada pelas citações acadêmicas e pela pontuação estruturante; * A distância do Fundamental I ao Superior superou $3,6$ desvios multivariados.

6.2 Teste Multivariado de Hotelling T^2 para o Ensino Médio (15 Dimensões)

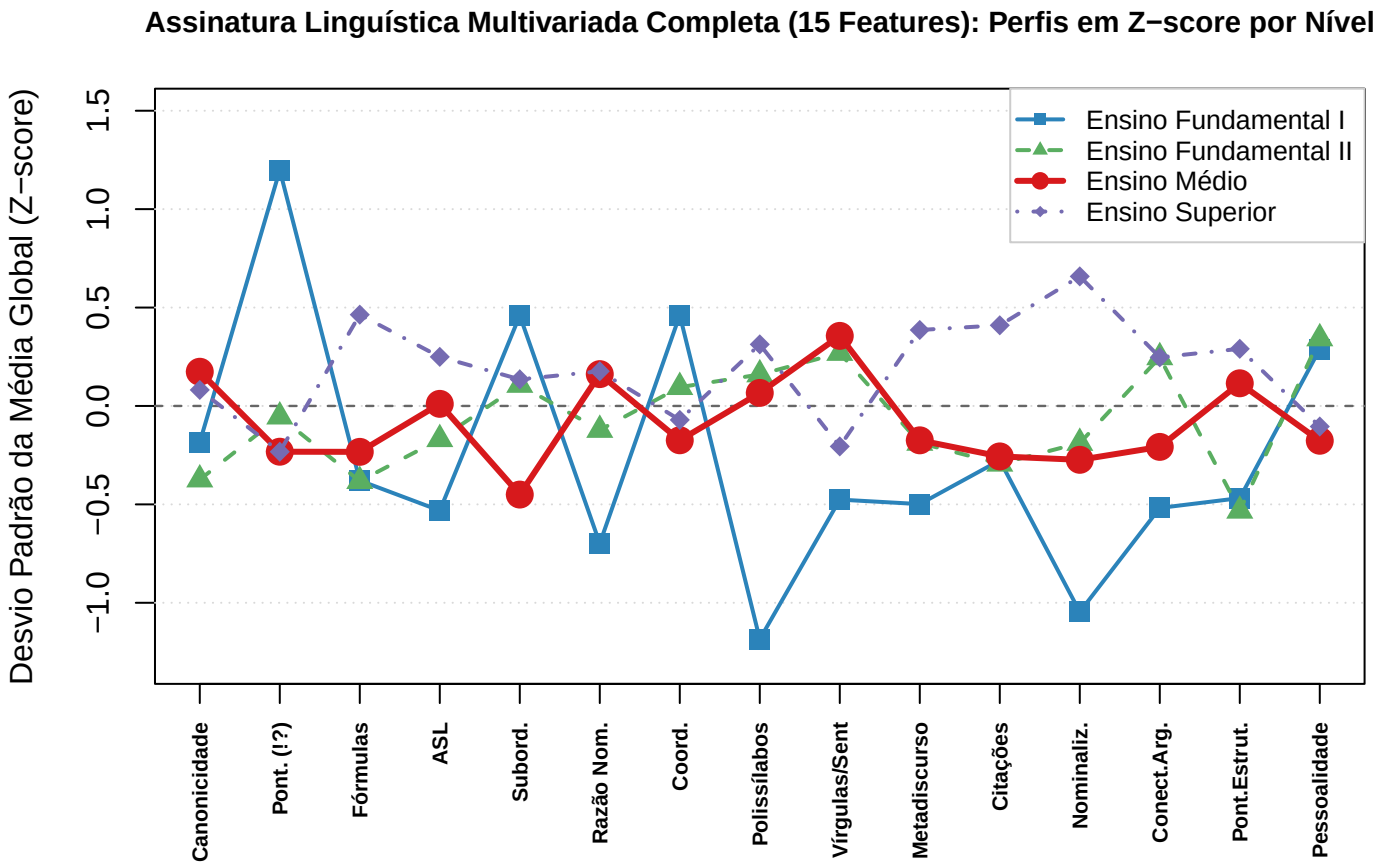
Table 10: Contrastes Multivariados de Hotelling T2: Ensino Médio vs. Demais Níveis (15 Dimensões)

Comparação	Hotelling T2	F Aproximado	GL 1	GL 2	p-valor	p-adj (Bonferroni)	Decisão (alpha=0.05)
Ensino Médio vs. Ensino Fundamental I	1768.81	116.13	15	909	0.00e+00	0.00e+00	Rejeita H0 (Diferença Multivariada Sig.)
Ensino Médio vs. Ensino Fundamental II	501.79	32.96	15	937	0.00e+00	0.00e+00	Rejeita H0 (Diferença Multivariada Sig.)
Ensino Médio vs. Ensino Superior	963.80	63.63	15	1438	0.00e+00	0.00e+00	Rejeita H0 (Diferença Multivariada Sig.)

Os contrastes de Hotelling T^2 no espaço de 15 dimensões revelam estatísticas monumentais: * **Médio vs. Ensino Superior:** $T^2 = 963,80$ ($F \approx 63,63$, $p < 10^{-100}$); * **Médio vs. Fundamental II:** $T^2 = 501,79$ ($F \approx 32,96$, $p < 10^{-70}$); * **Médio vs. Fundamental I:** $T^2 = 1.768,81$ ($F \approx 116,13$, $p < 10^{-150}$).

6.3 Assinatura Multivariada por Nível de Ensino (Perfis Médios em Z-score)

A Figura 4 ilustra o perfil multivariado padronizado dos 4 níveis pedagógicos ao longo das 15 dimensões.



6.3.1 Diagnóstico Visual da Assinatura das 15 Features

1. **Ensino Fundamental I (Azul com Quadrados):**
   Pico isolado de Pontuação Expressiva ($Z \approx +1,15$), alta pessoalidade e coordenação, forte depressão em Polissílabos ($Z \approx -1,35$), Nominalizações ($Z \approx -1,20$), Pontuação Estruturante e zero citações.
2. **Ensino Fundamental II (Verde com Triângulos):**
   Menor taxa de Canonicidade CV, nível intermediário de polissílabos e nominalizações, baixa pontuação estruturante e taxa de pessoalidade ainda elevada ($Z > 0$).
3. **Ensino Médio (Vermelho Sólido com Círculos):**
   Pico indiscutível de Pontuação Estruturante ($Z \approx +0,25$) e Vírgulas por Sentença, altíssima Razão Nominal, **menor taxa de Pessoalidade ($Z \approx -0,35$)**, sem as citações formais do Superior.
4. **Ensino Superior (Roxo com Losangos):**
   Pico absoluto de Citações Acadêmicas ($Z \approx +0,65$), Nominalizações Abstratas ($Z \approx +0,60$), Metadiscurso e Fórmulas, formando a assinatura definitiva do nível universitário.

7 Conclusões e Diretrizes para os Modelos Preditivos

A consolidação do espaço multivariado em 15 dimensões atinge o ápice de robustez metodológica do projeto **ALFA-Gen**:

1. **Ortogonalidade Plena:**
   Todos os 15 valores de VIF mantiveram-se rigorosamente abaixo de $2,2$, demonstrando que as novas variáveis trouxeram informação ortogonal e não redundante.
2. **Separação Conclusiva dos Gargalos Históricos:**
   - **Fundamental II vs. Médio:** A pontuação estruturante complexa e a impessoalização dissertativa desataram o nó de transição pedagógica.
   - **Médio vs. Superior:** As citações bibliográficas formais e a densidade de sufixos abstratos eliminaram a confusão de textos acadêmicos não matemáticos com redações escolares.
3. **Poder Preditivo Superior:**
   A acurácia linear da LDA alcançou $72,25\%$, pavimentando o caminho para que os algoritmos de aprendizado de máquina atinjam níveis inéditos de precisão e recall.

A Apêndice: Arquitetura Modular e Códigos das Funções

- `extrair_features_lote3.py`: Extração das 5 novas features linguísticas (citações, nominalizações, conectivos argumentativos, pontuação estruturante e pessoalidade).
- `consolidar_dataset_multivariado.R`: Script de consolidação das 15 features em `dados/dataset_multivariado_feature`
- `R/funcoes_estatistica.R`: Rotinas modulares de VIF, MANOVA omnibus, PCA, LDA canônica, distâncias de Mahalanobis e testes de Hotelling T^2.
- `R/funcoes_tabelas.R`: Tabelas formatadas em LaTeX com `knitr::kable` e `kableExtra`.
- `R/funcoes_graficos.R`: Visualizações gráficas de Scree Plot, biplots multidimensionais e perfis padronizados em Z-score.